

基于区块链的卫星终端试验任务数据管理与计算卸载技 术研究

姓名： 毛心璐

学号： 3220231823

学院： 网络空间安全学院

2026 年 6 月



基于区块链的卫星终端试验任务数据管理与计算卸载技术研究 毛心璐 北京理工大学

中图分类号：TQ028.1
UDC 分类号：540
学校代码：10007

★ 学生类型

☐ 工程硕博士专项

☐ 交叉研究方向

☐ 政府项目留学生

基于区块链的卫星终端试验任务数据管理与计算卸载技
术研究

作 者 姓 名	毛心璐
二 级 培 养 单 位	网络空间安全学院
指 导 教 师	朱超
行 业 合 作 导 师	朱超
答 辩 委 员 会 主 席	张涛
申 请 类 别	工学硕士
学 位 领 域	网络与信息安全
学 位 授 予 单 位	北京理工大学
论 文 提 交 日 期	2026 年 6 月

Data Management and Computing Offloading Technology Scheme for Satellite Terminal Test Task Based on Blockchain

Candidate Name:	<u>Xinlu Mao</u>
School or Department:	<u>School of Network Space Security</u>
Faculty Mentor:	<u>Prof. Zhu Chao</u>
Industry Collaboration Mentor:	<u>Prof. Zhu Chao</u>
Chair, Thesis Committee:	<u>Prof. Zhang Tao</u>
Degree Applied:	<u>Master of Engineering</u>
Major:	<u>Network and Information Security</u>
Degree by:	<u>Beijing Institute of Technology</u>
Submission date of the paper:	<u>June, 2026</u>

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的科研成果。文中所撰写内容符合以下学术规范（请勾选）：

☒ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☒ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☒ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☒ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☒ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签 名：

日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名：

日 期：

导师签名：

日 期：

致谢

在本论文的研究与撰写过程中，我得到了导师、课题组老师与同学们的悉心指导和帮助。导师在研究选题、技术路线设计、论文结构组织以及学术表达规范等方面给予了耐心细致的指导，使我能够逐步完成从问题分析到方法设计、再到论文整理的全过程。在此谨向导师致以诚挚的感谢。

同时，感谢课题组各位老师和同学在研究讨论、资料整理、实验推进与论文修改过程中提供的帮助与建议。与大家交流使我对天基网络计算卸载、区块链协同、联邦学习与强化学习等相关问题有了更加深入的理解，也为本论文的完善提供了重要支持。

此外，感谢学校和学院提供的学习与科研条件，感谢家人在研究和生活过程中给予的理解、鼓励与支持。正是因为来自师长、同学与家人的帮助，我才能较为顺利地完成本阶段的学习与研究工作。

基于区块链的卫星终端试验任务数据管理与计算卸载技术研究

摘要：近年来，随着天地一体化信息网络与“新基建”战略的深入推进，天基网络正经历从单一通信传输向边缘智能计算的跨越式转变。卫星终端作为天基数据的感知与处理前哨，在偏远地区监测、应急响应及各类在轨试验中发挥着不可替代的作用。然而，面对日益复杂的计算密集型试验任务，受限于星载设备的体积、功耗及抗辐射设计，卫星终端的计算资源极其有限。当海量任务并发产生时，传统的计算卸载方案往往忽视了资源竞争带来的“并发开销”，且依赖地面集中式决策导致的高时延与信令开销，已难以满足天基试验任务的实时性与可靠性需求。

针对上述挑战，本文提出了一种融合区块链、联邦学习（Federated Learning, FL）与深度强化学习（DRL）的卫星终端智能管控与计算卸载架构。该架构旨在利用联邦学习打破数据孤岛，在保护隐私的前提下实现协作式环境感知；利用区块链构建可信协作底座，解决分布式环境下的信任与状态同步问题。本文的主要研究内容与创新点如下：

（1）基于区块链的卫星试验任务可信存证与协同管理：针对多源异构试验数据的安全与一致性问题，设计了基于联盟链的分层式数据管理架构。利用智能合约实现试验任务全生命周期的自动化记录与防篡改存证，并构建非实时全局状态共享机制，为分布式协同计算提供可信的数据底座，确保了任务执行过程的可追溯性与多方协作的安全性。

（2）基于联邦学习的并发开销预测与卸载决策优化：针对多任务并发场景下的资源竞争难题，提出了一种基于 FL 与深度 Q 网络（DQN）的分布式卸载策略。通过在卫星终端间开展联邦协同训练，构建高精度的任务并发开销预测模型，使终端能够在不共享原始任务数据的前提下感知全局负载压力，从而实现任务卸载决策的智能化与隐私保护，有效解决了资源竞争导致的时延剧增问题。

（3）基于深度强化学习的动态资源调度与节点优选：针对天基网络拓扑高动态变化及星间链路不稳定的特性，设计了基于改进 PPO/DQN 算法的动态资源调度模型。该模型将时延、能耗、负载均衡度纳入多目标优化函数，通过智能体与环境的持续交互，实现复杂动态约束下的计算资源自适应分配与最优卸载节点选择。

（4）天基分布式试验智能管控平台的设计与验证：基于上述理论成果，设计并研制了包含卫星终端模拟、区块链网络、智能调度引擎及可视化监控的一体化演示验证

平台。在典型的卫星试验任务场景下进行了系统级测试，实验结果表明，本文提出的方案在降低平均任务时延、提升系统吞吐量及保障数据隐私方面均优于传统基准算法，验证了所提架构的有效性与优越性。

本研究探索了区块链与人工智能技术在天基网络中的深度融合应用，有效提升了受限资源下卫星终端的任务处理效能与数据安全水平，为未来构建高效、智能、可信的天基边缘计算网络提供了重要的理论依据与技术支撑。

关键词：区块链；卫星网络；强化学习；计算卸载；联邦学习

Data Management and Computing Offloading Technology Scheme for Satellite Terminal Test Task Based on Blockchain

Abstract: In recent years, with the in-depth advancement of space-ground integrated information networks and "New Infrastructure" strategies, space-based networks are undergoing a leapfrog transition from simple communication transmission to edge intelligent computing. As the forward outpost for space-based data perception and processing, satellite terminals play an irreplaceable role in remote area monitoring, emergency response, and various on-orbit experiments. However, faced with increasingly complex computation-intensive test tasks, satellite terminals are severely constrained by the size, weight, and power (SWaP) limitations of onboard equipment. When massive tasks are generated concurrently, traditional computation offloading schemes often overlook the "concurrency overhead" caused by resource competition. Furthermore, reliance on ground-based centralized decision-making leads to high latency and signaling overhead, making it difficult to meet the real-time and reliability requirements of space-based test tasks.

To address these challenges, this thesis proposes an intelligent management and computation offloading architecture for satellite terminals, fusing Blockchain, Federated Learning (FL), and Deep Reinforcement Learning (DRL). This architecture aims to utilize FL to break data silos and achieve collaborative environmental perception while preserving privacy; simultaneously, it leverages blockchain to build a trusted collaboration foundation, resolving trust and state synchronization issues in distributed environments. The main research contents and innovations are as follows:

(1) Trusted Storage and Collaborative Management of Satellite Test Tasks Based on Blockchain: Addressing the security and consistency issues of multi-source heterogeneous test data, a hierarchical data management architecture based on consortium blockchain is designed. Smart contracts are utilized to realize automated recording and tamper-proof storage of the entire lifecycle of test tasks. Additionally, a non-real-time global state sharing mechanism is constructed to provide a trusted data foundation for distributed collaborative computing, ensuring the traceability of the execution process and the security of multi-party collaboration.

(2) Concurrency Overhead Prediction and Offloading Decision Optimization Based on Federated Learning: Targeting the resource competition problem in multi-task concurrency scenarios, a distributed offloading strategy based on FL and Deep Q-Network (DQN) is proposed. By conducting federated collaborative training among satellite terminals, a high-precision prediction model for task concurrency overhead is constructed. This enables terminals to perceive global load pressure without sharing raw task data, thereby achieving intelligent and privacy-preserving offloading decisions and effectively solving the latency surge caused by resource competition.

(3) Dynamic Resource Scheduling and Node Selection Based on Deep Reinforcement Learning: Addressing the highly dynamic topology of space-based networks and the instability of inter-satellite links, a dynamic resource scheduling model based on improved PPO/DQN algorithms is designed. This model incorporates latency, energy consumption, and load balance into a multi-objective optimization function. Through continuous interaction between the agent and the environment, adaptive allocation of computing resources and optimal offloading node selection under complex dynamic constraints are achieved.

(4) Design and Verification of Space-based Distributed Test Intelligent Management Platform: Based on the above theoretical results, an integrated demonstration and verification platform containing satellite terminal simulation, blockchain network, intelligent scheduling engine, and visual monitoring is designed and developed. System-level tests under typical satellite test task scenarios demonstrate that the proposed scheme outperforms traditional benchmark algorithms in reducing average task latency, improving system throughput, and guaranteeing data privacy, verifying the effectiveness and superiority of the proposed architecture.

This research explores the deep integration and application of blockchain and artificial intelligence technologies in space-based networks, effectively improving the task processing efficiency and data security level of satellite terminals under resource-constrained conditions, providing important theoretical basis and technical support for building efficient, intelligent, and trusted space-based edge computing networks in the future.

Key Words: Blockchain; Satellite Network; Reinforcement Learning; Computing Offloading; Federated Learning

目次

1	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状与发展趋势	5
1.2.1	天基网络与卫星边缘计算研究现状	5
1.2.2	动态环境下智能调度与多智能体协同研究现状	8
1.2.3	区块链协同与隐私保护学习研究现状	9
1.2.4	现有研究存在的主要问题与挑战	12
1.3	本文主要研究内容与论文结构	12
2	天基网络计算卸载的技术基础与系统建模	15
2.1	天基网络协同计算场景与体系结构	15
2.1.1	天基网络协同计算场景分析	15
2.1.2	节点类型与功能划分	16
2.1.3	链路特性与资源受限特征	17
2.2	计算卸载与智能管控相关技术基础	18
2.2.1	计算卸载基本模式与性能指标	18
2.2.2	轨道边缘计算与星座协同处理基础	19
2.2.3	可信状态同步与分布式协同基础	20
2.2.4	多智能体强化学习的系统层协同决策基础	21
2.2.5	联邦学习与深度强化学习的任务层决策基础	22
2.3	系统建模与双层问题描述	23
2.3.1	系统模型	23
2.3.2	任务模型与代价建模	24
2.3.3	双层智能管控问题形式化描述	26
2.4	本章小结	28
3	基于区块链与多智能体强化学习的天基计算网络协同资源分配方法	29
3.1	引言	29

3.2	系统框架概述	33
3.2.1	系统组成与角色划分	33
3.2.2	联盟链公共信息板与协同流程	36
3.2.3	建模目标与协同难点	36
3.3	基于多智能体马尔可夫博弈的协同资源分配模型	37
3.3.1	建模动机与博弈形式化	38
3.3.2	状态、动作与奖励机制设计	40
3.3.3	约束条件与性质分析	42
3.4	区块链增强的多智能体协同资源分配算法设计	44
3.4.1	区块链共享与信誉反馈机制	44
3.4.2	算法总体框架	48
3.4.3	参数化策略与更新机制	50
3.4.4	训练与执行算法流程	51
3.5	实验设计与结果分析	52
3.5.1	实验设置、对比基线与评价指标	52
3.5.2	收敛性分析	53
3.5.3	不同负载水平下的系统性能分析	55
3.5.4	规模扩展与参数敏感性分析	56
3.5.5	抗自私行为鲁棒性分析	59
3.5.6	信誉机制效果分析	59
3.5.7	结果讨论	61
3.6	本章小结	61
4	基于联邦学习与深度强化学习的并发感知任务层计算卸载方法	62
4.1	引言	63
4.2	系统框架与任务层卸载问题建模	66
4.2.1	系统组成、工作流程与综合代价模型	66
4.2.2	并发开销建模	69
4.2.3	状态表征构造	71
4.2.4	任务层卸载问题的马尔可夫决策过程建模	72

4.3	基于联邦学习的并发开销预测方法	72
4.3.1	预测目标与样本构造	73
4.3.2	预测模型结构设计	73
4.3.3	分层聚类联邦架构与训练流程	74
4.3.4	可信维护与复杂度分析	76
4.4	FL-DQN 卸载决策算法设计	77
4.4.1	状态、动作与奖励函数设计	77
4.4.2	Q 网络结构与训练策略	78
4.4.3	在线决策流程与闭环机制	79
4.4.4	算法复杂度与可实现性分析	81
4.5	实验设计与结果分析	82
4.5.1	实验场景、对比方法与评价指标	82
4.5.2	并发开销预测模块性能分析	83
4.5.3	不同并发强度下的端到端卸载性能分析	85
4.5.4	鲁棒性、动作偏好与多目标折中分析	88
4.5.5	消融实验与模块贡献分析	90
4.5.6	本节小结	92
4.6	本章小结	93
5	面向天基协同计算的区块链平台架构与设计	94
5.1	平台设计动机与总体思路	95
5.2	平台总体架构与分层链设计	96
5.3	区块结构、数据流转与存证机制	99
5.4	双层智能方法的平台映射与运行闭环	101
5.5	平台运行流程、工程分析与本章小结	103
	结论	105
	参考文献	106
	附录 A 仿真参数与环境配置	110
	附录 B 关键模型推导与补充说明	111

附录 C 附录内容说明	112
C.1 附录内容组织说明	112
C.1.1 后续补充建议	112
攻读学位期间发表论文与研究成果清单	113
作者简介	114

插图

图 1.1 天基网络协同计算卸载应用场景	2
图 1.2 本论文研究思路及文章结构	13
图 3.1 天基协同资源分配中局部自利与全局协同差异示意	32
图 3.2 第三章协同资源分配框架的层次结构与信息流	35
图 3.3 从系统优化问题到多智能体马尔可夫博弈的建模推导路径	39
图 3.4 分层联盟链与公共信息板职责示意	45
图 3.5 信誉驱动的状态—动作—审计—反馈闭环	47
图 3.6 BC-CTDE-MAPPO 总体流程图	49
图 3.7 不同训练算法的收敛性对比	54
图 3.8 不同任务到达率下的系统性能对比	56
图 3.9 规模扩展与参数敏感性分析结果	57
图 3.10 消融实验结果：各模块对任务完成率（含 30% 自私节点场景）与 Jain 公平指数的贡献（误差棒为 $\pm 1\sigma$, $n=5$ ）	58
图 3.11 不同自私节点比例下的系统鲁棒性对比	60
图 4.1 天基分布式计算系统中的任务级卸载框架与信息交互流程	67
图 4.2 并发开销的形成机理与资源争用示意	70
图 4.3 融合并发开销预测先验的 FL-DQN 在线卸载决策闭环	79
图 4.4 并发开销预测模块的多维性能结果	84
图 4.5 不同并发强度下的卸载决策性能与稳定性	86
图 4.6 鲁棒性、动作偏好与多目标折中结果	88
图 4.7 消融实验结果	91
图 5.1 面向天基协同计算的区块链平台总体架构图	97
图 5.2 平台分层链结构设计图	99
图 5.3 平台状态—动作—存证—反馈闭环运行机制图	102

表格

表 1.1	典型天基网络计算模式及其技术特点	3
表 1.2	2024—2026 年天基计算卸载与智能调度代表研究	7
表 1.3	可信协同与隐私保护相关代表研究	10
表 3.1	链上公共摘要分量说明	41
表 3.2	奖励权重与作用说明	42
表 3.3	分层联盟链职责划分	46
表 3.4	仿真实验参数设置	53
表 3.5	不同训练算法的收敛性统计对比	54
表 3.6	不同任务到达率下各算法的 Jain 公平指数	56
表 3.7	消融实验结果 ($\lambda = 0.9$, 括号内为 $\pm 1\sigma$, $n=5$)	58
表 3.8	不同自私节点比例下的鲁棒性对比 (任务完成率%)	60
表 4.1	集中式学习在天基网络中的主要局限	65
表 4.2	任务级卸载框架中的角色划分	67
表 4.3	分层聚类联邦学习架构中的角色划分	75
表 4.4	节点侧决策的复合状态空间设计	77
表 4.5	FL-DQN 在线卸载决策流程	80
表 4.6	不同并发强度下各卸载策略的端到端性能汇总	87
表 4.7	FL-DQN 各模块消融实验结果	90

主要符号对照表

BIT	北京理工大学的英文缩写
$\text{\LaTeX}$	一个很棒的排版系统
$\text{\LaTeX} 2_{\epsilon}$	一个很棒的排版系统的最新稳定版
ctex	成套的中文 $\text{\LaTeX}$ 解决方案，由一帮天才们开发
$e^{\pi i} + 1 = 0$	一个集自然界五大常数一体的炫酷方程

1 绪论

1.1 研究背景与意义

天地一体化信息网络是支撑未来全球通信、遥感感知、任务协同与智能服务的重要基础设施，也是推动空天信息系统由传统“数据传输网络”向“综合信息处理网络”演进的关键方向。随着低轨卫星星座持续部署、星间链路逐步完善以及星载计算平台能力不断提升，卫星节点的功能定位正在发生深刻变化。传统卫星网络更多承担透明转发与数据中继功能，而新一代天基网络则逐步具备在轨处理、任务协同、资源调度和自治管控等能力，正在由单纯的信息传输载体演进为面向复杂业务场景的分布式协同计算平台。对于天地一体化信息网络而言，这种演进不仅意味着网络服务能力的提升，也意味着网络运行模式、任务组织方式与资源管理机制的系统性变革^[1-3]。

从现实应用需求看，天基网络正在承担越来越多高时敏、高动态和高自治要求的业务任务。在灾害应急通信、对地观测快速处理、区域目标识别、空间态势感知、海洋与航运监测以及跨区域任务协同等场景中，系统不仅需要完成数据采集和远程传输，还需要在有限可见窗口、受限链路条件和复杂任务环境下实现任务接入、资源协调、计算处理与结果反馈的快速闭环。尤其是在突发灾害、局部冲突、复杂海域巡检等场景中，任务往往具有突发性、密集性和强时效性，若仍然依赖传统“星上初步处理—地面集中分析”的工作模式，则容易受到星地链路时延、可见窗口受限以及地面中心计算负载瓶颈等因素制约，难以满足高时敏业务对于快速响应和在轨闭环处理的实际需求^[2,4]。

在此背景下，将计算能力由地面向星上前移，并在多颗卫星之间实现资源共享与协同处理，已成为提升天基网络智能服务能力的重要发展方向。与仅依赖地面中心的集中处理模式相比，星上计算能够缩短数据处理链路、降低回传压力、提升任务响应速度；而进一步引入多星协同计算，则有望突破单颗卫星在算力、能量、存储和链路条件等方面的资源限制，在更大空间范围内实现任务迁移、负载分担和算力共享，从而增强天基网络在复杂动态场景下的综合服务能力。

图 1.1 给出了天基网络协同计算卸载的典型应用场景。在该场景中，地面突发任务首先通过上行链路接入过载卫星，过载卫星在本地资源不足或任务积压严重时，可将部分任务经由星间链路卸载至资源相对空闲的卫星节点执行；同时，区块链/多智

能体管控层对各卫星节点的资源状态、协同关系和策略执行过程进行支撑，实现状态共享、共识记账与策略协同，最终将处理结果回传地面。该图较为直观地反映了本文所关注问题的典型特征，即高动态环境下多节点之间的任务迁移、资源协调、可信共享与协同决策问题。




图 1.1 天基网络协同计算卸载应用场景

从现有技术体系看，面向天基网络任务处理需求，当前计算能力部署方式主要可归纳为星地集中处理、星上本地处理、星间协同处理以及分布式智能管控等几种典型模式。不同模式在支撑基础、服务能力和适用范围等方面各有特点，但同时也存在明显局限。为更清晰地说明不同模式的适用性与不足，表 1.1 给出了典型天基网络计算模式及其技术特点对比。

如表 1.1 所示，星地集中处理模式依托地面中心强大的存储和计算资源，适合完成统一分析、全局调度与离线决策，但其运行效果高度依赖星地链路质量、卫星可见窗口和回传带宽条件，当任务具有强实时性要求时，该模式的闭环响应能力往往受到限制。相比之下，星上本地处理模式能够在数据产生位置附近完成预处理与快速决策，具有较好的实时性优势，但单颗卫星受平台尺寸、载荷能力、功耗预算、热控条件以及轨道能量循环等因素约束，难以长期承担高强度、连续化、多任务并发的计算需求。当任务密集到达或局部区域业务突发增长时，单节点容易出现排队积压、执行时延抬升以及任务失效等问题。

正是在上述矛盾推动下，星间协同处理逐渐成为天基网络计算能力提升的重要路

表 1.1 典型天基网络计算模式及其技术特点

计算模式	核心支撑	主要能力	典型局限
星地集中处理	地面中心、馈电链路	适合离线分析与统一调度	受星地时延、可见窗口和回传带宽限制
星上本地处理	星载处理器、单星资源	支持任务就地预处理与快速响应	受单星算力、功耗与能量循环约束
星间协同处理	星间链路、多星协同	支持跨节点算力共享与任务迁移	动态拓扑下状态获取与决策复杂
分布式智能管控	区块链、MARL、FL、DRL	支持可信共享、协同博弈与智能卸载	需同时解决共识开销、协同稳定与代价预测问题

径。所谓协同计算卸载，是指当任务接入卫星本地资源不足或本地执行代价过高时，通过星间链路将任务迁移至其他具备可用资源的协同节点执行，从而在更大范围内实现算力共享与负载分担^[1,5]。与传统纯星地集中处理模式相比，协同计算卸载能够更灵活地利用多节点资源；与单星本地处理模式相比，其能够突破单节点资源上限，在降低任务时延、提高系统吞吐量和增强网络鲁棒性方面具有明显优势。因此，协同计算卸载已成为天基网络由“可通信”向“可协同、可计算、可自治”演进过程中的关键技术之一。

然而，天基网络中的协同计算卸载并不是传统意义上的简单任务迁移问题。与地面云计算、边缘计算环境相比，天基网络中的节点资源更加受限、链路拓扑变化更加频繁、运行环境更加动态复杂。卫星高速运动使得网络拓扑、链路质量、覆盖关系和可见窗口持续变化，不同卫星节点在剩余算力、存储资源、链路状态和能量水平等方面往往存在显著异质性。与此同时，多颗卫星在同一时刻既可能是任务发起方，也可能是资源提供方，节点之间普遍存在资源竞争、收益耦合和协同行为。由此决定了天基协同计算卸载不仅要解决“任务是否卸载、卸载到哪里”的问题，更要解决高动态、去中心化环境下多节点之间的状态共享、协同博弈、实时决策与执行保障问题。

进一步而言，天基协同计算卸载的复杂性主要体现在以下几个层面。

首先，在信息层面，需要解决高动态环境下的可信状态共享问题。无论是节点间的资源协调，还是单任务的卸载决策，都依赖于对节点算力占用、剩余能量、链路连通性、队列长度和任务排队状态等信息的及时获取。然而在天基网络中，若仅依赖频繁广播实现全局状态同步，不仅会带来较大的通信开销，还可能由于链路时延、局部

信息失真和同步滞后导致认知不一致。更重要的是，在去中心化的天基环境中缺乏长期稳定且可信的中心控制节点，一旦共享状态出现滞后、篡改或偏差，后续资源调度与任务卸载就可能失去可靠依据。因此，如何为多节点协同决策提供可追溯、可信任、低冲突的状态共享基础，是实现协同计算卸载的首要前提。

其次，在决策层面，需要同时面对系统层协同和任务层执行两类问题。一方面，在多颗卫星同时发起卸载请求的场景下，优质节点极易成为竞争焦点。若各节点仅从局部收益出发进行贪婪选择，则容易引发策略震荡、热点聚集、负载失衡和资源抢占等问题，影响系统整体运行效率。另一方面，任务进入目标节点后并非立即进入理想执行状态，而是会受到排队延迟、上下文切换、缓存竞争、内存争用以及功耗波动等多种并发因素影响。由此，任务层卸载决策不仅要考虑传输时延与计算时间，还需要进一步考虑更贴近真实运行环境的执行代价，才能保证卸载策略在高负载和复杂动态场景下仍具备实际有效性。

再次，在实现层面，需要解决算法方法与系统平台之间的统一承载问题。对于天基协同计算卸载而言，仅有卸载模型或优化算法并不足以支撑系统的长期稳定运行。系统层协同方法需要状态同步、规则执行、行为记录和可信审计机制作为支撑；任务层实时决策方法则依赖模型版本管理、执行反馈、结果回流以及跨节点可追溯记录。若缺乏统一的平台承载，相关方法往往停留在算法验证或离线仿真层面，难以形成可部署、可验证、可持续演进的实际运行体系。因此，从平台视角统筹考虑可信共享、协同优化、模型治理和执行反馈，同样是天基协同计算卸载研究不可回避的重要内容。

综上所述，天基协同计算卸载并不是单一节点上的局部任务调度问题，而是涉及任务接入、状态共享、跨节点协同、资源竞争、执行扰动以及结果回传等多个环节的系统性问题。该问题既具有典型的高动态、异构、去中心化特征，又包含状态可信、协同博弈和实时决策等多层耦合关系。传统依赖静态假设或中心控制的处理思路，已难以满足复杂天基环境下多节点协同计算的实际需求。因此，有必要面向可信共享、系统层协同优化、任务层实时卸载决策以及平台化承载机制开展联合研究，构建更加适应天基网络运行特征的协同计算卸载方法体系。

基于上述背景，本文围绕天基网络协同计算卸载中的关键问题展开研究，重点关注高动态环境下的可信状态共享、多节点协同资源博弈、并发感知任务卸载以及双层智能方法的平台化承载等内容。本文认为，天基协同计算卸载研究不仅在工程应用层面对提升灾害应急、遥感快处理、空间任务协同和边远区域信息服务等能力具有重要

价值，而且在理论与方法层面也可为高动态、去中心化、资源受限网络环境中的分布式协同计算研究提供新的思路。通过构建兼顾可信共享、系统协同、任务决策与平台承载的统一研究框架，有望提升天基网络在复杂任务场景下的实时响应能力、资源利用效率与智能自治水平，为天地一体化信息网络向智能化、协同化和自治化方向发展提供理论支撑与技术参考。

1.2 国内外研究现状与发展趋势

围绕天基网络协同计算卸载问题，国内外研究已从体系架构、任务卸载、智能调度、去中心化协同、隐私保护建模以及平台化支撑等多个角度展开探索。总体来看，相关研究正沿两个方向并行推进：一方面，卫星边缘计算与星间协同处理不断走向实用化，任务卸载与资源调度问题逐步由静态建模转向动态学习；另一方面，随着网络规模扩张和节点自治能力增强，可信共享、分布式共识、联邦学习以及区块链平台等支撑机制日益成为研究重点。基于此，本节从天基边缘计算与卸载、动态环境下的智能调度、多节点可信协同与隐私保护三个方面进行梳理，并据此明确本文的研究定位。

1.2.1 天基网络与卫星边缘计算研究现状

随着低轨卫星星座的快速发展，卫星边缘计算已成为天基网络研究中的热点方向。已有研究普遍认为，未来卫星网络不应仅承担透明转发功能，而应具备在轨预处理、局部协同分析和边缘服务承载能力，以缓解地面中心压力并提升实时响应能力^[1,4]。围绕这一目标，学界先后提出星地协同、星间协同和天地融合等多种计算架构，试图根据任务复杂度、时延要求和资源约束，在终端、卫星与地面之间灵活划分处理位置。

在具体卸载方法方面，早期研究多采用解析优化、启发式搜索或博弈论方法，对时延、能耗和资源利用率进行联合建模。这类方法在问题规模较小且假设条件较强时具有较好的可解释性，但当网络拓扑频繁变化、链路状态动态波动或任务到达具有突发性时，其模型有效性往往难以长期保持。例如，Gao 等针对 LEO 星座网络中的分布式动态卸载问题，基于博弈论建立了联合计算卸载与功率分配模型，在分布式环境下优化了资源利用效率，但该方法的求解过程依赖较强的信道静态假设^[6]。

自 2024 年以来，相关研究开始更加重视卸载问题中的时变信道、队列状态和动态负载因素。Jia 等提出面向卫星边缘计算的深度多智能体强化学习方法 MATORA，将

任务卸载与资源分配拆分求解，在动态负载条件下提高了时延优化能力^[3]。Li 等针对 LEO 卫星边缘计算网络研究了基于 MADDPG 的联合卸载与资源分配问题，通过分布式学习处理高动态环境中的能耗与时延折中^[2]。Shuai 等讨论了基于 Q-learning 的卫星边缘计算卸载策略，进一步验证了强化学习方法在动态卫星场景中的适应性^[5]。与此同时，Tang 等研究了基于星间链路的星地一体化网络任务卸载与资源分配问题，提出混合云与卫星多层多接入边缘计算架构，通过联合优化节点选择、卸载比率和算力分配实现了网络资源的动态管理^[7]。

进入 2025 年以后，研究重点进一步从“是否卸载”扩展到“如何在多目标条件下稳定卸载”。Xu 等提出面向卫星边缘计算的多目标强化学习卸载方法，将时延、资源利用率和负载均衡纳入统一优化目标，改善了复杂任务场景下的综合性能^[8]。Ma 等则着重分析了任务优先级、资源竞争和联合分配之间的耦合关系，指出卸载研究正在由单一指标优化转向优先级感知、服务质量约束和多资源联合编排^[9]。在此基础上，Wang 等提出 MARATD3 算法，将循环神经网络与多头注意力机制引入多智能体深度确定性策略梯度框架，在部分可观测条件下实现了跨时隙的动态卸载与资源分配联合优化，为高动态卫星环境中的序贯决策问题提供了新的建模范式^[10]。与此同时，Jia 等探索了联邦深度强化学习在低轨卫星边缘计算中的应用，将联邦学习与 DRL 相结合，在保护用户数据隐私的同时优化计算卸载策略，指出联邦学习不仅能够保护隐私，还可作为卸载策略训练的分布式支撑手段^[11]。

这些研究表明，卫星边缘计算与任务卸载已由概念验证阶段逐步迈向细粒度建模与智能优化阶段。2024—2026 年天基计算卸载与智能调度领域的代表性研究如表 1.2 所示。

尽管相关研究已取得显著进展，但仍存在两方面关键局限。其一，多数工作默认系统能够获得较准确的全局或准全局状态，对高动态拓扑下的状态不一致、信息失真和分布式认知偏差问题考虑不足。其二，大量模型仍将任务代价简化为传输时间与纯计算时间的线性叠加，对多任务并发带来的内部竞争和执行扰动刻画不够充分。换言之，天基计算卸载虽已从静态优化走向动态学习，但在“可信共享”和“并发感知”两个维度上仍有待深入研究。

表 1.2 2024—2026 年天基计算卸载与智能调度代表研究

研究方向	代表文献	主要内容	不足或启示
卫星边缘计算架构	[1,4]	从星地融合、星间协同和天地一体化角度讨论卫星边缘计算架构与业务承载方式	侧重体系层面描述，对协同决策机制的讨论不足
博弈论与优化方法	[6-7]	利用博弈论、凸优化或分层架构处理卸载与资源联合分配	依赖较强的信道平稳或全局信息可获得假设
单智能体 RL 卸载	[5,8]	利用 Q-learning、DQN 及其改进模型优化卸载时延和资源利用率	多从单节点或单任务视角建模，难以处理多节点博弈
MARL 联合优化	[2-3,9-10]	将多颗卫星建模为多智能体，联合优化卸载、功率、带宽和资源分配	通常假设状态可获得，可信共享基础偏弱
联邦学习辅助卸载	[11]	将联邦学习与 DRL 结合，保护隐私同时优化卸载策略	联邦学习与卸载决策的闭环耦合仍待深化
2026 新趋势	[12]	引入大模型处理复杂状态下的卸载与资源分配	表明卸载研究向更复杂决策模型演进，但对系统层信任问题涉及较少

1.2.2 动态环境下智能调度与多智能体协同研究现状

天基网络环境具有高动态、强耦合和多主体并存等特征，面向动态环境的智能调度已成为近年来相关研究的核心方向。深度强化学习之所以被广泛引入，在于其能够在缺乏精确解析模型的条件下，通过与环境持续交互形成状态到动作的映射关系，从而有效处理链路波动、任务到达随机性和资源时变性等问题^[13]。

在单智能体强化学习阶段，研究通常聚焦单节点视角下的卸载动作、功率控制或链路选择，通过 DQN、DDQN、D3QN 等方法提升策略对复杂状态的适应能力。此类方法在小规模、中心化或弱耦合场景中效果较好，但当多个卫星节点同时参与决策时，其隐含的“环境平稳”假设不再成立。对任一节点而言，其他节点的动作会持续改变其观测环境和收益分布，导致单智能体方法面临显著的环境非平稳性问题。

基于这一认识，多智能体强化学习在天基计算调度中日益受到重视。2024 年以后，多项研究明确将多颗卫星建模为多智能体系统，通过集中训练分布执行（CTDE）或共享奖励等机制处理节点间的策略耦合关系^[2-3]。在 CTDE 范式的具体实现方面，Wu 等提出了面向 LEO 卫星网络的多智能体深度强化学习卸载与路由联合优化方法，将计算和路由需求同时纳入多智能体建模框架，在动态负载和拓扑变化条件下展现了分布式决策的灵活性^[14]。Qin 等则从可持续计算角度出发，利用 MARL 解决星地一体化网络中的计算卸载问题，强调全局奖励设计在多智能体收敛中的关键作用^[1]。

此类方法的核心优势在于能够同时考虑局部选择与全局负载之间的关系，使卸载策略从局部最优逐步逼近系统层协调。从当前发展趋势看，MARL 在天基网络中的定位已由辅助优化工具转变为描述多节点协同演化的方法论基础。这一趋势在 2025—2026 年间表现得尤为明显。在卫星对地观测调度领域，AAAI 2025 接收的一项工作将 MARL 应用于大规模序贯卫星任务分配问题，通过从多项式时间贪心求解器引导学习并结合分布式最优分配机制，成功扩展至数百个智能体和任务的规模，显著超越了先前方法^[15]。与此同时，2026 年的一项研究提出时空感知的 MAPPO 方法，用于周期性重访约束下的多星观测调度，并通过多目标奖励函数平衡任务完成率、首次观测时效性和重访均匀度^[16]。这些工作进一步表明，MARL 不仅适用于通信层面的资源分配，也正在向观测调度、联合计算与通信优化等更广泛的星上任务管控领域扩展。

需要指出的是，近年来还出现了将强化学习与联邦学习相结合的新趋势，以解决天基网络中分布式决策的隐私和通信效率问题。Han 等研究了星地一体化网络中联邦学习的合作卸载问题，联合优化本地计算和数据卸载策略，为联邦学习在天基协同场

景中的部署提供了理论框架^[17]。这一方向的出现，意味着智能调度正由“集中式学习后分布式部署”向“训练与部署全程分布式”演进。

与此同时，随着研究由“单一算法性能提升”走向“复杂系统长期运行优化”，越来越多工作开始关注调度算法与系统支撑环境之间的关系。换言之，多智能体协同并不只是算法选择问题，还涉及状态同步、规则执行、行为记录和跨层反馈等系统性条件。若缺乏统一的平台承载，即便算法本身能够在仿真环境中获得较好效果，也难以在真实分布式系统中持续稳定运行。这也说明，天基智能调度研究正由“算法导向”逐步迈向“算法—机制—平台”协同设计的新阶段。

然而，现有智能调度研究仍存在两个值得关注的问题。第一，许多研究虽采用多智能体框架，却仍默认节点间可以高效、真实地共享状态信息，对分布式系统中的虚假共享、状态滞后和认知不一致问题讨论不足。第二，部分工作侧重于算法收敛与指标提升，对“高动态去中心化环境为何必须采用多智能体协同而非中心化控制”的论证不够充分。实际上，MARL 在天基网络中的核心价值不仅在于提升数值性能，更在于为去中心化资源博弈提供统一的建模与求解框架。

1.2.3 区块链协同与隐私保护学习研究现状

随着天基网络从封闭体系向开放协同体系演进，可信共享与去中心化协同问题日益突出。传统中心控制模式虽便于统一管理，但在大规模低轨星座和多主体参与环境下，容易面临单点失效、扩展性不足以及状态采集开销过高等问题。为此，近年来研究开始尝试引入区块链、分布式共识和自治网络协议，为天基网络构建新型协同机制。

2024 年以来，该方向的代表性工作明显增多。Oh 等提出去中心化多方低轨网络 (MP-LEO) 设想，强调通过分布式控制和多方协同共享冗余能力，提升未来卫星网络的鲁棒性与可用性^[18]。Yan 等从网络协议层面提出面向通信卫星服务的去中心化协议，利用区块链式状态发布机制提升全网信息的透明度和公平性^[19]。与此同时，面向空天地一体化网络的区块链安全通信研究也在增加，Zhang 等利用区块链改善 SAGIN 中数据传输的信任问题，并探索低轨卫星承担去中心化账本维护与分布式记录的可行性^[20]。

在区块链与计算卸载的结合方面，2025 年的一项重要进展值得关注。相关研究提出了区块链辅助的数字孪生卸载机制，在空天地异构网络中构建了 SAG 数字孪生集成区块链模型，利用区块链保障数据安全与隐私的同时，通过数字孪生实现网络状态

的实时映射与优化,并给出了高效的任務卸載與資源分配聯合算法^[21]。該工作將區塊鏈由“外部安全模塊”推進到“與卸載決策緊密耦合的狀態底座”,與本文的核心理念高度契合。此外,面向衛星物聯網的 StarCross 框架提出了可編輯區塊鏈跨分片交易方案,在 LEO 輔助的分片區塊鏈架構下將吞吐量提升至基線的 260.9%,交易確認延遲降低 79.7%,說明通過架構創新可以有效緩解衛星網絡中區塊鏈的性能瓶頸^[22]。

進入 2025—2026 年,研究重點進一步由“能否去中心化”轉向“如何在高動態衛星網絡中實現更穩健的共識與控制”。2026 年的 DSH-Raft 研究針對衛星網絡中帶寬受限、計算能力異構和拓撲波動顯著等問題,提出動態分層 Raft 共識算法,表明傳統地面分布式共識機制無法直接移植到衛星環境,而必須圍繞鏈路質量、節點能力和覆蓋約束進行針對性重構^[23]。這一趨勢表明,去中心化衛星網絡研究已由宏觀願景逐步走向面向工程實現的機制設計階段。可信協同與隱私保護領域的代表性研究如表 1.3 所示。

表 1.3 可信協同與隱私保護相關代表研究

研究方向	代表文獻	主要內容	對本文的啟示
去中心化衛星網絡	[18-19]	提出多方參與、分布控制的衛星網絡願景與協議雛形	可信共享和自治控制將成為星座協同的重要基礎
區塊鏈支撐通信/協同	[20-23]	利用區塊鏈、數字孿生和改進共識提高空天地網絡中的數據可信傳輸與一致性維護	區塊鏈應從安全附加層轉變為資源調度的狀態底座
區塊鏈與聯邦學習融合	[24]	在 LEO 網絡中構建分片區塊鏈聯邦學習框架以應對惡意模型攻擊	區塊鏈可為聯邦學習提供可信聚合與安全保障
隱私保護聯邦學習	[11,25-28]	圍繞層次聚合、分裂聯邦、軌道感知和異構适配等機制提升衛星環境中的協同學習能力	聯邦學習不僅可保護隱私,更可作为并发代价建模的训练支撑

儘管如此,當前關於去中心化衛星網絡和區塊鏈協同的研究仍主要集中在安全、協議和網絡治理層面,與天基計算卸載的深度耦合尚不充分。已有工作回答了“為什麼需要去中心化”和“如何構建分布式信任機制”,但這些機制如何有效服務於具體的計算卸載、資源協調和任務調度,仍缺少系統性討論。本文正是在這一研究空白上

进一步推进，将区块链由“外部安全模块”转化为“系统层可信状态共享底座”，并进一步作为双层智能方法的平台化承载基础。

在隐私保护协同建模方面，联邦学习逐渐成为支撑天基网络分布式智能建模的重要方案。与传统集中式学习相比，联邦学习允许各节点在本地完成训练，仅交换模型参数或梯度，在“数据不出域”的前提下实现跨节点协同优化^[25,29]。

在卫星及星地融合场景中，联邦学习研究近两年呈现出两条清晰路径：一是围绕具体业务构建面向天基环境的协同学习框架，二是围绕高动态、异构和隐私约束条件改进联邦学习机制本身。前者如 Jiang 等将联邦学习与分裂学习结合，提出适用于卫星—地面融合网络（STIN）的分裂后联邦框架，证明在卫星链路和边缘服务器并存条件下可通过结构改造减少传输压力并保护局部数据^[26]；后者如 Li 等提出 HiSatFL，通过轨道感知层次聚合和跨域隐私自适应机制，专门针对卫星网络的动态拓扑、多维异构和隐私保护需求进行设计^[25]。此外，2025 年前后有关卫星 ISAC 网络中的联邦学习研究也开始关注收敛效率、传输开销与协同增益之间的平衡^[27]。

在联邦学习框架的可扩展性方面，近两年出现了多项面向 LEO 异构星座的代表性工作。FedLEO 是一个面向 LEO 卫星网络的卸载辅助去中心化联邦学习框架，通过利用 LEO 星座的拓扑特征设计卸载机制，有效缓解了卫星间计算能力不均衡带来的掉队者效应和统计异质性问题^[28]。同期，FedSN 框架提出了面向异构 LEO 卫星网络的通用联邦学习方案（2025），通过子结构方案支持不同计算、内存和通信能力的异构本地模型训练，并在真实卫星数据上验证了精度和开销方面的显著优势。这些工作进一步说明，联邦学习在天基网络中已进入面向实际工程约束的精细化设计阶段。

更进一步地，区块链与联邦学习的融合成为 2024 年以来的新兴方向。Wu 等提出了面向 LEO 网络的分片区块链联邦学习框架 SBFL-LEO，利用矿工卫星通过余弦相似度和 DBSCAN 算法检测恶意模型，并通过卫星间互相监督提升聚合安全性，在模型精度和能效方面均显著优于基线方法^[24]。这一研究表明，区块链不仅可以为资源状态提供可信底座，还能为联邦学习的模型聚合过程提供安全保障，这对于天基网络中缺乏可信中心的分布式训练场景具有重要意义。

总体而言，隐私保护联邦学习在卫星网络中的已有研究证明：联邦学习不仅能够降低原始数据汇聚压力，还能在异构节点条件下提升模型泛化能力。然而，多数现有工作仍停留在“如何将联邦学习部署到卫星网络”这一层面，较少深入讨论其与上层任务调度、代价预测和实时决策之间的闭环联动。与此同时，关于区块链平台的研究

虽已在数据存证、可信共享和跨域协同方面取得进展，但仍较少与系统层多智能体协同和任务层深度强化学习方法形成统一的体系设计。本文认为，天基协同计算研究下一阶段的重要突破点，不只是算法精度或指标提升，而是如何将可信共享、协同博弈、代价建模与实时卸载有机集成到一个可运行的平台环境中。

1.2.4 现有研究存在的主要问题与挑战

综合上述研究现状，当前围绕天基网络计算卸载的研究虽已从静态优化迈向智能化与分布式化，但仍存在以下四个方面的关键不足：

(1) 全网状态共享基础薄弱。现有计算卸载与智能调度研究往往默认节点能够获取较为准确的全局状态，却较少考虑高动态拓扑下的信息时延、认知偏差和共享可信性问题，使得诸多算法建立在偏理想化的前提之上。

(2) 系统层协同博弈与可信共享机制之间存在割裂。多智能体强化学习能够处理多节点资源竞争，但若缺少可信状态支撑，策略学习极易受到不一致观测的干扰；区块链和分布式共识虽能提供可信共享，却往往未能进一步服务于卸载决策过程，两者之间缺少有效的协同设计。

(3) 任务层执行代价建模偏于静态。现有大量研究仍将任务代价简化为传输时延与计算时长之和，对并发任务间的资源争用、排队延迟和性能退化考虑不足，导致算法在高负载场景下的实际适用性受到限制。

(4) 算法研究与平台实现尚未形成统一闭环。已有工作在计算卸载、区块链协同和联邦学习等方向分别取得进展，但如何把系统层协同优化、任务层卸载决策、模型治理、任务存证和执行反馈统一纳入同一分布式平台架构，仍缺乏完整的体系化设计。

基于上述问题，本文从系统层、任务层和平台层三个维度展开研究：在系统层，利用区块链和 MARL/PPO 构建可信协同资源博弈机制；在任务层，利用联邦学习和 DQN 建立并发感知卸载决策机制；在平台层，依托区块链平台架构实现双层智能方法的统一承载、规则治理与工程落地。通过“分层建模、双层决策、平台贯通”的设计思路，系统性回应当前研究中的上述关键不足。

1.3 本文主要研究内容与论文结构

针对天基网络中状态感知困难、多节点协同博弈复杂、并发执行代价难以准确刻画以及算法难以平台化落地等问题，本文围绕天基协同计算卸载中的可信共享、协同

优化、实时决策与平台承载需求展开研究，构建融合区块链、多智能体强化学习、联邦学习和深度强化学习的双层智能管控体系。本文从系统层、任务层和平台层三个维度出发，分别研究天基网络中的可信状态共享与多节点协同博弈问题、并发感知任务卸载问题以及双层智能方法的平台化承载问题，以期在高动态、去中心化环境下的天基协同计算提供系统化解决思路。

图 1.2给出了本文的整体研究思路与论文结构。该图从研究背景出发，依次梳理理论基础、面向场景的关键问题、相应方法与创新点，以及最终的平台闭环实现过程，体现了本文由“问题提出—模型建立—方法设计—平台承载—结论总结”逐步展开的总体逻辑。其中，第三章和第四章分别对应系统层可信协同资源优化与任务层并发感知卸载决策，第五章则进一步实现前述双层智能方法的平台化映射与工程承载。




图 1.2 本论文研究思路及文章结构

针对本文的研究工作，具体内容和章节安排如下：

第一章为绪论。首先介绍天基网络协同计算卸载的研究背景与意义，分析天基网络由传统转发网络向分布式协同计算平台演进的现实需求，以及在高动态、去中心化

环境下面临的状态共享、资源协同、实时决策与平台承载等关键问题。其次，从天基边缘计算与任务卸载、动态环境下智能调度与多智能体协同、区块链协同与隐私保护学习三个方面，对国内外研究现状与发展趋势进行梳理。在此基础上，总结现有研究存在的主要问题与挑战，并给出本文的研究内容与整体结构安排。

第二章主要研究面向天基协同计算卸载的系统模型与理论基础。首先，结合卫星节点异构、链路时变、任务随机到达以及资源受限等特征，建立天基协同计算系统模型，形成对节点、任务、链路和资源约束的统一描述。其次，围绕系统层协同与任务层卸载所涉及的关键问题，梳理可信共享、多智能体协同、联邦学习和深度强化学习等相关理论基础，为后续章节的方法设计提供建模依据和理论支撑。

第三章研究基于区块链与 MARL/PPO 的系统层可信协同资源博弈方法。针对天基网络中全局状态难以准确获取、多节点之间易出现资源竞争与负载失衡的问题，构建面向系统层协同优化的可信状态共享与多智能体博弈框架。通过将区块链机制引入分布式状态维护过程，实现多节点资源信息的可信记录与共享；在此基础上，将多个卫星节点建模为多智能体，利用 PPO 策略优化实现系统层的协同资源调度与负载均衡。通过该章研究，为后续任务层卸载决策提供可信状态基础和系统协同环境。

第四章研究基于联邦学习与 DQN 的任务层并发感知卸载方法。针对传统卸载模型难以准确刻画多任务并发执行代价的问题，构建面向任务层实时决策的并发感知建模与智能卸载方法。首先，结合节点内部任务排队、资源争用和运行扰动等因素，建立更贴近真实运行环境的执行代价建模思路；其次，引入联邦学习机制，在保护各节点本地数据隐私的前提下完成并发代价预测模型训练；进一步结合 DQN 方法，将任务特征、链上状态和并发代价预测结果映射为具体卸载动作，实现面向动态环境的实时任务卸载优化。

第五章研究面向天基协同计算的区块链平台架构与运行机制。针对现有相关研究中算法设计与系统实现相互割裂的问题，在前述系统模型与双层智能方法基础上，设计能够统一承载可信共享、协同优化、模型治理与任务执行反馈的区块链平台架构。通过构建链上治理与链下计算相结合的运行机制，实现系统层与任务层方法的协同集成，为双层智能方法的工程化部署与可持续运行提供支撑。

第六章对全文工作进行总结，并对后续研究方向进行展望。

2 天基网络计算卸载的技术基础与系统建模

2.1 天基网络协同计算场景与体系结构

2.1.1 天基网络协同计算场景分析

随着低轨卫星星座规模化部署、星间链路能力增强以及星上异构计算载荷逐步成熟,天基网络的功能定位正在由传统的“广域覆盖与信息转发”扩展到“通信、计算与智能协同服务”的综合平台。近年来,非地面网络(Non-Terrestrial Networks, NTN)已经从补盲式接入手段演进为 6G 体系中的关键组成部分。围绕 3GPP Release 17/18 的最新研究表明,卫星接入、再生式载荷、回传一体化以及天地融合组网正在推动卫星系统从专用通信体制走向与蜂窝网络深度耦合的统一架构^[30-32]。这意味着天基网络不再仅承担“把数据送回来”的传输角色,而开始承担“在何处处理、如何协同处理、何时返回结果”的计算与控制角色。

在这一背景下,轨道边缘计算(Orbital Edge Computing, OEC)成为天基网络的重要演进方向。与传统“天感地算”模式相比,OEC 强调在卫星侧、跨星链路侧以及天地协同侧完成数据预处理、任务调度与智能推理,其目标是在降低星地回传压力的同时,缩短端到端任务闭环时间^[33-34]。特别是在遥感感知、海洋监测、应急救援、边远区域物联网和全球连续感知等场景中,数据源与地面中心之间存在天然的空间分离,而业务又常常具有“数据量大、计算量大、实时性强”的复合特征。如果仍将全部原始数据下传至地面统一处理,则会受到星地链路容量、回传路径长度以及地面调度时延的共同制约,难以满足分钟级甚至秒级的任务响应要求^[35-37]。

进一步地,天基网络业务形态正在从“连接驱动”走向“任务驱动”。传统卫星通信业务更多强调链路连通性和广域可达性,而面向 6G 的新型业务则更关注从任务生成、任务传输、任务执行到结果反馈的端到端闭环性能。例如,在广域遥感与地球观测任务中,往往需要多颗卫星对大范围区域进行协同观测,并进一步完成图像路由、计算处理和结果下发,此时任务调度已经不再是单纯的数据回传问题,而是观测、转发、计算和资源编排的一体化问题^[35]。类似地,在远洋 IoT、灾害应急和偏远地区智能巡检等场景中,业务往往既依赖卫星提供广域接入,又依赖卫星边缘侧提供就近计算、模型推理和局部缓存能力^[37-38]。

然而,相较于地面边缘计算,天基网络协同计算场景具有更强的动态性、异构性

和资源约束。一方面，低轨卫星高速运行导致节点覆盖关系、可见窗口和路由拓扑持续变化；另一方面，星上计算、缓存和能量资源远弱于地面数据中心，节点间能力差异显著，且业务需求在时延容忍、任务规模、能耗预算和优先级等方面高度异构。此外，跨星协同和多任务并发还会引入服务部署、任务迁移、资源竞争和队列耦合等新问题^[39-41]。因此，天基网络中的计算卸载不应被简单理解为“本地执行”与“远端执行”之间的二元选择，而应被视为一个面向动态拓扑、异构资源和时变业务的多层协同优化问题。

基于上述认识，本文将天基网络计算卸载问题划分为两个相互关联的层次：其一是系统层资源协同问题，关注星座尺度上的资源组织、状态同步、服务部署与长期运行效率；其二是任务层计算卸载问题，关注单任务或局部任务集在当前环境中的执行位置选择及其时延、能耗与可靠性收益。这样的分层处理既符合天基网络“全局慢变量演化、局部快变量决策”的运行规律，也为后续分别研究系统层协同控制与任务层智能卸载提供了清晰的问题入口。

2.1.2 节点类型与功能划分

为清晰刻画天基网络中的协同计算体系，本文将参与任务处理与资源调控的节点划分为三类：卫星终端（Satellite Terminal, ST）、卫星边缘节点（Satellite Edge Node, SEN）以及地面控制中心（Constellation Controller, CC）。

卫星终端通常位于业务源头，是系统中计算任务的产生者。终端可以是边远区域的传感设备、海上浮标、无人平台、野外监测站，也可以是通过卫星接入网络的移动终端。这类节点具备基础感知、通信与轻量处理能力，但本地算力、电池容量和持续通信能力通常有限，难以独立承担复杂的模型推理、图像分析或多模态信息融合任务。因此，终端既是业务输入入口，也是任务卸载决策的直接触发点。

卫星边缘节点是指具备一定在轨计算与缓存能力、能够为终端提供近端计算服务的星上节点。与传统仅负责信号中继的通信卫星不同，SEN 具备任务预处理、AI 推理、缓存协同、跨星转发以及局部资源编排能力，是 OEC 场景中的核心计算承载实体^[33-34]。近年来，相关研究已从单星边缘处理逐步扩展到多星协同处理、星间任务转发和同轨/异轨资源共享，这说明 SEN 的角色正在从“边缘执行器”发展为“分布式协同计算节点”^[39-40]。但需要强调的是，SEN 仍受制于星上功耗、存储、热控和能量预算，其服务能力随实时负载、服务部署状态和可用链路条件而显著变化。

地面控制中心则是系统中的强算力支撑节点和全局协调实体。一方面, CC 具备更高等级的计算、存储和模型训练能力, 可承担复杂任务处理、长期策略训练、全局状态融合和跨域控制等功能; 另一方面, 它还负责星座资源编排、全局策略下发与系统运行维护。相比 SEN, CC 在资源规模和运行环境稳定性上具有显著优势, 但其处理路径更长, 通常需要经历额外的星地传输与调度开销, 因此并不总适合承担强实时业务。

由此可见, 本文所研究的天基协同计算体系本质上形成了“终端—星上—边缘—地面中心”的三级协同结构: 终端侧强调任务生成与本地快速响应, 边缘侧强调近端处理与局部协同, 地面侧强调强算力支撑与全局控制。该结构既符合当前天基网络向“通算智融合”演进的发展趋势, 也为后续双层智能管控框架的构建提供了直接依据。

2.1.3 链路特性与资源受限特征

在天基网络中, 计算卸载与协同处理能力不仅取决于节点自身算力, 还受到通信链路条件和资源约束的共同影响。与地面固定网络相比, 星地链路和星间链路在可见窗口、传播路径、带宽波动和拓扑稳定性方面均存在显著差异, 因此任务处理问题天然具有更强的动态耦合特征^[33,41]。

首先, 链路可见性的时变性是天基网络区别于地面网络的核心特征之一。低轨卫星高速运行导致终端与卫星之间、卫星与卫星之间的可达关系不断变化, 任务上传、转发和回传必须受到可见窗口约束。某一任务即便在当前时刻可以完成上传, 也未必能够在同一链路窗口内完成结果回传, 尤其当任务还伴随跨星转发或服务迁移时, 这种时变性会进一步放大^[35,41]。因此, 卸载决策不能只依赖静态路径假设, 而必须同时考虑链路存在性、持续时间与后继路由可达性。

其次, 链路带宽和质量具有明显的时间依赖性。卫星相对位置变化、链路负载波动以及环境扰动共同决定了有效带宽和传输时延的动态变化。对同一任务而言, 在不同时间片、不同可达卫星或不同转发路径上, 其通信代价可能存在显著差异。进一步地, 星上计算资源与链路资源往往不是彼此独立的: 链路拥塞会导致排队和调度开销上升, 而节点过载又可能触发任务迁移、跨星协同或服务重新部署, 从而反过来影响网络负载分布^[39,42]。

最后, 资源受限性贯穿于终端、卫星边缘和地面协同的全过程。终端面临算力不足和能耗受限问题; SEN 则同时面临算力、缓存、能量与服务槽位约束, 且不同卫星

上的服务实例部署状态并不一致；地面中心虽然资源充足，但在路径时延与回传开销方面存在天然劣势^[43-45]。这意味着，天基网络计算卸载的本质并不是“谁更强就给谁算”，而是在链路可达性、资源剩余量、服务可用性以及任务 QoS 需求共同约束下，对执行位置进行动态选择。

综上，天基网络中的计算卸载本质上是由计算资源、通信资源、服务部署状态与时间窗口共同耦合的复杂优化问题。链路的动态可见性决定任务是否具备卸载条件，通信能力的时变性决定任务传输代价，节点资源受限特征决定任务是否能够稳定执行，而服务部署与跨星协同能力则进一步影响系统的长期收益。因此，有必要在后续建模中将上述因素统一纳入系统模型与任务模型。

2.2 计算卸载与智能管控相关技术基础

2.2.1 计算卸载基本模式与性能指标

计算卸载的基本思想，是将资源受限节点上的任务全部或部分迁移至外部节点执行，以缓解本地算力不足、降低终端能耗并改善服务时延。在天基网络场景中，由于终端、卫星边缘节点和地面控制中心在计算能力、链路条件和资源成本上存在显著差异，卸载机制不再只是简单的“本地执行”与“远端执行”二元选择，而是演化为多层异构节点之间的动态协同过程^[41,44]。

从执行位置看，本文考虑三种基本处理方式：一是由源终端本地执行；二是卸载至可达的卫星边缘节点执行；三是进一步卸载至地面控制中心执行。本地执行避免了传输开销，但受限于终端资源能力；边缘执行能够在较近位置提供计算服务，通常能在时延与能耗之间取得更优平衡；地面中心执行依托强大算力适合复杂任务，但需承担更长路径和更高回传代价。因此，如何在三级执行方式之间作出合理选择，是天基网络任务卸载的核心。

从任务粒度看，现有研究通常区分为全卸载、部分卸载和协同卸载三类模式。全卸载适用于本地能力严重不足且链路条件较好的场景；部分卸载强调任务可拆分与模块化执行，但在卫星网络中会受到多路径传输与子任务同步成本的额外影响；协同卸载则强调多个节点共同参与任务处理，需要联合考虑路由、服务部署、带宽分配和计算资源分配等多个维度^[36,39]。近期研究进一步表明，在卫星边缘计算网络中，卸载问题往往需要与服务部署、路由选择、跨星协同和长期系统成本一并考虑，这使得卸载

优化从单一决策问题演化为多变量耦合问题^[39,42]。

评价卸载策略优劣的核心指标通常包括任务完成时延、终端能耗、任务成功率、系统吞吐量、资源利用率和负载均衡程度等。其中，任务时延与终端能耗是最基本也是最关键的两类指标：时延刻画任务从生成、上传、执行到结果回传全过程的总耗时，直接反映业务实时性；能耗则刻画任务在本地执行或传输过程中对终端资源的消耗，对于能源受限终端尤为重要^[40-41]。此外，在动态天基网络中，服务稳定性、任务成功率、节点公平性和长期系统成本也逐渐成为重要补充指标^[43-44]。

总体上看，计算卸载问题已经从传统的规则匹配、凸优化和启发式搜索，逐步扩展到多智能体强化学习、联邦学习、两时间尺度优化以及数据驱动的环境感知建模框架^[42,46-48]。这说明在天基网络环境中，计算卸载不仅是资源分配问题，更是面向动态复杂系统的智能决策问题。

2.2.2 轨道边缘计算与星座协同处理基础

轨道边缘计算是理解天基网络计算卸载问题的重要理论基础。现有综述研究普遍指出，OEC 的核心特征可以概括为“三强一限”：即轨道移动性强、节点异构性强、任务空间耦合强，以及星上计算/存储/能量资源受限^[33]。这与传统地面 MEC 存在本质差异，决定了天基任务卸载不能照搬地面边缘计算中的静态建模与局部最优思路。

首先，OEC 并非单星能力增强的简单延伸，而是星座尺度上的协同处理体系。随着大规模 LEO 星座成为未来网络的重要基础设施，研究重点已从单星上运行 AI 推理扩展到跨星资源共享、任务迁移、协同感知、服务部署和网络计算一体化管理^[34,39]。例如，针对大范围地球观测任务，SECO 工作提出将多星观测协同、图像路由与边缘计算联合优化，从而使“观测—传输—处理”闭环在卫星网络内部尽可能完成^[35]。这说明面向星座的协同处理已成为天基网络计算服务能力提升的关键方向。

其次，OEC 中“服务部署”与“任务卸载”往往同时存在。在地面 MEC 中，服务实例通常部署于固定基站或边缘云，任务主要决定卸载位置；而在天基网络中，不同卫星可承载的服务实例种类与数量受到载荷资源和时变业务分布影响，必须通过服务部署与服务迁移机制动态适配热点区域^[39,42]。因此，系统层不仅需要感知“哪颗卫星空闲”，还需要感知“哪颗卫星上是否存在所需服务、部署代价有多高、迁移收益是否值得”，这使得系统层资源协同具有显著的长期性和结构性。

再次，OEC 的任务处理通常伴随跨星协同。当地面用户分布不均、热点区域突发

业务集中或单星负载过高时，仅依赖当前可见卫星可能导致局部拥塞和资源浪费。近期研究已经开始从“单跳卫星卸载”转向“星—星—地”协同，联合考虑任务转发比率、跨星资源分配和服务成功率最大化问题^[40,45]。这表明天基网络中的资源协同对象，不应局限于终端与某一颗卫星之间，而应扩展为覆盖多个卫星节点和地面中心的多层协同系统。

因此，在本文研究框架中，轨道边缘计算不仅是应用背景，更是问题建模的重要出发点。它说明天基计算卸载必须同时关注任务执行位置、服务可用性、链路时变性和跨星协同处理机制，进而为系统层与任务层的双层智能管控提供理论支撑。

2.2.3 可信状态同步与分布式协同基础

在天基网络的协同计算过程中，资源调度与任务卸载的有效性高度依赖系统状态信息的准确性、时效性与一致性。然而，由于卫星节点空间分布广、链路窗口短且拓扑动态变化显著，系统中的不同节点通常只能获得局部观测信息，难以及时形成完整一致的全局状态视图。这种状态不对称和不同步会直接导致错误卸载、资源竞争失衡和服务冲突。

因此，从系统层视角看，需要构建一种可信、可共享、可追溯且适配时变链路环境的状态同步机制。这里的“可信状态同步”并不局限于某一种具体技术实现，其核心目标是保证关键系统状态（如节点负载、服务部署、链路可达性、缓存与队列占用等）在多节点之间能够以可验证、低开销和可容错的方式传播。对天基网络而言，状态同步的重点不在于追求绝对实时和绝对全局，而在于在受限资源条件下实现“足够可信、足够一致、足够可用”的系统视图。

从机制设计看，这类状态同步通常需要满足四点要求：一是轻量化，不能显著占用星上计算与带宽资源；二是容错性，能够容忍链路间歇中断和局部网络分区；三是可追溯性，便于后续系统审计与策略回溯；四是可扩展性，能够适应大规模星座环境下的节点增长与业务扩展。围绕这些要求，已有研究在卫星边缘计算中开始关注系统层的服务部署、资源共享、长时间尺度优化与分布式协同问题^[39,42]。这说明，仅靠任务层即时决策难以保证系统长期稳定运行，必须有系统层状态同步与协同支撑作为基础。

在本文中，可信状态同步的定位并不是独立研究目标，而是系统层资源协同的前置条件：只有当节点对关键状态形成相对一致的认知，系统层策略才可能有效引导后

续任务层的局部决策。因此，本文后续将其视为双层管控体系中的系统支撑能力，而非单纯的安全附加模块。

2.2.4 多智能体强化学习的系统层协同决策基础

强化学习通过“状态—动作—奖励”交互机制学习最优策略，能够在环境模型难以精确建立、系统状态快速变化的复杂问题中体现较强适应能力。然而，在天基网络协同计算场景中，系统天然具有多主体特征：多个卫星边缘节点需要共同承担任务接入、处理、缓存、服务迁移和转发等功能，局部决策之间存在显著耦合，因此单智能体框架难以充分刻画这种分布式协同过程。

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）将多个自治实体抽象为多个交互智能体，使各智能体在局部观测条件下学习协同或竞争策略。特别是中心化训练、分布式执行（CTDE）框架，非常适配天基网络的特点：训练阶段可以利用较完整的全局信息学习协同策略，而执行阶段每个智能体只需依据本地状态和有限邻域信息完成在线决策，从而降低对实时全局通信的依赖^[46-47]。

对于系统层资源协同而言，MARL 的价值主要体现在三个方面。其一，卫星节点天然具备多主体结构，不同 SEN 既共享系统环境，又在局部服务承载与资源竞争上存在独立决策需求，因此适合建模为多智能体协同控制问题。其二，系统层状态通常是局部可观测的，单节点难以完整掌握全局资源分布，而 MARL 能够较好处理此类部分可观测马尔可夫决策过程。其三，卫星网络环境具有显著非平稳性，传统静态规则难以长期保持有效，而多智能体学习方法能够通过持续交互更新策略，从而适应时变业务和动态拓扑^[46-47,49]。

近期研究已经将 MARL 应用于 LEO 卫星边缘计算中的计算卸载、资源分配和任务协同问题。例如，Li 等人在 *Computer Communications* 2024 中利用 MADDPG 联合优化发射功率、CPU 频率、比特分配、卸载决策和带宽分配^[46]；Xiu 等人在 *Computer Networks* 2025 中引入 RNN 和记忆注意力机制以提升多时隙动态环境中的状态建模能力^[47]；围绕分布式卫星边缘智能的研究还进一步探索了“学习—服务—资源”耦合优化框架^[43]。这些工作共同表明，MARL 已成为处理系统层全局协同与长期收益优化的重要技术路线。

因此，在本文技术框架中，多智能体强化学习主要被视为系统层资源协同的重要理论基础。该方法能够将星座尺度的全局协同问题抽象为多个边缘节点在共享环境中

的联合学习问题，从而更自然地适应天基网络分布式、动态化与局部观测受限的运行特征。

2.2.5 联邦学习与深度强化学习的任务层决策基础

除系统层的全局协同外，任务层计算卸载同样需要在动态环境中进行自适应决策。由于任务到达过程随机、链路状态时变、节点负载持续波动且多任务并发扰动难以精确解析，传统基于固定规则或静态参数的任务选择方法难以在复杂环境中长期保持稳定性能。因此，联邦学习（Federated Learning, FL）与深度强化学习（Deep Reinforcement Learning, DRL）逐渐成为卫星边缘智能研究中的重要技术路径^[43,48,50]。

联邦学习的核心思想是各参与节点利用本地数据训练模型，仅上传模型参数或梯度进行聚合，而不直接共享原始数据。对于天基网络而言，FL 的价值主要体现在两个方面：其一，星地链路资源宝贵，大规模原始样本汇聚代价高昂，而联邦参数聚合能够显著降低通信负担；其二，不同卫星节点所积累的任务执行轨迹、队列变化、资源利用率和失败样本具有较高价值，若能通过联邦方式整合，有助于提升环境代价模型或状态预测模型的泛化能力^[50]。因此，在本文研究中，联邦学习更适合作为“环境感知模型”的训练机制，而非直接替代在线决策本身。

深度强化学习则通过神经网络逼近策略函数或值函数，使强化学习能够处理高维状态输入和复杂动作映射问题。在任务层计算卸载场景中，DRL 可以根据任务规模、工作量、时延门限、节点负载、链路状态、服务可用性以及并发扰动估计，学习输出长期收益更优的执行位置选择策略^[41,43-44]。相较于传统优化方法，DRL 更适合处理动态环境下的序贯决策问题，尤其适用于卫星网络这种拓扑时变、状态相关性强、解析建模困难的场景。

进一步地，2025–2026 年的研究趋势表明，任务层智能决策正从“经典 DRL”继续向更复杂的数据驱动范式扩展：一类工作引入扩散模型、Lyapunov 优化或图神经网络以增强策略稳定性和约束满足能力^[48]；另一类工作则开始尝试将大模型或语义先验用于任务卸载与资源配置，以降低策略设计复杂度并增强策略泛化性^[38]。这些新进展说明，任务层计算卸载已经从单纯的动作选择问题，演化为环境表征、策略学习与结构先验联合驱动的问题。

从技术关系看，联邦学习与深度强化学习并不是相互替代，而更适合作为“环境感知—策略决策”的组合框架：前者利用多节点历史数据训练环境相关模型，后者利

用当前状态进行在线序贯决策。对本文所研究的任务层问题而言，这种组合既符合天基网络“数据分布分散、环境动态复杂”的特点，也为后续构建基于联邦学习与深度强化学习的分布式卸载方法提供了理论基础。

2.3 系统建模与双层问题描述

在前文场景分析与技术基础之上，本节构建面向天基网络计算卸载的完整数学建模框架，并对双层智能管控问题进行形式化描述，为后续章节的方法设计提供统一的符号体系与问题接口。

2.3.1 系统模型

符号约定与整体架构。除特殊说明外，下标 k 表示任务索引，下标 i, j 表示节点索引， n 表示任意候选执行节点； $\mathcal{N}$ 表示系统节点集合， $\mathcal{M}(t)$ 表示时刻 t 的任务集合， $\mathcal{L}(t)$ 表示时刻 t 的链路集合； T 与 E 分别表示时延与能耗相关量， $\mathcal{S}$ 与 Π 分别表示系统状态与决策策略。

本文考虑由卫星终端、卫星边缘节点与地面控制中心共同构成的天基网络协同计算系统，定义节点集合为

$$\mathcal{N} = \mathcal{N}_S \cup \mathcal{N}_E \cup \{n_{CC}\}, \quad (2.1)$$

其中 $\mathcal{N}_S$ 、 $\mathcal{N}_E$ 分别表示终端节点集合与卫星边缘节点集合， n_{CC} 表示地面控制中心。由于低轨卫星持续运动，将系统在时刻 t 的拓扑抽象为动态图

$$\mathcal{G}(t) = (\mathcal{N}, \mathcal{L}(t)), \quad (2.2)$$

以统一刻画节点连通关系与资源状态的时变演化。

节点计算资源与服务状态。设节点 n 的标称处理能力为 $f_n^{\max}$ ，时刻 t 的资源占用率为 $\rho_n(t) \in [0, 1)$ ，则当前可分配的有效算力为

$$f_n(t) = (1 - \rho_n(t)) f_n^{\max}. \quad (2.3)$$

考虑到并非所有卫星在任意时刻均部署有目标服务，引入服务可用状态变量 $\sigma_n^{(r)}(t) \in \{0, 1\}$ ，其中 $\sigma_n^{(r)}(t) = 1$ 表示节点 n 在时刻 t 已部署任务类型 r 所需的服务实例。该变量显式刻画了系统层服务部署与任务层卸载之间的耦合：即便节点算力充足，若目标

服务未就绪，仍需承担服务拉起、迁移或远端转发的额外代价^[39,42]。

链路模型与可见性约束。定义节点 n_i 与 n_j 在时刻 t 的可见性变量为

$$\phi_{ij}(t) = \begin{cases} 1, & \text{若两节点在时刻 } t \text{ 可建立有效通信链路} \\ 0, & \text{否则.} \end{cases} \quad (2.4)$$

在链路可见的前提下，记节点间可用带宽为 $B_{ij}(t)$ ，传播时延为 $D_{ij}^{\text{prop}}(t)$ ，链路剩余可见窗口为 $\tau_{ij}(t)$ 。其中 $\tau_{ij}(t)$ 构成卸载可行性的硬约束：若任务在窗口内无法完成数据交互，则该链路对应的卸载动作应从候选集中剔除。链路状态因此既决定通信代价，也直接界定可行动作空间。

2.3.2 任务模型与代价建模

任务属性定义。设时刻 t 的任务集合为 $\mathcal{M}(t) = \{m_1, \dots, m_{M(t)}\}$ 。对任一任务 m_k ，定义其属性六元组为

$$m_k = (L_k, W_k, T_k^{\max}, p_k, s_k, r_k), \quad (2.5)$$

其中 L_k 为输入数据量， W_k 为计算工作量， $T_k^{\max}$ 为最大可容忍时延， p_k 为调度优先级， s_k 为源节点， r_k 为服务依赖类型。该六元组从通信、计算、QoS 与服务依赖四个维度统一刻画了任务特征，并通过 r_k 与系统层服务状态 $\sigma_n^{(r)}(t)$ 建立直接关联。

卸载决策变量。本文考虑本地执行、卸载至卫星边缘节点以及卸载至地面控制中心三种执行方式，引入统一决策变量

$$x_k \in \{0\} \cup \mathcal{N}_E \cup \{n_{\text{CC}}\}, \quad (2.6)$$

其中 $x_k = 0$ 表示本地执行， $x_k = e_j$ 表示卸载至边缘节点 e_j ， $x_k = n_{\text{CC}}$ 表示卸载至地面中心。若任务存在服务依赖，则 $x_k = e_j$ 时还需满足 $\sigma_{e_j}^{(r_k)}(t) = 1$ ，否则将产生额外部署或转发代价。

通信时延模型。任务 m_k 从源节点 s_k 上传至目标节点 n_j 的传输时延为

$$T_{s_k, j}^{\text{trans}}(k, t) = \frac{L_k}{B_{s_k, j}(t)} + D_{s_k, j}^{\text{prop}}(t), \quad (2.7)$$

结果回传时延为

$$T_{j, s_k}^{\text{back}}(k, t) = \frac{L_k^{\text{out}}}{B_{j, s_k}(t)} + D_{j, s_k}^{\text{prop}}(t). \quad (2.8)$$

对于跨星转发场景，以端到端等效带宽 $\hat{B}_{s_k j}(t)$ 和等效传播时延 $\hat{D}_{s_k j}^{\text{prop}}(t)$ 替代多跳展开，保持表达式结构统一。此外，链路窗口硬约束要求

$$\frac{L_k}{B_{s_k j}(t)} \leq \tau_{s_k j}(t), \quad (2.9)$$

否则该链路在当前时刻不构成可行卸载路径。

计算时延模型。不考虑并发干扰时，任务 m_k 在节点 n 上的基础执行时延为

$$T_{n, \text{base}}^{\text{exec}}(k) = \frac{W_k}{f_n(t)}. \quad (2.10)$$

实际场景中，排队积压、CPU 争用、缓存冲突和调度扰动会导致执行时延偏离基础值。考虑到星上资源受限、任务异构且调度策略多样，直接采用封闭排队解析模型（如 M/G/1 队列）往往难以准确刻画实际波动，且会将建模过早绑定于强分布假设。因此，本文将上述多种并发干扰的综合影响统一抽象为附加时延项 $\Delta_n(k, t)$ ，实际执行时延写为

$$\tilde{T}_n^{\text{exec}}(k, t) = T_{n, \text{base}}^{\text{exec}}(k) + \Delta_n(k, t), \quad (2.11)$$

其中 $\Delta_n(k, t) \geq 0$ 是依赖节点实时状态与并发任务集合的随机量，可由历史样本估计并通过联邦学习感知，为后续“代价建模—策略决策”耦合框架预留接口^[46-47]。综合三种执行模式，端到端总时延统一表示为

$$T_k^{\text{total}} = \begin{cases} \tilde{T}_{s_k}^{\text{exec}}(k, t), & x_k = 0, \\ T_{s_k, e_j}^{\text{trans}}(k, t) + \tilde{T}_{e_j}^{\text{exec}}(k, t) + T_{e_j, s_k}^{\text{back}}(k, t), & x_k = e_j, \\ T_{s_k, n_{\text{CC}}}^{\text{trans}}(k, t) + \tilde{T}_{n_{\text{CC}}}^{\text{exec}}(k, t) + T_{n_{\text{CC}}, s_k}^{\text{back}}(k, t), & x_k = n_{\text{CC}}. \end{cases} \quad (2.12)$$

能耗模型。能耗从任务发起终端的视角衡量。本地执行时，计算能耗为

$$E_n^{\text{comp}}(k) = \kappa_n W_k (f_n(t))^2, \quad (2.13)$$

其中 κ_n 为单位计算能耗系数。选择卸载时，终端承担上传传输能耗

$$E_{ij}^{\text{trans}}(k, t) = P_{ij}^{\text{tx}} \cdot T_{ij}^{\text{trans}}(k, t), \quad (2.14)$$

以及等待结果回传期间的空闲监听能耗

$$E_{s_k}^{\text{idle}}(k, t) = P_{s_k}^{\text{idle}} \cdot \left(\tilde{T}_n^{\text{exec}}(k, t) + T_{n, s_k}^{\text{back}}(k, t) \right). \quad (2.15)$$

综合两者，任务总能耗为

$$E_k^{\text{total}} = \begin{cases} E_{s_k}^{\text{comp}}(k), & x_k = 0, \\ E_{s_k, e_j}^{\text{trans}}(k, t) + E_{s_k}^{\text{idle}}(k, t), & x_k = e_j, \\ E_{s_k, n_{\text{CC}}}^{\text{trans}}(k, t) + E_{s_k}^{\text{idle}}(k, t), & x_k = n_{\text{CC}}. \end{cases} \quad (2.16)$$

本地执行能耗随算力需求非线性增长（正比于 f_n^2 ），而卸载执行能耗主要由传输与等待时长决定，与链路条件和目标节点负载紧密耦合，两类代价结构的本质差异为后续策略对比提供了统一基准。

2.3.3 双层智能管控问题形式化描述

系统层资源协同问题。系统层以全局视角运行，目标不是最小化单一任务的瞬时代价，而是在动态拓扑与异构资源约束下持续提升资源利用效率、负载均衡水平和服务稳定性。将时刻 t 的全局状态记为

$$\mathcal{S}^{\text{sys}}(t) = \{\rho_n(t), f_n(t), \sigma_n^{(r)}(t), \phi_{ij}(t), B_{ij}(t), Q_n(t)\}, \quad (2.17)$$

以 $U(t)$ 、 $L(t)$ 、 $R(t)$ 分别表示资源利用率、负载均衡度和系统稳定性，系统层优化目标为

$$\max_{\Pi_{\text{sys}}} \mathbb{E} \left[\sum_t (\lambda_1 U(t) + \lambda_2 L(t) + \lambda_3 R(t)) \right], \quad (2.18)$$

其中 $\lambda_1, \lambda_2, \lambda_3$ 为权重系数。该问题本质上是一个面向长期收益的动态协同优化问题，适合采用多智能体强化学习与两时间尺度优化框架求解^[39,42,47]。

任务层计算卸载问题。任务层聚焦于单任务在给定环境下的实时执行位置选择，目标是在满足 QoS 约束的前提下降低综合代价。定义任务 m_k 的观测状态为

$$\mathcal{S}_k^{\text{task}}(t) = \{L_k, W_k, T_k^{\text{max}}, p_k, r_k, \mathcal{C}_k(t)\}, \quad (2.19)$$

其中 $\mathcal{C}_k(t) = \{f_n(t), \sigma_n^{(r_k)}(t), \phi_{s_k n}(t), B_{s_k n}(t), Q_n(t)\}_{n \in \mathcal{N}_E \cup \{n_{\text{CC}}\}}$ 为当前所有候选节点的环境上下文。任务综合代价函数为

$$J_k = \omega_T \cdot \frac{T_k^{\text{total}}}{T_k^{\text{max}}} + \omega_E \cdot \frac{E_k^{\text{total}}}{E_k^{\text{budget}}}, \quad (2.20)$$

任务层目标即为在动态环境中学习策略 Π_{task} ，使长期平均综合代价最低。

统一优化目标与约束条件。综合两层，本文研究问题的统一形式为

$$\min_{\Pi_{\text{sys}}, \Pi_{\text{task}}} \eta_1 \mathcal{J}_{\text{sys}} + \eta_2 \sum_{m_k \in \mathcal{M}(t)} J_k, \quad (2.21)$$

其中 η_1, η_2 为两层目标权重。该问题需满足以下约束：

1. 卸载可行性约束： $x_k \in \{0\} \cup \mathcal{N}_E \cup \{n_{\text{CC}}\}$;
2. 链路可达性约束：卸载至节点 n_j 时需满足 $\phi_{s_k j}(t) = 1$;
3. 服务可用性约束：卸载至边缘节点 e_j 时需满足 $\sigma_{e_j}^{(r_k)}(t) = 1$ ，或额外计入服务部署/迁移代价，该约束将系统层服务状态直接耦合至任务层可行动作集合；
4. 计算资源容量约束： $\sum_{m_k \in \mathcal{M}_n(t)} f_{n,k}(t) \leq f_n^{\text{max}}$;
5. 链路带宽约束： $\sum_{m_k \in \mathcal{M}_{ij}(t)} b_{ij}^{(k)}(t) \leq B_{ij}(t)$;
6. 任务时延约束： $T_k^{\text{total}} \leq T_k^{\text{max}}$;
7. 任务能耗约束： $E_k^{\text{total}} \leq E_k^{\text{budget}}$ 。

上述约束从动作合法性、物理可达性、服务依赖、资源容量与 QoS 五个层面共同界定了问题的可行解空间。

两层问题的关联关系。系统层与任务层在时间尺度上存在差异——前者关注秒级至分钟级的长期资源演化，后者关注毫秒级的即时任务决策——但两者通过双向耦合形成闭环。一方面，系统层通过资源分布、服务部署和负载均衡塑造任务层的决策环境：系统运行稳定时，任务层更易选到优质执行节点；反之，若服务部署滞后或节点过载，任务层的局部最优选择也可能因目标节点不可用而退化。另一方面，任务层的每次卸载动作均会改变节点负载与链路占用，这些局部行为在时间上累积后反过来重塑系统层的资源格局，例如大量终端集中卸载至同一卫星会诱发热点并触发服务重部署^[39,42]。由此，两层之间形成如下反馈闭环：

$$\mathcal{S}^{\text{sys}}(t) \rightarrow \mathcal{S}_k^{\text{task}}(t) \rightarrow x_k \rightarrow \mathcal{S}^{\text{sys}}(t+1). \quad (2.22)$$

这一结构决定了两层既不能完全解耦，也不宜合并为单一超大规模问题，而应通过分层协作的智能管控架构兼顾全局长期收益与局部即时性能。本文后续章节将沿此逻辑分别展开系统层与任务层的方法研究。

2.4 本章小结

本章围绕天基网络计算卸载问题，系统构建了关键技术基础、系统模型与问题描述框架。首先，从 NTN、OEC 和卫星边缘智能的发展趋势出发，分析了低轨卫星协同计算环境下的动态拓扑、异构节点与资源受限特征，明确了天基网络正在由“通信支撑平台”向“通算智融合平台”演进^[30-31,33]。其次，围绕计算卸载、轨道边缘计算、可信状态同步、多智能体强化学习以及联邦学习与深度强化学习等关键技术，梳理了本文后续方法设计所依赖的理论基础，并结合 2024–2026 年代表性研究归纳了当前研究主线与趋势^[39,42-43,46,50]。

在此基础上，本章建立了系统模型、任务模型以及通信时延、计算时延（含并发附加扰动）、终端能耗等代价模型，并将研究问题形式化为由系统层资源协同与任务层计算卸载共同构成的双层智能管控问题。通过明确约束条件的物理意义和两层问题的反馈闭环结构，本章清晰揭示了该问题由通信、计算、服务部署与资源竞争多维耦合的本质特征，为第三章的系统层协同优化方法和第四章的任务层分布式卸载策略提供了统一的问题描述基础与数学建模接口。

3 基于区块链与多智能体强化学习的天基计算网络协同资源分配方法

随着天基计算网络的规模化部署，分布式资源协同调度已成为支撑在轨实时任务处理的核心瓶颈。在无全局中心协调者的去中心化环境中，异构计算节点受自身效用最大化的理性决策驱动，往往倾向于争抢高价值任务、回避低收益负载，进而引发“单节点最优、系统全局劣化”的公地悲剧困境。这一困境在节点能力高度异构、任务到达过程非平稳、星间链路带宽受限等多维复杂性的耦合叠加下进一步加剧，导致传统集中式优化方法与简单启发式策略均难以有效适配。

针对上述挑战，本章将系统层协同资源分配问题建模为多智能体马尔可夫博弈，在理论上刻画节点间竞争—合作并存的交互结构，并提出一种区块链增强的集中训练—分散执行（Centralized Training and Decentralized Execution, CTDE）多智能体强化学习框架。该框架以联盟链作为“公共博弈信息板”，在保障去中心化自治的同时，实现全局状态的可信共享与策略审计；在奖励机制层面，设计融合任务完成质量、系统公平性与信誉激励的三维混合奖励函数，引导自利节点在纳什均衡方向上趋近社会最优。本章通过多场景仿真实验，从收敛性、负载均衡、任务完成率及抗自私攻击能力等维度验证所提方法的有效性与鲁棒性，为后续章节中服务层与任务层的协同优化奠定系统层基础。与近年来卫星边缘计算中的多智能体卸载研究相比，本章更强调“可信共享 + 博弈求解 + 信誉治理”的统一闭环^[1-3]。

3.1 引言

随着低轨卫星互联网、在轨智能处理与星间协同计算的发展，天基计算网络正在从“以通信为主”的基础设施演化为“通信、计算、存储、智能处理一体化”的分布式服务平台。不同轨道层、不同载荷能力以及不同链路条件的卫星节点，通过时变星间链路构成动态互联的在轨计算网络，共同承担遥感影像预处理、目标检测、轨道态势分析、数据压缩转发、任务规划等多类任务。与传统“先回传、后处理”的地面中心化模式相比，这种在轨协同处理方式能够显著降低原始数据的大规模回传压力，缩短任务响应路径，并提高系统在时敏型任务下的自主运行能力。因此，系统是否能够对异构节点进行高效、可信、持续的协同资源分配，已成为影响网络整体服务能力的

关键基础问题。

然而，天基计算网络与地面云边协同系统相比存在更加突出的资源受限性和环境不确定性。首先，卫星节点的计算能力、可用存储、剩余能量和热控条件天然受限，无法简单通过横向扩容方式缓解局部过载；其次，星间链路的建立与维持高度依赖可见关系、轨道位置和瞬时拥塞状态，导致网络拓扑和通信条件持续变化；再次，任务负载并非平稳到达，不同类型任务在计算量、数据规模和时延约束上差异显著，突发重型任务常常会在短时间内形成局部瓶颈。也就是说，天基协同资源分配并不是一个静态的资源映射问题，而是一个伴随任务到达、资源消耗、链路波动和节点行为演化不断变化的连续序贯决策问题。

更为重要的是，该问题通常发生在缺乏长期稳定全局协调者的去中心化环境中。任一节点只能直接掌握本地高频状态，而对远端节点的任务队列、资源占用、信誉水平和协作意愿，通常只能通过有限的公共摘要进行间接感知。在这种条件下，节点天然会优先追求本地效用最大化，例如优先保障本地高价值任务、拒绝低收益协作、选择性接纳外部卸载任务，甚至通过策略性上报影响任务流向。由此带来的后果是：能力强节点被高收益任务持续吸引而逐渐拥塞，能力弱节点则因为处理效率低或协作收益不足而长期闲置，最终诱发“局部理性—全局失衡”的公地悲剧。可见，第三章要解决的核心矛盾，并不只是“如何更快地做调度”，而是“如何在去中心化、自利行为和信信息不完全共存条件下维持持续协同”。

现有研究在面对这一类问题时，往往存在三方面不足。第一类方法依赖集中式全局优化，假设系统能够实时收集所有节点的完整状态，并据此统一求解全局最优调度策略。这类方法在小规模、静态网络中具有一定理论优势，但在天基网络中往往面临状态同步代价高、链路时延大、全局视图易过期等现实障碍。第二类方法采用启发式或局部规则进行分布式调度，其优点是实现简单、开销较低，但由于缺乏对多节点长期博弈关系和系统级公平性的统一刻画，通常只能在局部场景下取得较好的即时效果。第三类方法引入强化学习进行自适应策略求解，但若仍以单智能体视角建模，便会把其他节点的策略变化等价为环境扰动，难以准确表达多主体之间“策略—环境”双向耦合的本质。

因此，要有效解决天基协同资源分配问题，至少需要回答三个层面的研究问题：其一，如何以统一的动态博弈模型刻画多个异构节点之间兼具竞争与合作特征的长期交互关系；其二，在缺乏中心协调者的条件下，如何使节点获得可信且可审计的系统

级上下文，避免完全依赖不可靠的私有感知；其三，如何设计兼顾任务处理效率、全局公平性与长期协作意愿的激励机制，使节点在追求自身长期回报的同时逐步逼近系统总体更优的协同状态。这三个问题分别对应“建模”“共享”“治理”三个层面，也是本章方法设计的主线。

基于上述认识，本章提出一种区块链增强的集中训练—分散执行多智能体强化学习框架 BC-CTDE-MAPPO。其核心思想是：以联盟链作为系统级可信公共信息板，实现全局状态摘要、信誉信息与策略行为的可验证共享；以多智能体马尔可夫博弈统一刻画异构节点之间的竞争—合作关系；以集中训练—分散执行机制支持训练阶段的全局价值评估和执行阶段的局部自治决策；并通过混合奖励设计把任务完成质量、系统公平性和信誉激励耦合进同一学习闭环，从而在不依赖中心调度器的条件下，引导自利节点逐步收敛到更接近系统最优的协同策略。与现有仅强调“提高吞吐量”或“降低时延”的调度方法相比，本章更强调“可信共享 + 博弈求解 + 信誉治理”的统一闭环，这也是它与后续服务层、任务层优化章节之间的重要衔接点。

从全文结构来看，第三章承担的是“系统层协同基础”的角色。后续章节中，无论是服务级协同还是任务级实时卸载，都需要建立在一个能够稳定共享状态、约束自利行为、维持长期负载均衡的系统层机制之上。因此，本章并不直接关注单个任务在微观时间尺度上的最优执行，而是从更宏观的系统层角度，回答“多个理性节点如何在长期运行中形成可信协同关系”这一更基础的问题。只有这一层机制成立，后续章节中的更细粒度卸载、预测和调度方法才具备可落地的运行前提。

图 3.1 从资源流向和节点负载状态两个角度刻画了天基协同资源分配中的局部自利与全局协同差异。图左侧表示缺乏可信协调机制时的局部自利竞争场景。由于各节点主要依据自身收益进行任务选择，高收益任务 $H1$ 、 $H2$ 会吸引大量资源请求集中流向少数强节点，导致强节点队列快速堆积并形成热点拥塞；与此同时，部分弱节点或中等能力节点因任务收益较低、协作价值难以体现而长期处于低利用或闲置状态。该过程说明，在异构节点和非均匀任务收益并存的条件下，单个节点的理性选择并不必然带来系统层面的最优资源配置，反而可能造成“强节点过载、弱节点闲置、系统负载失衡”的局部最优陷阱。

图右侧给出了引入可信共享与协同激励后的全局协同分配效果。此时，高收益任务与普通任务不再简单流向局部收益最高的节点，而是依据联盟链公共信息板中维护的全局平均负载、负载方差、任务分布摘要、信誉评分向量和链路统计信息进行综合

天基协同资源分配中局部自利与全局协同差异示意




图 3.1 天基协同资源分配中局部自利与全局协同差异示意

分配。公共信息板在图中起到系统级上下文聚合与广播的作用，使各节点能够在局部观测之外感知整体负载状态和协作关系；同时，信誉激励机制将节点的历史协作行为反馈到后续收益中，使诚实上报、合理接收外部任务和参与负载分担的节点获得长期正向激励。由此，任务流在多个异构节点之间形成更均衡的分布，系统表现出负载更均衡、任务完成率更高和长期协同更稳定的特征。因此，图 3.1 并非仅用于展示两种调度结果的差异，而是用于引出本章的核心问题：如何在去中心化、信息不完全和节点自利行为并存的天基计算网络中，通过可信共享和激励约束抑制局部自利导致的全局失衡。

本章后续内容按照“系统框架—博弈建模—算法求解—实验验证”的逻辑展开。第 3.2 节首先给出系统参与者、联盟链公共信息板与协同流程的整体框架；第 3.3 节在此基础上建立多智能体马尔可夫博弈模型；第 3.4 节介绍区块链增强的 CTDE 多智能体强化学习求解方法；第 3.5 节通过多场景仿真实验验证所提方法在收敛性、负载均衡、任务完成率及抗自私行为方面的有效性；最后在第 3.6 节进行本章总结。

3.2 系统框架概述

为使后续建模与算法推导建立在清晰一致的系统图景之上，本节首先从系统组成、信息流转和协同目标三个方面，对本章所研究的天基协同资源分配框架进行概述。相较于直接进入公式化建模，这种“先框架、后抽象”的展开方式，更有助于说明各类状态、动作、奖励与联盟链要素在系统中的实际来源与功能定位。

3.2.1 系统组成与角色划分

本章考虑的天基计算网络由四类核心参与者共同构成：执行在轨任务的异构计算节点、负责状态记账与摘要广播的联盟链节点、承担本地调度与协同决策的智能体模块，以及在训练阶段负责全局价值评估的集中式训练协调器。四者既分工明确，又通过任务流、状态流与信誉流形成紧密耦合。

第一类参与者是**异构计算节点**。它们分布在不同轨道层和不同星座拓扑位置上，具备差异化的计算、存储、能量和通信能力，是在轨任务执行的直接承担者。对系统而言，每个节点既可能处理本地生成的任务，也可能接收其他节点卸载而来的任务，因此天然兼具“任务生产者”和“任务处理者”双重身份。

第二类参与者是**联盟链节点**。它们共同维护系统级公共摘要，包括节点负载、信

誉评分、链路统计与历史行为记录等信息。联盟链并不替代实时调度器，而是充当“可信公共信息板”：一方面为各节点提供可审计、可验证、可追溯的系统级上下文；另一方面通过链上信誉累积和行为留痕机制，为后续的激励约束提供可信依据。

第三类参与者是**局部决策智能体**。每个计算节点内部均部署一个策略模块，依据本地私有状态与链上公共摘要联合决定任务是否本地执行、向哪个邻居卸载、投入多少本地资源以及是否接收外部任务。由于执行阶段无法依赖中心控制器，各节点必须具备在部分可观测条件下独立做出近实时决策的能力。

第四类参与者是**集中训练协调器**。它只在训练阶段存在，用于整合联合状态和联合动作，对多智能体策略进行价值评估与参数更新；在实际执行阶段，各节点仅保留各自的局部 Actor 网络，实现分散执行。这样的结构兼顾了训练阶段的信息利用效率与执行阶段的去中心化自治要求。

图 3.2 给出了本章所提出协同资源分配框架的层次结构与信息流转关系。图中最上层为任务与资源环境层，包含动态任务到达、异构节点资源、时变链路拓扑和执行结果反馈等要素，反映了天基计算网络中任务负载、节点资源和通信条件随时间共同演化的系统事实。其中，动态任务到达对应不同类型任务的持续输入，异构节点资源刻画 CPU、内存、能量和队列等节点能力差异，时变链路拓扑体现星间可见关系与链路质量变化，执行结果反馈则为后续奖励计算和信誉更新提供依据。

中间层为联盟链公共信息板层，负责对来自环境侧和节点侧的状态摘要进行聚合、存证与广播。该层并不承担实时中心调度器的角色，而是提供可信公共上下文，包括全局平均负载、负载方差、任务分布摘要、信誉评分向量、链同步时延估计和吞吐统计等低维摘要信息。通过该设计，系统避免了在链上直接存储高维原始任务数据，同时又保留了多智能体协同决策所需的关键状态信息。图中从环境层指向公共信息板的箭头表示状态摘要、任务结果和链路统计的上链过程，从公共信息板指向局部智能体的箭头表示可信公共摘要和信誉信息的广播过程。

底层为局部智能体决策层。每个卫星节点内部部署一个 Actor 策略网络，其输入由本地私有状态 l_t^i 和链上公共摘要 g_t 共同构成，即 $o_t^i = (l_t^i, g_t)$ 。智能体据此输出混合动作 a_t^i ，包括卸载目标选择、资源分配比例和外部任务接收意愿。图右侧的集中训练调度器表示训练阶段的全局价值评估过程：系统将多个节点的轨迹信息汇聚为联合状态，输入集中式 Critic 进行价值估计，并通过 GAE 和 PPO 更新 Actor/Critic 参数。需要强调的是，该集中训练模块只在训练阶段使用联合信息；在实际执行阶段，各节点




图 3.2 第三章协同资源分配框架的层次结构与信息流

仅依赖本地观测和链上摘要进行分散决策。因此，图 3.2 集中体现了本章方法“链上可信共享、节点局部自治、训练阶段集中评估、执行阶段分散决策”的总体结构。

3.2.2 联盟链公共信息板与协同流程

在上述系统组成基础上，本章将协同资源分配过程组织为一个持续循环的闭环流程。不同于传统中心调度模式中“中心收集全局状态—中心下发动作”的单向控制链条，本章方法强调由联盟链维持公共上下文，由节点完成局部决策，再将执行反馈重新写回系统，从而实现可信共享与自主协同的统一。

具体而言，该协同流程可以概括为以下五个步骤。首先，**任务到达与本地感知**：当节点感知到新任务到达时，实时更新本地队列长度、CPU/内存利用率、剩余能量和当前工作负载等高频状态。其次，**链上摘要获取**：节点从联盟链读取全局平均负载、负载方差、链路统计、信誉评分和链上时延估计等低频但可信的公共摘要，用以补充局部感知中难以直接获得的系统级信息。再次，**局部协同决策**：策略网络基于“本地私有状态+链上公共摘要”输出卸载目标、资源分配比例和接收意愿等动作，并作用于当前节点。随后，**执行反馈与信誉更新**：动作执行后，系统会获得任务完成情况、平均时延、能耗、负载变化和协作质量等反馈，并据此更新节点信誉和系统负载摘要。最后，**链上记账与参数迭代**：联盟链将关键行为结果与信誉变化写入账本，在训练阶段进一步服务于全局价值评估和参数更新，在执行阶段则为下一轮协同决策提供新的可信上下文。

上述协同流程强调了三个关键闭环：一是“任务到达—局部决策—执行反馈”的任务闭环，决定了系统的实时响应能力；二是“状态汇总—链上广播—节点读取”的信息闭环，决定了多节点之间能否在缺乏中心调度器的情况下获得统一的协同上下文；三是“协作行为—信誉变化—后续激励”的治理闭环，决定了系统能否对长期自利与机会主义偏离形成可持续约束。三者共同构成了本章后续博弈建模与强化学习求解的系统基础。

3.2.3 建模目标与协同难点

在上述框架下，本章关注的核心问题可以概括为：当任务持续动态到达系统后，多个异构节点如何在不依赖中心调度器的条件下，联合决定任务由谁处理、何时处理、是否接纳外部卸载以及投入多少本地资源，使系统整体在任务完成率、平均时延、能耗开销、负载均衡和协同可信性之间取得更优平衡。换言之，本章研究的不是静态任

务指派问题，而是一个随任务流、资源状态、链路关系和信誉轨迹不断演化的多主体序贯决策问题。

这一问题之所以困难，主要来自四类耦合难点。其一是**资源异构与收益非一致性**：相同任务在不同节点上的执行代价、完成收益和机会成本并不相同，局部最优动作往往会诱导全局失衡。其二是**任务到达与链路状态的时变性**：任务负载具有突发与长尾特征，链路可用性则随轨道位置和拥塞条件动态变化，使得调度策略必须具备在线适应能力。其三是**可信共享信息的时效性约束**：联盟链提供了可验证的系统级上下文，但链上信息同步本身存在时延，节点决策必须同时考虑“信息可信”与“信息陈旧”两种因素。其四是**自利行为与长期治理问题**：节点会根据局部收益结构动态调整行为，若缺少信誉约束和公共审计机制，系统容易重新滑向任务热点聚集与协作退化。

因此，从方法论角度看，后续建模必须同时满足三点要求：一是能够刻画多节点之间“策略—环境”双向耦合的动态交互；二是能够把联盟链提供的可信公共摘要纳入状态建模与激励设计；三是能够在训练阶段充分利用联合信息、在执行阶段保持局部自治。基于这一认识，下一节将进一步把上述系统框架形式化为多智能体马尔可夫博弈模型，并为后续的区块链增强 CTDE 求解方法奠定数学基础。

3.3 基于多智能体马尔可夫博弈的协同资源分配模型

第 3.2 节已经从系统组成、联盟链公共信息板与任务—状态—信誉闭环流程三个方面，建立了本章方法的整体框架，并指出该问题的核心困难不仅在于组合优化层面的计算压力，更在于多个理性决策主体在信息不对称、利益冲突和长期收益耦合条件下的策略交互。由此可见，若仅依赖集中式全局优化方法，虽然理论上能够给出某种最优解，但其对全局信息实时可获取性的要求与天基网络固有的去中心化约束形成根本矛盾；若采用单智能体马尔可夫决策过程（MDP），又会将其他节点的策略变化等价地视为环境扰动，从而无法刻画多节点之间“策略—环境”双向耦合的本质。因此，本文选择以多智能体马尔可夫博弈（Multi-Agent Markov Game, MAMG）作为系统层协同资源分配的统一建模框架，并在此基础上进一步引入区块链公共信息板与信誉驱动机制，使抽象博弈模型能够在去中心化场景中落地执行。

3.3.1 建模动机与博弈形式化

在将协同资源分配问题映射到数学框架之前，有必要首先说明为何采用马尔可夫博弈而非标准形式博弈或重复博弈。标准形式博弈仅适用于一次性策略选择，无法表达资源状态随时间演化的序贯特征；重复博弈虽考虑多轮交互，但默认每一轮都在相同阶段博弈上重复进行，并不显式刻画系统状态随联合动作变化而转移的机制。然而，在天基计算网络中，任何一次任务卸载决策都会改变后续时刻的队列长度、资源占用率、链路可用性与信誉演化轨迹，即当前动作会通过状态转移持续影响未来收益。因此，该问题本质上是一个多主体、序贯式、状态相关的动态博弈问题。

基于上述认识，本文将 N 个异构边缘计算节点的协同调度问题形式化为如下七元组：

$$\mathcal{G} = \langle N, S, \{A^i\}, P, \{R^i\}, \gamma, \{O^i\} \rangle, \quad (3.1)$$

其中， N 表示智能体集合， S 表示全局状态空间， A^i 表示节点 i 的动作空间， P 表示联合状态转移函数， R^i 表示节点 i 的即时奖励函数， $\gamma \in [0, 1)$ 为折扣因子， O^i 表示局部观测函数。

需要特别指出的是，天基计算网络并不满足完全信息博弈假设。受限于星间链路的间歇连通性、有限带宽和状态同步代价，任何单个节点都不可能实时获得所有远端节点的完整原始状态。因此，本文将该问题进一步建模为部分可观测的多智能体马尔可夫博弈。对节点 i 而言，其在时刻 t 的观测表示为

$$o_t^i = O^i(s_t), \quad (3.2)$$

其中 s_t 表示时刻 t 的全局状态， o_t^i 属于节点 i 的局部观测空间 Ω^i 。相应地，每个节点维护一个随机化策略 $\pi^i : \Omega^i \rightarrow \Delta(A^i)$ ，并以最大化期望累积折扣回报为目标：

$$J^i(\pi^i, \pi^{-i}) = \mathbb{E} \left[\sum_t \gamma^t R^i(s_t, a_t^i, a_t^{-i}, s_{t+1}) \mid \pi^i, \pi^{-i} \right], \quad (3.3)$$

这里 π^{-i} 表示除节点 i 之外其余所有节点的联合策略。上述目标函数表明，节点 i 的收益不仅取决于自身策略，还显式依赖于其他节点的策略组合，这也是单智能体强化学习框架难以直接适配该问题的根本原因。

图 3.3 展示了本文从天基协同资源分配问题到多智能体马尔可夫博弈模型的建模推导路径。图中第一部分概括了原始系统问题的四类关键特征：动态任务到达、节点

图3-3 从系统优化问题到多智能体马尔可夫博弈的建模推导路径




图 3.3 从系统优化问题到多智能体马尔可夫博弈的建模推导路径

资源异构、星间链路时变以及去中心化自治。这些特征共同决定了该问题不能被简单处理为静态任务指派问题，而应被视为一个随任务流、资源占用、链路状态和节点行为持续变化的序贯决策问题。

第二部分进一步提炼出该问题的博弈特征。节点在选择是否接收任务、是否卸载任务以及如何分配资源时，既存在对高收益任务和有限资源的竞争关系，也存在通过协同卸载与资源共享提升系统整体效率的合作关系。同时，由于各节点只能获得本地状态和链上摘要，系统还具有部分可观测性；由于当前动作会影响后续队列、能耗、链路占用和信誉状态，系统具有明显的长期序贯决策特征。上述因素说明，标准形式博弈难以表达状态演化，重复博弈难以刻画动作引起的状态转移，单智能体 MDP 又无法描述多个节点策略之间的相互影响，因此需要采用多智能体马尔可夫博弈进行统一建模。

第三部分给出了博弈模型选择逻辑。图中将标准形式博弈、重复博弈与多智能体马尔可夫博弈进行对比，强调 MAMG 能够同时刻画多主体交互、动态状态转移、序贯决策和策略耦合关系。第四部分则将系统要素映射为 MAMG 七元组 $G = \langle N, S, \{A_i\}, P, \{R_i\}, \gamma, \{O_i\} \rangle$ ：其中 N 对应异构卫星节点集合， S 对应全局系

统状态, A_i 对应节点 i 的混合动作空间, P 对应任务与资源驱动的状态转移, R_i 对应融合效率、公平与信誉的奖励函数, γ 表示长期回报折扣因子, O_i 表示节点的局部观测函数。图右侧进一步给出了建模结果在状态、动作和奖励三个层面的落地形式, 即观测 $o_t^i = (l_t^i, g_t)$ 、动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ 以及混合奖励 $r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i$ 。因此, 图 3.3 的作用是将前述系统问题形式化为后续强化学习求解所需的数学对象。

3.3.2 状态、动作与奖励机制设计

在明确了博弈形式之后, 接下来需要回答一个更具体的问题: 节点究竟基于什么信息决策、能够采取哪些行动, 以及系统希望通过何种奖励塑形引导节点从个体理性走向集体理性。对此, 本文分别从状态空间、动作空间和奖励机制三个层面进行设计。

首先, 在状态空间设计上, 需要在“信息充分性”和“维度可控性”之间取得平衡。若观测过于贫乏, 节点将因缺乏必要上下文而难以形成有效策略; 但若直接纳入过多原始任务级信息, 又会导致状态维度膨胀, 增加训练难度与通信开销。为此, 本文将节点 i 在时刻 t 的观测结构化为“本地私有状态 + 链上公共摘要”两部分:

$$o_t^i = (l_t^i, g_t), \quad (3.4)$$

其中, 本地私有状态 l_t^i 由节点自行采集, 表示为

$$l_t^i = (Q_t^i, \rho_{\text{cpu}}^i(t), \rho_{\text{mem}}^i(t), E_t^i, h_i, w_t^i), \quad (3.5)$$

这里 Q_t^i 为本地队列长度, $\rho_{\text{cpu}}^i(t)$ 和 $\rho_{\text{mem}}^i(t)$ 分别为 CPU 与内存利用率, E_t^i 表示剩余能量预算或累计能耗, h_i 为节点静态硬件特征向量, w_t^i 概括当前工作负载信息。另一方面, 链上公共摘要 g_t 由联盟链周期性聚合并广播, 表示为

$$g_t = (\bar{L}_t, \sigma_L^2(t), D_t^{\text{task}}, R_t^{\text{rep}}, \hat{D}_{\text{chain}}(t), T_t^{\text{stat}}), \quad (3.6)$$

其中 $\bar{L}_t$ 表示全局平均负载, $\sigma_L^2(t)$ 表示负载方差, D_t^{task} 为任务分布摘要, R_t^{rep} 为信誉评分向量, $\hat{D}_{\text{chain}}(t)$ 为链上同步延迟估计, T_t^{stat} 为吞吐量统计摘要。

值得注意的是, R_t^{rep} 为信誉约束提供了可信输入, 而 $\hat{D}_{\text{chain}}(t)$ 的显式纳入使节点能够感知当前信息时效性, 并在策略中对链上同步滞后进行自适应补偿。

其次, 在动作空间设计上, 原始调度决策天然包含离散与连续两类分量: 节点既要决定任务是本地执行还是卸载给哪个邻居, 也要决定本地资源分配比例以及是否愿意接收外部任务。若直接将“逐任务优先级向量”作为动作输出, 其维度会随队列长

表 3.1 链上公共摘要分量说明

分量	名称	说明
$\bar{L}_t$	全局平均负载	所有节点队列长度的加权均值，反映系统整体繁忙程度
$\sigma_L^2(t)$	负载方差	各节点负载的离散程度，衡量系统均衡性
D_t^{task}	任务分布摘要	各类型任务在网络中的分布统计，用于感知业务结构变化
R_t^{rep}	信誉评分向量	各节点的链上信誉评分，反映历史行为质量
$\hat{D}_{\text{chain}}(t)$	链上延迟估计	共识与数据同步的当前延迟估计值，用于补偿信息滞后
T_t^{stat}	吞吐量统计	近期各节点及系统整体吞吐量的滑动统计，用于辅助协同判断

度变化，不利于神经网络策略表示与训练稳定性。因此，本文采用固定维混合动作表示：

$$a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i), \quad (3.7)$$

其中 $a_{\text{off},t}^i$ 表示卸载目标选择， $a_{\text{res},t}^i \in [0, 1]$ 表示本地资源分配比例， $a_{\text{acc},t}^i \in [0, 1]$ 表示接收外部任务的意愿系数。对于本地队列内部的细粒度排序，本文不再将其直接作为策略网络输出，而是通过一个基于任务时延约束、计算量和信誉补偿的规则化排序器在节点本地生成。这样既能保持 Actor 输出维度固定，又实现了“高层学协同、低层做排序”的结构化解耦。

最后，在奖励机制设计上，若仅以本地吞吐或完成收益作为奖励，节点策略将自然倾向于争抢高价值任务并规避低收益协作，从而重演前文所分析的公地悲剧。为此，本文构建融合效率、公平与可信性的三维混合奖励函数：

$$r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i, \quad (3.8)$$

其中 $w_q, w_f, w_c \geq 0$ 且 $w_q + w_f + w_c = 1$ 。效率项用于刻画节点自身任务处理质量，可写为

$$r_{q,t}^i = \alpha_1 \text{Succ}_t^i - \alpha_2 \text{Delay}_t^i - \alpha_3 \text{Energy}_t^i, \quad (3.9)$$

其中 Succ_t^i 为成功完成任务数, Delay_t^i 为平均完成时延, Energy_t^i 为单位时间能耗。公平项用于引导系统整体负载均衡, 本文采用基于 Jain 公平指数的全局度量^[18]:

$$J_t = \frac{(\sum_i x_i(t))^2}{N \sum_i x_i^2(t)}, \quad (3.10)$$

其中 $x_i(t)$ 表示节点 i 的有效服务率或负载承担量, 进而定义

$$r_{f,t}^i = J_t - \beta \max \{0, \rho_i(t) - \rho_{\text{th}}\}. \quad (3.11)$$

可信性项则将节点历史行为纳入激励闭环:

$$r_{c,t}^i = \gamma_1 \Delta \text{Rep}_i(t) - \gamma_2 \delta_i(t), \quad (3.12)$$

其中 $\Delta \text{Rep}_i(t)$ 表示信誉增量, $\delta_i(t)$ 表示负载偏差度。诚实上报与积极协同的节点将获得正向激励, 虚报状态和拒绝协作的节点则受到惩罚。

表 3.2 奖励权重与作用说明

权重	对应项	核心作用	默认值
w_q	效率项 r_q	保证任务完成率、时延与能耗三者的局部效率优化	0.5
w_f	公平项 r_f	抑制热点拥塞, 提升系统负载均衡与长期稳定性	0.3
w_c	可信项 r_c	将信誉增量与负载偏差反馈到策略更新中, 约束欺骗行为	0.2

3.3.3 约束条件与性质分析

作为一个面向真实天基计算网络的协同调度模型, 上述博弈并非在抽象无限制环境中运行, 而必须满足物理资源约束与通信可行性约束。对任意节点 i 而言, 首先有基本的本地资源约束:

$$0 \leq a_{\text{res},t}^i \leq 1, \quad (3.13)$$

$$C_i^{\text{used}}(t) \leq C_i^{\text{max}}, \quad B_i^{\text{used}}(t) \leq B_i^{\text{max}}, \quad E_i^{\text{used}}(t) \leq E_i^{\text{cap}}, \quad (3.14)$$

其中 $C_i^{\text{used}}(t)$ 、 $B_i^{\text{used}}(t)$ 、 $E_i^{\text{used}}(t)$ 分别表示时刻 t 的计算资源占用、带宽占用和能量消耗。当节点选择执行卸载动作时, 相应任务的数据传输量还必须满足链路带宽预算和可见窗口约束。本文在环境层通过动作可行性检查与不可行动作惩罚共同保证策略学

习始终发生在物理可行域内。

在满足上述约束的前提下，还需要讨论模型在理论上的可解释性。需要说明的是，原始问题同时包含离散卸载选择与连续资源比例控制，严格意义上的全局均衡求解较为困难。因此，本文并不试图对原始离散—连续混合博弈给出过强的解析结论，而是在混合策略和连续松弛意义下给出两个性质说明。

定理 3.1（连续松弛下的均衡存在性） 在各智能体采用混合策略、奖励函数对联合策略连续，且连续动作空间为非空紧凸集的条件下，所构造的松弛博弈至少存在一个混合策略纳什均衡^[19]。

该结论可由 Glicksberg 不动点定理得到。需要强调的是，这里讨论的是连续松弛后的策略博弈，其意义在于说明本文设计的奖励结构与策略表示不会破坏均衡存在性，而非声称原始混合动作博弈在所有条件下都可直接解析求解。

定理 3.2（局部稳定性说明） 若在某一局部邻域内，联合策略更新可近似表示为对某个光滑潜在函数的上升过程，且学习率足够小，则策略迭代在该邻域内具有局部稳定性。

该性质为后续采用 MAPPO 求解提供理论直觉：通过将公平项与信誉项嵌入奖励函数，不同节点的局部优化方向在一定程度上得到对齐，从而减弱了纯竞争博弈中常见的剧烈震荡现象。这里给出的并非严格的全局收敛证明，而是对训练稳定性来源的性质解释。

在上述状态、动作、奖励与约束设计的基础上，本节已经回答了“系统希望节点依据什么信息决策、能够采取哪些行动、以及为何通过混合奖励塑形来抑制公地悲剧”这三个核心问题。换言之，第 3.3 节完成的是**问题求解对象的数学抽象**：它把第 3.2 节中的系统角色、链上公共摘要与信誉治理机制统一映射为一个部分可观测、多主体、序贯式的动态博弈模型，并说明了该模型在物理可行域内的基本性质。

但仅有建模仍不足以直接落地到天基网络的在线协同决策。原因在于：第一，联合状态与联合动作维度随节点数量增长而迅速膨胀；第二，Actor 在执行阶段只能访问局部观测与链上摘要，不能依赖训练期的全局信息；第三，链上公共信息板虽然提供了可信共享与审计能力，但其时延、更新周期和信誉回写机制必须被纳入具体的学习与执行流程，才能真正转化为策略性能增益。因此，下一节将从“如何求解”而非“如何建模”的角度出发，把上述马尔可夫博弈进一步映射为区块链增强的集中训练—分散执行多智能体强化学习框架，并说明策略参数更新、链上共享、信誉反馈和在

线部署之间的耦合关系。

3.4 区块链增强的多智能体协同资源分配算法设计

上一节从系统约束、局部观测、混合动作和三维奖励塑形四个方面完成了协同资源分配问题的博弈建模，但这仍停留在“优化目标与交互结构已被定义”的层面。要使该模型真正用于天基网络在线运行，还需要进一步解决两个实现性问题：其一，在多节点联合策略持续变化的条件下，如何缓解多智能体学习中的环境非平稳性；其二，链上公共摘要与信誉反馈如何嵌入参数更新与在线执行过程，而不是停留在建模假设中。基于此，本节从求解层面对第 3.3 节的博弈模型进行算法化实现，构建区块链增强的集中训练—分散执行多智能体强化学习框架 BC-CTDE-MAPPO。

该框架的核心思想是：在训练阶段，利用联合状态近似表示、链上公共摘要与全局回报信号构造集中式 Critic，以降低多智能体环境中的策略漂移；在执行阶段，各节点仅保留本地私有状态与联盟链广播的可信摘要作为决策输入，维持去中心化自治；同时，链上公共信息板不仅提供系统级上下文，还承担信誉更新、行为审计与异常约束的反馈通道，使“可信共享—策略优化—治理回写”三者形成统一闭环。按照这一思路，本节依次介绍区块链共享与信誉反馈机制、算法总体框架、混合动作策略与参数更新机制，以及训练—执行一体化流程。

3.4.1 区块链共享与信誉反馈机制

在给出博弈模型及其内部要素之后，还需要进一步回答一个关键的实现性问题：在缺乏中心协调者的天基网络中，支撑公平项、信誉项和全局负载统计的公共状态信息究竟从何而来？若各节点只能依赖局部观测，则上述共享信息无法稳定获得；若人为引入中心汇聚节点，又会违背去中心化约束，并带来单点故障与数据篡改风险。为此，本文引入联盟链作为“公共博弈信息板”，使节点能够在无需绝对信任彼此的前提下共享经验证的系统级摘要信息。为了提高许可链环境下的工程可实现性，本文采用轻量级联盟链架构，并参考 Hyperledger Fabric 等许可链系统中“成员管理 + 摘要共享 + 审计可追溯”的设计思想^[20]。

设节点上报交易经本地验证后进入待共识池，则某次公共状态写入的总延迟可近似表示为

$$D_{\text{chain}}(t) = D_{\text{consensus}}(t) + D_{\text{broadcast}}(t) + D_{\text{verify}}(t), \quad (3.15)$$

其中 $D_{\text{consensus}}(t)$ 为子链或主链共识延迟, $D_{\text{broadcast}}(t)$ 为区块广播传播延迟, $D_{\text{verify}}(t)$ 为本地验证与状态解析延迟。默认实验中账本同步平均附加延迟设为 1.0 s, 并在敏感性分析中扩展到 0.5–3.0 s 的范围。

为使链上数据能够直接服务于博弈观测与合约执行, 本文将区块载荷划分为五类记录: 资源状态记录块、任务摘要记录块、信誉更新记录块、策略审计记录块以及子链聚合摘要块。通过上述字段设计, 链上账本既保留了博弈求解所需的最小充分统计量, 又避免直接存储高维原始任务数据, 从而控制了存储与传输开销。




图 3.4 分层联盟链与公共信息板职责示意

图 3.4 进一步说明了联盟链在本章方法中的功能定位和分层职责。图上方表示异构节点与链上数据源, 每个节点持续产生资源状态、任务事件、局部执行结果和行为审计记录等信息。这些信息并不直接进入中心调度器, 而是通过状态与事件上报机制写入分层联盟链结构, 从而形成可验证、可追溯的公共状态来源。

图中部展示了联盟链的两级结构。子链采用较短更新周期, 主要面向任务事件流和局部资源状态的快速记录, 承担任务开始/结束事件记录、资源状态摘要记录、局部行为审计记录和局部可信摘要广播等职责。其特点是更新频率高、面向局部调度, 适合承载快时标的任务与状态信息。主链采用较长更新周期, 主要承担节点身份管理、

信誉锚定与累积、治理规则维护以及跨子链监管和全局审计等职责。其特点是更新频率较低，但具有更强的系统级治理属性和全局可信约束能力。图中子链与主链之间的双向箭头表示：一方面，子链将局部任务和资源摘要聚合后上链到主链；另一方面，主链将治理规则、信誉约束和审计结果下发到各子链，形成跨层协同治理机制。

图下方的联盟链公共信息板是面向智能体决策的摘要输出层，主要提供全局平均负载 $\bar{L}_t$ 、负载方差 $\sigma_L^2(t)$ 、任务分布摘要 D_t^{task} 、信誉评分向量 R_t^{rep} 、链上延迟估计 $\hat{D}_{\text{chain}}(t)$ 和吞吐量统计 T_t^{stat} 等公共上下文。该公共信息板并不直接替代智能体进行调度决策，而是为各节点提供统一、可信、不可随意篡改的状态摘要，使节点能够在部分可观测条件下获得系统级协同依据。图中智能合约治理模块则用于异常识别、一致性检查、信誉扣奖、权限更新和策略审计，并将审计结果反馈给公共信息板和节点策略。由此可见，图 3.4 强调的是：联盟链在本文中不是简单的数据存储模块，而是连接状态共享、行为审计和信誉治理的可信公共信息基础设施。

表 3.3 分层联盟链职责划分

层级 / 模块	主要职责	更新周期	主要服务对象
主链 / 资源审计链	身份管理、信誉锚定、治理规则与跨链监管	慢时标	监管与系统层策略更新
子链 / 任务指令链	任务开始/结束事件、资源摘要、局部审计	快时标	节点侧调度与局部反馈
公共信息板聚合层	输出全局平均负载、负载方差、任务分布与信誉向量	中时标	多智能体协同决策
智能合约	执行异常识别、信誉扣奖、策略审计与权限更新	事件驱动	系统治理与行为约束

在信誉机制方面，本文采用“链上记录 + 合约审计 + 奖励回写”的闭环方式。对节点 i ，其信誉值 $\text{Rep}_i(t)$ 随诚实性、协同贡献与异常惩罚动态演化。若节点长期夸大繁忙程度、拒收外部任务或低报负载吸引高收益业务，则审计合约会根据链上任务事件与资源摘要的一致性检查结果触发信誉惩戒，并将惩罚结果回写到后续奖励中。这意味着区块链在本文中的作用不应被简单理解为“天然提升性能”，而应理解为：它为可信共享、行为审计与中长期激励执行提供统一机制，使系统在面对自私与欺骗行为时具备可持续协同的条件。




图 3.5 信誉驱动的状态—动作—审计—反馈闭环

图 3.5 刻画了节点信誉值在协同资源分配过程中的动态演化机制。图中心的 $\text{Reputation}_i(t)$ 表示节点 i 在时刻 t 的链上信誉状态，它不是静态标签，而是由节点长期行为、任务执行质量、协同贡献和链上审计结果共同决定的动态变量。信誉值一方面作为链上公共摘要的一部分进入节点观测，影响后续任务分配和协同优先级；另一方面又通过奖励函数中的可信性项反馈到策略更新过程，从而形成长期激励约束。

图中外圈按照时间顺序描述了信誉闭环的六个阶段。第一阶段为状态观测，节点根据本地资源状态、链上公共摘要和历史信誉信息形成当前观测。第二阶段为动作决策，节点决定是否接收任务、本地执行或卸载、资源比例分配以及状态上报方式。第三阶段为行为执行，系统记录任务处理结果、协同贡献、负载承担情况和上报行为。第四阶段为链上审计，智能合约依据任务事件、资源摘要和执行记录进行一致性检查，识别异常行为、虚假上报、拒收协作或恶意卸载等偏离行为。第五阶段为信誉更新，诚实协同、稳定贡献和有效负载分担将提升节点信誉，而虚报状态、拒绝协作和异常偏差将触发信誉惩罚。第六阶段为奖励回写，信誉变化进入可信性奖励项，并进一步影响后续任务分配、协同优先级和策略学习方向。

图中绿色箭头表示正向协同循环，即节点通过诚实协作提升信誉，进而获得更高协同优先级和长期收益；红色箭头表示负向惩罚循环，即节点的虚报或拒收行为经链上审计识别后引发信誉扣减，进而降低其后续协作机会和策略收益。该机制的关键作用在于，将一次性的任务收益扩展为跨时间的长期行为约束，使自利节点在最大化长期回报时必须考虑信誉损失和未来协作机会。因此，图 3.5 说明了本文奖励函数中可信性项 $r_{c,t}^i$ 的机制来源，也解释了联盟链如何从“可信记录工具”进一步转化为“协同治理工具”。

以上内容回答了“链上信息从哪里来、如何进入策略、以及信誉如何反向作用于奖励与治理”三个问题，为算法层面的设计奠定了基础。下面进一步介绍算法总体框架和参数更新机制。

3.4.2 算法总体框架

设节点 i 的 Actor 参数为 θ_i ，共享 Critic 参数为 ϕ 。在时刻 t ，节点首先从本地环境与联盟链中读取观测 $o_t^i = (l_t^i, g_t)$ ，然后按照当前策略采样混合动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ 。环境执行联合动作 $a_t = (a_t^1, \dots, a_t^N)$ 后，更新任务队列、链路状态、能耗状态与信誉中间量，并将新的链上摘要写入公共信息板。随后，系统依据

式 (3.8) 定义的三维奖励函数计算各节点即时回报 r_t^i ，并将交互轨迹存入 rollout 缓冲区。一个 rollout 周期结束后，集中训练模块基于联合轨迹估计优势函数并更新 Actor/Critic 参数。

其中，集中式 Critic 的输入为全局状态近似表示

$$s_t^{\text{ctr}} = (l_t^1, \dots, l_t^N, g_t), \quad (3.16)$$

输出价值估计 $V_\phi(s_t^{\text{ctr}})$ 。考虑到天基网络拓扑随时间动态变化，本文在状态编码阶段引入图结构聚合器，用于对邻接节点状态和链路关系进行表征学习。这样，一方面能够避免简单拼接带来的维度膨胀，另一方面也使价值网络具备对拓扑动态变化的敏感性。




图 3.6 BC-CTDE-MAPPO 总体流程图

图 3.6 给出了 BC-CTDE-MAPPO 的训练—执行一体化流程。该图按照时间顺序将在线执行阶段和集中训练阶段划分为八个步骤，并通过颜色区分系统状态、动作执行、奖励计算和训练优化等不同功能模块。左侧为在线执行阶段，其目标是在无中心调度器参与的情况下完成节点局部决策和环境交互；右侧为集中训练阶段，其目标是利用联合轨迹和全局价值评估对多智能体策略进行稳定更新。

在在线执行阶段，步骤 1 表示观测获取。每个节点首先读取本地私有状态 l_t^i 和链上公共摘要 g_t ，形成局部观测 $o_t^i = (l_t^i, g_t)$ 。其中，本地私有状态反映节点自身队列、资源、能量和工作负载等高频信息，链上公共摘要反映全局负载、任务分布、信誉评分和链路统计等低频可信信息。步骤 2 表示局部 Actor 决策。节点基于观测输入策略网络 π_{θ_i} ，输出混合动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ ，分别对应卸载目标选择、资源控制和外部任务接收意愿。步骤 3 表示环境执行联合动作。多个节点的动作共同作用于任务队列、资源占用、链路状态和能耗状态，从而推动系统状态由 t 时刻转移到 $t+1$ 时

刻。

步骤 4 表示链上更新与可信摘要广播。环境执行结果经联盟链记录后，资源摘要、任务摘要、审计记录和信誉中间量被写入链上，并生成下一时刻公共摘要 g_{t+1} 。步骤 5 表示奖励计算与 rollout 缓存。系统根据任务完成质量、负载公平性和信誉变化计算混合奖励 $r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i$ ，并将 $(o_t^i, a_t^i, r_t^i, o_{t+1}^i)$ 等交互数据保存到 rollout buffer 中。需要指出的是，该缓存用于 on-policy 轨迹收集，而不是离线经验回放池；每轮参数更新完成后，旧轨迹将被丢弃，以满足 MAPPO 的训练设定。

右侧的步骤 6 至步骤 8 对应集中训练阶段。步骤 6 中，集中式 Critic 接收由各节点局部状态与链上摘要构成的联合状态 $s_t^{\text{ctr}} = (l_t^1, \dots, l_t^N, g_t)$ ，并输出价值估计 $V_\phi(s_t^{\text{ctr}})$ 。该设计使训练阶段能够利用全局状态信息缓解多智能体策略共同变化导致的环境非平稳性。步骤 7 通过 GAE 计算优势函数 $\hat{A}_t^i$ ，将即时奖励、下一状态价值和当前状态价值结合起来，估计各节点动作相对于当前策略的改进方向。步骤 8 采用 PPO 裁剪目标对 Actor 和 Critic 参数进行多轮小批量更新，避免策略更新幅度过大造成训练震荡。更新完成后，各节点仅部署更新后的局部 Actor 参数 θ_i ，在下一轮执行中继续依据本地观测和链上摘要进行分散决策。由此，图 3.6 完整展示了本文方法如何将联盟链可信共享、信誉反馈、集中式价值评估和分散式局部执行整合为统一的闭环算法流程。

上述总体框架强调的是“谁在什么阶段使用哪些信息完成何种功能”：集中式 Critic 负责在训练阶段吸收联合状态与联合动作中的耦合信息，局部 Actor 负责在执行阶段依据“本地观测 + 链上摘要”完成自治决策，而联盟链则持续提供可信上下文与行为留痕。接下来，本文进一步说明这一框架在参数层面如何被具体实现，即混合动作策略如何表示、优势函数如何构造，以及 Actor / Critic 如何在破坏去中心化执行约束的前提下完成稳定更新。

3.4.3 参数化策略与更新机制

由于动作同时包含离散卸载选择与连续资源控制两类分量，本文采用混合参数化 Actor。具体而言，对离散动作 $a_{\text{off},t}^i$ 输出 categorical 分布，对连续动作 $a_{\text{res},t}^i$ 和 $a_{\text{acc},t}^i$ 输出高斯分布参数，其联合策略可写为

$$\pi_\theta^i(a_t^i | o_t^i) = \pi_{\theta,d}^i(a_{\text{off},t}^i | o_t^i) \cdot \pi_{\theta,c}^i(a_{\text{res},t}^i, a_{\text{acc},t}^i | o_t^i). \quad (3.17)$$

其中连续分量经 **sigmoid** 映射后投影到 $[0, 1]$ 区间，以保证动作满足物理可行性约束。为了增强探索能力，训练初期在连续分量上保留较高的熵正则项，随后随训练过程逐步衰减。

在参数更新方面，本文沿用 **PPO** 的裁剪目标^[4-5,51]。对节点 i 定义策略比值

$$\rho_t^i(\theta_i) = \frac{\pi_{\theta_i}(a_t^i | o_t^i)}{\pi_{\theta_i^{\text{old}}}(a_t^i | o_t^i)}, \quad (3.18)$$

则其裁剪目标函数为

$$L_i^{\text{clip}}(\theta_i) = \mathbb{E}_t \left[\min \left(\rho_t^i(\theta_i) \hat{A}_t^i, \text{clip}(\rho_t^i(\theta_i), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^i \right) \right], \quad (3.19)$$

其中 $\hat{A}_t^i$ 为优势估计。本文采用广义优势估计（**GAE**）构造该项：

$$\hat{A}_t^i = \sum_{l=0}^{T-1} (\gamma \lambda)^l \delta_{t+l}^i, \quad \delta_t^i = r_t^i + \gamma V_\phi(s_{t+1}^{\text{ctr}}) - V_\phi(s_t^{\text{ctr}}). \quad (3.20)$$

Critic 则通过最小化时序差分误差进行更新：

$$L_V(\phi) = \mathbb{E}_t \left[\left(V_\phi(s_t^{\text{ctr}}) - \hat{V}_t \right)^2 \right]. \quad (3.21)$$

需要强调的是，本文方法属于严格的 **on-policy** 学习流程。也就是说，系统采用“采样一批 rollout → 计算优势 → 多轮小批量更新 → 丢弃旧轨迹”的训练方式，而不使用大规模经验回放池，从而与 **MAPPO** 的理论设定保持一致。

基于此，最后需要将 **Actor** 采样、环境交互、链上更新和集中式参数优化组织成统一的时间序列流程。为此，下面给出 **BC-CTDE-MAPPO** 的训练与在线执行伪代码，用于完整描述本章方法的落地过程。

3.4.4 训练与执行算法流程

为进一步明确算法执行顺序，本文将 **BC-CTDE-MAPPO** 的训练与在线部署过程整理为算法 1。该算法体现了“链上信息更新—环境状态转移—策略参数优化”三者并行耦合的特点：链上公共信息板为每轮决策提供可信上下文，环境根据联合动作更新队列与能耗状态，而集中训练模块则利用全局状态近似表示更新参数。

算法 1 BC-CTDE-MAPPO 协同资源分配算法

Require: 节点集合 N ; 本地观测 $o_t^i = (l_t^i, g_t)$; 奖励权重 (w_q, w_f, w_c) ; 训练轮数 E ; rollout 长度 T

Ensure: 每个节点的协同策略 π_θ^i 与共享价值函数 V_ϕ

```

1: 初始化各节点 Actor 参数  $\theta_i$ 、共享 Critic 参数  $\phi$ 、联盟链账本状态与信誉值  $\text{Rep}_i(0)$ 
2: for  $episode = 1, \dots, E$  do
3:   for  $t = 1, \dots, T$  do
4:     for 每个节点  $i$  do
5:       读取本地私有状态  $l_t^i$  与最新链上公共摘要  $g_t$ , 构造观测  $o_t^i$ 
6:       按策略  $\pi_\theta^i(a_t^i | o_t^i)$  采样混合动作  $a_t^i$ 
7:     end for
8:     环境执行联合动作  $a_t$ , 更新任务队列、链路状态、能耗状态与信誉中间量
9:     联盟链写入资源摘要、任务摘要与审计记录, 生成新的公共状态  $g_{t+1}$ 
10:    按式 (3.8) 计算各节点即时奖励  $r_t^i$ 
11:    将  $\{o_t^i, a_t^i, r_t^i, o_{t+1}^i\}$  存入 rollout 缓冲区
12:   end for
13:   基于联合轨迹计算优势函数  $\hat{A}_t^i$  与目标价值  $\hat{V}_t$ 
14:   多轮小批量优化 Actor 与 Critic, 更新  $\theta_i, \phi$ 
15: end for
16: return 训练完成的  $\pi_\theta^i$  与  $V_\phi$ 

```

3.5 实验设计与结果分析

本节围绕“收敛是否稳定、性能是否全面、规模变化下是否仍然有效、在异常行为下是否足够鲁棒”四个核心问题展开验证。实验分析强调对关键现象的因果解释：即链上可信共享、CTDE 训练机制与信誉约束分别在何种场景下贡献性能增益，以及这些增益是否能够在高负载、强异构与异常节点存在时持续成立。为保证结果的统计可靠性，所有实验均独立运行 5 次，报告均值与标准差。

3.5.1 实验设置、对比基线与评价指标

实验场景中包含 20 个异构卫星计算节点，分布在 3 个轨道层上，系统共考虑 4 类在轨任务（遥感预处理、目标检测、压缩转发与任务规划）。为验证算法在不同业务压力下的适应性，本文将任务到达率 λ 从 0.3 逐步增加至 1.1（单位：task/(slot·node)），训练总回合数为 500，每回合包含 200 个时隙。敏感性实验进一步将节点规模扩展至 20–80 个，以评估算法的可扩展性。

默认采用“子链 + 主链”的分层联盟链结构。子链出块周期设为 1 s，主链聚合周期设为 5 s，账本同步平均附加延迟为 1.0 s。为评估链上时延对策略性能的影响，在敏感性实验中进一步将平均附加延迟扩展至 0.5–3.0 s。信誉机制采用指数平滑更新方式，其中 $\lambda_r = 0.8$ ，诚实性、协同贡献和异常惩罚的系数分别设置为 $\xi_1 = 0.4$ 、 $\xi_2 = 0.3$ 、 $\xi_3 = 0.3$ 。对于存在明显负载虚报行为的节点，当偏差度 δ_i 超过阈值 $\delta_{th} = 0.2$ 时触发

惩罚与限权流程。

本文方法基于 MAPPO 实现，训练配置如下：折扣因子 $\gamma = 0.99$ ，GAE 系数 $\lambda = 0.95$ ，PPO 裁剪系数 $\epsilon = 0.2$ ，Actor 学习率 3×10^{-4} ，Critic 学习率 1×10^{-3} ，策略更新 epoch 数为 10，小批量大小为 256。奖励权重默认设置为 $w_q = 0.5$ 、 $w_f = 0.3$ 、 $w_c = 0.2$ 。为保证对比的完整性，本文选取以下四种基线方法：（1）MAPPO，采用标准集中训练一分散执行框架但不引入区块链与信誉机制；（2）MADDPG，采用集中式 Critic 与确定性策略梯度的多智能体方法；（3）IPPO（Independent PPO），各节点独立训练，不使用集中式 Critic 或公共状态共享；（4）Greedy，基于局部即时收益的启发式调度策略；（5）Random，随机卸载与资源分配策略。此外，在鲁棒性实验中将自私节点比例从 0% 增加至 40%。

表 3.4 仿真实验参数设置

参数	取值	说明
卫星节点数量	20	参与协同资源调度的异构计算节点总数
轨道层数	3	抽象为不同的可见性与链路条件层
任务类型数	4	遥感预处理、目标检测、压缩转发与任务规划
单回合时隙数	200	每个训练回合包含的环境交互步数
训练回合数	500	用于策略优化的总训练回合数
Actor 学习率	3×10^{-4}	局部 Actor 网络学习率
Critic 学习率	1×10^{-3}	集中式 Critic 网络学习率
折扣因子 γ	0.99	长期累计回报折扣因子
GAE 参数 λ	0.95	广义优势估计系数
PPO 裁剪系数	0.2	策略更新裁剪阈值
奖励权重 (w_q, w_f, w_c)	(0.5, 0.3, 0.2)	效率、公平与可信三项奖励权重
链上平均同步时延	1.0 s	默认联盟链同步时延
任务到达率范围	0.3–1.1	单位: task/(slot·node)
自私节点比例范围	0%–40%	用于鲁棒性实验

3.5.2 收敛性分析

首先考察不同方法在训练过程中的收敛性。图 3.7(a) 给出了不同训练算法在 500 回合中的平均回报收敛曲线，其中阴影区域为 5 次独立运行的 $\pm 1\sigma$ 标准差范围，体

现了结果的统计可靠性。可以看出，随着训练回合增加，各算法的平均回报整体呈现逐步上升并最终趋于稳定的趋势。其中，BC-CTDE-MAPPO 在约 200 回合后已进入稳定收敛区间，且最终平均回报 (88.4 ± 2.1) 明显高于其余基线方法，阴影带也最窄，表明训练方差最小；相比之下，MAPPO 的收敛速度略慢（260 回合），MADDPG 与 IPPO 则表现出更明显的波动和更低的稳态回报。这表明，在引入区块链公共信息板和可信激励机制后，智能体在训练阶段能够更充分地利用系统级上下文，从而降低多智能体环境中的非平稳性。

图 3.7(b) 以误差棒形式进一步比较了不同算法的收敛回合数，误差棒大小根据各算法后 50 回合的回报标准差等比缩放，反映各方法收敛的稳定程度。BC-CTDE-MAPPO 的收敛回合最少，仅为 210 回合；MAPPO、MADDPG 和 IPPO 分别需要 260、330 和 360 回合才达到稳定状态。




图 3.7 不同训练算法的收敛性对比

表 3.5 不同训练算法的收敛性统计对比

算法	最终平均回报	收敛回合	后 50 回合回报标准差	$\lambda = 0.9$ 时任务完成率 (%)
BC-CTDE-MAPPO	88.4	210	2.1	92.3
MAPPO	77.6	260	3.4	88.1
MADDPG	70.2	330	4.2	84.2
IPPO	66.8	360	4.8	82.9

结合表 3.5 中的统计结果可知, BC-CTDE-MAPPO 在最终平均回报、收敛速度及后 50 回合回报标准差等指标上均优于对比方法。尤其是在任务到达率 $\lambda = 0.9$ 的场景下, 其任务完成率达到 92.3%, 分别高于 MAPPO 的 88.1% (+4.2pp) 和 MADDPG 的 84.2% (+8.1pp)。这说明所提方法不仅具备更快的收敛速度, 而且在收敛后仍能保持较高的策略稳定性。

从机理上看, 链上可信摘要主要解决“看不清系统”的问题, CTDE-MAPPO 主要解决“学不稳策略”的问题, 而三维奖励则解决“学出来的策略是否愿意协同”的问题。三者缺一不可。若只有公共摘要而没有集中式价值估计, 则策略仍可能在局部探索中震荡; 若只有 MAPPO 而没有可信共享, 则价值函数将长期暴露于陈旧或片面的状态信息; 若缺少公平和信誉激励, 即便训练可以收敛, 也很容易收敛到对局部强节点有利但对系统整体不友好的策略结构。

3.5.3 不同负载水平下的系统性能分析

为考察算法在不同业务压力下的适应能力, 本文进一步比较了各方法在任务到达率 $\lambda \in \{0.3, 0.5, 0.7, 0.9, 1.1\}$ 下的任务完成率、平均任务时延和 Jain 公平指数, 结果如图 3.8 和表 3.6 所示。

从图 3.8(a) 可以看出, 随着任务到达率由 0.3 增加到 1.1, 所有算法的任务完成率均有所下降, 图中误差棒为 5 次独立运行的 $\pm 1\sigma$ 标准差。这是因为系统负载持续增加后, 节点的局部队列长度和资源竞争程度显著提升。然而, BC-CTDE-MAPPO 在整个负载区间内始终保持最优性能, 其任务完成率由 98.2% 下降至 89.1%, 下降幅度 (9.1pp) 明显小于 MAPPO (13.5pp) 和 Greedy (23.6pp)。值得重点关注的是图中以背景色块标注的高负载区间 ($\lambda = 0.9 \sim 1.1$): 低负载时 ($\lambda \leq 0.5$) 所有方法均能维持 90% 以上的完成率, 各方法间差距在 4pp 以内; 而在 $\lambda = 1.1$ 的高负载条件下, BC-CTDE-MAPPO (89.1%) 与 Greedy (70.8%) 相差近 18.3pp, 与 Random (58.9%) 相差逾 30pp, 方法间差距显著拉大。这说明多智能体协同调度与负载均衡机制的核心价值在高竞争场景中才得到充分体现, 低负载环境下各方法的性能差异相对有限。

图 3.8(b) 给出了不同负载水平下的平均任务时延变化趋势, 高负载区间同样以背景色块标注。BC-CTDE-MAPPO 的增长最缓, 在 $\lambda = 0.9$ 和 $\lambda = 1.1$ 时分别仅为 178 ms 和 214 ms, 显著低于 MAPPO (203 ms / 249 ms) 和 MADDPG (228 ms / 278 ms)。这说明所提方法能够通过链上公共摘要感知全局负载状态, 并在协同调度时主动规避

热点节点，从而降低拥塞传播对系统时延的影响。




图 3.8 不同任务到达率下的系统性能对比

表 3.6 不同任务到达率下各算法的 Jain 公平指数

算法	$\lambda = 0.3$	$\lambda = 0.5$	$\lambda = 0.7$	$\lambda = 0.9$	$\lambda = 1.1$
BC-CTDE-MAPPO	0.966	0.951	0.936	0.918	0.897
MAPPO	0.951	0.932	0.904	0.878	0.846
MADDPG	0.943	0.918	0.887	0.853	0.821
Greedy	0.931	0.886	0.843	0.781	0.724
Random	0.881	0.834	0.786	0.731	0.679

除效率指标外，本文还使用 Jain 公平指数评价不同算法的负载均衡能力。表 3.6 表明，BC-CTDE-MAPPO 在各负载水平下均保持最高公平指数。例如，当 $\lambda = 0.9$ 时，其 Jain 公平指数为 0.918，而 MAPPO 和 MADDPG 分别为 0.878 和 0.853，Greedy 与 Random 则仅为 0.781 和 0.731。这说明混合奖励中的公平项能够有效抑制“强节点持续抢占高收益任务”的现象，引导系统逐步形成更均衡的任务分担格局。

3.5.4 规模扩展与参数敏感性分析

为评估方法的可扩展性，本文将节点规模从 20 逐步扩展至 40、60 和 80，并在各规模下重新训练策略。图 3.9(a) 给出了不同网络规模下各算法的任务完成率 ($\lambda = 0.9$)。随着节点规模增大，所有方法的完成率均有所下降，但 BC-CTDE-MAPPO 的下降最缓

(从 92.3% 降至 86.8%，降幅 5.5pp)，而 IPPO 和 Greedy 分别下降了 12.1pp 和 14.3pp。这说明 BC-CTDE-MAPPO 的策略并未过度依赖固定规模下的拓扑结构，而是通过链上公共摘要与图结构建模学习到了更稳定的协同模式。

图 3.9(b) 给出了链上附加时延对任务完成率的影响。当链上附加延迟位于 0.5–2.0 s 区间时，任务完成率下降较为平缓（从 93.1% 降至 90.4%），这表明本文方法对中等程度的信息陈旧具有一定容忍性；但当延迟继续上升至 2.5–3.0 s 后，性能开始显著恶化（降至 85.2%），说明公共摘要一旦过时，策略将难以及时修正热点拥塞。




图 3.9 规模扩展与参数敏感性分析结果

为识别各模块的边际贡献，本文在 $\lambda = 0.9$ 的场景下进一步开展消融实验，结果如图 3.10 与表 3.7 所示。图 3.10(a) 和 (b) 分别展示了各方法变体在任务完成率与 Jain 公平指数上的差异，每个柱子均附有 $\pm 1\sigma$ 误差棒 ($n=5$)，图 3.10(a) 中左侧实色柱为全场景均值，右侧斜线柱为 30% 自私节点场景下的结果，以同时体现效率维度与抗异常维度的贡献。与完整 BC-CTDE-MAPPO 相比，去除区块链公共信息板后，任务完成率由 92.3% 降至 89.1%（全场景 -3.2pp，30% 自私节点下 -6.7pp），说明可信共享的系统级上下文是整套方法的核心增益来源，且在异常节点存在时作用更为关键。去除公平奖励项后，系统的 Jain 公平指数从 0.918 大幅降至 0.842（-0.076），表明公平激励对抑制负载失衡尤为重要。去除可信奖励项后，虽然平均任务时延变化不大，但在 30% 自私节点场景下的任务完成率下降至 84.1%（-5.3pp），反映出信誉约束在抗自私行为中发挥了不可替代的作用。公平项与可信项分别作用于不同维度，缺一不可。




图 3.10 消融实验结果：各模块对任务完成率（含 30% 自私节点场景）与 Jain 公平指数的贡献（误差棒为 $\pm 1\sigma$, $n=5$ ）

表 3.7 消融实验结果（ $\lambda = 0.9$ ，括号内为 $\pm 1\sigma$, $n=5$ ）

方法变体	任务完成率 (%)	平均任务时延 (ms)	Jain 公平指数	30% 自私节点下任务完成率 (%)
完整 BC-CTDE-MAPPO	92.3 $\pm$ 0.8	178	0.918 $\pm$ 0.008	89.4 $\pm$ 1.0
去除区块链公共信息板	89.1 $\pm$ 1.3	194	0.889 $\pm$ 0.013	82.7 $\pm$ 1.6
去除公平奖励项	90.4 $\pm$ 1.0	186	0.842 $\pm$ 0.016	86.5 $\pm$ 1.3
去除可信奖励项	90.8 $\pm$ 1.1	183	0.901 $\pm$ 0.010	84.1 $\pm$ 1.4

从这一组结果可以进一步推断：本文方法的性能提升不是由某一个“万能组件”单独带来，而是由“链上摘要提供全局上下文、公平奖励约束热点行为、信誉机制抑制策略投机、图结构提升多节点关系建模能力”共同构成的系统性增益。

3.5.5 抗自私行为鲁棒性分析

为检验所提方法在非合作环境中的鲁棒性，本文设置不同自私节点比例（0%–40%），并比较各算法的任务完成率与 Jain 公平指数，结果如图 3.11 和表 3.8 所示。

实验中，自私节点的异常行为模型定义如下：节点以概率 $p_s = 0.7$ 拒绝接受来自其他节点的卸载任务（任务拒收），同时以均值 $\mu_f = -0.3$ 的偏移量虚报自身当前负载（虚报负载），在接受任务时优先选择计算量小、收益高的任务（偏好高收益任务）。三类异常行为同时激活，共同模拟机会主义节点在去中心化网络中的典型偏离策略；仿真中通过随机选取一定比例的卫星节点激活上述行为，横轴表示自私节点在总节点中的占比。

从图 3.11(a) 可以看出，随着自私节点比例从 0% 提高到 40%，所有算法的任务完成率均呈下降趋势，图中误差棒为 5 次独立运行的 $\pm 1\sigma$ 标准差。这是因为自私节点倾向于拒绝外部卸载或虚报自身状态，从而削弱系统整体协作效率。然而，BC-CTDE-MAPPO 的性能退化最小，其任务完成率仅由 93.2% 下降至 87.2%（降幅 6.0pp）；相比之下，MAPPO 从 89.6% 下降至 78.4%（降幅 11.2pp），Greedy 和 Random 则下降得更加明显。这表明，所提方法通过区块链的可审计共享和信誉惩罚机制，能够有效缓解自私行为对系统性能的破坏。

图 3.11(b) 显示了不同自私节点比例下的 Jain 公平指数变化情况，同样附有 $\pm 1\sigma$ 误差棒。随着自私节点增多，所有方法的公平指数均有所下降，但 BC-CTDE-MAPPO 始终保持最高水平。例如，在 30% 自私节点条件下，BC-CTDE-MAPPO 的公平指数仍达到 0.886（ ± 0.011 ），而 MAPPO、Greedy 和 Random 分别下降至 0.816、0.722 和 0.659，说明链上信誉机制能够有效抑制自私行为对系统公平性的破坏。这说明所提方法不仅能够在效率层面维持更高的任务完成率，也能够在此类场景下保持更稳定的全局负载均衡。

3.5.6 信誉机制效果分析

为进一步验证信誉机制的治理效果，本文展示了合作节点与自私节点的链上信誉演化过程。在仿真中，合作节点持续诚实上报状态并积极响应协同请求，自私节点则




图 3.11 不同自私节点比例下的系统鲁棒性对比

表 3.8 不同自私节点比例下的鲁棒性对比（任务完成率%）

算法	0%	10%	20%	30%	40%
BC-CTDE-MAPPO	93.2	92.3	90.9	89.4	87.2
MAPPO	89.6	87.2	84.6	81.6	78.4
Greedy	82.1	78.6	74.8	71.1	67.2
Random	68.9	64.1	60.3	55.6	51.9

以一定概率拒收外部任务或虚报负载。实验结果表明，合作节点的信誉值随时间步增加逐渐上升，并最终稳定在 0.90 以上；自私节点的信誉值则从初始值 0.50 持续下降至 0.20 以下。该结果说明，链上信誉反馈机制能够有效区分合作行为与机会主义偏离行为，并将其结果持续回写到后续决策激励中，从而形成“状态感知—策略执行—链上审计—信誉更新”的闭环治理机制。

3.5.7 结果讨论

综合以上结果，可以得到三点核心结论。其一，天基协同资源分配问题的主要难点并不仅在于“如何找一个更优分配”，而在于“如何让多个理性节点在长期演化中持续愿意协同”；因此，相比只优化单步收益的启发式策略，可信共享与信誉约束在长期运行中更重要。其二，区块链在本文中的作用并非简单地提供一个“额外模块”，而是为公共状态共享、行为审计和激励兑现提供了统一执行媒介，使得奖励塑形具备现实落点。其三，本文方法的优势在高负载、强异构和异常节点存在时更加明显，这说明它更适合被理解作为一种“压力场景下优势更突出的系统层协同方法”，而不是仅在轻负载环境下追求微小平均收益提升的局部优化技巧。

3.6 本章小结

本章围绕天基计算网络在去中心化环境下面临的协同资源分配难题，系统研究了从问题分析、博弈建模、可信信息共享到多智能体强化学习求解的完整方法链。首先，从节点异构性、任务非平稳性、链上记账延迟与信誉动态演化四个维度揭示了自利行为导致的公地悲剧困境；其次，将系统层调度问题形式化为部分可观测的多智能体马尔可夫博弈，并设计了固定维混合动作空间与融合效率、公平、可信性的三维奖励函数；随后，引入联盟链作为公共博弈信息板，并通过智能合约实现信誉驱动的自动激励与约束；最后，基于区块链增强的 CTDE-MAPPO 框架实现协同策略学习，并通过多组实验验证了所提方法在收敛稳定性、负载均衡、任务完成率及抗自私攻击能力方面的优势。

本章的核心贡献在于：在保持去中心化结构约束的前提下，提出了一种兼顾可实现性、可信性与系统性能的协同资源分配方法，为后续服务层卸载策略与任务层执行优化提供了统一的系统层决策基础。

4 基于联邦学习与深度强化学习的并发感知任务层计算卸载方法

第三章已经从系统层构建了基于分层联盟链的可信协同资源分配框架，解决了多节点之间的状态共享、信誉约束与全局协调问题；但在真实运行环境中，系统层的“可协同”并不天然等价于任务层的“可高效”。当新的计算任务到达卫星终端（Satellite Terminal, ST）时，节点必须在极短时间内综合本地资源状态、链路质量、候选卫星边缘节点（Satellite Edge Node, SEN）的公共摘要以及潜在并发风险，判断应当本地执行还是卸载到哪个目标节点。若仍采用“候选节点只要当前负载不高就可安全接收任务”的静态假设，便会忽略多任务并发条件下 CPU 时间片、缓存、内存带宽和 I/O 队列竞争所带来的额外性能损失，从而使看似合理的卸载动作在实际执行中出现明显的时延放大和能耗偏差。

围绕上述问题，本章以天基分布式计算系统为研究对象，聚焦多任务并发条件下的任务级卸载决策机制，重点回答以下问题：在链上状态存在时滞、节点数据难以集中共享且样本分布明显异构的条件下，如何有效感知候选节点的并发开销，并将这种感知能力转化为节点侧可实时执行的卸载策略。为此，本文构建了“联邦学习预测 + 深度强化学习决策”的闭环方法：首先利用聚类式联邦学习在不上传原始执行日志的前提下训练并发开销预测模型，以获得对候选节点未来拥塞风险的先验估计；随后将预测结果与本地观测状态、链上公共摘要共同输入深度 Q 网络（Deep Q-Network, DQN）代理，实现节点侧实时、低开销且具备并发感知能力的任务卸载。

从章节组织上看，本章首先阐述研究背景、核心挑战和技术路线；随后给出系统场景、并发开销与任务层代价模型；在此基础上，介绍基于联邦学习的并发开销预测方法及其可信维护机制；接着给出 FL-DQN 卸载决策算法设计、在线执行流程与复杂度分析；最后通过预测精度、端到端性能、鲁棒性和消融实验验证所提方法的有效性。通过上述安排，本章形成了从问题提出、理论建模、算法设计到实验验证的完整论述链条。

从章节贡献角度看，本章的创新点可概括为四个方面：其一，面向多任务并发场景建立任务级并发开销形式化模型，将新任务进入成本与存量任务受扰成本统一纳入建模；其二，构建分层聚类联邦学习框架，在 Non-IID 与隐私受限条件下训练并发开

销预测模型，并结合联盟链完成模型版本可信维护；其三，提出 FL-DQN 卸载决策机制，将并发开销预测值与置信信息显式融入状态空间和奖励函数，使节点侧策略具备并发风险前瞻能力；其四，通过预测层、端到端性能、鲁棒性和消融实验的分层验证，说明所提方法在高并发和链上状态滞后条件下仍具有稳定优势。上述四点共同构成了本章相对于第三章的任务层补充，也使全文形成“系统层可信协同—任务层实时执行”的完整闭环。

4.1 引言

随着在轨试验、遥感预处理、异常事件检测与应急响应等业务不断向天基网络侧延伸，卫星终端不再只是数据采集与转发节点，而逐步演化为具备本地处理与协同计算能力的智能边缘实体。然而，受星载平台体积、功耗、抗辐照设计和载荷预算等因素限制，卫星终端可用计算资源仍然十分有限。当计算密集型、时延敏感型任务持续到达时，仅依赖终端本地执行往往难以同时满足实时性、能耗约束与任务完成质量要求。因此，将任务动态卸载至具备更强处理能力的卫星边缘节点（Satellite Edge Node, SEN），已成为提升天基分布式计算效率的重要途径。

但对天基网络而言，真正困难的并不是“是否存在可卸载节点”，而是“面对动态环境时，节点应当如何做出正确卸载动作”。当一个新任务到达卫星终端（Satellite Terminal, ST）时，终端必须在极短时间内综合任务计算量、输入规模、时延阈值、本地资源余量、链路可达性以及候选节点状态等多维因素，判断应当本地执行，还是卸载到哪一个目标 SEN。与地面有线或稳定无线环境不同，天基网络中的链路带宽、传播时延和可见窗口随轨道运动持续变化，节点状态感知具有天然时滞，因此这一决策问题呈现出显著的动态性、局部性与不完全信息特征。

现有不少任务卸载与资源调度方法默认调度器能够获得候选节点准确、即时且全局一致的运行状态，并在此基础上进行最优动作选择。然而，这种“全局实时透明信息”假设在天基网络环境下通常难以成立。一方面，星间链路传播时延明显，链路窗口有限，节点间状态同步天然存在异步性；另一方面，不同节点的硬件能力、任务组合和负载模式存在显著差异，即便能够周期性交换状态，也难以获得足够细粒度且完全实时的系统全貌。因此，若仍采用依赖完美状态信息的集中式思路，实际部署时往往会面临观测滞后、通信开销高以及模型泛化能力不足等问题。

在上述因素中，并发开销是最容易被低估、却又最直接决定卸载效果的关键变量。

当多个任务在同一候选 SEN 上并发执行时，新任务的进入不仅会延长自身完成时延，还会通过 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队等机制干扰既有任务的推进过程，进而造成整个执行队列的系统级性能退化。也就是说，并发开销并不是附着于新任务本身的单一额外代价，而是同时作用于新任务与存量任务的耦合扰动。如果卸载策略仍主要依据候选节点当前平均负载、瞬时 CPU 利用率或链上静态摘要做出判断，就很容易把任务送往“表面空闲、实际拥挤”的目标节点，最终导致时延放大、能耗增加和拥塞累积。

从全文研究链条来看，第三章重点解决的是系统层面的可信协同问题，即多节点之间如何在联盟链支撑下实现状态共享、信誉约束与资源协调；而本章进一步聚焦于任务层面的实时执行问题，即在既有可信共享基础上，节点如何把链上信息转化为面向当前时刻的可执行动作。两章由此构成从系统层可信协同到任务层快速决策的连续逻辑。需要特别指出的是，联盟链在本章中的角色并不是提供某一时刻绝对精确的瞬时全局状态，而是维护一种可信但非实时的公共摘要：它能够保证候选节点摘要、任务生命周期事件以及模型版本信息的可验证性与一致性，却不能消除传播、确认与同步带来的时滞。因此，节点侧卸载决策不能简单依赖链上信息本身，而必须进一步结合本地观测与风险预测能力。

进一步看，在天基网络中直接沿用传统集中式训练或集中式调度思路并不可行。任务执行日志、运行轨迹和资源利用信息往往携带敏感业务特征，不适合长期集中上传；星间链路带宽有限且可用性随轨道变化波动，持续传输原始样本代价高昂；不同节点又普遍存在明显的 Non-IID 数据分布，使得统一集中模型难以稳定泛化。表 4.1 对集中式思路在本场景中的主要局限进行了总结。

表 4.1 集中式学习在天基网络中的主要局限

问题维度	具体表现	直接影响
数据隐私	任务日志、运行时轨迹及资源占用明细不适合长期集中上传	降低可部署性
通信带宽	星间链路带宽有限，持续传输原始样本代价高	增加训练成本
链路时延	星地/星间传播时延明显，集中同步存在先天滞后	难以在线更新
链路可用性	卫星运动导致链路存在窗口限制和随机中断	影响训练稳定性
数据异构性	不同节点硬件能力、业务形态和负载模式差异显著	集中式模型泛化受限

基于上述约束，本章采用“并发开销预测 + 在线卸载决策”的闭环思路来解决天基任务级卸载问题：首先利用聚类式联邦学习在不上传原始执行日志的前提下训练并发开销预测模型，以学习候选节点在不同任务组合、不同运行背景下的潜在拥塞风险；随后将预测得到的并发开销及其置信信息，与任务特征、本地观测状态和链上公共摘要共同输入深度 Q 网络（Deep Q-Network, DQN）代理，生成节点侧可实时执行的离散卸载动作。之所以采用这种“预测—决策”分层结构，是因为并发开销同时受硬件架构、任务类型和执行上下文影响，用固定解析公式往往难以稳定刻画，而数据驱动的预测模型更适合学习这类复杂耦合关系；与此同时，天基任务卸载的候选动作集合通常有限，基于离散动作空间的 DQN 能够在保持较低在线推理开销的同时，将预测先验有效转化为可部署的决策能力。

据此，本章的总体目标可以概括为：在隐私受限、观测不完全、链上状态存在滞后且负载动态变化的条件下，构建一种能够显式感知并规避并发风险的任务级卸载方法，使节点侧策略在任务完成时延、能耗、吞吐量与负载均衡之间实现更合理的折中。围绕这一目标，本文主要开展以下四方面工作：第一，建立面向节点侧实时决策的任务层代价模型，将时延、能耗与并发开销统一纳入优化框架；第二，设计聚类式联邦学习机制，在 Non-IID 与隐私受限条件下训练并发开销预测模型，并通过联盟链维护模型版本可信性；第三，提出 FL-DQN 卸载决策机制，将并发开销预测值及其不确定性显式融入状态空间和奖励函数设计，使智能体具备并发风险前瞻能力；第四，通过预测层、端到端性能层、鲁棒性与消融实验的分层验证，检验预测先验能否切实转化为节点侧卸载性能提升。

从实现链路看，系统在离线阶段依托历史执行日志构造并发开销监督样本，并完成聚类联邦训练与模型聚合；在在线阶段，每当新任务到达，卫星终端首先提取任务属性并采集本地状态，然后读取链上维护的候选节点公共摘要，调用目标节点所属簇的最新预测模型估计各候选动作的并发开销，最后由 DQN 输出本地执行或目标节点卸载动作。由此形成“后台训练、前台推理、链上维护可信摘要”的运行机制。按照这一逻辑，第 4.2 节将给出系统框架与任务层卸载问题建模，第 4.3 节介绍基于联邦学习的并发开销预测方法，第 4.4 节给出 FL-DQN 卸载决策算法设计，第 4.5 节通过实验验证所提方法的有效性，并在本章结尾完成阶段性总结。

4.2 系统框架与任务层卸载问题建模

本节首先介绍天基分布式计算系统中的任务级卸载场景及综合代价模型，随后围绕并发开销给出形式化建模与工程近似表达，最后构造状态表征并建立任务层卸载问题的 MDP 表达，为后续联邦预测与强化决策提供统一数学基础。

4.2.1 系统组成、工作流程与综合代价模型

本节围绕天基分布式计算环境中的参与者、信息流和任务生命周期展开说明，并在此基础上引入综合代价模型。考虑由若干卫星终端 ST、卫星边缘节点 SEN、联盟链控制平面以及联邦协调单元共同构成的天基计算系统：终端节点负责业务接入、本地状态采样与卸载动作执行；边缘节点负责外部任务的接收、排队和执行；联盟链负责维护候选节点公共摘要、任务生命周期事件及模型版本摘要；联邦协调单元则负责预测模型的簇划分、参数聚合与版本下发。这样的角色划分使本章方法既能继承第三章提供的可信共享能力，又能在节点侧保留足够轻量的实时决策机制。图 4.1 展示了任务级卸载场景下卫星终端、卫星边缘节点、联盟链控制平面与联邦协调单元之间的整体交互关系。系统在离线阶段完成并发开销预测模型的联邦训练与可信维护，在在线阶段完成新任务到达后的状态采样、并发风险估计与节点侧卸载决策。




图 4.1 天基分布式计算系统中的任务级卸载框架与信息交互流程

为了使系统角色更清晰，表 4.2 总结了任务级卸载框架中的主要参与者及其职责。

表 4.2 任务级卸载框架中的角色划分

角色	主要职责
卫星终端 ST	生成新任务、采集本地 CPU/队列/剩余能量状态、读取链上摘要、触发并发开销预测并执行本地/卸载动作
卫星边缘节点 SEN	接收外部任务、维护执行队列、反馈任务完成状态、沉淀历史执行日志并参与联邦训练
联盟链控制平面	维护候选节点公共摘要、任务开始/结束事件、模型版本号与哈希摘要，提供异步非实时全局视图
联邦协调单元	根据负载模式进行簇划分、完成簇内聚合与异常更新筛选、下发最新预测模型
DQN 决策代理	将任务特征、本地状态、链上摘要和预测先验映射为离散卸载动作，并通过经验回放持续优化策略

从任务生命周期看，节点侧卸载决策遵循如下闭环流程：1) 新任务到达后，终端提取计算量、输入规模、时延阈值与优先级等属性；2) 终端同步采样本地资源状态，并从联盟链读取候选节点的公共摘要；3) 调用目标节点所属簇的联邦预测模型，对各候选动作对应的并发开销进行快速估计；4) 将任务特征、本地观测、链上摘要和预测先验拼接为统一状态向量；5) 由 DQN 输出本地执行或目标节点卸载动作；6) 环境返回真实时延、能耗和任务完成结果，并反向写入经验回放池；7) 任务开始/结束事件与模型版本摘要继续在链上更新，构成“决策—执行—反馈—再决策”的闭环。

该流程与图 4.1 中的信息流保持一致，即先由系统级可信共享与联邦维护提供背景支撑，再由节点侧完成面向单任务的实时决策。

对任意时刻到达终端的一个新任务，记其描述为

$$T_i = (C_i, S_i, T_i^{\max}, \tau_i, \zeta_i), \quad (4.1)$$

其中， C_i 表示任务计算量， S_i 表示输入数据大小， $T_i^{\max}$ 为最大可接受完成时延， τ_i 为任务类型编码， ζ_i 为任务优先级。

与第三章的系统层全局建模不同，本章关注的是单任务在到达瞬间面临的局部动作选择。设候选动作集合为

$$\mathcal{A} = \{0, 1, 2, \dots, N_c\}, \quad (4.2)$$

其中，动作 0 表示本地执行，动作 $n \in \{1, \dots, N_c\}$ 表示卸载至第 n 个可达候选边缘节点。节点侧决策需要在一个极短时间窗口内完成，因此策略不仅要追求高质量，还要具备较低的在线推理开销。

为支撑后续奖励函数和评价指标设计，本节先给出单任务在本地执行和边缘卸载两种情形下的时延、能耗模型。

若任务在本地执行，则其完成时延与本地计算能耗分别为

$$L_i^{\text{loc}} = \frac{C_i}{f_i^{\text{loc}}}, \quad (4.3)$$

$$E_i^{\text{loc}} = \kappa_i C_i (f_i^{\text{loc}})^2, \quad (4.4)$$

其中， f_i^{loc} 为终端在当前时刻可分配给该任务的有效计算频率， κ_i 为设备有效电容系数。

若任务卸载到候选边缘节点 n ，则其端到端完成时延可近似分解为上行传输时延、传播时延、边缘执行时延和并发开销四部分，即

$$L_i^{\text{off}}(n) = \frac{S_i}{R_{i,n}^{\text{up}}} + d_{i,n}^{\text{prop}} + \frac{C_i}{F_n} + \Delta(l_i, n), \quad (4.5)$$

其中， $R_{i,n}^{\text{up}}$ 为上行传输速率， $d_{i,n}^{\text{prop}}$ 为传播时延， F_n 为目标节点标称计算能力， $\Delta(l_i, n)$ 为将新任务放置到节点 n 后产生的并发开销。

相应地，卸载能耗可写为

$$E_i^{\text{off}}(n) = P_i^{\text{tx}} \left(\frac{S_i}{R_{i,n}^{\text{up}}} + d_{i,n}^{\text{prop}} \right) + \eta_n \frac{C_i}{F_n}, \quad (4.6)$$

其中， P_i^{tx} 为终端发射功率， η_n 为将目标节点执行能耗折算回任务代价的系数。式 (4.6) 不仅刻画了传输能耗，也保留了边缘侧执行的代价信息，从而避免策略一味追求低时延卸载而忽略系统整体能源消耗。

在进一步建模之前，有必要说明本章变量的来源与适用边界。任务计算量、输入数据规模和优先级来自业务层任务描述；本地 CPU 占用、队列长度和剩余能量由终端实时采样获得；候选节点平均负载、负载方差和版本号等信息来自联盟链维护的公共摘要；执行中任务剩余工作量和上下文切换强度由边缘节点日志离线统计获得，并在联邦训练阶段转化为监督样本。与此同时，式 (4.5) 与式 (4.6) 建立在几个工程假设之上：其一，任务到达可用泊松流或离散事件过程近似；其二，边缘节点在短时间窗内的标称算力变化相对平缓；其三，链上摘要虽然可能存在陈旧性，但版本顺序是可信的。后续实验中的链上滞后敏感性分析，正是对上述假设边界进行专门验证。

4.2.2 并发开销建模

并发开销是本章区别于传统卸载模型的关键变量。设在时刻 t ，目标节点 Θ 上已有一个执行中任务集合 $\{\tau_e\}$ ，新任务 τ_i 被放置到该节点后，系统会因资源争用出现额外时延。借鉴原稿中的定义思路，可将并发开销写为

$$CO(t; \tau_i, \Theta) = [L_i^{\text{conc}}(t) - L_i^{\text{iso}}] + \sum_{e \in \{\tau_e\}} [L_e^{\text{conc}}(t) - L_e^{\text{iso}}], \quad (4.7)$$

其中， L_i^{iso} 和 L_e^{iso} 分别表示任务在资源独占条件下的隔离时延， $L_i^{\text{conc}}(t)$ 和 $L_e^{\text{conc}}(t)$ 则表示在并发环境下的实际时延。该定义同时计入了新任务的进入成本与存量任务的受扰成本，因此更符合节点侧真实的资源竞争机制。

图 4.2 展示了并发开销的形成机理：在无新任务加入时，节点内任务可按既定资源份额相对平稳推进；而当新任务进入后，CPU 时间片、缓存、内存带宽和 I/O 队列等资源竞争会同时拉长新任务与存量任务的完成时延，最终使累计执行进度整体放缓。

并发开销的形成机理与直观示意

$$\text{并发开销} = \text{新任务进入成本} + \text{存量任务受扰成本}$$




图 4.2 并发开销的形成机理与资源争用示意

在工程实现中, 式 (4.7) 所涉及的未来并发时延难以直接获得, 因此还需构造一个可学习、可预测的近似表达。记目标节点当前已有 $k-1$ 个并发任务, 节点总计算能力为 F_n , 任意执行中任务的剩余计算量为 C_e^{rem} , 则可以用平均资源分配假设给出一个工程上常用的近似式:

$$\Delta(l_i, n) \approx \frac{(k-1)C_i}{F_n} + \sum_{e \in T_n^{\text{exec}}} \frac{C_e^{\text{rem}}}{F_n}, \quad (4.8)$$

该表达式揭示了并发开销与新任务计算量、当前并发任务数以及执行中任务剩余工作量之间的正相关关系, 便于在后续样本标注和模型解释中使用。

进一步地, 从统计学习角度可以将并发开销写为

$$CO \approx F_{\text{new}}(\tau_i, \Theta, \text{obs}) + G_{\text{exec}}(\{\tau_e\}, \Theta, \text{obs}) + R, \quad (4.9)$$

其中, $F_{\text{new}}(\cdot)$ 捕获新任务加入带来的瞬时冲击, $G_{\text{exec}}(\cdot)$ 刻画已执行任务间的持续资源竞争, R 表示未建模的高阶耦合残差。该可分解表达虽不直接用于在线推理, 却有助于解释为何联邦模型在轻负载和重负载场景下会表现出不同的误差模式: 前者更依赖新任务特征, 后者更依赖存量任务组合和运行背景。

考虑时延、能耗和并发扰动三类代价, 本章将单任务总代价定义为

$$J_i = \alpha L_i + \beta E_i + \gamma \Delta(l_i), \quad \alpha + \beta + \gamma = 1, \quad (4.10)$$

其中, L_i 为动作执行后的端到端完成时延, E_i 为对应能耗, $\Delta(l_i)$ 表示目标节点上的并发开销。三个权重参数可根据业务偏好灵活调整: 对实时业务可提高 α , 对能源敏感任务可提高 β , 对高拥塞控制场景则可适当增加 γ 。

值得指出的是, 式 (4.10) 的意义并不仅在于给出加权求和目标, 更重要的是为后续 DQN 奖励函数设计提供统一的任务层优化视角。第三章关注的是系统层的全局资源配置, 本章则将优化边界收缩到节点侧单任务决策, 从而在保持整体方法链连贯性的同时, 避免重复求解上一章已经讨论过的系统层全局资源调度问题。

4.2.3 状态表征构造

为了使并发开销能够被机器学习模型预测, 并使 DQN 能够进行可执行的在线决策, 需要构造一个统一的复合状态表征。设可观测特征向量为

$$\mathbf{x} = [\mathbf{x}^{\text{task}}, \mathbf{x}^{\text{local}}, \mathbf{x}^{\text{chain}}, \mathbf{x}^{\text{conc}}], \quad (4.11)$$

其中:

- $\mathbf{x}^{\text{task}}$: 新任务特征, 包括计算量、输入大小、时延阈值、任务类型编码、优先级等;
- $\mathbf{x}^{\text{local}}$: 本地状态, 包括本地 CPU 占用、队列长度、剩余能量、可用频率和链路质量估计等;
- $\mathbf{x}^{\text{chain}}$: 链上公共摘要, 包括候选节点平均负载、负载方差、信誉评分、账本确认延迟估计等;
- $\mathbf{x}^{\text{conc}}$: 并发环境统计, 包括目标节点当前并发任务数、执行中任务总剩余工作量、平均内存占用和上下文切换强度等。

所有连续特征在进入模型前都进行标准化处理, 即

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j + \varepsilon}, \quad (4.12)$$

其中, μ_j 和 σ_j 分别为训练集统计均值和标准差, ε 为数值稳定常数。

需要强调的是, 节点侧状态天然是不完全的: 一方面, 本地节点只能直接观测自身状态, 无法获取其他候选节点的细粒度实时运行轨迹; 另一方面, 链上摘要虽然提供了全网一致视图, 但其时间戳可能早于当前决策时刻。因此, 本章所研究的卸载问

题本质上是在部分可观测、带滞后信息的动态环境下进行的序贯决策问题。引入 FL 预测模块的意义，正是在不可能获得完整实时信息的前提下，用历史数据学习出的风险先验来弥补观测缺口。

4.2.4 任务层卸载问题的马尔可夫决策过程建模

在上述基础上，节点侧任务卸载被建模为马尔可夫决策过程

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle. \quad (4.13)$$

其中：

- 状态空间 $\mathcal{S}$ 由任务特征、本地资源状态、链上公共摘要和 FL 预测值共同组成；
- 动作空间 $\mathcal{A}$ 为“本地执行 + 若干候选 SEN”构成的离散集合；
- 状态转移概率 $\mathcal{P}$ 由任务到达、链路变化、资源占用演化和预测结果更新共同决定；
- 奖励函数 $\mathcal{R}$ 采用总代价负值并叠加轻量奖惩项。

为了便于工程部署，本章选择基于离散动作值函数的 DQN，而没有采用连续动作策略梯度类方法，主要原因有二：其一，本场景的动作集合有限，DQN 推理效率高、实现成本低；其二，本章更希望把模型复杂度预算留给“并发开销预测”这一难点环节，而非在在线阶段引入过于复杂的连续动作网络。

4.3 基于联邦学习的并发开销预测方法

在上一节完成任务层代价建模之后，本节进一步回答“并发开销如何在隐私受限和样本异构条件下被有效学习”这一问题。按照“预测目标—模型结构—联邦训练—可信维护”的链式逻辑，本节首先说明监督样本如何从执行日志中构造，其次给出预测器为什么采用轻量 MLP/1D-CNN 结构，再介绍聚类式联邦训练为何优于统一 FedAvg，最后讨论模型版本如何借助联盟链进行可信维护与在线调用。这样的组织方式与参考章节中“框架概述之后再逐层展开算法设计”的写法保持一致，便于读者把每个模块放回整体系统闭环中理解。

4.3.1 预测目标与样本构造

并发开销预测本质上是一个监督回归问题。其输入为式 (4.11) 定义的多维特征，输出为目标节点在接受新任务后的并发开销估计值 $\widehat{CO}$ 及其置信信息。设节点本地构造的监督样本为

$$\mathcal{D}_k = \{(\mathbf{x}^{(m)}, y^{(m)})\}_{m=1}^{N_k}, \quad (4.14)$$

其中， $y^{(m)}$ 为根据运行日志标注得到的真实并发开销。对于每个样本，需要记录任务到达前后的队列长度、CPU 频率、内存占用、任务开始时间、完成时间、输入大小、计算量等信息，再依照式 (4.7) 或式 (4.8) 计算标签。

为了使预测模型尽可能覆盖多样化的竞争形态，本章沿用原稿中的“双代理负载”的思路：一类是图像处理任务，用于模拟视觉感知类边缘业务；另一类是数值计算任务，用于模拟计算密集但数据规模较小的负载。这种设计的好处在于，既能让模型观察到数据搬移开销与计算开销同时占优的混合场景，又能避免训练集完全偏向单一类型任务而失去泛化性。

4.3.2 预测模型结构设计

考虑到输入特征既包含结构化统计量，也可能包含短时间窗内的序列信息，本章在模型结构上兼容两类实现：

- 1) **MLP 结构**：适用于结构化向量输入。模型通常由 3–5 个全连接隐藏层构成，每层采用 ReLU 激活并可结合 Dropout 抑制过拟合；
- 2) **1D-CNN 结构**：当输入拼接了过去若干时间步的 CPU 利用率、队列长度或链路质量序列时，1D-CNN 可以提取时序局部模式，再通过全连接层输出最终预测值。

为了使预测结果能够在决策阶段发挥更稳健的作用，本章进一步采用**均值 + 方差双输出**的设计，即网络输出

$$f_{\theta}(\mathbf{x}) = (\widehat{CO}, \hat{\sigma}^2), \quad (4.15)$$

其中， $\widehat{CO}$ 为并发开销点估计， $\hat{\sigma}^2$ 为预测方差估计。与只输出单一标量相比，增加不确定性分支具有两方面价值：一是便于在 DQN 状态中引入“模型对该预测是否有把握

握”的额外信息；二是在高异构、弱覆盖样本区间内，不确定性可以提醒策略避免过度依赖单一预测值。

从实现角度看，预测器本身不追求过深或过重的网络结构，而强调对结构化特征、短时间窗统计序列以及不确定性信息的统一表达。也正因为本章的重点在于“并发风险感知如何服务任务级决策”，所以模型结构仅保留轻量、可部署和可解释的设计原则，而不将网络复杂度本身作为主要创新点。

在损失函数设计上，若仅关注点估计，可使用均方误差

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{m=1}^N \left(\widehat{CO}^{(m)} - CO^{(m)} \right)^2. \quad (4.16)$$

若同时训练不确定性分支，则可以采用异方差高斯负对数似然形式

$$\mathcal{L}_{\text{pred}} = \frac{1}{N} \sum_{m=1}^N \left[\frac{\left(\widehat{CO}^{(m)} - CO^{(m)} \right)^2}{2\hat{\sigma}^2(m)} + \frac{1}{2} \log \hat{\sigma}^2(m) \right]. \quad (4.17)$$

该损失函数允许模型在噪声较大的区域给出更高的不确定性估计，从而避免对本就难以准确预测的样本过度拟合。

4.3.3 分层聚类联邦架构与训练流程

由于不同边缘卫星节点的本地样本分布具有显著 Non-IID 特征，直接使用统一的 FedAvg 训练单一全局模型往往难以兼顾不同簇之间的局部负载模式。基于此，本文采用聚类式联邦学习（clustered FL）对预测模型进行训练。其核心思路是：不再假设全网节点共享同一个最优模型，而是先根据节点负载模式、硬件能力或更新方向将其划分为多个簇，再在簇内执行模型聚合。

面向天基网络的层次化结构，本章将联邦预测框架设计为“全局协调层—区域聚合层—本地训练层”三层架构。与参考章节中“系统组成—工作流程—算法设计”的写法一致，这里先说明各层角色，再给出训练流程与簇内聚合规则。

三层架构的职责分工如表 4.3 所示。

表 4.3 分层聚类联邦学习架构中的角色划分

层级	典型实体	主要职责
全局协调层	地面控制中心 / 星座控制器	模型版本管理、训练轮次调度、簇级模型下发、链上摘要维护
区域聚合层	核心边缘卫星节点	区域内节点分组、异常更新检测、簇内参数加权聚合
本地训练层	参与训练的 SEN 集合	基于本地执行日志训练预测模型，不上传原始样本，仅上传模型更新

在一次完整的联邦训练周期内，预测模型的工作流程可以概括为：1) 全局协调层根据节点历史负载模式完成簇划分并下发初始化模型；2) 本地训练层在各自执行日志上完成若干轮本地更新；3) 区域聚合层对上传参数执行一致性检查、异常更新筛除与簇内加权聚合；4) 聚合后的模型版本号和参数哈希写入联盟链，供后续在线推理时进行版本校验与追溯；5) 最新簇模型再次下发至簇内节点，进入下一轮训练。上述流程使预测模型的训练、维护和可信存证形成统一闭环。

设第 c 个簇内包含若干节点集合 C_c ，第 t 轮通信后簇模型参数更新为

$$\theta_c^{(t+1)} = \sum_{k \in C_c} \frac{n_k}{\sum_{j \in C_c} n_j} \theta_k^{(t+1)}, \quad (4.18)$$

其中， n_k 为节点 k 的本地样本量， $\theta_k^{(t+1)}$ 为节点本地更新后的参数。与传统 FedAvg 相比，式 (4.18) 的改进并不体现在加权形式本身，而在于聚合只在“样本分布相近的节点簇内”进行，因此更容易捕捉局部任务模式。

在实现层面，聚类式联邦训练不只是“把 FedAvg 换成簇内 FedAvg”，还需要把训练过程与区块链提供的可信机制结合起来。具体而言，区域聚合层在每轮簇内聚合后，可将模型版本号、参数哈希和训练轮次摘要写入联盟链，用于完成模型溯源、版本一致性校验与异常更新留痕；终端节点在调用预测器时只需读取候选节点当前所属簇的最新可用模型版本，从而避免在在线阶段访问原始训练日志。这样的设计使“数据不出域”和“模型可追溯”同时成立，也使预测模块更容易并入第三章已经建立的可信协同框架中。

聚类式联邦学习的一个完整训练轮次可由算法 2 概括。相较原始 FedAvg，该流程新增了簇内聚合、异常更新筛查与链上存证三个关键步骤，因此更适合 Non-IID 且可信要求较高的天基边缘场景。

算法 2 聚类式联邦学习 (Clustered FedAvg) 训练流程

输入：簇划分集合 $\{C_1, \dots, C_K\}$, 本地数据集 $\mathcal{D}_k$, 本地训练轮数 E , 通信轮数 T 。
输出：各簇最终预测模型参数 $\theta_c^{(T)}$ 。

```

1: for 每个簇  $C_c$  do
2:   初始化簇模型参数  $\theta_c^{(0)}$  并下发至簇内节点
3: end for
4: for  $t = 0, 1, \dots, T - 1$  do
5:   for 每个簇  $C_c$  并行执行 do
6:     for 每个参与节点  $k \in C_c$  do
7:       以  $\theta_c^{(t)}$  为初值, 在  $\mathcal{D}_k$  上执行  $E$  个 epoch 本地更新
8:       得到本地参数  $\theta_k^{(t+1)}$  及样本量  $n_k$ 
9:     end for
10:    区域聚合层对上传更新做一致性检查与异常剔除
11:    按式 (4.18) 聚合得到新的簇模型  $\theta_c^{(t+1)}$ 
12:    将模型版本号、参数哈希及训练轮次摘要写入联盟链
13:   end for
14: end for

```

在线推理阶段, 终端节点并不直接参与联邦训练, 而是在需要决策时调用候选边缘节点所属簇的最新预测模型, 对每个候选动作的并发开销进行快速估计。这一点十分重要: 联邦学习的高开销发生在离线训练或后台异步更新阶段, 而在线阶段保留下来的只是一个轻量前向推理过程, 因此不会破坏节点侧决策的实时性要求。

4.3.4 可信维护与复杂度分析

从时间复杂度看, 若单个本地预测模型包含 P_f 个参数, 本地每轮训练使用 B_f 个 mini-batch, 则节点单轮本地训练复杂度约为 $\mathcal{O}(B_f P_f)$; 簇内聚合本质是参数加权求和, 复杂度为 $\mathcal{O}(|C_c| P_f)$ 。由于聚类式 FL 把全局聚合分解为多个簇内聚合过程, 单轮同步对全网连通性的要求低于统一 FedAvg。相比之下, 在线阶段仅保留一次前向推理, 因此预测模块在部署时的主要成本不是计算本身, 而是模型版本刷新与链上摘要读取的调度机制。

从通信复杂度看, 联邦学习阶段每轮只需要在节点与聚合层之间传递参数摘要, 而无需传递原始日志数据。在天基网络这类带宽和链路可用性受限的环境中, 这种“模型移动而非数据移动”的设计具有明显优势。与此同时, 聚类式 FL 还可以借助区域聚合层把大规模全局同步拆解成多个较小的局部同步过程, 降低单轮训练对网络连通性的苛刻要求。

进一步地, 若把模型可信维护纳入考虑, 则每轮额外链上开销主要来自模型哈希写入和版本确认, 这部分复杂度与模型参数规模无关, 而与摘要长度和交易确认时延

有关。因此，区块链并不会显著增加预测器训练的算力负担，但会通过信息年龄影响在线可用模型版本的新鲜度。后续实验中的“链上确认延迟敏感性”正是对这一现实部署约束的量化验证。

4.4 FL-DQN 卸载决策算法设计

如果说上一节解决的是“如何看见未来并发风险”，那么本节解决的便是“如何把这种风险感知转化为实时动作”。因此，本节不再重复描述预测模型本身，而是聚焦于节点侧决策代理如何读取预测先验、如何构造奖励约束、如何在在线阶段完成闭环交互，以及为什么该算法在工程上可实现。整体上，本节按照“状态—奖励—训练—在线执行—复杂度”的顺序展开，使算法描述与章节主线保持一致。

4.4.1 状态、动作与奖励函数设计

在获得并发开销预测能力后，节点侧仍需进一步解决“面对新任务应当本地执行还是卸载到哪个候选节点”的决策问题。本文将单个 ST 的卸载过程建模为 MDP，其状态向量定义为

$$s_t = \{s_t^{\text{task}}, s_t^{\text{local}}, s_t^{\text{chain}}, s_t^{\text{FL}}\}, \quad (4.19)$$

其中， s_t^{task} 包含任务计算量、数据规模、时延阈值与任务类型编码； s_t^{local} 包含本地 CPU 占用、队列长度、剩余能量与链路质量估计； s_t^{chain} 来自联盟链上的候选节点公共摘要； s_t^{FL} 则由并发开销预测模型给出，包括各候选节点的 $\widehat{CO}$ 及其置信信息。

表 4.4 总结了复合状态空间的设计。

表 4.4 节点侧决策的复合状态空间设计

状态分量	主要内容	作用
任务特征向量	任务计算量、输入数据大小、时延容忍阈值、任务类型编码、优先级	刻画当前任务需求
本地资源与链路状态	本地 CPU 占用、队列长度、剩余能量、可用频率、链路时延与带宽估计	反映当前本地资源与通信条件
链上公共摘要	候选节点平均负载、负载方差、信誉评分、账本延迟估计	提供系统级非实时协同上下文
FL 预测值	各候选节点的并发开销预测值与置信度	显式表征卸载后的额外风险

奖励函数在总代价负值的基础上引入轻量奖惩机制：

$$r_t = - \left(\alpha T_i^{\text{total}} + \beta E_i^{\text{total}} + \gamma \hat{\Delta}(l_i) \right) - \lambda P_{\text{imbalance}} + R_{\text{bonus}}, \quad (4.20)$$

其中， $P_{\text{imbalance}}$ 表示负载不均衡惩罚项，用于抑制任务长期集中到少数高性能边缘节点； R_{bonus} 为任务在截止期内完成、满足优先级约束或成功避开高拥塞节点时给予的正向奖励。与仅使用加权代价不同，式 (4.20) 将系统设计者对“低时延、低能耗、低拥塞和适度均衡”的偏好统一写入策略目标，因此更适合天基边缘场景下的多目标折中。

从机制上看，将 $\hat{\Delta}(l_i)$ 写入奖励函数有两种作用：一是直接把“潜在拥塞风险”转化为策略优化目标的一部分；二是当某些候选节点当前负载相近、但未来并发风险不同的时候，奖励函数可以迫使策略学会避开高风险节点。原稿中曾分别强调预测先验进入状态空间和进入奖励设计的必要性，本融合稿将二者统一为“预测既作为观测先验，也作为代价约束”的双重作用。与此同时， $P_{\text{imbalance}}$ 的引入使策略不再只追求单次动作收益，而是能够兼顾较长时间尺度上的节点利用均衡。

4.4.2 Q 网络结构与训练策略

由于动作空间是有限离散集合，本文采用 DQN 学习最优动作价值函数 $Q^*(s, a)$ 。这一处理方式与参考章节中“先给出通信/聚合模型，再进一步写成 MDP 并给出 DQN 选择过程”的写法一致：先明确状态、动作与奖励，再说明值函数逼近与训练机制。令主网络参数为 θ ，目标网络参数为 θ^- ，则 Bellman 目标值写为

$$y_t = r_t + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-), \quad (4.21)$$

损失函数为

$$\mathcal{L}(\theta) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}) \sim D} \left[(y_t - Q(s_t, a_t; \theta))^2 \right], \quad (4.22)$$

其中， D 为经验回放池， γ 为折扣因子。

为提高训练稳定性，本章沿用标准 DQN 的三项关键机制：

- 1) **经验回放**：将交互产生的样本打乱后重用，削弱序列相关性；
- 2) **目标网络**：使用滞后更新的目标网络生成目标值，减少训练震荡；
- 3) **ϵ -greedy 探索**：在探索与利用之间进行平衡，防止策略过早陷入局部最优。

在网络结构上,考虑到状态维度相对有限且要求在线推理足够快,本文使用两层或三层全连接网络逼近 $Q(s, a; \theta)$, 隐藏层采用 ReLU 激活。相比于更复杂的 dueling、double 或 attention 结构,这种配置在节点侧具有更低的实现门槛和推理开销,更符合“轻量快速决策”的系统定位。当然,在实验中我们仍保留增强型 DQN 变体作为对比基线,以检验“改进 DRL 结构”和“引入预测先验”两条路线的相对收益。

4.4.3 在线决策流程与闭环机制

本章的关键不在于单独提出一个联邦预测器,也不在于单独训练一个 DQN,而在于二者如何形成有效闭环。图 4.3 给出了融合并发开销预测先验的 FL-DQN 在线卸载决策闭环:新任务到达后,节点先收集本地状态和链上摘要;随后调用候选节点对应簇的最新预测模型生成并发开销估计及其不确定性;这些预测结果与原始状态一起构成 DQN 的输入;DQN 输出动作后,环境返回真实时延、能耗和任务结果,再以奖励形式反哺后续策略更新。




图 4.3 融合并发开销预测先验的 FL-DQN 在线卸载决策闭环

这种协同方式的优势在于,它把难以直接编码进解析策略的“未来并发风险”显

式注入到了决策模块中。换言之，DQN 并不是在纯粹的即时观测之上做反应式决策，而是在带有预测先验的扩展状态上做前瞻式决策。特别是在高并发、链上状态滞后的场景中，这种差异通常会转化为更低的时延退化斜率和更好的系统鲁棒性。

综合上述设计，FL-DQN 在线卸载决策流程可概括为表 4.5 所示的七个步骤。

表 4.5 FL-DQN 在线卸载决策流程

步骤	流程描述
1	终端节点接收新任务，提取计算量、数据大小、任务类型、优先级和时延等级等特征。
2	从本地环境读取 CPU、内存、队列长度、剩余能量与链路状态，并从联盟链获取候选边缘节点的公共摘要。
3	调用所属簇的联邦预测模型，对各候选边缘节点的并发开销进行快速推理。
4	将任务特征、本地资源状态、链上公共摘要和预测结果拼接为状态向量 s_t 。
5	DQN 计算各动作的 Q 值，并按 ϵ -greedy 规则选择本地执行或目标节点卸载动作。
6	环境返回任务完成时延、能耗和结果状态，据此计算奖励并写入经验回放池。
7	主网络按 mini-batch 更新参数，目标网络按固定步长同步；策略持续与环境交互直至收敛。

为了更清楚地展示“预测先验如何进入在线动作选择”，算法 3 对 FL-DQN 的节点侧执行流程给出伪代码描述。该伪代码与图 4.3 的区别在于：前者强调实现时的控制流，后者强调预测与决策之间的信息闭环。

算法 3 FL-DQN 在线任务卸载决策流程

输入：最新可用联邦预测模型 f_{θ_f} ，DQN 主网络 $Q(\cdot; \theta)$ ，目标网络 $Q(\cdot; \theta^-)$ ，经验回放池 $\mathcal{D}$ 。
输出：收敛后的节点侧卸载策略。

```

1: for 每个决策周期 do
2:   接收新任务并提取任务特征、本地资源状态与链上公共摘要
3:   for 每个候选动作  $a \in \mathcal{A}$  do
4:     构造动作相关特征向量  $\mathbf{x}(s_t, a)$ 
5:     调用  $f_{\theta_f}$  得到并开发销预测值及不确定性  $(\widehat{CO}(s_t, a), \hat{\sigma}^2(s_t, a))$ 
6:   end for
7:   拼接得到扩展状态  $s_t$ ，按  $\varepsilon$ -greedy 选择动作  $a_t$ 
8:   执行动作并获得即时奖励  $r_t$  与下一状态  $s_{t+1}$ 
9:   将  $(s_t, a_t, r_t, s_{t+1})$  写入经验回放池  $\mathcal{D}$ 
10:  if 经验池样本数量足够 then
11:    从  $\mathcal{D}$  随机采样 mini-batch，并按式 (4.21) 更新主网络
12:    每隔固定步长同步目标网络参数  $\theta^- \leftarrow \theta$ 
13:  end if
14: end for

```

4.4.4 算法复杂度与可实现性分析

对于单次在线决策，若候选边缘节点数量为 N_c ，预测模型前向推理复杂度为 $\mathcal{O}(P_f)$ ，Q 网络前向推理复杂度为 $\mathcal{O}(P_q)$ ，则单次决策复杂度近似为

$$\mathcal{O}(N_c P_f + P_q). \quad (4.23)$$

由于 N_c 通常远小于全网节点数，且 P_f 和 P_q 均来自轻量级 MLP/1D-CNN 结构，因此该复杂度满足节点侧实时部署需求。

若考虑训练阶段，则每次 DQN 参数更新需要对一个大小为 B_q 的 mini-batch 执行前向与反向传播，复杂度约为 $\mathcal{O}(B_q P_q)$ ；经验回放池若容量为 $|\mathcal{D}|$ ，则其空间复杂度为 $\mathcal{O}(|\mathcal{D}| d_s)$ ，其中 d_s 为状态维度。与引入预测先验所带来的性能收益相比，这部分额外存储开销是可控的。进一步地，预测模型本身可以异步更新，节点侧仅维护最近一次下发的模型副本，因此不会把联邦训练的成本直接叠加到每个在线动作上。

相比之下，若使用中心控制器收集全网细粒度状态再做统一决策，则不仅通信开销更高，而且难以满足天基网络中严格的时延约束。尤其是在链上状态存在确认延迟、候选节点可达性随轨道运动变化的条件下，把所有决策都放在中心完成会进一步放大信息年龄问题，而 FL-DQN 通过“链上摘要 + 本地观测 + 预测先验”的组合，能够在分布式条件下保留较高的动作质量。

4.5 实验设计与结果分析

为系统验证所提 FL-DQN 任务卸载方法的有效性,本节按照“预测层验证—端到端性能验证—鲁棒性与可解释性分析—模块贡献分析”的逻辑展开实验。首先,通过并发开销预测精度、训练收敛过程、置信校准结果和异构环境下的预测误差,验证聚类式联邦学习能否为节点侧决策提供可靠的并发风险先验;其次,通过平均任务时延、系统吞吐量、SLA 完成率和 P99 尾时延等指标,分析预测先验是否能够有效转化为实际卸载收益;随后,从链上摘要陈旧性、动作选择偏好和效率—公平性折中三个角度进一步评估方法的鲁棒性与可解释性;最后,通过消融实验分析联邦预测模块、并发惩罚项、经验回放机制和奖励塑形项对整体性能的具体贡献。

需要说明的是,受限于真实在轨天基边缘计算环境难以直接部署和复现实验,本文实验部分采用模型驱动的离散事件仿真方式进行验证。仿真参数依据前文建立的任务层时延模型、能耗模型和并发开销模型设定,并结合图像处理类任务与数值计算类任务构造不同并发强度下的资源竞争场景。实验结果主要用于比较不同策略在相同约束条件下的相对性能差异,而不代表某一具体星载平台的绝对实测性能。

4.5.1 实验场景、对比方法与评价指标

实验场景模拟由若干卫星终端 ST、候选卫星边缘节点 SEN、联盟链控制平面和联邦协调单元共同组成的天基分布式计算系统。终端侧任务按照离散事件方式持续到达,每个任务包含计算量、输入数据大小、时延约束、任务类型和优先级等属性;候选边缘节点具有不同的计算能力、队列长度、背景负载和并发任务数;链上公共摘要以固定周期更新,用于提供候选节点的平均负载、负载方差、信誉评分和模型版本信息。为模拟天基网络中的状态滞后现象,实验进一步设置可控的链上摘要延时,并考察不同延时条件下各策略的性能变化。

并发开销预测数据由两类代理任务构造:一类为图像处理任务,用于模拟遥感预处理、轻量识别和视觉感知类边缘负载;另一类为数值计算任务,用于模拟输入规模较小但计算强度较高的计算密集型负载。每条样本记录任务类型、输入规模、估计计算量、节点 CPU 状态、并发任务数、执行中任务剩余工作量、上下文切换强度以及实际完成时延,并根据前文定义的并发开销表达式构造监督标签。这样既能够覆盖数据搬运和计算争用同时存在的混合场景,也能够避免训练样本过度偏向单一任务类型。

对比方法包括以下几类: **FL-DQN** 表示本文提出的完整方法; **DQN-only** 表示不

引入联邦预测先验，仅依靠即时状态训练 DQN 策略；**FL-only** 表示使用联邦预测结果辅助启发式卸载，但不进行强化学习策略优化；**Centralized-DQN** 表示在理想条件下能够获得全局实时状态的集中式 DQN，可视为性能上界参考；**Heuristic** 表示基于当前负载、链路质量和队列长度的启发式卸载策略。对于预测层实验，额外比较 **Clustered FL**、**FedAvg**、**Centralized** 和 **Local-only** 四类训练方式，以验证聚类式联邦学习在 Non-IID 数据分布下的优势。

评价指标分为预测层指标和决策层指标。预测层采用 MAE、RMSE 和预测-真实拟合关系衡量并发开销预测精度，同时通过置信校准结果分析模型输出不确定性的有效性。决策层采用平均任务时延、系统吞吐量、SLA 完成率、P99 尾时延、在线决策开销、跨轮次波动和 Jain 公平性指数等指标衡量卸载策略的综合表现。其中，平均任务时延反映整体服务效率，P99 尾时延反映极端拥塞条件下的稳定性，SLA 完成率反映任务时延约束满足能力，Jain 公平性指数用于衡量任务分配在不同候选节点之间的均衡程度。

4.5.2 并发开销预测模块性能分析

节点侧卸载策略能否提前规避潜在拥塞，很大程度上取决于并发开销预测模块是否能够提供稳定可靠的风险先验。因此，本节首先对预测模块进行独立验证。图 4.4 从联邦训练收敛过程、预测-真实散点密度、置信度校准结果以及不同异构强度下的测试误差四个角度展示了并发开销预测模块的综合性能。




图 4.4 并发开销预测模块的多维性能结果

由图 4.4(a) 可见，随着通信轮次增加，各类训练方式的验证集 MAE 均逐步下降，说明模型能够从历史执行日志中学习并发开销与任务特征、节点状态和资源竞争程度之间的映射关系。其中，Clustering FL 的误差下降速度明显快于 FedAvg 和 Local-only，并且在训练后期达到更低的稳定误差水平。这表明，在节点负载模式和任务分布存在差异的情况下，先根据负载模式进行聚类，再在簇内执行模型聚合，能够有效缓解统一全局模型在多峰分布下的偏移问题。

图 4.4(b) 给出了预测并发开销与真实并发开销之间的散点密度关系。大多数样本集中分布在对角线附近，说明预测值与真实值总体保持较高一致性。当真实并发开销较低时，样本分布相对紧凑，预测误差较小；当真实并发开销增大时，散点分布略有扩散，说明高并发条件下资源争用的不确定性更强，但整体仍能保持较好的趋势跟踪能力。该结果说明，预测模型不仅能够学习平均意义上的并发开销变化，也能够对不同负载区间下的风险差异做出有效区分。

图 4.4(c) 展示了预测不确定性与实际绝对误差之间的关系。可以看到，经验误差

总体随预测不确定性增加而上升，说明模型输出的置信信息具有一定校准意义。换言之，当预测模型对某些样本给出较高不确定性时，这些样本通常也更容易产生较大的实际误差。该结果对于后续 DQN 决策具有重要意义：DQN 不仅可以利用并发开销点估计值，还可以利用不确定性信息判断当前预测是否可靠，从而避免在高风险、高不确定性状态下过度依赖单一预测值。

图 4.4(d) 进一步比较了不同数据异构强度下的测试集 MAE。可以看出，在 IID 场景下，各方法之间的差距相对有限；但随着数据分布从轻度 Non-IID 增强到重度 Non-IID，FedAvg 和 Local-only 的误差增长更为明显，而 Clustered FL 的误差上升幅度较小，表现出更好的异构鲁棒性。该现象说明，标准 FedAvg 在节点负载模式差异较大时容易受到全局平均效应影响，而聚类式联邦学习能够通过簇内聚合保留局部负载特征，从而为节点侧决策提供更加稳定的并发风险估计。

综合图 4.4 的结果可以看出，聚类式联邦学习不仅提高了并发开销预测精度，也提升了模型在异构环境下的收敛稳定性和置信表达能力。这为后续 FL-DQN 将预测先验引入状态空间和奖励函数提供了基础支撑。

4.5.3 不同并发强度下的端到端卸载性能分析

在验证并发开销预测模块能够提供有效风险先验之后，进一步需要回答的问题是：预测得到的并发风险信息能否真正转化为任务级卸载性能提升。为此，本文在不同平均并发任务数下，对 FL-DQN 与多种基线方法在平均任务时延、系统吞吐量、SLA 完成率和 P99 尾时延四项指标上的表现进行对比，结果如图 4.5 所示。




图 4.5 不同并发强度下的卸载决策性能与稳定性

为了进一步给出典型并发区间下的定量对比，表 4.6 汇总了低并发、中并发和高并发条件下各方法的关键指标。其中， $\bar{k}$ 表示平均并发任务数，Avg. Delay 表示平均任务时延，Thr. 表示系统吞吐量，SLA 表示任务完成率，P99 表示尾部时延。表中红色表示最优结果，蓝色表示次优结果。需要指出的是，Centralized-DQN 假设能够获得全局实时状态，因此主要作为理想性能上界；FL-DQN 则是在分布式、状态滞后和隐私受限条件下可部署的节点侧策略。

由图 4.5(a) 可见，随着平均并发任务数增加，所有方法的平均任务时延均呈上升趋势。这是因为并发任务增多后，候选节点内部的 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队现象更加明显，导致任务端到端完成时间持续增加。然而，不同方法的时延增长斜率存在明显差异。Heuristic 和 DQN-only 在高并发区间时延上升较快，说明仅依赖当前负载或即时观测状态难以准确判断候选节点的未来拥塞风险。相比之下，FL-DQN 的时延增长更为平缓，说明引入并发开销预测先验后，策略能够在

表 4.6 不同并发强度下各卸载策略的端到端性能汇总

方法	低并发 $\bar{k} = 4$				中并发 $\bar{k} = 8$				高并发 $\bar{k} = 12$			
	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓
Heuristic	160	53	93.9	253	240	40	82.3	399	361	28	65.6	612
DQN-only	145	56	95.5	228	222	44	86.9	368	334	32	72.3	548
FL-only	141	57	96.2	219	208	48	89.3	331	296	36	77.1	489
FL-DQN	134	59	97.3	211	188	52	93.1	284	256	43	84.7	401
Centralized-DQN	130	61	97.7	202	181	54	94.0	273	247	46	86.5	387

任务卸载前提前识别潜在拥塞节点，从而减少将任务发送到“表面空闲但实际竞争严重”节点的概率。

从表 4.6 也可以看出，在低并发、中并发和高并发三个典型场景下，Centralized-DQN 在多数指标上取得最优结果，这是因为其具备理想化的全局实时状态信息，能够作为性能上界参考。而 FL-DQN 在所有典型并发强度下均取得次优结果，并明显优于 DQN-only、FL-only 和 Heuristic。尤其在高并发条件下，FL-DQN 的平均时延为 256 ms，明显低于 DQN-only 的 334 ms 和 Heuristic 的 361 ms；其 SLA 完成率为 84.7%，也显著高于 DQN-only 和 Heuristic。这说明在分布式可部署约束下，FL-DQN 能够较好逼近集中式策略的性能上界。

图 4.5(b) 给出了系统吞吐量随并发强度变化的情况。随着并发任务数增加，各方法吞吐量均出现不同程度下降，这是由于节点队列积压和任务执行时间延长降低了单位时间内的任务完成数量。Centralized-DQN 由于假设能够获得全局实时状态，因此整体吞吐量最高。FL-DQN 虽略低于 Centralized-DQN，但明显优于 DQN-only、FL-only 和 Heuristic，说明在不依赖全局实时透明信息的前提下，所提方法通过“链上摘要 + 本地观测 + 联邦预测先验”的组合，已经能够获得接近集中式策略的任务处理能力。

图 4.5(c) 展示了 SLA 完成率随并发强度变化的趋势。在低并发条件下，各方法之间的差距相对较小，说明系统资源较充足时，不同策略都较容易满足任务时延约束。但当平均并发任务数持续增加后，Heuristic 和 DQN-only 的完成率下降更快，表明其高负载条件下更容易产生拥塞误判和任务超时。FL-DQN 的 SLA 完成率下降最慢，说明其能够通过预测先验提前规避高风险卸载动作，从而在资源竞争增强时仍保持较高的任务完成质量。

图 4.5(d) 从尾部性能角度进一步验证了上述结论。P99 尾时延反映了最差一部分任务的完成情况，对时延敏感型天基业务尤为重要。随着并发任务数增加，各方法的

P99 尾时延均明显上升,但 FL-DQN 的增长幅度相对较小。相比 DQN-only 和 Heuristic, FL-DQN 在高并发区间能够显著降低尾部时延,说明其不仅改善了平均意义上的服务质量,也有效抑制了极端拥塞样本对系统稳定性的影响。

总体来看,图 4.5 和表 4.6 共同表明,FL-DQN 的优势在中高并发场景中更加明显。这与本文方法设计目标一致:当系统处于轻载状态时,候选节点之间的资源竞争尚不显著,预测模块带来的收益有限;而当系统逐步逼近拥塞边界时,并发开销预测能够为 DQN 提供更有价值的前瞻信息,使策略在平均时延、吞吐量、SLA 完成率和尾部时延方面均表现出更好的稳定性。

4.5.4 鲁棒性、动作偏好与多目标折中分析

仅从平均时延或完成率角度评价卸载策略,仍不足以全面说明方法的部署性。天基网络中链路窗口有限、链上摘要存在确认延迟,节点状态不可避免地具有陈旧性;同时,卸载策略还应具备可解释的动作选择行为,并在效率、能耗和节点均衡之间取得合理折中。基于此,本文进一步从链上陈旧性敏感性、动作选择偏好和效率—公平性折中三个角度进行分析,结果如图 4.6 所示。




图 4.6 鲁棒性、动作偏好与多目标折中结果

图 4.6(a) 展示了链上摘要延时增加时各方法的平均任务时延变化。可以看到，随着链上摘要延时从较低水平逐步增加，各方法的平均时延均有所上升。这是因为候选节点公共摘要越陈旧，终端侧获得的节点负载状态越可能偏离真实运行状态，从而增加错误卸载的概率。然而，FL-DQN 的退化幅度明显小于 DQN-only、FL-only 和 Heuristic。该结果说明，FL-DQN 并不完全依赖链上摘要本身，而是能够通过本地实时观测和联邦预测模型对状态陈旧性进行一定补偿。当链上信息不能准确反映当前节点状态时，预测模块仍可根据历史负载模式和并发环境特征估计潜在风险，从而降低摘要延迟对决策质量的影响。

图 4.6(b) 给出了 FL-DQN 在不同候选节点负载风险区间下的动作选择热力图。该热力图通过统计策略收敛后在测试集中的动作选择频次，并对同一风险区间内的动作次数进行归一化得到。可以看出，在负载风险较低时，策略更倾向于选择本地执行或风险较低的候选边缘节点；随着候选节点负载风险逐步升高，动作选择概率逐渐向其他节点分散，表明智能体会根据风险变化动态调整卸载目标，而不是长期固定选择某一个高性能节点。该结果说明，FL-DQN 学到的并不是简单的“选择当前负载最低节点”规则，而是一种结合任务属性、链上摘要和并发风险预测的自适应卸载行为。

图 4.6(c) 进一步展示了不同方法在能时积 EDP 与 Jain 公平性指数之间的折中关系，其中气泡大小表示对应方法的任务完成率。EDP 越低，说明方法在时延和能耗之间具有更好的综合效率；Jain 公平性指数越高，说明任务在不同节点之间分配越均衡。可以看到，Centralized-DQN 由于拥有理想全局状态，在公平性和效率方面表现较好，但其依赖强全局实时信息假设，实际部署难度较高。FL-DQN 在 EDP 和公平性之间取得了较优折中，虽然其公平性略低于集中式上界，但明显优于 DQN-only、FL-only 和 Heuristic，并且仍保持较高任务完成率。相比之下，Heuristic 和 DQN-only 更容易将任务集中到少数表面负载较低的节点，从而导致公平性下降和能时积增大。

综合图 4.6 可以看出，FL-DQN 的优势不仅体现在平均性能指标上，还体现在对链上状态滞后的适应能力、动作选择行为的合理性以及效率—公平性多目标折中能力上。这说明所提方法更符合天基分布式计算环境中“信息不完全、状态有时滞、节点负载动态变化”的实际部署需求。

4.5.5 消融实验与模块贡献分析

为了进一步分析完整方法中各组成模块的具体作用，本文设计消融实验，分别移除联邦预测模块、并发惩罚项、经验回放机制和奖励塑形项，并与完整 FL-DQN 进行对比。除被移除模块外，其余训练参数、任务到达过程、候选节点配置和评价指标均保持一致，以保证不同消融版本之间具有可比性。为便于直接对比，表 4.7 汇总了平均并发任务数为 16 时的关键指标，其中 Avg. Delay 和 SLA 分别来自图 4.7(a)(b) 的高并发点，Online Cost 与 Std. Dev. 则对应图 4.7(c) 的双纵轴柱状统计结果。表中红色表示最优结果，蓝色表示次优结果。

表 4.7 FL-DQN 各模块消融实验结果

方法变体	Avg. Delay ↓	SLA ↑	Online Cost ↓	Std. Dev. ↓	结果说明
FL-DQN	209	91.2	3.8	5.1	完整方法，综合性能最优
-FL 预测	284	80.1	3.1	9.6	缺少并发风险先验，退化最明显
-并发惩罚	243	84.7	3.6	8.1	拥塞规避约束减弱
-经验回放	256	86.4	2.4	11.2	开销最低但训练波动最大
-奖励塑形	238	87.9	3.4	7.3	收敛引导能力减弱

进一步地，图 4.7 从平均时延、SLA 完成率以及“在线决策开销-跨轮次波动”联合视角展示了消融实验结果。为了便于排版，图 4.7 由三个 Python 绘制的子图组合而成。




图 4.7 消融实验结果

图 4.7(a) 展示了不同消融版本在平均并发任务数增加时的平均时延变化。可以看到，完整 FL-DQN 在所有并发水平下均保持最低平均时延；去除 FL 预测模块后，平均时延显著上升，且并发任务数越高，性能劣化越明显。这说明联邦预测模块是完整方法取得性能优势的核心来源。没有预测先验时，DQN 只能依赖当前观测状态和链上摘要进行反应式决策，难以及时识别候选节点的潜在并发风险，因此在高并发条件下更容易发生错误卸载。相比之下，去除并发惩罚项后时延也有所增加，但劣化程度低于去除 FL 预测模块，说明并发惩罚主要起到强化拥塞规避偏好的作用，而预测模块则决定了策略是否具备风险前瞻能力。

图 4.7(b) 给出了不同消融版本的 SLA 完成率变化趋势。完整 FL-DQN 的完成率始终最高，并且随着并发增强下降较为平缓；去除 FL 预测模块后，SLA 完成率下降

最明显，说明缺少并发风险估计会直接影响任务是否能够在时延阈值内完成。去除并发惩罚项后，SLA 完成率也明显低于完整方法，表明仅将预测值作为状态输入仍不足以完全引导策略规避拥塞，还需要在奖励函数中显式体现并发开销代价，使智能体在训练过程中形成对高风险动作的惩罚记忆。

图 4.7(c) 以双纵轴柱状图联合比较了各版本的在线决策开销与跨轮次波动。完整 FL-DQN 的在线开销略高于去除 FL 预测模块或去除经验回放的简化版本，这是因为完整方法需要在决策前调用预测模型，并进行 DQN 动作价值计算；但其开销仍维持在毫秒级，满足节点侧实时决策需求。与此同时，完整 FL-DQN 的跨轮次标准差最低，说明其在多次独立运行中更稳定。去除经验回放后尽管在线开销最低，但这往往以更大的跨轮次波动为代价；去除 FL 预测模块后波动同样明显增大，说明缺少稳定风险先验会降低策略一致性。该联合结果表明，完整方法在“决策效率-训练稳定性”之间取得了更优综合折中。

综合消融实验结果可以看出，FL 预测模块决定了策略的风险前瞻能力，是降低高并发时延和维持 SLA 完成率的关键；并发惩罚项增强了策略对拥塞节点的规避倾向，使预测信息能够更直接地转化为优化目标；经验回放机制主要提升训练稳定性，降低跨轮次波动；奖励塑形项则进一步改善策略收敛方向和任务完成质量。因此，完整 FL-DQN 的性能提升并非来自单一模块堆叠，而是来自预测先验、奖励约束和强化学习稳定机制之间的协同作用。

4.5.6 本节小结

本节围绕并发感知任务卸载方法的有效性进行了分层实验验证。预测层结果表明，聚类式联邦学习能够在不集中上传原始日志的前提下，有效学习候选节点的并发开销变化规律，并在 Non-IID 环境下保持较好的预测精度和收敛稳定性。端到端卸载结果表明，将并发开销预测值及其置信信息引入 DQN 后，节点侧策略在平均任务时延、系统吞吐量、SLA 完成率和 P99 尾时延等指标上均优于分布式基线方法，尤其在中高并发区间优势更加明显。鲁棒性分析进一步说明，FL-DQN 能够在链上摘要存在陈旧性的情况下维持较平缓的性能退化，并形成符合风险变化规律的动作选择行为。消融实验则验证了联邦预测模块、并发惩罚项、经验回放机制和奖励塑形项对整体性能提升的不同贡献。

总体而言，实验结果说明，本文所提出的 FL-DQN 方法能够在隐私受限、状态滞

后和负载异构的天基分布式计算环境中，将联邦学习得到的并发风险预测有效转化为节点侧实时卸载决策收益，从而在时延、吞吐量、完成率、尾部稳定性和负载均衡之间取得更合理的综合折中。

4.6 本章小结

本章围绕天基网络任务层实时卸载问题，提出了一个面向并发开销的“联邦预测 + DQN 决策”闭环方法。不同于第三章从系统层讨论全局可信协同资源分配，本章进一步下沉到节点侧，以单任务到达瞬间的快速动作选择为核心，系统性解决了链上状态滞后、隐私受限、负载动态变化和并发资源竞争等多重挑战，因此在全文中承担着把“可信共享能力”转化为“实时执行能力”的桥梁作用。

具体而言，本文首先从任务层视角建立了时延、能耗与并发开销的统一代价模型，并给出了并发开销的形式化定义、工程近似表达及其可分解解释；随后，针对节点本地日志难以集中上传且样本分布高度异构的问题，构建了分层聚类联邦学习框架，实现并发开销预测模型的隐私友好训练；进一步地，本文将预测值及其置信信息显式纳入 DQN 状态空间与奖励函数设计，使卸载策略具备对潜在并发风险的前瞻感知能力。实验结果表明，在中等并发工作点下，所提 FL-DQN 相比 DQN-only 的平均任务时延下降约 19.6%、P99 时延下降约 22.7%、吞吐量提升约 17.0%、SLA 完成率提高超过 6 个百分点，并且在高并发和链上状态滞后条件下仍保持更平缓的性能退化趋势。

归纳而言，本章形成了以下三个结论：第一，并发开销是影响天基网络任务级卸载质量的关键隐藏变量，不能被简单平均负载替代；第二，聚类式联邦学习能够在不上传原始数据的前提下有效建模并发风险，为节点侧决策提供可靠先验；第三，将预测先验与强化学习决策进行深度耦合，能够显著增强策略在信息不完全与高并发场景下的鲁棒性。由此，第三章所建立的系统层可信协同框架与本章提出的任务层实时决策机制共同构成了一个跨层闭环：前者保障状态共享的可信与可得，后者保障任务执行的高效与稳健。上述研究也为后续进一步讨论跨层协同优化、多智能体联合决策或更复杂的星地协同边缘智能机制奠定了方法基础。

5 面向天基协同计算的区块链平台架构与设计

在前文中，本文围绕天基网络协同计算卸载问题，分别从系统建模、系统层协同优化以及任务层实时决策三个层面展开研究。第2章建立了面向天基协同计算的系统模型，明确了节点异构、链路时变、任务随机到达以及多主体协作等关键特征；第3章提出了基于区块链与多智能体强化学习的系统层协同资源分配方法，从全局层面实现可信状态共享与协同优化；第4章进一步提出了基于联邦学习与深度强化学习的任务层并发感知卸载方法，实现面向局部任务到达场景的实时决策。至此，全文已经形成“系统层全局协同—任务层局部决策”的双层智能管控框架。

然而，前述研究主要集中于模型构建与算法设计层面。若缺乏统一的平台承载机制，第3章提出的系统层协同优化方法与第4章提出的任务层卸载决策方法仍难以在真实分布式环境中形成稳定、可信且持续演化的运行体系。一方面，系统层协同优化依赖跨节点可信状态同步与一致性规则支撑；另一方面，任务层实时决策依赖模型版本治理、执行结果回流和行为存证机制。若仍采用传统集中控制方式或松散耦合式系统拼接方式，则难以同时满足状态可信、规则可执行、行为可追溯和跨层可协同等要求。

基于此，本章在第2章系统建模结果以及第3章、第4章算法设计的基础上，提出一种面向天基协同计算的区块链平台架构。该平台并非将区块链作为附加的安全模块，而是将其作为连接系统层资源协同与任务层实时卸载的分布式可信底座，通过轻量级联盟链共识、分层链结构、链上/链下协同机制以及智能合约治理体系，实现关键状态共享、任务行为存证、模型版本溯源与执行反馈闭环。

本章围绕平台设计动机与总体思路、总体架构与分层链设计、区块结构与数据流转机制、双层智能方法的平台映射与运行闭环，以及工程可行性分析等五个方面展开。其目的不是在前文之外再增加一个独立模块，而是依托已完成的平台项目，将第2章系统建模、第3章系统层协同资源分配方法与第4章任务层并发感知卸载方法统一映射到一个可运行、可验证、可审计的平台环境中。

5.1 平台设计动机与总体思路

平台设计动因。天基协同计算卸载问题本质上并非单一任务的转发或调度问题，而是在动态网络条件下，由多类异构节点共同参与的状态感知、资源竞争、任务迁移、行为反馈与规则治理问题。尤其在本文所研究的场景中，卫星节点既可能作为任务发起方，也可能作为协同计算资源提供方，节点之间在共享资源与竞争收益的同时，还受到拓扑时变、链路波动和任务突发到达等多种不确定因素影响。这决定了仅依靠单节点局部决策或单次优化求解，难以从根本上解决天基环境下的持续协同问题。

第3章从系统层角度出发，构建了基于区块链与多智能体强化学习的协同资源分配方法，重点解决多节点在全局资源竞争背景下如何实现状态可信共享与协同策略学习。然而，该方法成立的前提在于系统中存在一个可为多主体提供统一规则约束和可信共享信息的支撑环境。若节点之间缺乏一致的状态同步与审计机制，则系统层智能体获取的全局状态可能受局部偏差或虚假上报影响，从而削弱系统层协同优化的有效性。

第4章从任务层角度出发，提出了基于联邦学习与深度强化学习的并发感知卸载方法，解决任务到达瞬间如何在局部环境下做出实时卸载决策的问题。该方法在运行过程中需要依赖联邦学习模型的持续更新、模型参数的一致性校验、任务执行结果的回流反馈以及跨节点行为的可追溯记录。若缺乏统一平台，任务层方法虽然可以在局部条件下形成决策，但其模型版本治理、执行结果可验证性以及长期策略迭代能力将难以保证。

因此，从全文结构看，第2章回答了“研究对象是什么”的问题，第3章和第4章分别回答了“系统层如何协同”和“任务层如何决策”的问题，而本章进一步回答“前述方法如何形成统一系统并支撑工程落地”的问题。第五章的平台设计并非独立于前文之外的附加内容，而是对全文双层智能管控框架的体系化承接与系统化实现。

平台在全文中的作用定位。结合前文研究内容，本文所设计的平台总体上可定位为面向天基协同计算的分布式可信运行底座，其作用主要体现在以下三个层面。

其一，平台是双层智能决策的可信状态同步底座。无论是第3章中的系统层协同资源分配，还是第4章中的任务层并发感知卸载，其核心前提都是能够获取与当前环境相匹配的有效状态信息。然而，天基网络中的状态信息天然具有分散性、异步性和动态变化性。平台通过联盟链维护关键状态摘要、模型版本信息和治理规则，为多节

点提供一致、可验证且可回溯的公共状态视图，从而为双层智能决策提供可信输入环境。

其二，平台是连接系统层优化与任务层执行的协同中枢。第 3 章提出的多智能体强化学习方法关注较长时间尺度下的全局资源协调，第 4 章提出的联邦学习—深度强化学习方法关注较短时间尺度下的单任务实时决策。两者虽然作用粒度不同，但在实际运行中存在明显的约束传递与结果反馈关系。平台通过共享状态接口、模型治理接口和结果回流机制，将系统层全局协同结果传递给任务层局部决策，并将任务层执行反馈进一步汇聚为系统层状态更新依据，从而实现跨层协同。

其三，平台是面向异构多节点环境的治理与审计载体。天基协同计算不仅涉及任务卸载和资源调度，还涉及节点准入、服务迁移、模型更新、信誉演化和异常行为约束等治理问题。平台通过智能合约将这些关键流程固化为自动执行规则，使任务从生成、分配、执行到结算的全过程具备一致性、可追溯性与可审计性，从而降低多主体协同中的信任成本。

平台设计目标。平台设计目标可概括为以下四点。第一，支撑天基动态环境下的可信状态共享。第二，支撑双层智能方法的统一落地。第三，兼顾可信性与轻量化。第四，满足长期演化和工程扩展需求。

平台设计原则。基于上述目标，平台设计遵循轻量高效、可信共享、分层解耦、跨层协同和面向工程部署等原则。

5.2 平台总体架构与分层链设计

平台总体架构与网络映射。为支撑天基协同计算环境下“资源状态可信同步—系统层协同决策—任务层动态卸载—执行结果审计反馈”的完整闭环，本章设计了一种面向动态星地网络的区块链协同计算平台总体架构，如图 5.1 所示。该平台并非对计算、通信与管控模块的简单堆叠，而是围绕前文提出的双层智能优化方法，对异构节点状态汇聚、链上可信治理、跨层策略联动以及应用侧任务编排进行统一组织，从而为天基协同计算中的实时调度与可靠执行提供工程化载体。

从功能上看，平台可划分为基础设施与网络环境层、区块链平台核心层、双层智能决策层以及应用与管理层四个层次。其中，基础设施与网络环境层负责提供卫星、边缘站、地面云及星地链路等异构资源基础，并向上暴露计算能力、缓存占用、链路时延、可见窗口和剩余能量等原始运行状态；区块链平台核心层承担全局状态存证、

轻量级共识维护、任务事件上链、策略结果追踪以及多源日志审计等功能，是平台实现可信协同的中枢；双层智能决策层对应本文前两章提出的系统层区块链增强多智能体协同资源分配方法与任务层联邦强化学习并发感知卸载方法，分别面向全局资源编排和局部任务决策提供策略输出；应用与管理层则面向应急遥感、星座协同处理、任务监管与可视化运维等场景，实现平台能力的业务化承载。

上述四层结构的关键不在于层次划分本身，而在于其形成了由”状态感知—链上同步—联合决策—执行反馈”构成的运行闭环。基础设施层产生的动态环境状态首先进入链上治理与共享过程，随后被系统层与任务层决策模块共同利用；决策结果再以调度指令、资源约束和执行策略的形式回写至任务执行侧，并通过链上审计机制形成后验反馈。




图 5.1 面向天基协同计算的区块链平台总体架构图

在网络映射方面，平台将天基协同网络抽象为时变有向图，并据此区分共识维护节点与普通业务节点。定义时刻 t 的天基协同网络为时变有向图

$$\mathcal{G}(t) = (\mathcal{V}, \mathcal{E}(t)),$$

其中，节点集合 $\mathcal{V}$ 表示参与天基协同计算与区块链维护的星地节点集合，边集合 $\mathcal{E}(t)$ 表示随时间变化的星间或星地通信连接关系。进一步将节点划分为负责区块打包、共识验证与全局状态定序的共识节点集合 $\mathcal{C}$ ，以及负责发起任务请求、状态上报和局部

决策的普通节点集合 $\mathcal{L}$ ，满足

$$\mathcal{C} \subseteq \mathcal{V}, \quad \mathcal{L} = \mathcal{V} \setminus \mathcal{C}.$$

进一步地，为避免平台层建模停留于纯粹的网络拓扑抽象，本文借鉴支撑项目中的天基网络试验任务调度思想，将平台中的任务—资源映射进一步表述为

$$\text{SNEMS} = \{T, R, X, F\}$$

的四元组决策空间。其中， T 表示待调度任务集合， R 表示由平台集、载荷集、窗口集和执行时机构成的资源集合， X 表示任务—资源决策矩阵， F 表示由硬约束与收益函数构成的评价集合。该定义的作用不在于替代第 2 章的系统模型，而在于为第 5 章的“平台化实现补充”任务如何进入区块链治理框架、资源如何进入系统层动作空间、局部决策如何受全局约束”的统一表达接口。

分层链组织与运行接口。在平台运行过程中，不同类型的业务事件在频率、时延需求和安全等级方面存在明显差异。结合项目中已有的分层联盟链方案，平台将链结构划分为主链层、子链层和链下设备层。其中，主链负责任务调度、全局状态摘要、日志摘要及关键治理信息维护；子链负责特定区域、特定业务或特定任务类型的数据存证与协同；链下设备层负责原始数据、模型参数和大对象日志的缓存与对象化存储。

从节点角色看，平台可进一步区分为共识节点与非共识节点。主链共识节点负责区块打包、交易校验和全局广播；子链共识节点负责局部数据验证与存证；非共识节点主要承担任务接入、数据采集、状态上报和链下存储等功能。这一划分与项目中的主链—子链—边缘设备设计保持一致，有助于在可信性与资源开销之间取得平衡。

进一步地，设平台在时刻 t 的全局状态为 $S^{(t)}$ ，则在新区块 B_h 经过共识确认后，平台可通过状态转移函数 $\Gamma(\cdot)$ 完成状态更新：

$$S^{(t+1)} = \Gamma(S^{(t)}, B_h, \Omega_{\text{rules}}),$$

其中， Ω_{rules} 表示平台治理规则与约束集合，其内部可映射第 3 章系统层协同策略所给出的全局资源边界、节点信誉约束和任务处理规则。

平台在区块链核心层之上提供统一的状态共享与约束传递接口。系统层输出的资源占用上界、节点可调度集合及链路可用区间，将作为任务层决策的外部约束输入；任务层在执行过程中产生的排队时延、任务成功率、资源消耗和异常事件等结果，则

进一步回流至链上状态空间，为后续系统层迭代提供反馈依据。

在应用与管理侧，平台进一步提供任务管理、服务部署与迁移、模型版本管理、运行监控、日志分析、审计查询和策略展示等能力，为前文方法提供可观测、可分析和可配置的统一支撑环境。

图5-2 平台分层链结构设计图

强调业务解耦、效率与安全平衡




图 5.2 平台分层链结构设计图

5.3 区块结构、数据流转与存证机制

分层联盟链与链上/链下协同设计。传统公有链普遍采用工作量证明等高消耗共识机制，但该类机制难以适应天基网络环境下节点算力受限、能量预算紧张和业务时延敏感的实际约束。对于本文研究场景而言，平台更适合采用许可制联盟链结构，仅允许经过授权的卫星边缘节点、控制节点和少量高可信节点参与账本维护与交易验证，以减少无效竞争开销。

在具体机制选择上，权威证明和委托权益证明是两类较为适合的候选方案。权威证明依赖授权节点轮流出块，适合作为平台初始部署阶段的基础方案；委托权益证明则在保持较高效率的同时，引入代表节点选举机制，可结合节点信誉值、历史贡献度和服务能力动态调整记账节点集合，更适合平台进入稳定运行后的自治演进场景。

区块结构与链上/链下协同。结合项目中的主链—子链设计，平台继承主链与子链的差异化区块结构。主链区块主要承载任务元数据、跨链摘要、治理规则、资源分配摘要与审计索引；子链区块主要承载业务域内的试验数据摘要、任务状态与局部日

志记录。主链更强调调度与治理，子链更强调业务数据存证与局部协同。

在链上/链下协同方面，平台采用“链上保存摘要、链下保存实体对象”的分层管理方式。链上主要保存任务标识、状态摘要、模型版本哈希、审计索引、合约结果和关键治理规则等小体积但高价值的信息；链下则保存任务原始输入、完整模型参数、服务镜像和详细日志等大规模对象。链上记录通过哈希指针与链下对象建立映射关系，当节点需要访问链下数据时，可通过对比其哈希值验证对象的一致性与完整性。

结合项目文件中的分层联盟链与跨链网关设计，链上/链下协同机制还可进一步细化为“子链局部存证 + 主链摘要锚定”的双层存储流程。具体而言，任务执行过程中形成的原始数据、模型参数与详细日志首先保存在链下对象存储或边缘服务集群中，子链仅记录其哈希摘要和过程状态；跨链网关随后将子链摘要提交至主链进行全局锚定。

若记某一业务子链上的区块为 B_s ，其保存的核心内容可抽象表示为

$$B_s = \{D_{\text{hash}}, H(B_s^-), H(B_s)\},$$

主链在接收跨链网关提交的摘要后，将对应锚定区块记为

$$B_m = \{H(B_s), H(B_m^-), H(B_m)\}.$$

这一设计能够在不显著增加链上存储压力的前提下，为数据完整性与跨域可验证性提供密码学支撑。

数据流转、存证流程与可信执行。在数据流转方面，平台沿用项目中“任务基础信息生成与广播—资源与数据信息管理—数据存储与验证—跨链接入与调度管理”的处理链路。具体而言，任务基础信息首先在主链层生成并广播，随后任务需求资源、试验数据和日志信息根据业务类型进入对应子链；大规模原始对象保存在链下，由子链记录摘要并通过跨链网关上传主链锚定。

进一步地，项目中的数据存证流程可为本章平台提供直接的工程实现参考。在数据写入过程中，客户端先向主链发起请求并完成身份与权限校验，随后由跨链网关按照路由转发至对应数据子链；子链完成写入后，将隐私数据哈希、存储位置和过程摘要回传主链存证。在数据读取过程中，主链先完成身份与权限确认，再由跨链网关访问对应子链并返回数据结果与哈希校验信息。由此，项目中的主链—子链—跨链网关—链下对象存储流程，正好为本章平台中的任务状态存证、模型版本锚定和执行日志

回写提供了工程模板。

在分布式天基环境下，仅依赖人工配置和静态规则难以保证协同过程的持续稳定运行。为了将任务流转、模型治理和安全约束等关键逻辑由”人为约束”转化为”规则自动执行”，本文在平台中引入智能合约治理机制。任务管理合约用于完成任务注册、参数校验、任务接纳确认、执行开始记录、完成结果写回以及结算与奖惩触发；模型版本管理合约用于登记第 4 章联邦学习并发开销预测模型与第 3 章系统层策略模型的版本号、参数哈希、性能摘要和更新时间等内容。

进一步地，考虑到第 4 章中的联邦学习模型需要在多节点条件下持续演化，平台可将节点信誉值纳入模型聚合过程。即在完成本地训练后，各节点仅提交参数摘要、版本信息及必要的聚合索引，链下完成模型参数交换，链上则记录版本登记与合法性校验结果；对于信誉值持续偏低或存在异常行为的节点，其提交的聚合权重可被削弱或拒绝，从而增强模型治理的可靠性。

5.4 双层智能方法的平台映射与运行闭环

系统层与任务层方法的平台映射。第 3 章提出的基于区块链与多智能体强化学习的系统层协同资源分配方法，主要面向全局尺度下的资源竞争与协同优化问题。在平台化实现中，该方法被映射为双层智能决策层中的系统层控制模块，其核心职责不再是单纯输出离线策略，而是持续接收链上共享状态并对全局资源边界进行动态更新。

具体而言，平台通过区块链核心层维护节点负载摘要、可用算力信息、链路质量指标、历史信誉状态以及任务分布统计结果等公共环境变量。系统层智能体在此基础上依据马尔可夫博弈框架进行策略更新，并形成资源分配建议、节点协同关系和服务能力边界等结果。这些结果并不直接替代任务层决策，而是以资源约束、候选集优先级和协同调度边界的形式向下传递。

在任务层，第 4 章提出的并发感知卸载方法被映射为局部实时决策模块，其输入由任务属性、本地节点状态、候选节点共享状态、系统层约束边界以及联邦学习模型预测结果共同构成。联邦学习预测模型的版本信息和参数摘要由模型版本管理合约统一维护，任务层节点在调用模型前可通过链上查询确认其版本合法性，并对模型参数进行哈希校验，从而保证预测输入来源可信。

状态—动作—存证—反馈闭环。为了更清晰地描述平台中双层智能决策的运行逻辑，本文将平台核心流程抽象为”状态—动作—存证—反馈”闭环机制。设平台在时

刻 t 的联合状态表示为

$$S(t) = \{S_{\text{sys}}(t), S_{\text{task}}(t), S_{\text{chain}}(t)\},$$

其中, $S_{\text{sys}}(t)$ 表示系统层公共状态, $S_{\text{task}}(t)$ 表示任务层局部状态, $S_{\text{chain}}(t)$ 表示链上共享状态。

系统层根据联合状态生成资源协同动作 $a_{\text{sys}}(t)$, 任务层结合局部状态与系统层约束生成卸载动作 $a_{\text{task}}(t)$ 。因此, 平台在时刻 t 的联合动作可表示为

$$A(t) = \{a_{\text{sys}}(t), a_{\text{task}}(t)\}.$$

在动作执行后, 平台通过智能合约将关键行为记录为链上事件集合

$$E(t) = \{e_{\text{start}}(t), e_{\text{end}}(t), e_{\text{model}}(t), e_{\text{audit}}(t)\}.$$

在反馈阶段, 任务执行所产生的时延、能耗、资源占用变化和任务完成质量等结果被汇聚为反馈向量 $F(t)$, 并用于更新下一时刻的平台状态, 即

$$S(t+1) = \Phi(S(t), A(t), E(t), F(t)).$$




图 5.3 平台状态—动作—存证—反馈闭环运行机制图

资源审计、身份控制与信誉评估。第 3 章提出的系统层多智能体强化学习方法输出的是全局资源协同结果, 而第 4 章任务层方法则面向单任务到达瞬间做出局部动作选择。为了避免两层决策彼此割裂, 平台需要建立从系统层到任务层的约束传递机

制。为此，平台可将系统层输出的协同动作表示为 A_{sys} ，并进一步映射为面向任务层的局部约束集合 C_{limit} 。当单任务到达并触发任务层深度强化学习决策时，其可行动作空间可表示为

$$A'_{\text{task}} = A_{\text{task}} \cap C_{\text{limit}}.$$

在身份认证方面，平台采用联盟链白名单准入机制，仅允许经过授权的节点参与网络；并通过数据访问授权与合约调用授权，限制不同角色对任务信息、试验数据、模型版本与治理合约的操作权限。该部分直接继承了项目中已有的身份管理与访问控制思路。

在资源审计与信誉评估方面，平台持续记录节点的资源声明、任务接纳情况、实际执行结果和历史服务质量，并结合审计规则对其一致性进行检查。设节点 i 在时间窗 τ 内的信誉值为 $R_i(\tau)$ ，则其更新可表示为

$$R_i(\tau) = \alpha R_i(\tau - 1) + (1 - \alpha) \sum_{k \in T_i} I(\text{link}_k) \omega_k \varphi(k),$$

其中， $\alpha \in (0, 1)$ 为历史遗忘因子， ω_k 为任务重要度权重， $\varphi(k)$ 表示任务 k 的执行评价项， $I(\text{link}_k)$ 为链路状态感知因子，用于刻画任务执行期间对应星间或星地链路是否处于可见且可通信状态。

5.5 平台运行流程、工程分析与本章小结

平台运行流程。为进一步展示平台的数据流转机制，本节结合灾害应急多星协同计算场景，对双层智能方法在平台中的运行逻辑进行说明。系统初始阶段，各卫星节点同步包含全局负载摘要与模型版本哈希的最新区块头，并结合本地缓存完成运行状态初始化。当高密度遥感图像识别任务在某一低轨卫星节点产生后，任务层首先提取局部状态，并从链下模型库获取当前有效模型参数，通过模型版本管理合约完成哈希一致性校验。在模型合法性得到确认后，任务层深度强化学习模块输出具体卸载动作。

随后，任务请求进入平台合约处理流程。跨层约束机制将依据系统层资源协同结果判断目标节点是否仍处于允许接纳任务的资源边界之内。若满足约束条件，则平台生成任务开始事件并记录相应状态；若不满足，则任务需重新选择候选节点或回退至本地执行。待任务执行结束后，系统将时延、能耗和完成质量等结果封装为反馈信息写回平台，并同步完成链上存证、信誉结算和样本沉淀。

模型更新与版本治理过程中，各节点基于本地任务样本开展联邦训练，聚合后的新模型由版本管理合约登记其版本号、参数哈希与性能摘要。平台还可在检测到局部区域出现任务热点、节点拥塞或服务失衡时，触发服务部署与迁移流程，以保持系统能力分布的动态均衡。

平台项目对前文方法的支撑作用。从全文结构看，本章引入平台项目的目的，在于把前文分散于模型、算法和决策层的研究内容串联起来。第2章给出了天基协同计算的系统模型与状态约束，第3章提出了基于区块链与多智能体强化学习的系统层协同资源分配方法，第4章提出了基于联邦学习与深度强化学习的任务层并发感知卸载方法；而本章则依托项目中已完成的分层联盟链、主链—子链区块结构、跨链网关、数据流转与存证流程、以及身份与访问控制等设计，为这些方法提供统一的工程承载环境。

工程可行性分析。为进一步验证本文所设计区块链平台架构在天基动态环境下的可行性，本文结合 STK 生成星座轨道与可见性关系，并利用 NS-3 构建网络层通信仿真环境。仿真重点关注平台在共识开销、存储增长和异常节点隔离等方面的运行特性，以检验平台对前文双层智能方法的承载能力。

评估指标主要包括确认时延、存储开销增长以及信誉驱动的异常节点隔离效果等。通过上述配置，可以从“吞吐与时延”“存储可持续性”“异常治理能力”三个维度对平台工程适应性进行考察。综合结果表明，平台在吞吐能力、确认时延、存储控制和异常治理等方面均表现出较好的工程适应性。

本章小结。综合上述分析可以看出，本章所设计的平台并非对前文算法的简单附属说明，而是依托已完成的平台项目，将系统建模、系统层协同优化与任务层实时决策统一到一个可运行、可验证、可审计的工程框架中。其中，项目中已有的分层联盟链、主链—子链区块结构、跨链网关、数据流转与存证流程、以及身份与访问控制等设计，为平台的可信状态同步、任务行为存证、模型版本治理和执行反馈闭环提供了直接支撑；而第3章和第4章提出的双层智能方法，则在这一平台上完成了从算法层到系统层的落地映射。由此，本文实现了从系统模型、算法设计到平台实现的研究链条闭合，也使第五章真正承担起“用平台项目把前几章串起来”的作用。

结论

本文围绕天基网络环境下计算卸载过程中存在的可信共享不足、系统层协同困难以及任务层并发开销难以准确感知等问题，构建了“系统层可信协同—任务层并发感知卸载”的分层研究框架。前文分别从系统层协同资源分配方法、任务层并发开销预测与卸载决策方法两个层面展开了建模、算法设计与实验验证，形成了较为完整的研究链条。

从研究内容上看，本文的主要工作包括以下几个方面：其一，围绕天基网络动态拓扑、异构资源与去中心化协同需求，分析了计算卸载问题的关键约束与研究挑战，并建立了统一的系统模型与问题描述框架；其二，针对多节点协同过程中状态共享不可信、资源竞争失衡等问题，研究了基于区块链与多智能体强化学习的系统层协同资源分配方法，以提升资源利用率、负载均衡性与长期协同稳定性；其三，针对多任务并发条件下传统静态代价模型难以准确反映真实执行开销的问题，研究了基于联邦学习与深度强化学习的任务层计算卸载方法，通过引入并发开销预测机制提升节点侧决策的前瞻性与适应性。

总体而言，本文的研究表明：在天基网络计算卸载场景中，仅依赖单一层面的优化方法难以同时兼顾系统全局协同效率与任务局部执行性能；通过将区块链可信共享、多智能体强化学习、联邦学习以及深度强化学习进行分层耦合，可以在一定程度上缓解高动态环境中的状态不一致、资源竞争与代价失真等问题，为后续构建智能化、可信化的天基协同计算体系提供了方法参考。

需要说明的是，本文目前重点完成了方法框架、关键模型与阶段性实验部分的研究与整理。关于更大规模场景下的系统级综合实验、不同轨道层条件下的参数敏感性分析以及工程化部署细节，仍可在后续工作中进一步补充和完善。未来研究可继续围绕以下方向展开：一是进一步完善面向多星异构环境的统一实验平台与对比验证体系；二是增强模型对链路剧烈波动、节点失效和异常行为的鲁棒性；三是探索更适用于天基网络复杂业务场景的轻量化智能决策方法与可信协同机制。

参考文献

- [1] Kodheli O, Lagunas E, Maturo N, et al. Satellite Communications in the New Space Era: A Survey and Future Challenges[J]. IEEE Communications Surveys & Tutorials, 2021, 23(1): 70-109.
- [2] Liu J, Mao Y, Zhang J, et al. Delay-Optimal Computation Task Scheduling for Mobile-Edge Computing Systems[J]. IEEE Transactions on Wireless Communications, 2018, 17(5): 3400-3412.
- [3] Nakamoto S. Bitcoin: A Peer-to-Peer Electronic Cash System[J]. Bitcoin Whitepaper, 2008.
- [4] Tan L T, Hu R Q, Hanzo L. A Survey on Physical Layer Security for 5G Wireless Networks[J]. IEEE Communications Surveys & Tutorials, 2015, 17(3): 1242-1258.
- [5] Ousterhout K, Rasti R, Ratnasamy S, et al. Making Sense of Performance in Data Analytics Frameworks[J]. Proceedings of the 12th USENIX Symposium on Networked Systems Design and Implementation, 2015: 293-307.
- [6] Y G, Z J, K Z, et al. Game-Based Computation Offloading and Power Allocation for LEO Constellation Networks in Distributed and Dynamic Environment[J]. IEEE Internet of Things Journal, 2024, 11(4): 7040-7058.
- [7] Y T, N C, L Z, et al. Task Offloading and Resource Allocation for Satellite-Terrestrial Integrated Networks[J]. IEEE Transactions on Communications, 2024, 72(12): 7840-7855.
- [8] Kang J, Yu R, Huang X, et al. Blockchain for Internet of Things: Architecture, Applications and Challenges[J]. IEEE Internet of Things Journal, 2019, 6(5): 8106-8123.
- [9] Bonawitz K, Eichner H, Grieskamp W, et al. Towards Federated Learning at Scale: System Design[J]. Proceedings of Machine Learning and Systems, 2019, 1: 374-388.
- [10] X W, H L, Y Z, et al. Computation Offloading and Resource Allocation in Satellite Edge Computing Networks: A Multi-Agent Reinforcement Learning Approach[J]. Computer Networks, 2025, 272: 111680.
- [11] M J, J W, L Z, et al. Federated Deep Reinforcement Learning Based Computation Offloading in a Low Earth Orbit Satellite Edge Computing System[J]. Frontiers of Information Technology & Electronic Engineering, 2025, 26(6): 805-815.
- [12] M S, J H, K Q, et al. LLM-Based Task Offloading and Resource Allocation in Satellite Edge Computing Networks[J]. IEEE Transactions on Vehicular Technology, 2026, 75(3): 5262-5267.
- [13] Kshetri N. Blockchain's Roles in Meeting Key Supply Chain Management Objectives[J]. International Journal of Information Management, 2018, 39: 80-89.
- [14] J W, M J, Q G, et al. Multi-Agent Deep Reinforcement Learning-Based Offloading Computation in LEO Satellite Networks[C]. Proceedings of IEEE VTC 2025-Spring. 2025: 1-6.

- [15] A H, V C J, H S. Multi Agent Reinforcement Learning for Sequential Satellite Assignment Problems [C]. Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-25): vol. 39. 2025.
- [16] Z C, L W, J L, et al. Spatiotemporal-Aware Multi-Agent Reinforcement Learning for Revisit-Oriented Multi-Satellite Observation Task Scheduling[J]. Applied Sciences, 2026, 16(6): 2685.
- [17] J H D, S H, J L D, et al. Cooperative Federated Learning over Ground-to-Satellite Integrated Networks: Joint Local Computation and Data Offloading[J]. IEEE Journal on Selected Areas in Communications, 2024, 42(5): 1080-1096.
- [18] Mnih V, Kavukcuoglu K, Silver D. Playing Atari with Deep Reinforcement Learning[J]. arXiv preprint arXiv:1312.5602, 2013.
- [19] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous Control with Deep Reinforcement Learning[J]. arXiv preprint arXiv:1509.02971, 2015.
- [20] Huang L, Bi S, Zhang Y A. Deep Reinforcement Learning for Online Computation Offloading in Mobile Edge Computing[J]. IEEE Transactions on Mobile Computing, 2020, 19(11): 2581-2593.
- [21] Z L, X C, Y W, et al. Blockchain-Aided Digital Twin Offloading Mechanism in Space-Air-Ground Networks[J]. IEEE Transactions on Mobile Computing, 2025, 24(1): 1-16.
- [22] L X, H Z, Y L, et al. StarCross: Redactable Blockchain-Based Secure and Lightweight Data Sharing Framework for Satellite-Based IoT[J]. Computer Networks, 2024, 253: 110718.
- [23] Dorri A, Kanhere S S, Jurdak R. Blockchain in Internet of Things: Challenges and Solutions[J]. Future Generation Computer Systems, 2018, 88: 173-190.
- [24] W W, Z S, Q Z, et al. A Sharded Blockchain-Based Secure Federated Learning Framework for LEO Satellite Networks[Z]. arXiv preprint arXiv:2411.06137. 2024.
- [25] Wang J, Liu Y, Song B, et al. Intelligent Resource Allocation for Co-Locating Latency-Sensitive Services[J]. IEEE/ACM Transactions on Networking, 2018, 26(5): 2225-2238.
- [26] Foerster J, Farquhar G, Afouras T, et al. Counterfactual Multi-Agent Policy Gradients[J]. arXiv preprint arXiv:1705.08056, 2017.
- [27] H Z, Y L, S C, et al. Federated learning-based ISAC network in cohesive clustered satellite networks [J]. Science China Information Sciences, 2025, 68(3): 132301.
- [28] Z C, S Y, Y D, et al. FedLEO: An Offloading-Assisted Decentralized Federated Learning Framework for Low Earth Orbit Satellite Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(5): 5260-5279.
- [29] Dinh T T A, Liu R, Zhang M, et al. Untangling Blockchain: A Data Processing View of Blockchain Systems[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(7): 1366-1385.
- [30] Saad M M, Tariq M A, Khan M T R, et al. Non-Terrestrial Networks: An Overview of 3GPP Release 17 & 18[J]. IEEE Internet of Things Magazine, 2024, 7(1): 20-26.

- [31] Wang F, Zhang S, Yang H, et al. Non-Terrestrial Networking for 6G: Evolution, Opportunities, and Future Directions[J]. Engineering, 2025, 54: 56-68.
- [32] Mahboob S, Liu L. Revolutionizing Future Connectivity: A Contemporary Survey on AI-Empowered Satellite-Based Non-Terrestrial Networks in 6G[J]. IEEE Communications Surveys & Tutorials, 2024, 26(2): 1279-1321.
- [33] Yin Z, Wu C, Guo C, et al. A Comprehensive Survey of Orbital Edge Computing: Systems, Applications, and Algorithms[J]. Chinese Journal of Aeronautics, 2025, 38(7): 103316.
- [34] Huang T, Fang Z, Tang Q, et al. Integrated Computing and Networking for LEO Satellite Mega-Constellations: Architecture, Challenges and Open Issues[J]. IEEE Wireless Communications, 2024, 31(5): 92-100.
- [35] Zhai Z, Zeng L, Ouyang T, et al. SECO: Multi-Satellite Edge Computing Enabled Wide-Area and Real-Time Earth Observation Missions[C]. Proceedings of IEEE INFOCOM 2024. 2024: 2548-2557.
- [36] Qu Y, Dai H, Wang X, et al. End-to-End Task Offloading and Resource Allocation in Satellite-Terrestrial Edge Computing Networks[J]. IEEE Transactions on Wireless Communications, 2024, 23(8): 9224-9238.
- [37] Zhao D, Ding R, Song B. Satellite-assisted 6G Wide-Area Edge Intelligence: Dynamics-Aware Task Offloading and Resource Allocation for Remote IoT Services[J]. Science China Information Sciences, 2025, 68: 122303.
- [38] Sun M, Hou J, Qiu K, et al. LLM-Based Task Offloading and Resource Allocation in Satellite Edge Computing Networks[J]. IEEE Transactions on Vehicular Technology, 2026, 75(3): 5262-5267.
- [39] Tang Q, Xie R, Fang Z, et al. Joint Service Deployment and Task Scheduling for Satellite Edge Computing: A Two-Timescale Hierarchical Approach[J]. IEEE Journal on Selected Areas in Communications, 2024, 42(5): 1063-1079.
- [40] Zhang X, Liu J, Zhang R, et al. Energy-Efficient Computation Peer Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(4): 3077-3091.
- [41] Zhou J, Yang Q, Zhao L, et al. Mobility-Aware Computation Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(10): 9135-9149.
- [42] Feng C, Yang M, Jing Z, et al. Latency-Aware Service Deployment and Peer Offloading: A Long-Term Optimization Framework for Satellite Edge Computing[J]. IEEE Internet of Things Journal, 2026, 13(1): 405-417.
- [43] Fan W, Meng Q, Wang G, et al. Satellite Edge Intelligence: DRL-Based Resource Management for Task Inference in LEO-Based Satellite-Ground Collaborative Networks[J]. IEEE Transactions on Mobile Computing, 2025, 24(10): 10710-10728.

- [44] Zhong L, Li Y, Ge M F, et al. Joint Task Offloading and Resource Allocation for LEO Satellite-Based Mobile Edge Computing Systems With Heterogeneous Task Demands[J]. IEEE Transactions on Vehicular Technology, 2025, 74(7): 11337-11352.
- [45] Liu S, Zhang Z, Zeadally S. Device-satellite-satellite Collaborative Task Offloading Computing and Resource Allocation in 6G Satellite-Ground Edge Computing Network[J]. Computer Networks, 2026, 274: 111871.
- [46] Li H, Yu J, Cao L, et al. Multi-agent Reinforcement Learning Based Computation Offloading and Resource Allocation for LEO Satellite Edge Computing Networks[J]. Computer Communications, 2024, 222: 268-276.
- [47] Xiu Q, Liu J, Liu X, et al. Computation Offloading and Resource Allocation in Satellite Edge Computing Networks: A Multi-Agent Reinforcement Learning Approach[J]. Computer Networks, 2025, 272: 111680.
- [48] Rao Z, Zhu Z, Yao Y, et al. Computation-Offloading Optimization for Satellite Edge Computing via Diffusion and Lyapunov-Based Deep Reinforcement Learning[J]. IEEE Internet of Things Journal, 2025, 12(18): 37747-37762.
- [49] Zhang H, Zhao H, Liu R, et al. Collaborative Task Offloading Optimization for Satellite Mobile Edge Computing Using Multi-Agent Deep Reinforcement Learning[J]. IEEE Transactions on Vehicular Technology, 2024, 73(10): 15483-15498.
- [50] Matthiesen B, Razmi N, Leyva-Mayorga I, et al. Federated Learning in Satellite Constellations[J]. IEEE Network, 2024, 38(2): 232-239.
- [51] Tan M, Marwah M. Multiagent Reinforcement Learning in Sequential Social Dilemmas[J]. Proceedings of the 16th International Conference on Autonomous Agents and Multiagent Systems, 2016: 464-473.

附录 A

仿真参数与环境配置

本附录用于补充正文实验部分未展开列出的参数设置与环境说明，便于对本文方法的实验条件进行统一说明与后续复现实验。实验环境主要围绕天基网络计算卸载场景进行构建，涉及卫星终端、卫星边缘节点、链路参数、任务到达过程以及算法超参数等多个方面。对于不同实验场景，可在统一参数基线的基础上对节点规模、任务强度、链路时延与负载水平进行适当调整。

在系统参数设置方面，可重点说明卫星节点数量、节点计算能力范围、任务输入规模、任务计算量分布、链路带宽区间、传播时延范围以及任务时延约束设置等内容；在算法参数设置方面，可进一步补充多智能体强化学习、联邦学习与深度强化学习相关的学习率、折扣因子、训练轮数、批大小与聚合周期等参数。对于实验中使用的评价指标，如平均时延、任务完成率、系统吞吐量、负载均衡度和能耗等，也可在附录中统一列出其统计口径与计算方式。

附录 B

关键模型推导与补充说明

本附录用于补充正文中为保持行文紧凑而未详细展开的模型推导过程与符号说明。针对系统层协同资源分配问题，可进一步给出状态变量、动作变量、奖励函数各分量以及约束条件之间的对应关系；针对任务层并发感知卸载问题，可补充并发开销定义、工程近似表达及其与综合代价函数之间的推导联系。

此外，对于文中涉及的关键符号、参数物理意义与公式适用条件，也可在本附录中进行集中说明，以增强模型表达的一致性与可读性。当后续章节补充完整实验内容后，本附录还可进一步加入复杂度分析、敏感性分析推导或部分中间证明过程，以形成与正文相互支撑的完整结构。

附录 C

附录内容说明

附录部分主要用于补充不宜在正文中大篇幅展开、但对理解论文研究过程和复现实验结果具有参考价值的材料。其内容通常包括但不限于以下几类：

1. 正文中为保证结构紧凑而省略的详细模型推导、符号说明与中间证明过程；
2. 实验平台配置、参数设置、数据生成规则与评价指标统计口径等支撑性材料；
3. 关键算法流程、训练细节、补充结果或扩展对比分析；
4. 对同行读者具有参考意义、但不适合直接纳入正文主体的技术性补充内容。

C.1 附录内容组织说明

为便于后续完善，附录可按照“实验参数补充—模型推导补充—结果说明补充”的结构逐步补全，并与正文中对应章节保持编号和引用关系的一致性。

C.1.1 后续补充建议

随着第五章、第六章内容的进一步完善，可将更具体的仿真参数表、额外实验图表及推导细节逐步整理至本附录中，以增强全文结构的完整性与学术表达的规范性。

攻读学位期间发表论文与研究成果清单

1. 暂无攻读学位期间发表论文与研究成果。

作者简介

本人为北京理工大学网络与信息安全专业硕士研究生，研究方向为区块链、卫星网络、计算卸载与智能优化。硕士阶段围绕天基网络环境下的可信数据管理、协同资源分配与任务级计算卸载问题开展学习与研究，重点关注区块链、联邦学习和强化学习等方法在分布式智能协同场景中的应用。

硕士学位论文不必提供作者简介。博士学位论文应该提供作者简介，主要包括：姓名、性别、出生年月、民族、出生地；简要学历、工作经历（职务）；攻读学位期间取得的其他研究成果或奖励。