

基于区块链的天基网络可信协同计算技术研究

姓名： ***

学号： *****

学院： 网络安全学院

2026 年 6 月



基于区块链的天基网络可信协同计算技术研究

*
*
*

北京理工大学

中图分类号: TQ028.1
UDC 分类号: 540
学校代码: 10007

★ 学生类型

☐ 工程硕博士专项

☐ 交叉研究方向

☐ 政府项目留学生

基于区块链的天基网络可信协同计算技术研究

作者姓名	***
二级培养单位	网络空间安全学院
指导教师	*****
行业合作导师	*****
答辩委员会主席	*****
申请类别	工学硕士
学位领域	网络与信息安全
学位授予单位	北京理工大学
论文提交日期	2026 年 6 月

Blockchain-Based Trusted Collaborative Computing Technology for Space-Based Networks

Candidate Name:	*****
School or Department:	School of Network Space Security
Faculty Mentor:	*****
Industry Collaboration Mentor:	*****
Chair, Thesis Committee:	*****
Degree Applied:	Master of Engineering
Major:	Network and Information Security
Degree by:	Beijing Institute of Technology
Submission date of the paper:	June, 2026

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的科研成果。文中所撰写内容符合以下学术规范（请勾选）：

☒ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☒ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☒ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☒ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☒ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签 名：

日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名：

日 期：

导师签名：

日 期：

致谢

基于区块链的天基网络可信协同计算技术研究

摘要：随着天地一体化信息网络、低轨卫星星座和在轨智能处理技术的发展，天基网络正由传统数据传输网络向集通信、计算、存储与智能处理于一体的分布式协同计算网络演进。卫星终端试验任务数据具有来源分散、链路受限、时效性强和过程需可信记录等特点，传统星地集中处理模式易受可见窗口、回传带宽和传输时延限制，单星本地处理又受算力、能量、存储和星间链路条件约束，难以持续支撑高并发、高动态任务的快速闭环处理。因此，本文拟解决的核心问题是：在高动态、资源受限和去中心化的天基网络环境中，如何在节点状态难以实时一致、资源竞争关系复杂、任务执行过程存在并发开销的条件下，实现可信、高效的多星协同计算卸载。

针对上述问题，本文围绕天基网络可信协同计算卸载需求，融合区块链、多智能体强化学习、联邦学习和深度强化学习等技术，形成“统一建模—系统层协同—任务层卸载决策”的研究主线。本文首先构建面向天基网络可信协同计算卸载的统一建模框架，明确节点、任务、链路、资源、区块链账本可信状态与执行反馈之间的关系；随后在统一模型下分别研究系统层协同资源分配方法和任务层并发感知计算卸载方法。本文主要研究内容如下：

（1）构建面向天基网络可信协同计算卸载的统一建模框架。针对天基网络节点异构、链路时变、任务随机到达和状态共享可信性不足等问题，本文建立包含卫星终端、卫星边缘节点、地面控制中心和区块链账本的协同计算模型，分别刻画节点资源、任务属性、链路传输、计算时延、能耗开销、节点信誉和任务生命周期记录过程。在此基础上，将总体协同计算卸载问题分解为系统层协同资源分配问题和任务层并发开销感知卸载问题，为后续方法设计提供统一符号体系、状态接口和优化目标。

（2）提出基于区块链与多智能体强化学习的系统层协同资源分配方法。针对去中心化天基环境中节点自利、信息不完全和资源竞争导致的负载失衡问题，本文将系统层资源分配建模为多智能体马尔可夫博弈，构建区块链增强的集中训练—分散执行协同决策框架。该方法利用联盟链维护节点负载、链路状态、信誉评分和历史行为等公共摘要，并设计融合任务完成质量、系统公平性与信誉激励的混合奖励机制，引导异构卫星节点在自治条件下实现稳定协同。结果表明，所提方法能够有效提升任务完成率和负载均衡水平，在典型负载场景下任务完成率达到 92.3%，Jain 公平指数达到 0.918；在高负载条件下仍能保持较高任务完成率，并有效降低平均任务时延。

(3) 提出基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法。针对多任务并发条件下 CPU 时间片、缓存、内存带宽和 I/O 队列竞争引发的隐性执行代价, 本文建立任务级并发开销模型, 将新任务自身计算时延以及新任务加入后对存量任务造成的剩余时延增加统一纳入代价刻画, 并构建“聚类式联邦学习预测 + DQN 卸载决策”的闭环机制。该方法在不上传原始任务日志的前提下, 通过聚类式联邦学习训练并发开销预测模型, 并将预测结果、本地状态和区块链账本维护的可信公共摘要共同输入深度 Q 网络, 使卫星终端能够在状态时滞和节点数据异构条件下完成具备并发开销前瞻能力的卸载决策。结果表明, 在高并发场景下, 所提 FL-DQN 方法的平均任务时延为 256 ms, SLA 完成率达到 84.7%, 优于 DQN-only、FL-only 和启发式卸载策略。

综上, 本文围绕高动态天基网络中的可信协同计算卸载问题, 形成了“统一建模—系统层协同—任务层卸载决策”的研究体系, 可为资源受限条件下天基网络任务处理效率、自治协同能力和可信运行水平提升提供理论依据与方法支撑。

关键词: 区块链; 卫星网络; 强化学习; 计算卸载; 联邦学习

Blockchain-Based Trusted Collaborative Computing Technology for Space-Based Networks

Abstract: With the development of space-ground integrated information networks, low Earth orbit satellite constellations, and on-orbit intelligent processing technologies, space-based networks are evolving from traditional data transmission networks into distributed collaborative computing networks integrating communication, computation, storage, and intelligent processing. Satellite terminal test task data are characterized by distributed sources, constrained links, strict timeliness requirements, and the need for trustworthy process recording. Traditional space-ground centralized processing is limited by visibility windows, feeder link bandwidth, and transmission latency, while single-satellite local processing is constrained by onboard computing capability, energy, storage, and inter-satellite link conditions. Therefore, this thesis focuses on the following core problem: how to achieve trustworthy and efficient multi-satellite collaborative computation offloading in highly dynamic, resource-constrained, and decentralized space-based networks where node states are difficult to keep consistent in real time, resource competition is complex, and concurrent execution introduces concurrency overhead.

To address this problem, this thesis studies trusted collaborative computation offloading for space-based networks by integrating blockchain, multi-agent reinforcement learning, federated learning, and deep reinforcement learning. The research follows a unified line of “unified modeling–system-layer collaboration–task-layer offloading decision-making”. A unified modeling framework is first established to describe nodes, tasks, links, resources, blockchain-based trusted states, and execution feedback. Based on this framework, the system-layer collaborative resource allocation problem and the task-layer concurrency-aware computation offloading problem are further investigated. The main contributions are as follows.

(1) A unified modeling framework for trusted collaborative computation offloading in space-based networks is constructed. Considering node heterogeneity, time-varying links, random task arrivals, and insufficient trustworthiness of state sharing, a collaborative computation model is established, including satellite terminals, satellite edge nodes, the ground control center, and the blockchain-based trusted control plane. Node resources, task attributes,

link transmission, computation delay, energy consumption, node reputation, and task life-cycle recording are modeled. The overall offloading problem is then decomposed into a system-layer collaborative resource allocation problem and a task-layer concurrency-aware offloading problem, providing a unified notation system, state interface, and optimization objective for subsequent method design.

(2) A blockchain and multi-agent reinforcement learning based system-layer collaborative resource allocation method is proposed. To address load imbalance caused by selfish node behavior, incomplete information, and resource competition in decentralized space environments, the system-layer resource allocation problem is modeled as a multi-agent Markov game. A blockchain-enhanced centralized training and decentralized execution framework is constructed. The consortium blockchain maintains public summaries such as node load, link status, reputation scores, and historical behaviors. A hybrid reward mechanism incorporating task completion quality, system fairness, and reputation incentives is designed to guide heterogeneous satellite nodes toward stable collaboration under autonomous execution. Experimental results show that the proposed method effectively improves task completion rate and load balancing performance. In a typical load scenario, the task completion rate reaches 92.3%, and the Jain fairness index reaches 0.918.

(3) A cluster-based federated learning and DQN based concurrency-aware task-layer computation offloading method is proposed. To characterize the hidden execution costs caused by CPU time slicing, cache conflicts, memory bandwidth contention, and I/O queue competition under multi-task concurrency, a task-level concurrency overhead model is established, where both the delay of the newly offloaded task and the increased remaining delay of existing tasks are incorporated. A closed-loop mechanism combining cluster-based federated learning based prediction and DQN based offloading decision-making is then designed. The proposed method trains concurrency overhead prediction models through clustered federated learning without uploading raw task logs, and feeds the predicted overhead, local state, and on-chain public summaries maintained by the blockchain ledger into a deep Q-network. As a result, satellite terminals can make forward-looking offloading decisions under delayed states and heterogeneous node data distributions. Experimental results show that, in high-concurrency scenarios, the proposed FL-DQN method achieves an average task delay of 256

ms and an SLA completion rate of 84.7%, outperforming DQN-only, FL-only, and heuristic offloading strategies.

In summary, this thesis forms a research system of “unified modeling–system-layer collaboration–task-layer offloading decision-making” for trusted collaborative computation offloading in highly dynamic space-based networks. The research provides theoretical foundations and methodological support for improving task processing efficiency, autonomous collaboration capability, and trusted operation in resource-constrained space-based networks.

Key Words: Blockchain; Satellite Network; Reinforcement Learning; Computing Offloading; Federated Learning

目次

1	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状	3
1.2.1	天基网络计算卸载与轨道边缘计算研究现状	4
1.2.2	区块链辅助的可信状态共享与协同调度研究现状	6
1.2.3	智能优化驱动的多节点资源分配与任务卸载研究现状	7
1.3	本文主要研究内容	8
1.4	论文结构安排	9
2	相关理论与技术基础	11
2.1	天基网络与计算卸载技术	11
2.1.1	天基网络的层级架构与链路特性	11
2.1.2	计算卸载基本范式	12
2.1.3	深度强化学习在卸载决策中的应用	13
2.2	区块链与可信协同技术	14
2.2.1	联盟链与共识机制	14
2.2.2	可信状态共享与节点信誉	15
2.2.3	区块链辅助的多方协同范式	15
2.3	联邦学习与聚类联邦学习	16
2.3.1	FedAvg 算法与基本流程	16
2.3.2	数据异质性挑战与聚类联邦学习	17
2.3.3	区块链辅助的联邦学习	17
2.4	多智能体强化学习与协同决策	18
2.4.1	多智能体马尔可夫决策过程	18
2.4.2	集中训练分散执行范式	19
2.4.3	协同决策中的奖励设计与扩展性	20
2.5	本章小结	20

3	天基网络可信协同计算卸载场景与基础建模	22
3.1	引言	22
3.2	天基网络可信协同计算卸载场景	22
3.3	系统基础模型	25
3.3.1	网络拓扑模型	26
3.3.2	节点资源模型	26
3.3.3	任务模型	27
3.3.4	链路传输模型	28
3.3.5	本地计算与星间卸载模型	28
3.3.6	联盟链结构与区块结构	30
3.3.7	链上状态摘要模型	32
3.4	本章小结	33
4	基于区块链与多智能体强化学习的系统层协同资源分配方法	34
4.1	引言	34
4.2	系统框架	37
4.2.1	系统组成	37
4.2.2	公共信息板与协同流程	39
4.2.3	协同难点	40
4.3	多智能体马尔可夫博弈建模	40
4.3.1	问题形式化	41
4.3.2	状态、动作与奖励	42
4.3.3	约束与性质分析	46
4.4	算法设计	47
4.4.1	链上共享与信誉反馈	48
4.4.2	CTDE-MAPPO 框架	51
4.4.3	策略表示与参数更新	53
4.4.4	训练与执行流程	54
4.5	实验分析	54
4.5.1	实验设置	55

4.5.2	收敛性分析	56
4.5.3	性能对比	57
4.5.4	规模与时延敏感性分析	59
4.5.5	消融分析	59
4.5.6	鲁棒性与敏感性分析	61
4.5.7	结果讨论	62
4.6	本章小结	63
5	基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法	64
5.1	引言	64
5.2	系统框架与问题建模	67
5.2.1	系统组成与卸载流程	67
5.2.2	任务代价模型	68
5.2.3	并发开销建模	71
5.2.4	状态表征与 MDP 建模	73
5.3	并发开销预测方法	75
5.3.1	预测目标与样本构造	75
5.3.2	预测模型设计	75
5.3.3	聚类联邦训练	76
5.3.4	模型可信维护	78
5.4	FL-DQN 卸载决策算法	79
5.4.1	状态、动作与奖励	79
5.4.2	DQN 网络训练	81
5.4.3	在线决策流程	81
5.4.4	复杂度分析	84
5.5	实验设计与结果分析	84
5.5.1	实验设置	85
5.5.2	预测性能分析	86
5.5.3	卸载性能对比	87
5.5.4	消融分析	89

5.5.5 鲁棒性与敏感性分析	92
5.5.6 本节小结	93
5.6 本章小结	94
结论与展望	95
参考文献	98
附录 A 基于区块链的试验数据存证原型软件测试补充材料	101
A.1 功能测试用例汇总	101
A.2 性能指标测试汇总	101
A.3 接口与工程实现基础	101
A.4 原型系统运行界面与测试截图	103
攻读学位期间发表论文与研究成果清单	106

插图

图 1.1	天基网络协同计算卸载应用场景	2
图 1.2	本论文研究思路及文章结构	9
图 3.1	天基网络可信协同计算卸载场景与四类参与角色	23
图 3.2	天基协同卸载基础模型架构	25
图 4.1	天基协同资源分配中局部自利与全局协同差异示意	35
图 4.2	系统层协同资源分配框架的层次结构与信息流	38
图 4.3	分层联盟链与公共信息板职责示意	49
图 4.4	信誉驱动的状态—动作—审计—反馈闭环	51
图 4.5	BC-CTDE-MAPPO 总体流程图	52
图 4.6	不同训练算法的收敛性对比	56
图 4.7	不同任务到达率下的系统性能对比	58
图 4.8	规模扩展与参数敏感性分析结果	59
图 4.9	任务完成率与 Jain 公平指数贡献	60
图 4.10	不同自私节点比例下的系统鲁棒性对比	62
图 5.1	任务级卸载的系统级双时间尺度架构与信息交互流程	67
图 5.2	并发开销的形成机理与资源争用示意	72
图 5.3	融合并发开销预测先验的 FL-DQN 在线卸载决策流程	82
图 5.4	并发开销预测模块的多维性能结果	86
图 5.5	不同并发强度下的卸载决策性能	87
图 5.6	不同并发强度下的卸载决策稳定性	88
图 5.7	消融实验结果	90
图 5.8	在线决策开销与跨轮次波动联合对比	91
图 5.9	鲁棒性与动作偏好结果	92
图 5.10	多目标折中结果	92
图 A.1	分层联盟链架构设计图	104
图 A.2	原型系统运行与管理界面截图（二）	104
图 A.3	原型系统运行与管理界面截图（三）	105

图 A.4	原型系统运行与管理界面截图（四）	105
图 A.5	原型系统运行单个节点服务器	105

表格

表 1.1	2024—2026 年天基计算卸载与智能调度代表研究	5
表 3.1	区块头字段定义	31
表 4.1	链上公共摘要分量说明	43
表 4.2	奖励权重与作用说明	46
表 4.3	分层联盟链职责划分	50
表 4.4	主要实验参数设置	55
表 4.5	不同训练算法的收敛性统计对比	57
表 4.6	不同任务到达率下各算法的 Jain 公平指数	58
表 4.7	消融实验结果	60
表 4.8	不同自私节点比例下的鲁棒性对比	61
表 5.1	集中式学习在天基网络中的主要局限	66
表 5.2	任务级卸载框架中的角色划分	68
表 5.3	任务符号对应关系	69
表 5.4	分层聚类联邦学习架构中的角色划分	77
表 5.5	节点侧决策的复合状态空间设计	80
表 5.6	不同并发强度下各卸载策略的端到端性能汇总	88
表 5.7	FL-DQN 各模块消融实验结果	90
表 A.1	原型系统功能测试用例汇总	102
表 A.2	原型系统性能指标测试汇总	103

主要符号对照表

ST	卫星终端 (Satellite Terminal)
SEN	卫星边缘节点 (Satellite Edge Node)
CC	地面控制中心 (Ground Control Center)
FL	联邦学习 (Federated Learning)
DQN	深度 Q 网络 (Deep Q-Network)
DRL	深度强化学习 (Deep Reinforcement Learning)
MARL	多智能体强化学习 (Multi-Agent Reinforcement Learning)
CTDE	集中训练—分散执行 (Centralized Training and Decentralized Execution)
MAPPO	多智能体近端策略优化 (Multi-Agent Proximal Policy Optimization)
$\mathcal{V}$	天基协同计算网络节点集合
$\mathcal{V}_{ST}, \mathcal{V}_{SEN}, \mathcal{V}_{CC}$	分别表示 ST、SEN、CC 节点集合
$\mathcal{G}(t)$	时刻 t 的动态网络拓扑图
$\mathcal{E}_{\text{link}}(t)$	时刻 t 的可用链路集合
$\ell_{ij}(t)$	节点 $i \rightarrow j$ 链路状态向量
$B_{ij}(t)$	节点 $i \rightarrow j$ 链路可用带宽
$d_{ij}^{\text{prop}}(t)$	节点 $i \rightarrow j$ 链路传播时延
$\tau_{ij}^{\text{vis}}(t)$	节点 $i \rightarrow j$ 链路剩余可见窗口
$R_i(t)$	节点 i 在时刻 t 的资源状态向量
$F_i(t), M_i(t), Q_i(t), E_i(t), \rho_i(t), \text{Rep}_i(t)$	分别表示可用算力、可用存储、队列长度、剩余能量、资源利用率与信誉评分
$\mathcal{T}$	任务集合
T_k	第 k 个任务, $T_k = (s_k, c_k, d_k, \tau_k, \zeta_k, t_k^{\text{arr}})$
$s_k, c_k, d_k, \tau_k, \zeta_k, t_k^{\text{arr}}$	分别表示输入数据规模、计算量、时延约束、任务类型、优先级与到达时刻
$R_{ij}(t)$	节点 $i \rightarrow j$ 传输速率

$D_{k,ij}^{\text{tx}}(t)$	任务 T_k 从节点 i 卸载至节点 j 的传输时延
$D_{k,i}^{\text{loc}}(t)$	任务 T_k 在节点 i 本地执行完成时延
$D_{k,ij}^{\text{off}}(t)$	任务 T_k 卸载至节点 j 执行完成时延
$\Delta_{k,j}^{\text{conc}}(t)$	任务 T_k 在节点 j 的并发开销时延项
$E_{k,i}^{\text{loc}}(t), E_{k,ij}^{\text{off}}(t)$	任务本地执行能耗与卸载执行能耗
$\Sigma_i(t)$	节点 i 的链上状态摘要
$G(t)$	链上公共状态摘要
$\bar{L}(t), \sigma_L^2(t)$	系统平均负载与负载方差
$D^{\text{task}}(t)$	任务分布摘要
$R^{\text{rep}}(t)$	全网信誉向量摘要
$\hat{D}_{\text{chain}}(t), D_{\text{chain}}(t)$	链上同步延迟估计与链上总附加时延
o_t^i	智能体 i 在时刻 t 的观测, $o_t^i = (l_t^i, g_t)$
a_t^i	智能体 i 在时刻 t 的动作, $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$
r_t^i	智能体 i 在时刻 t 的混合奖励
w_q, w_f, w_c	效率、公平、可信三类奖励权重
$J(t)$	Jain 公平指数
$\mathcal{A}_k(t)$	任务 T_k 的动作集合 (本地执行与可卸载候选节点集合)
$CO_i(n, t)$	新任务 i 在候选节点 n 上的并发开销
$\hat{\Delta}_i(n, t)$	并发开销预测值
$J_i(a_t)$	任务层动作 a_t 对应的单任务综合代价
$\omega_L, \omega_E, \omega_C$	任务层时延、能耗与并发代价权重

1 绪论

1.1 研究背景与意义

天地一体化信息网络是支撑全球通信、遥感感知、任务协同与智能服务的重要基础设施。随着低轨卫星星座持续部署、星间链路逐步完善以及星载计算平台能力不断提升,卫星节点的功能定位正在由单一的数据中继载体演进为具备在轨处理、任务协同和资源调度能力的分布式协同计算平台^[1-3]。这种演进不仅提升了网络服务能力,也对网络运行模式、任务组织方式和资源管理机制提出了新的要求。

在卫星终端试验任务场景中,试验数据具有来源分散、链路受限、时效要求高和过程需可追溯等特点。特别是在灾害应急通信、对地观测快速处理、区域目标识别、空间态势感知和跨区域任务协同等场景中,系统不仅需要完成数据采集与远程传输,还需要在有限可见窗口和受限链路条件下实现任务接入、资源协调、计算处理与结果反馈的快速闭环。若仍依赖传统“星上初步处理—地面集中分析”的工作模式,则容易受到星地链路时延、可见窗口和地面中心计算瓶颈的制约,难以满足高时敏业务对快速响应和在轨闭环处理的实际需求^[3-4]。

在此背景下,将计算能力由地面向星上前移,并在多颗卫星之间实现资源共享与协同处理,已成为提升天基网络智能服务能力的重要发展方向。所谓协同计算卸载,是指当任务接入卫星本地资源不足或本地执行代价过高时,通过星间链路将任务迁移至其他具备可用资源的协同节点执行,从而在更大范围内实现算力共享与负载分担^[1,4]。图 1.1给出了天基网络协同计算卸载的典型应用场景。在该场景中,地面突发任务首先通过上行链路接入当前服务卫星;当该卫星本地资源不足或任务积压严重时,可将部分任务经由星间链路卸载至资源相对空闲的卫星节点执行;同时,卫星节点利用区块链共识机制以异步、非实时的方式共享候选节点资源信息和任务生命周期事件,支撑可信状态共享、协同决策和结果反馈。

然而,天基网络中的协同计算卸载并不是传统意义上的简单任务迁移问题。与地面云计算和边缘计算环境相比,天基网络节点资源更加受限,链路拓扑变化更加频繁,运行环境也更加动态复杂。卫星高速运动使得网络拓扑、链路质量和可见窗口持续变化,不同卫星节点在剩余算力、存储资源、链路状态和能量水平等方面存在显著异质性;多颗卫星在同一时刻既可能是任务发起方,也可能是资源提供方,节点之间存在




图 1.1 天基网络协同计算卸载应用场景

资源竞争与收益耦合。因此，天基协同计算卸载不仅要解决“任务是否卸载、卸载到哪里”的问题，还需要进一步解决状态是否可信、资源如何协同、并发执行代价如何刻画等问题。

结合上述背景，本文研究主要面临以下三个关键挑战：

(1) 高动态环境下的可信状态共享问题。协同卸载依赖节点算力占用、剩余能量、链路连通性、队列长度和任务执行状态等信息。然而，天基网络中的链路连接具有间歇性和时变性，频繁广播全局状态不仅会增加通信负担，还可能因传播时延和局部信息缺失造成多节点认知不一致。对于缺乏长期稳定中心控制节点的天基环境而言，若共享状态存在篡改、滞后或失真，后续资源分配和任务卸载决策将缺乏可靠依据。因此，如何在高动态拓扑下构建可追溯、低冲突、可验证的状态共享机制，是本文面临的首要挑战。

(2) 多节点资源竞争下的系统层协同问题。多颗卫星在同一时刻可能同时发起卸载请求，资源充足或链路条件较好的卫星节点容易成为竞争热点。若各节点仅依据局部收益进行贪婪选择，容易导致负载集中、策略震荡和系统吞吐下降；同时，节点既是任务发起方又是资源提供方的双重身份还会引发自利行为，使得局部最优与全局协同收益之间产生矛盾。因此，如何在去中心化、信息不完全和资源竞争条件下，建立兼顾任务完成质量、负载公平性和长期协作收益的系统层协同决策机制，是本文面临的第二个关键挑战。

(3) 异步链上信息与并发开销耦合下的任务层实时卸载问题。系统层协同能够为任务卸载提供候选节点集合、公共状态摘要和信誉约束,但区块链共识机制本质上提供的是异步、非实时的全局信息共享,链上记录的节点状态相对于真实运行状态存在固有时滞。当新任务到达卫星终端时,终端需在较短时间内结合本地状态、链路条件,以及链上记录的候选节点资源信息和正在执行任务信息作出具体卸载动作。同时,新任务一旦卸载至目标节点,便会与该节点上正在执行的任务争用计算资源,由此引入并发开销——其同时包括新任务自身的计算时延以及对存量任务剩余执行时延的延长,受任务异构性和节点动态负载共同影响,传统“传输时延 + 计算时延”的线性建模难以准确刻画。因此,如何在链上信息存在异步时滞、节点运行数据难以集中共享和多任务并发开销难以解析建模的条件下,实现具备并发开销感知能力的任务层实时卸载决策,是本文面临的第三个关键挑战。

针对上述问题,本文围绕“统一建模—系统层协同—任务层卸载”的研究主线展开。首先构建面向天基网络可信协同计算卸载的统一建模框架,并将总体问题分解为系统层协同资源分配和任务层并发开销感知卸载两个子问题;随后分别研究基于区块链与多智能体强化学习的系统层协同资源分配方法,以及基于聚类联邦学习与 DQN 的任务层实时卸载方法。

综上所述,本文研究面向灾害应急通信中的快速响应闭环、对地观测数据的在轨实时处理以及跨区域协同任务的可信调度等典型天基应用场景,有助于完善高动态、资源受限、去中心化网络环境下的协同计算卸载建模方法,为可信状态共享、多节点资源博弈和并发感知卸载决策提供新的研究思路;同时,可为区块链可信记录、任务卸载决策和模型治理的一体化支撑机制提供参考,推动天基边缘计算体系的工程化建设,具有一定的理论意义与应用价值。

1.2 国内外研究现状

围绕天基网络协同计算卸载问题,国内外研究已从体系架构、任务卸载、智能调度、去中心化协同和隐私保护建模等多个角度展开探索。总体来看,相关研究正沿两个方向并行推进:一方面,卫星边缘计算与星间协同处理不断走向实用化,任务卸载与资源调度问题逐步由静态建模转向动态学习;另一方面,随着网络规模扩张和节点自治能力增强,可信共享、分布式共识、联邦学习以及区块链辅助机制日益成为研究重点。基于此,本节从天基网络计算卸载与轨道边缘计算、区块链辅助可信状态共享

与协同调度、智能优化驱动的多节点资源分配与任务卸载三个方面进行梳理，并据此明确本文的研究定位。

1.2.1 天基网络计算卸载与轨道边缘计算研究现状

随着低轨卫星星座的快速发展，卫星边缘计算已成为天基网络研究中的热点方向。已有研究普遍认为，未来卫星网络不应仅承担透明转发功能，而应具备在轨预处理、局部协同分析和边缘服务承载能力，以缓解地面中心压力并提升实时响应能力^[3,5]。围绕这一目标，学界先后提出星地协同、星间协同和天地融合等多种计算架构，试图根据任务复杂度、时延要求和资源约束，在终端、卫星与地面之间灵活划分处理位置。

在具体卸载方法方面，早期研究多采用解析优化、启发式搜索或博弈论方法，对时延、能耗和资源利用率进行联合建模。这类方法在问题规模较小且假设条件较强时具有较好的可解释性，但当网络拓扑频繁变化、链路状态动态波动或任务到达具有突发性时，其模型有效性往往难以长期保持。例如，Gao 等针对 LEO 星座网络中的分布式动态卸载问题，基于博弈论建立了联合计算卸载与功率分配模型，在分布式环境下优化了资源利用效率，但该方法的求解过程依赖较强的信道静态假设^[6]。

自 2024 年以来，相关研究开始更加重视卸载问题中的时变信道、队列状态和动态负载因素。Jia 等提出面向卫星边缘计算的深度多智能体强化学习方法 MATORA，将任务卸载与资源分配拆分求解，在动态负载条件下提高了时延优化能力^[7]。Li 等针对 LEO 卫星边缘计算网络研究了基于多智能体强化学习的联合卸载与资源分配问题，通过分布式学习处理高动态环境中的能耗与时延折中^[8]。Shuai 等讨论了基于 Q-learning 的卫星边缘计算卸载策略，进一步验证了强化学习方法在动态卫星场景中的适应性^[9]。与此同时，Tang 等研究了基于星间链路的星地一体化网络任务卸载与资源分配问题，提出混合云与卫星多层多接入边缘计算架构，通过联合优化节点选择、卸载比率和算力分配实现了网络资源的动态管理^[10]。

进入 2025 年以后，研究重点进一步从“是否卸载”扩展到“如何在多目标条件下稳定卸载”。Wang 等提出面向卫星边缘计算的多目标强化学习卸载方法，将时延、资源利用率和负载均衡纳入统一优化目标，改善了复杂任务场景下的综合性能^[11]。Zhong 等则着重分析了异构任务需求、资源竞争和联合分配之间的耦合关系，指出卸载研究正在由单一指标优化转向服务质量约束和多资源联合编排^[12]。在此基础上，Xiu 等提

出 MARATD3 算法，将循环神经网络与多头注意力机制引入多智能体深度确定性策略梯度框架，在部分可观测条件下实现了跨时隙的动态卸载与资源分配联合优化，为高动态卫星环境中的序贯决策问题提供了新的建模范式^[13]。

这些研究表明，卫星边缘计算与任务卸载已由概念验证阶段逐步迈向细粒度建模与智能优化阶段。2024—2026 年天基计算卸载与智能调度领域的代表性研究如表 1.1 所示。

表 1.1 2024—2026 年天基计算卸载与智能调度代表研究

研究方向	代表文献	主要内容	不足或启示
卫星边缘计算架构	[3,5]	从星地融合、星间协同和天地一体化角度讨论卫星边缘计算架构与业务承载方式	侧重体系层面描述，对协同决策机制的讨论不足
博弈论与优化方法	[6,10]	利用博弈论、凸优化或分层架构处理卸载与资源联合分配	依赖较强的信道平稳或全局信息可获得假设
单智能体 RL 卸载	[9,14]	利用 Q-learning、DQN 及其改进模型优化卸载时延和资源利用率	多从单节点或单任务视角建模，难以处理多节点博弈
MARL 联合优化	[8,13,15-16]	将多颗卫星建模为多智能体，联合优化卸载、功率、带宽和资源分配	通常假设状态可获得，可信共享基础薄弱
联邦学习辅助卸载	[7]	将联邦学习与 DRL 结合，保护隐私同时优化卸载策略	联邦学习与卸载决策的闭环耦合仍待深化

尽管相关研究已取得显著进展，但仍存在两方面关键局限。其一，多数工作默认系统能够获得较准确的全局或准全局状态，未能有效刻画高动态拓扑下的状态不一致、信息失真和分布式认知偏差；其二，大量模型仍将任务代价简化为传输时间与纯计算时间的线性叠加，对多任务并发带来的内部竞争和执行扰动刻画不足，导致实际卸载决策中的代价估计存在系统性偏差。本文正是针对上述两个维度的不足，在“可信共享”和“并发感知”层面推进天基计算卸载研究。

1.2.2 区块链辅助的可信状态共享与协同调度研究现状

随着天基网络从封闭体系向开放协同体系演进,可信共享与去中心化协同问题日益突出。传统中心控制模式虽便于统一管理,但在大规模低轨星座和多主体参与环境下,容易面临单点失效、扩展性不足以及状态采集开销过高等问题。为此,近年来研究开始尝试引入区块链、分布式共识和自治网络协议,为天基网络构建新型协同机制。

2024 年以来,该方向的代表性工作明显增多。例如,Elmahallawy 等围绕多厂商低轨卫星网络提出面向空间智能的去中心化信任框架,强调通过区块链与联邦学习协同提升跨主体协作的鲁棒性与可用性^[17]。Zhai 等提出面向低轨卫星网络的联邦学习框架 FedLEO,通过卸载辅助与去中心化训练机制提升分布式学习效率^[18]。与此同时,面向空天地一体化网络的区块链安全通信研究也在增加,Du 等提出 StarCross 可编辑区块链跨分片数据共享框架,表明通过链结构与交易机制创新可缓解卫星网络中的区块链性能瓶颈^[19]。

在区块链与计算卸载的结合方面,2025 年的一项重要进展值得关注。相关研究提出了区块链辅助的数字孪生卸载机制,在空天地异构网络中构建了 SAG 数字孪生集成区块链模型,利用区块链保障数据安全与隐私的同时,通过数字孪生实现网络状态的实时映射与优化,并给出了高效的任务卸载与资源分配联合算法^[20]。该工作将区块链由“外部安全模块”推进到“与卸载决策紧密耦合的状态底座”,与本文的核心理念高度契合。此外,面向卫星物联网的 StarCross 框架提出了可编辑区块链跨分片交易方案,说明通过架构创新可以有效缓解卫星网络中区块链的性能瓶颈^[19]。

进入 2025—2026 年,研究重点进一步由“能否去中心化”转向“如何在高动态卫星网络中实现更稳健的共识与控制”。相关研究针对高覆盖联盟链场景提出了网络拓扑感知的容错共识机制,表明传统地面分布式机制难以直接迁移到卫星网络环境,必须围绕链路质量、节点能力与覆盖约束进行针对性重构^[21]。这一趋势表明,去中心化卫星网络研究已由宏观愿景逐步走向面向工程实现的机制设计阶段。

尽管如此,当前研究主要回答了“为什么需要去中心化”和“如何构建分布式信任机制”,但对这些机制如何有效服务于具体的计算卸载、资源协调和任务调度,仍缺少系统性设计。已有工作中,区块链与卸载决策的耦合通常停留在“数据安全保障”层面,尚未形成覆盖状态记录、节点选择、执行反馈和信誉更新的完整闭环。本文将区块链由“外部安全模块”转化为“可信状态底座”,使其同时服务于系统层协同资源分配和任务层实时卸载,在这一耦合维度上推进现有研究。

1.2.3 智能优化驱动的多节点资源分配与任务卸载研究现状

天基网络环境具有高动态、强耦合和多主体并存等特征，面向动态环境的智能调度已成为近年来相关研究的核心方向。深度强化学习之所以被广泛引入，在于其能够在缺乏精确解析模型的条件下，通过与环境持续交互形成状态到动作的映射关系，从而有效处理链路波动、任务到达随机性和资源时变性等问题^[9,22]。

在单智能体强化学习阶段，研究通常聚焦单节点视角下的卸载动作、功率控制或链路选择，通过 DQN、DDQN、D3QN 等方法提升策略对复杂状态的适应能力。此类方法在小规模、中心化或弱耦合场景中效果较好，但当多个卫星节点同时参与决策时，其隐含的“环境平稳”假设不再成立。对任一节点而言，其他节点的动作会持续改变其观测环境和收益分布，导致单智能体方法面临显著的环境非平稳性问题。

基于这一认识，多智能体强化学习在天基计算调度中日益受到重视。2024 年以后，多项研究明确将多颗卫星建模为多智能体系统，通过集中训练分散执行（CTDE）或共享奖励等机制处理节点间的策略耦合关系^[8,13,15]。在 CTDE 范式的具体实现方面，Wu 等提出了面向 LEO 卫星网络的多智能体深度强化学习卸载与路由联合优化方法，将计算和路由需求同时纳入多智能体建模框架，在动态负载和拓扑变化条件下展现了分布式决策的灵活性^[15]。Qin 等则从可持续计算角度出发，利用 MARL 解决星地一体化网络中的计算卸载问题，强调全局奖励设计在多智能体收敛中的关键作用^[23]。

在隐私保护协同建模方面，联邦学习逐渐成为支撑天基网络分布式智能建模的重要方案。与传统集中式学习相比，联邦学习允许各节点在本地完成训练，仅交换模型参数或梯度，在“数据不出域”的前提下实现跨节点协同优化^[24-25]。在卫星及星地融合场景中，联邦学习研究近两年呈现出两条清晰路径：一是围绕具体业务构建面向天基环境的协同学习框架，二是围绕高动态、异构和隐私约束条件改进联邦学习机制本身。已有研究表明，联邦学习不仅能够降低原始数据汇聚压力，还能在异构节点条件下提升模型泛化能力。

总体而言，智能优化方法为天基网络多节点资源分配与任务卸载提供了重要工具，但现有研究仍存在两类不足：一是系统层多智能体协同通常将可信状态视为已知前提，未能回答“卫星节点如何在去中心化环境下获得可信的他方状态”这一基础问题，使得自利行为和局部信息不对称难以从根本上得到约束；二是任务层深度强化学习多将环境代价直接作为即时反馈，对并发开销、状态时滞和联邦预测之间的闭环关系刻画不足，导致实际代价与模型输入之间存在结构性偏差。本文在统一问题模型下，

以区块链可信状态共享回答第一类问题，以聚类联邦学习与并发开销建模回答第二类问题，通过分层耦合实现两个层面的协同。

1.3 本文主要研究内容

本文旨在面向卫星终端试验任务和天基协同计算场景，研究高动态、资源受限和去中心化环境下的可信协同计算卸载方法。针对天基网络中节点状态难以可信共享、多节点资源竞争关系复杂以及并发任务执行代价难以准确刻画等问题，本文围绕统一建模与问题分解、系统层协同资源分配以及任务层并发感知卸载三个层面开展研究，主要研究内容如下：

(1) 天基网络可信协同计算卸载统一建模与问题分解。针对现有研究中系统模型、区块链可信状态、资源协同和任务卸载决策之间缺乏统一描述的问题，本文构建了包含卫星终端、卫星边缘节点、地面控制中心和区块链账本的统一建模框架，从节点资源、任务属性、动态链路、计算时延、能耗、节点信誉和任务生命周期等方面对协同计算卸载过程进行形式化刻画，将总体问题分解为系统层协同资源分配和任务层并发开销感知卸载两个子问题，并明确两层之间通过“系统层状态—任务层动作—执行反馈—链上更新”形成闭环，为后续章节提供统一的符号体系和优化目标。

(2) 基于区块链与多智能体强化学习的系统层协同资源分配方法。针对去中心化天基网络中节点自利、状态不完全和资源竞争导致的负载失衡问题，本文将多个异构卫星节点之间的长期资源协同建模为多智能体马尔可夫博弈，利用联盟链维护节点负载、链路状态、信誉评分和历史行为等公共摘要，结合集中训练—分散执行机制和融合任务完成质量、公平性与信誉激励的混合奖励函数，引导异构节点在自治条件下实现多节点稳定的协同资源分配。

(3) 基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法。针对区块链共识机制引入的异步时滞、节点数据隐私受限和多任务并发开销难以准确建模等问题，本文提出 FL-DQN 集成决策框架：建立面向计算资源竞争的并发开销模型，将新任务计算时延和存量任务剩余时延延长统一纳入代价函数；按节点并发任务数进行分簇，采用聚类联邦学习训练并发开销预测模型；将预测结果、本地状态和链上候选节点信息共同输入深度 Q 网络，实现具备并发开销前瞻能力的任务层实时卸载决策。

1.4 论文结构安排

本文共分为六章，各章围绕“统一建模—系统层协同—任务层卸载”的研究主线依次展开，整体结构如图 1.2 所示。




图 1.2 本论文研究思路及文章结构

图中各章从研究背景出发，依次经由理论基础、统一建模、两级方法设计，到总结展望，形成完整的研究闭环。各章具体内容如下。

第1章为绪论。本章首先介绍天地一体化信息网络和天基协同计算的发展背景，分析高动态、资源受限和去中心化天基网络中协同计算卸载面临的关键问题；随后梳理国内外相关研究现状，总结现有研究在状态可信共享、系统层协同资源分配和任务层并发开销感知卸载方面的不足；最后给出本文的主要研究内容和论文结构安排。

第2章为相关技术与理论基础。本章介绍天基网络、轨道边缘计算、计算卸载、区块链可信共享、多智能体强化学习、联邦学习和深度强化学习等相关理论与技术，为后续统一建模和方法设计提供理论基础。

第3章为天基网络可信协同计算卸载统一建模与问题分解。本章构建包含节点、任务、链路、资源、区块链账本可信状态和执行反馈的统一系统模型，建立时延、能耗、负载、信誉和任务完成收益等代价模型，并将总体问题分解为系统层协同资源分配子问题和任务层并发开销感知卸载子问题，为第4章、第5章提供建模基础和接口定义。

第4章为基于区块链与多智能体强化学习的系统层协同资源分配方法。本章面向第3章提出的系统层子问题，建立多智能体马尔可夫博弈模型，设计区块链增强的集中训练—分散执行协同决策框架，通过信誉激励和混合奖励机制实现多节点负载均衡与长期协同。

第5章为基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法。本章面向第3章提出的任务层并发感知卸载子问题，在区块链账本提供的候选节点信息与系统层输出的信誉约束基础上，研究链上信息存在异步时滞、节点数据隐私受限和多任务并发开销耦合条件下的实时卸载决策机制，验证所提 FL-DQN 框架在预测精度、端到端时延、SLA 完成率和链上信息时滞鲁棒性等方面的有效性。

最后一章为总结与展望。本章总结全文研究工作和主要结论，分析当前研究仍存在的不足，并对未来可进一步开展的研究方向进行展望。

2 相关理论与技术基础

本章系统梳理本研究所涉及的天基网络计算卸载、区块链可信协同、联邦学习以及多智能体强化学习四类核心技术的基本原理、典型方法与应用边界，旨在为后续章节中天基协同计算系统的统一建模、长时间尺度协同优化以及短时间尺度卸载决策提供完整的理论支撑与技术依据。天基协同计算系统具有节点高速运动、链路时变、资源异构与可信环境受限等鲜明特征，传统地面边缘计算中所沿用的卸载方法与协同方法难以同时兼顾通信约束的精准刻画与协同决策的可信执行。本章梳理的四类前沿技术，正是本研究实现天基场景下高效卸载与可信协同的核心技术基础。

2.1 天基网络与计算卸载技术

天基网络是指以低轨（Low Earth Orbit, LEO）、中轨（Medium Earth Orbit, MEO）和高轨（Geostationary Earth Orbit, GEO）卫星星座为核心，辅以地面控制中心、信关站及用户终端构成的一类天地一体化通信与计算网络。近年来，随着 LEO 巨型星座的快速部署与星上计算能力的持续提升，天基网络已从单纯的“通信中继”角色逐步演化为面向 6G 的“通信—感知—计算”一体化基础设施^[2,26]。本节将依次梳理天基网络的层级架构与链路特性、计算卸载的基本范式以及面向 LEO 环境的卸载决策方法。

2.1.1 天基网络的层级架构与链路特性

目前关于天基网络的体系结构尚无统一规范，学术界普遍采用空—天—地一体化网络（Space-Air-Ground Integrated Network, SAGIN）的层级框架对其进行描述^[11,26]。在该框架下，LEO 卫星因其轨道低、传播时延小、链路增益高的优势，成为承载星上边缘计算的主要平台^[27]。本文将天基协同计算网络抽象为如下三层结构：

具体而言，用户终端层主要负责任务接入、任务属性提取和结果接收；星上边缘层由具备计算、缓存和星间通信能力的卫星边缘节点构成，承担任务本地处理、协同卸载和资源共享功能；地面控制层由地面控制中心和信关站等组成，主要负责系统管理、模型初始化、策略评估和长期运行维护。上述三层结构与第3章中的 ST、SEN 和 CC 三类节点角色相对应。

天基网络的链路特性显著区别于地面网络，主要体现在三方面。第一，链路时变性强。LEO 卫星轨道周期约为 90 到 100 分钟，星—地、星—星之间的可见性窗口在

分钟级尺度反复出现与消失，导致链路拓扑随时间剧烈变化^[27]。第二，带宽与时延非对称。星—地下行链路普遍优于上行链路，且馈电链路与用户链路在频段、功率预算上差异显著^[2]。第三，可达性受星历强约束，任意一对节点之间的端到端时延并非常数，而是随轨道相位的周期性变化的随机过程。上述特性使得传统假设链路恒定或缓变的卸载方法难以直接迁移，必须显式建模链路的时变性与可见性窗口约束。

本节梳理的天基网络层级结构是第3章建模工作的应用背景。第3章中将“用户终端层—星上边缘层—地面控制层”三层结构进一步形式化为卫星终端（Satellite Terminal, ST）、卫星边缘节点（Satellite Edge Node, SEN）和地面控制中心（Control Center, CC）三类节点角色，并在此基础上建立链路时延、可达性与资源异构的数学模型。

2.1.2 计算卸载基本范式

计算卸载是指将计算密集型或时延敏感型任务从资源受限的终端节点迁移至算力充裕的边缘或云端节点执行的一类技术，其核心目标是在用户体验质量与系统资源开销之间取得平衡^[16,22]。按卸载粒度划分，卸载方案通常包括二元卸载、部分卸载与依赖型卸载三类。二元卸载将任务视为不可分割的整体，决策变量仅为本地执行或卸载执行；部分卸载允许将任务按比例分割后并行处理；依赖型卸载则进一步考虑任务内部子模块之间的依赖关系，通常以有向无环图（Directed Acyclic Graph, DAG）的形式描述^[4]。

无论采用何种卸载粒度，卸载决策的形式化通常围绕时延、能耗与可靠性三项指标展开。任务在节点 i 上的本地执行时延 T_i^{loc} 可表示为：

$$T_i^{\text{loc}} = \frac{c_k}{f_i} \quad (2.1)$$

其中 c_k 为任务所需的 CPU 周期数， f_i 为节点 i 的计算频率。当任务被卸载至边缘节点 j 时，端到端时延由传输时延、排队时延与边缘执行时延共同构成：

$$T_{i,j}^{\text{off}} = \frac{d_k}{r_{i,j}} + T_j^{\text{queue}} + \frac{c_k}{f_j} \quad (2.2)$$

其中 d_k 为任务输入数据量， $r_{i,j}$ 为节点 i 到节点 j 的瞬时传输速率， T_j^{queue} 为目标节点的排队时延。能耗模型通常采用动态电压频率调整（Dynamic Voltage and Frequency Scaling, DVFS）假设，以芯片功耗系数 κ 与计算频率立方的乘积形式表达^[27]。

针对天基场景，计算卸载的研究焦点逐步从地面单跳卸载演进为多跳协同卸载与星一地联合卸载。Sun 等人^[27]考虑 LEO 卫星运动性带来的链路时变，提出了运动感知的卸载策略，联合最小化网络时延与能耗。Wang 等人^[11]进一步将主从星协同纳入决策空间，提出多目标 D3QN 算法以兼顾任务完成率、负载均衡、时延与能耗。Guo 等人^[4]则针对端到端任务，将卸载与路由联合建模为 NP 难问题并设计分解算法。这些工作虽然在仿真层面验证了卸载在天基场景下的可行性，但普遍假设链路状态、节点信誉等关键变量集中可得，尚未充分考虑大规模、多管理域场景下“信息可信共享”这一前提。

本研究在第3章定义的任务模型基础上，在第5章构建基于 DQN 的任务层卸载决策方法，并在此基础上引入由第4章系统层下发的候选约束，以缓解上述工作中“集中可得信息”假设的局限。

2.1.3 深度强化学习在卸载决策中的应用

由于卸载决策本质上是序列化决策问题，且环境状态具有高维、时变与部分可观特征，基于深度强化学习（Deep Reinforcement Learning, DRL）的方法近年来成为该领域的主流研究范式^[22,28]。DRL 通过将神经网络作为价值函数或策略函数的近似器，结合马尔可夫决策过程（Markov Decision Process, MDP）的形式化框架，实现对卸载策略的端到端学习。

深度 Q 网络（Deep Q-Network, DQN）是该领域的奠基性工作，其核心思想是用神经网络 $Q(s, a; \theta)$ 近似最优动作—价值函数，并通过经验回放和目标网络两项机制缓解训练发散问题。DQN 的更新目标为：

$$y = r + \gamma \max_{a'} Q(s', a'; \theta^-) \quad (2.3)$$

其中 θ^- 表示目标网络参数。然而原始 DQN 存在过估计偏差与价值估计与动作选择耦合两个问题。Double DQN 通过将动作选择与价值评估解耦缓解了过估计偏差，Dueling DQN 进一步将 Q 函数分解为状态价值与动作优势两支路，提升了在动作差异较小场景下的样本效率^[28]：

$$Q(s, a) = V(s) + A(s, a) - \frac{1}{|\mathcal{A}|} \sum_{a'} A(s, a') \quad (2.4)$$

将 DQN 类方法应用于计算卸载场景的关键在于状态空间与动作空间的合理设

计。Tang 与 Wong^[22] 将节点队列状态、信道质量与历史决策共同纳入状态空间，采用 LSTM 与 Dueling DQN 结合的方式建模长期回报。Adu 等人^[16] 进一步在多接入边缘计算场景下将 DQN 扩展为多智能体形式，使每个边缘设备可基于本地观测做出去中心化卸载决策。Wang 等人^[11] 则针对 LEO 巨型星座设计了 D3QN 算法，在多目标（完成率、负载、时延、能耗）联合优化中取得了显著效果。

DQN 类方法是本研究第5章任务层方法的核心技术路径。第5章将以轻量化 DQN 为基础，以第3章定义的链上摘要、链路状态与候选约束为状态输入，输出短时间尺度的离散卸载动作，并通过候选约束机制将系统层的协同意图传递到任务层执行。

2.2 区块链与可信协同技术

区块链是一种以链式数据结构存储交易、以分布式共识维护账本一致性、以密码学保证数据不可篡改的分布式账本技术^[29-30]。在天基协同计算场景下，引入区块链可在缺乏可信中心的条件下，为多管理域之间的状态共享、行为审计与模型治理提供透明、可追溯的可信底座^[17,31]。本节将分别介绍联盟链与共识机制、节点信誉机制，以及区块链辅助下的多方协同范式。

2.2.1 联盟链与共识机制

按节点准入策略划分，区块链可分为公有链、联盟链与私有链三类。公有链节点完全开放、采用工作量证明（Proof of Work, PoW）等高资源消耗共识，适合无中心化加密货币场景但难以适配资源受限的天基环境；私有链节点完全封闭、性能高但缺乏多方信任价值；联盟链则在两者之间取得平衡，通过组织级准入机制控制节点身份，采用拜占庭类共识保障一致性，既保留了分布式信任的优势，又显著降低了共识能耗，因而成为面向行业级可信协同的主流选择^[21,29]。

实用拜占庭容错（Practical Byzantine Fault Tolerance, PBFT）及其衍生算法是联盟链中最为广泛使用的共识机制。PBFT 通过预准备、准备、提交三阶段的多轮消息交互，在不超过 $\lfloor (n-1)/3 \rfloor$ 个拜占庭节点的前提下保证账本一致性，具有确定性最终性与无需挖矿的优势^[21]。然而，经典 PBFT 算法的通信复杂度为

$$C_{\text{PBFT}} = \mathcal{O}(n^2), \quad (2.5)$$

在节点规模较大时延迟随节点数迅速恶化。为此，后续研究从两个方向加以改进：一

是引入分片（Sharding）机制将共识负载分散到多个子链，显著提升系统吞吐^[31]；二是结合节点信誉对参与共识的节点子集进行动态筛选，将式（2.5）压缩为面向高信誉节点的 $\mathcal{O}(k^2)$ 通信（ $k \ll n$ ），从而在大规模异构网络中保持可用的共识时延^[21]。

智能合约（Smart Contract）是联盟链的核心可编程接口，其本质是部署在区块链上、由共识节点协同执行、执行结果上链可追溯的一段确定性代码。智能合约通过将业务逻辑显式表达为代码，使得多方协同中的关键判定（如准入审核、积分发放、违规惩戒）能够在无需可信第三方的条件下自动完成，极大提升了多方协同的执行效率与可审计性^[30]。

本研究在第3章中以联盟链作为天基协同计算系统的可信底座，将链上摘要、生命周期事件、节点信誉与模型版本等关键状态以分层共识方式维护；PBFT 类共识与智能合约则在第4、5章方法中作为约束执行与凭据流转的实现假设。

2.2.2 可信状态共享与节点信誉

在多方协同的可信场景下，仅依靠共识机制保证账本一致性尚不足以支撑长期协作，还需进一步引入节点信誉（Reputation）机制对参与方的历史行为进行定量评估，以激励诚实行为、抑制恶意或低质量行为^[21,29]。节点信誉的核心在于将节点过往的行为（如任务执行准时率、模型更新质量、共识参与稳定性等）转换为一个随时间演化的可比较标量，并将该标量作为节点参与协同的权重或资格的判据。

典型的信誉演化模型采用指数加权移动平均的形式：

$$R_i(t+1) = (1-\eta)R_i(t) + \eta r_i(t) \quad (2.6)$$

其中 $R_i(t)$ 为节点 i 在时刻 t 的信誉值， $r_i(t)$ 为本轮的行为评分， η 为学习率。信誉机制可与共识算法深度耦合，例如基于信誉的 PBFT 仅允许信誉高于阈值的节点参与共识投票，从而在保证安全的前提下进一步压缩共识规模^[21]。

节点信誉机制是第3章中“链上摘要—行为审计—权限调整”反馈环的关键中间变量，亦是第4章系统层方法在筛选候选节点、第5章任务层方法在过滤目标节点时所共享的状态接口。式（2.6）是第3章信誉更新规则的理论原型。

2.2.3 区块链辅助的多方协同范式

区块链作为可信中介，已被广泛应用于多方协同场景下的去中心化数据共享、可追溯任务调度与多管理域治理。其典型应用范式包括：（1）将关键事件以哈希摘要

的形式上链，原始数据保存于链下，形成“链上摘要 + 链下实体”的轻量化存证机制；（2）利用智能合约实现可编程的多方业务规则，例如自动化的资源分配、信誉惩戒和异常处置；（3）将分布式共识与多方协同决策深度耦合，使协同结果具备可审计性^[17,29]。

针对天基场景，Zhang 等人^[31]提出了面向 LEO 网络的分片化区块链框架，通过将卫星节点按轨道平面划分为多个分片以缓解全网共识开销；Elmahallawy 等人^[17]进一步将其拓展至多厂商星座场景，引入区块链辅助机制以应对跨星座间的信任薄弱问题。这些工作共同表明，区块链不仅是可信存储工具，还能与上层协同决策深度集成，构成多管理域天基协同的基础设施。

本研究将上述范式具体化为面向天基协同计算的“可信控制平面”：第3章定义链上数据集合 $\mathcal{D}_{\text{on}}$ 与摘要一对象哈希映射；第4章利用链上公共摘要支撑系统层多智能体协同；第5章利用链上模型版本凭据支撑任务层并发开销预测模型的可信调用。

2.3 联邦学习与聚类联邦学习

随着天基网络中的节点数量、任务多样性与隐私敏感性持续上升，传统的集中式机器学习范式难以满足“数据不出域”与“模型可协同”的双重要求。联邦学习（Federated Learning, FL）作为一类典型的隐私友好型分布式学习框架，能够在保留原始数据于本地的前提下，通过模型参数的多轮交换实现跨节点协同建模，已经成为天基边缘智能与跨星座协同的重要技术基础^[24,32]。本节首先介绍 FedAvg 算法及其在异质性条件下的局限，随后讨论聚类联邦学习的基本思想，最后回到区块链辅助的联邦学习范式与本研究的关联。

2.3.1 FedAvg 算法与基本流程

FedAvg 是联邦学习领域最具代表性的基线算法。设全网共有 N 个客户端，第 k 个客户端的本地数据集为 $\mathcal{D}_k$ ，本地经验风险为 $F_k(w)$ ，则 FedAvg 的全局优化目标可写为

$$\min_w f(w) = \sum_{k=1}^N p_k F_k(w), \quad p_k = \frac{|\mathcal{D}_k|}{\sum_{j=1}^N |\mathcal{D}_j|}, \quad (2.7)$$

其中 p_k 为客户端权重，通常正比于其本地样本量。FedAvg 的工作流程可概括为四步：（1）服务器初始化全局模型 $w^{(0)}$ 并下发至客户端；（2）每个客户端在本地以多轮

SGD 更新得到本地参数 $w_k^{(t+1)}$ ；(3) 客户端将本地参数上传至服务器；(4) 服务器按式 (2.7) 中的权重对客户端参数进行加权平均，得到新的全局模型

$$w^{(t+1)} = \sum_{k=1}^N p_k w_k^{(t+1)}. \quad (2.8)$$

在通信—聚合循环若干轮后，全局模型逐步收敛。FedAvg 的优势在于无需上传原始数据，仅交换模型参数，因而通信开销与隐私风险均较集中式训练显著下降^[32]。

2.3.2 数据异质性挑战与聚类联邦学习

然而，FedAvg 在面对客户端数据非独立同分布（Non-IID）时存在收敛慢、模型质量下降甚至训练发散的问题^[33-34]。其根本原因在于：当不同客户端的本地最优解 w_k^* 相差较大时，单一全局模型 w 必然会落在某种“折中”位置，对多数客户端而言并非最优。在天基场景下，这一问题尤为突出——不同卫星节点的硬件能力、负载模式、任务类型与可见窗口差异显著，本地数据分布天然具有强异质性。

为缓解这一问题，聚类联邦学习（Clustered Federated Learning, Clustered FL）应运而生。其核心思想是放弃“全网共享单一模型”的强假设，转而将客户端按数据分布或参数更新方向划分为若干簇，每簇维护一个独立的簇模型，仅在簇内进行参数聚合。形式化地，设客户端被划分为 K 个互不相交的簇 $\{C_1, C_2, \dots, C_K\}$ ，则第 c 个簇在第 $t+1$ 轮的模型聚合可写为

$$w_c^{(t+1)} = \sum_{k \in C_c} \frac{|D_k|}{\sum_{j \in C_c} |D_j|} w_k^{(t+1)}. \quad (2.9)$$

与式 (2.8) 相比，式 (2.9) 的关键差异在于聚合范围被限制在“数据分布相近”的客户端子集内，从而能够保留局部模式、避免被全局平均效应淹没。簇划分本身可以基于客户端的负载特征、参数更新方向、梯度相似度或硬件能力等多种依据，常用方法包括 k -means 聚类、层次聚类与基于参数余弦相似度的动态分组^[33-34]。聚类联邦学习已在医疗影像、移动终端与物联网等多个异质性强的场景中表现出优于 FedAvg 的预测精度与收敛稳定性。

2.3.3 区块链辅助的联邦学习

虽然联邦学习能够避免原始数据的集中传输，但其安全性仍依赖于一个可信的中心聚合服务器：一旦该服务器失效或被攻陷，恶意更新可能在不被察觉的情况下污染

全局模型。区块链辅助的联邦学习（Blockchain-assisted Federated Learning, BCFL）将区块链作为可信聚合中介或可信凭据账本，将每轮的模型更新、参与方贡献、聚合凭据等以哈希摘要的形式上链，既消除了对中心聚合服务器的单点信任依赖，又借助区块链的可追溯性使恶意更新可被识别与回溯^[17,29]。针对天基场景，Zhang 等人^[31]提出了面向 LEO 网络的分片化 BCFL 框架，通过将卫星节点按轨道平面划分为多个分片以缓解全网共识开销；Elmahallawy 等人^[17]进一步将其拓展至多厂商星座场景，引入 BCFL 以应对跨星座间的信任薄弱问题。

本节梳理的 FedAvg、聚类联邦学习与 BCFL 是第5章任务层方法的核心技术路径之一。具体而言，第5章将基于式（2.9）的簇内聚合规则训练并发开销预测模型，按节点并发任务数对节点进行分簇以应对工作负载的异质性；同时，将每轮聚合后的模型版本摘要按 BCFL 思想写入第3章定义的模型版本集合 $\mathcal{D}_{\text{on}}^{\text{model}}$ ，实现“训练—发布—回滚”的可信治理闭环。

2.4 多智能体强化学习与协同决策

天基协同计算系统中，多个 SEN 节点需要在通信受限、信息部分可观的环境下做出长时间尺度的资源分配与候选筛选决策，其本质属于多智能体协同决策问题。与单智能体方法相比，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）需要同时应对环境非平稳性与动作空间指数级膨胀两大挑战^[35-36]。本节将依次介绍 MARL 的基本框架、CTDE 训练范式以及代表性算法。

2.4.1 多智能体马尔可夫决策过程

多智能体协同决策问题通常形式化为去中心化部分可观马尔可夫决策过程（Decentralized Partially Observable Markov Decision Process, Dec-POMDP），其形式化定义为如下七元组：

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}}, \mathcal{P}, \mathcal{R}, \{\mathcal{O}_i\}_{i \in \mathcal{N}}, \gamma \rangle \quad (2.10)$$

其中 $\mathcal{N}$ 为智能体集合， $\mathcal{S}$ 为全局状态空间， $\mathcal{A}_i$ 为智能体 i 的动作空间， $\mathcal{P}$ 为状态转移函数， $\mathcal{R}$ 为团队共享奖励函数， $\mathcal{O}_i$ 为智能体 i 的局部观测空间， γ 为折扣因子。每个智能体 i 仅可观测其局部观测 $o_i \in \mathcal{O}_i$ ，根据策略 $\pi_i(a_i | o_i)$ 选择动作，所有智能体

共同最大化期望累积折扣奖励：

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t \mathcal{R}(s_t, \mathbf{a}_t) \right] \quad (2.11)$$

Dec-POMDP 的核心难点在于，从任意单个智能体的角度看，其他智能体策略的演变会使得环境呈现非平稳特征（Non-stationarity），从而违反单智能体强化学习中环境动态平稳的关键假设^[36]。这种非平稳性是直接将单智能体方法独立部署于多智能体环境时，常常出现训练不稳定甚至发散的根本原因。

2.4.2 集中训练分散执行范式

集中训练分散执行（Centralized Training with Decentralized Execution, CTDE）是当前缓解 MARL 非平稳性问题的主流框架^[35]。CTDE 的核心思想是：在训练阶段，各智能体可访问全局状态或其他智能体的私有信息，从而在更准确的环境模型下学习策略；而在执行阶段，各智能体仅依据本地观测做出决策，从而满足现实通信受限场景的部署约束。CTDE 框架与全局集中式方法相比，显著缓解了动作空间随智能体数指数增长的扩展性问题；与全分散式方法相比，又通过训练阶段的全局信息共享避免了非平稳性带来的训练失稳。

CTDE 范式下的代表性算法可分为价值分解（Value Decomposition）与集中评论家（Centralized Critic）两大类。价值分解方法将团队联合 Q 函数分解为各智能体局部 Q 函数的某种聚合，代表性工作包括 VDN、QMIX 与 QPLEX，其单调性约束保证了局部最优与全局最优的一致性^[35]。集中评论家方法则在训练时维护一个以全局状态为输入的中心化评论家网络，并以此指导各智能体局部策略的更新，代表性工作包括 MADDPG 与 MAPPO^[36-37]。

MAPPO 作为近年来最受关注的 CTDE 算法之一，将单智能体 PPO 扩展到多智能体场景，通过共享参数与集中评论家显著提升训练稳定性。其策略更新目标为：

$$L^{\text{CLIP}}(\theta) = \mathbb{E} \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.12)$$

其中 $\rho_t(\theta) = \pi_{\theta}(a_t | o_t) / \pi_{\theta_{\text{old}}}(a_t | o_t)$ 为重要性比率， $\hat{A}_t$ 为基于集中评论家估计的优势函数， ϵ 为裁剪系数。MAPPO 在 SMAC、GRF 等基准上的表现已被多项研究证实其综合性能优于 QMIX 等价值分解方法^[37]。

2.4.3 协同决策中的奖励设计与扩展性

奖励函数设计是 MARL 应用于具体协同问题的关键环节。共享团队奖励能够在原则上鼓励合作，但在大规模智能体场景下会引发信用分配（Credit Assignment）问题——即难以从团队整体奖励中区分各个智能体的具体贡献。COMA 等反事实基线方法通过构造“假设智能体 i 执行其他动作”的对照基线，显式估计每个智能体对团队奖励的边际贡献，从而缓解信用分配难题^[35]。在工程实践中，常用方法是将团队奖励与个体奖励按比例加权，从而在协同性与个体可控性之间寻求平衡。

针对扩展性问题，近期研究探索了基于图神经网络的层级注意力机制^[38]，通过对智能体之间的依赖关系建模，将注意力计算压缩到必要的邻居子集，从而显著降低智能体规模带来的状态拼接维度。该思路与本研究中“基于信誉与可见性筛选候选邻居”的协同模式具有较强的契合性。

CTDE 范式与 MAPPO 算法是本研究第4章系统层方法的核心技术路径。第4章将以每个 SEN 抽象为一个智能体，以第3章定义的链上共享状态作为观测输入，通过 MAPPO 联合学习任务流向偏好、资源分配比例和外部任务接收意愿等长时间尺度协同动作，并通过候选约束机制将协同意图下发至第5章的任务层执行。式（2.12）即为第4章策略更新目标的理论原型。

2.5 本章小结

本章围绕本文后续方法设计所需的理论基础，分别介绍了天基网络与计算卸载、区块链可信协同、联邦学习与聚类联邦学习、多智能体强化学习等相关技术。在天基网络与计算卸载方面，本章梳理了天基网络的层级结构、链路时变特性以及卸载决策的基本时延模型，为第3章构建卫星终端、卫星边缘节点、地面控制中心和动态链路模型提供基础。在区块链可信协同方面，本章介绍了联盟链、共识机制、智能合约和节点信誉机制，为后续可信状态共享、行为审计和链上反馈机制提供支撑。在联邦学习与聚类联邦学习方面，本章说明了分布式数据不出域条件下的模型协同训练方法，为第5章并发开销预测模型的训练提供理论依据。在多智能体强化学习方面，本章介绍了 Dec-POMDP、CTDE 和 MAPPO 等基本方法，为第4章多节点系统层协同资源分配奠定基础。

总体而言，本章的作用在于为后续章节提供必要的理论和技术支撑，后续第3章

将在上述技术基础上建立天基协同计算卸载统一模型；第4章将结合区块链可信状态共享与多智能体强化学习，研究系统层协同资源分配方法；第5章将结合聚类联邦学习与 DQN，研究并发开销感知的任务层实时卸载方法。由此，本文形成从理论基础到统一建模，再到系统层协同和任务层卸载的递进关系。

3 天基网络可信协同计算卸载场景与基础建模

3.1 引言

天基网络协同计算卸载的难点并不局限于单次任务的节点选择，而在于动态拓扑、异构资源、并发竞争与可信协同之间的耦合关系。卫星轨道运动使星间与星地链路的可达性、带宽和可见窗口持续变化；不同卫星终端、卫星边缘节点和地面控制中心在计算能力、存储容量、能量预算和通信条件上存在显著差异；同时，多节点并发卸载会使目标节点上的新任务和存量任务共同争用计算资源，导致传统“传输时延 + 计算时延”模型难以准确反映真实执行代价。

在去中心化天基环境中，协同卸载还依赖可信状态共享。若节点仅依据局部观测进行卸载，容易因信息不足造成负载集中；若依赖集中式全局状态采集，则又会受到链路可见窗口、状态传播时延和中心节点可达性的限制。区块链账本可为节点资源摘要、任务生命周期事件、信誉记录和模型版本凭据提供可信、可追溯的共享底座，但其共识与同步过程本身具有非实时性。因此，链上信息更适合作为可信公共上下文，而不能简单替代任务到达瞬间的本地快速观测与决策。

基于上述特点，本章按照“系统角色—链上账本—任务生命周期—基础代价模型—可信状态摘要”的顺序展开建模。首先明确卫星终端、卫星边缘节点、地面控制中心和区块链可信控制平面在协同卸载中的职责；随后从链上事件和任务生命周期角度说明区块链如何支撑非实时可信状态共享；在此基础上，进一步建立网络拓扑、节点资源、任务属性、链路传输、本地计算、星间卸载、并发开销和链上摘要模型。与直接给出优化目标的写法不同，本章重点在于统一场景假设和基础变量含义，使后续章节能够在同一系统语境下分别展开系统层协同资源分配和任务层并发感知卸载方法。

3.2 天基网络可信协同计算卸载场景

本节从系统组成、链上账本和任务生命周期三个层面描述本文所研究的协同计算卸载场景。整个系统由物理网络层和区块链可信控制平面共同支撑：物理网络层提供动态时变的星间与星地链路，是任务传输和计算执行的物理载体；区块链可信控制平面以联盟链与智能合约为载体，记录低维可信摘要和关键生命周期事件，为节点间协作提供可追溯的公共上下文。场景总体结构如图3.1所示。




图 3.1 天基网络可信协同计算卸载场景与四类参与角色

图3.1中，物理网络层刻画卫星轨道运动以及由此产生的时变星间和星地链路。链路的可达性、可用带宽和剩余可见窗口随轨道相对几何关系动态变化，使节点之间的状态同步和任务传输均具有明显的时变特征。节点本地状态摘要 $\Sigma_i(t)$ 在频次受控的前提下经由该层链路提交至链上，其上链频率需综合考虑链路带宽预算、可见窗口长度和共识开销，避免高频状态广播挤占任务数据通信带宽。

参与协同计算的实体划分为四类。卫星终端 ST（属于 V_{ST} ）一般指资源受限的小型卫星或专用终端，主要负责生成计算任务、采集本地状态、读取链上摘要并执行卸载动作，是任务发起方。卫星边缘节点 SEN（属于 V_{SEN} ）通常具备更强算力和转发能力，负责接收外部卸载任务、维护执行队列、参与协同资源分配并反馈执行结果。地面控制中心 CC（属于 V_{CC} ）拥有更充裕的计算和存储资源，但其与天基节点之间的可达性受轨道可见窗口约束，主要承担模型聚合、全局策略训练、跨域监管与审计等低频或后台任务。区块链可信控制平面不直接执行高频计算任务，而是维护节点资源摘要、任务开始与结束事件、信誉记录、模型版本摘要和审计凭据等低维可信信息。

形式化地，参与协同计算的节点集合表示为

$$\mathcal{V} = \mathcal{V}_{\text{ST}} \cup \mathcal{V}_{\text{SEN}} \cup \mathcal{V}_{\text{CC}}. \quad (3.1)$$

任一物理节点既可能是任务发起方，也可能在满足资源与权限条件时成为任务执行方。为支撑可信共享，本文进一步从功能职责角度定义共识维护节点集合 $\mathcal{V}_{\text{con}} \subseteq \mathcal{V}$ 、任务执行节点集合 $\mathcal{V}_{\text{exe}} \subseteq \mathcal{V}$ 和链下存储节点集合 $\mathcal{V}_{\text{sto}} \subseteq \mathcal{V}$ 。三类集合分别对应区块定序与状态广播、任务承接与执行反馈、以及大规模实体对象的链下存储。上述集合并非互斥关系，同一 SEN 可同时承担共识和任务执行功能，CC 在可见窗口内也可兼具共识、执行和链下存储能力。

区块链账本在该场景中承担“可信但非实时”的信息共享功能。其核心作用不是替代实时调度器，而是把影响后续决策和审计的关键事件固化为可追溯记录。结合天基协同卸载过程，链上事件可概括为

$$\mathcal{E}_{\text{chain}} = \{\mathcal{E}_{\text{res}}, \mathcal{E}_{\text{start}}, \mathcal{E}_{\text{end}}, \mathcal{E}_{\text{rep}}, \mathcal{E}_{\text{model}}, \mathcal{E}_{\text{audit}}\}, \quad (3.2)$$

其中， $\mathcal{E}_{\text{res}}$ 表示节点资源状态摘要事件，用于描述节点算力、队列、能量、链路统计和信誉等低维状态； $\mathcal{E}_{\text{start}}$ 表示任务开始事件，用于标记任务进入本地执行或卸载执行阶段； $\mathcal{E}_{\text{end}}$ 表示任务结束事件，用于记录完成时间、执行结果和异常状态； $\mathcal{E}_{\text{rep}}$ 表示信誉变更事件，用于记录节点行为评分及激励惩戒结果； $\mathcal{E}_{\text{model}}$ 表示模型版本事件，用于维护联邦预测模型的版本号、哈希和适用范围； $\mathcal{E}_{\text{audit}}$ 表示审计事件，用于记录异常上报、验证失败或跨域协作凭据。

基于上述链上事件，一次任务从到达完成可描述为如下生命周期。首先，ST 产生任务并提取输入规模、计算量、截止期、类型和优先级等属性；其次，ST 读取本地状态与链上公共摘要，获得当前可用资源、候选节点信誉、任务执行队列和模型版本等可信上下文；随后，系统依据链路可见窗口、节点信誉门限和负载状态形成候选动作集合，任务层再在候选集合内选择本地执行或卸载至某一目标节点；若任务被卸载，则产生任务开始事件并写入链上，目标节点完成任务计算后返回结果；最后，任务结束事件和执行反馈被写入链上，并进一步影响后续资源摘要、信誉评分和模型训练样本。由此，任务执行不再是单向的“发起—执行—返回”过程，而是形成“读取可信摘要—做出卸载决策—记录执行事件—反馈更新状态”的闭环。

需要强调的是，链上摘要具有可信性和可追溯性，但不具有强实时性。共识确认、

区块广播和账本同步引入的附加时延记为 D_{chain} 。在系统层较长时间尺度上, D_{chain} 通常可被视为可容忍的小量; 在单任务到达的短时间尺度上, 链上摘要相对于真实运行状态可能存在时滞。因此, 后续任务决策不能仅依赖链上摘要, 还需要结合本地高频观测与并发开销预测。以下基础模型正是在这一场景假设下建立。

3.3 系统基础模型

第3.2节从角色和生命周期角度刻画了协同卸载场景, 本节进一步建立支撑该场景的基础数学模型。考虑到天基协同卸载涉及变量众多、跨越物理传输与可信共享两类机制, 本节按照“物理层-代价层-可信控制平面”的三层结构组织各子模型, 使变量之间的耦合关系清晰可循, 基础模型整体架构如图3.2所示。




图 3.2 天基协同卸载基础模型架构

图3.2中, 物理层模型包含网络拓扑、节点资源和任务三个子模型, 共同刻画任务到达时系统的物理状态与可行域; 代价层模型包含链路传输模型、本地计算与星间卸载模型, 以及作为本章核心的并发资源竞争模型, 后者通过资源竞争映射函数 $g_j(\cdot)$ 将新任务自身额外时延 $\Delta_{k,j}^{\text{new}}(t)$ 与对存量任务的扰动 $\Delta_{u|k,j}^{\text{rem}}(t)$ 区分开, 定义总并发开销 $CO_{k,j}(t)$; 可信控制平面模型包含联盟链结构与区块结构、链上状态摘要模型, 通过区块头-区块体双段式结构和哈希指针机制实现链上摘要与链下原始数据的解耦。三层

之间通过纵向数据流耦合: 物理层向代价层提供可行性约束与资源竞争上下文, 代价层向可信控制平面回写任务生命周期事件, 可信控制平面向上为后续任务决策提供经共识确认的公共上下文。值得说明的是, 可信控制平面与上层之间存在链上时滞 D_{chain} , 链上摘要具有可信性但不具有强实时性, 这一特性使任务到达瞬间的决策需要同时结合链上摘要、本地高频观测与并发开销估计, 也是连接本章基础模型与后续章节方法的关键性质。

下面按照图3.2给出的三层结构, 自上而下逐一描述各子模型的形式化定义。

3.3.1 网络拓扑模型

天基网络拓扑随轨道运动和链路可见关系动态变化。本文将其表示为时变有向图

$$\mathcal{G}(t) = (\mathcal{V}, \mathcal{E}_{\text{link}}(t)), \quad (3.3)$$

其中, $\mathcal{V}$ 由式(3.1)给出, $\mathcal{E}_{\text{link}}(t)$ 为时刻 t 可用通信链路集合。若节点 i 与节点 j 在时刻 t 存在可用链路, 则 $(i, j) \in \mathcal{E}_{\text{link}}(t)$ 。链路状态可表示为

$$\ell_{ij}(t) = (B_{ij}(t), d_{ij}^{\text{prop}}(t), \tau_{ij}^{\text{vis}}(t), p_{ij}^{\text{loss}}(t)), \quad (3.4)$$

其中, $B_{ij}(t)$ 为可用带宽, $d_{ij}^{\text{prop}}(t)$ 为传播时延, $\tau_{ij}^{\text{vis}}(t)$ 为剩余可见窗口, $p_{ij}^{\text{loss}}(t)$ 为链路中断概率估计。该链路状态既决定任务是否具备卸载可行性, 也影响链上状态摘要能否在有限窗口内完成提交和同步。

3.3.2 节点资源模型

节点 v_i 的资源状态定义为

$$R_i(t) = (F_i(t), M_i(t), Q_i(t), E_i(t), \rho_i(t), \text{Rep}_i(t)), \quad (3.5)$$

其中, $F_i(t)$ 表示可用计算能力, $M_i(t)$ 表示可用存储或缓存容量, $Q_i(t)$ 表示任务队列长度, $E_i(t)$ 表示剩余能量或能量预算, $\rho_i(t)$ 表示资源利用率, $\text{Rep}_i(t)$ 表示节点信誉评分。这里的资源利用率可根据需要进一步展开为 CPU、内存、缓存或链路等不同维度的利用率分量; 在统一模型中记为 $\rho_i(t)$, 后续具体方法可按决策粒度选择相应分量。

资源状态具有双重作用: 一方面, 它是判断节点能否承接新任务的物理基础; 另一方面, 它经过摘要化处理后进入链上账本, 成为其他节点进行候选筛选和风险评估

时可验证的公共信息。由于原始资源状态采样频率较高，本文不假设其全量实时共享，而是在第3.3.7节中进一步定义低维状态摘要 $\Sigma_i(t)$ 。

3.3.3 任务模型

设任务集合为 $\mathcal{T}$ 。任一新到达任务 T_k 可表示为

$$T_k = (s_k, c_k, d_k, \tau_k, \zeta_k, t_k^{\text{arr}}), \quad (3.6)$$

其中， s_k 为任务输入数据规模， c_k 为完成任务所需的 CPU 周期数， d_k 为任务最大可接受完成时延， τ_k 为任务类型标识， ζ_k 为任务优先级， t_k^{arr} 为任务到达时间。该表示方式适用于遥感图像识别、目标检测、通信解调、数据压缩和信号处理等多类天基计算任务。

并发卸载的关键在于，新任务到达时目标节点上往往已有任务正在执行。设时刻 t 节点 j 上正在执行的任务集合为

$$\mathcal{Q}_j(t) = \{T_u \mid T_u \text{ 在时刻 } t \text{ 正在节点 } j \text{ 上执行}\}, \quad (3.7)$$

其规模 $|\mathcal{Q}_j(t)|$ 表示节点 j 的当前并发任务数。对于任一存量任务 $T_u \in \mathcal{Q}_j(t)$ ，其状态可由任务计算量、开始时间、已完成计算量和剩余时限等信息刻画。令 $\eta_u(t)$ 表示任务 T_u 在时刻 t 前已经完成的计算量，则其剩余计算量为

$$c_u^{\text{rem}}(t) = \max\{c_u - \eta_u(t), 0\}. \quad (3.8)$$

上述存量任务集合是并发开销产生的直接来源：新任务一旦被分配到节点 j ，就会与 $\mathcal{Q}_j(t)$ 中的任务共同竞争计算资源。

对于任务 T_k ，其动作集合由本地执行和候选卸载节点共同组成。令 $\mathcal{N}_k^{\text{off}}(t)$ 表示满足链路可达性、信誉门限和基本资源约束的候选执行节点集合，则任务动作集合为

$$\mathcal{A}_k(t) = \{i\} \cup \mathcal{N}_k^{\text{off}}(t), \quad (3.9)$$

其中 i 为任务发起节点。卸载决策变量定义为

$$x_{k,j}(t) = \begin{cases} 1, & \text{任务 } T_k \text{ 在时刻 } t \text{ 选择节点 } j \text{ 执行,} \\ 0, & \text{否则,} \end{cases} \quad j \in \mathcal{A}_k(t), \quad (3.10)$$

并满足 $\sum_{j \in \mathcal{A}_k(t)} x_{k,j}(t) = 1$ 。与只讨论是否卸载的二元决策不同，天基协同计算场景

中可选目标通常包含多个 SEN 或可见窗口内的 CC，因此本文采用多候选节点动作表示。

为使建模具有典型物理锚点，本文以低轨遥感星座辅助应急图像识别任务作为参考场景：考虑由若干卫星终端、卫星边缘节点和地面控制中心构成的协同计算网络，单次试验典型时长为分钟级，单任务典型输入数据规模为兆字节量级，典型计算量为百万至十亿浮点运算量级。

3.3.4 链路传输模型

当任务 T_k 从节点 i 卸载至节点 j 时，其传输速率可写为

$$R_{ij}(t) = B_{ij}(t) \log_2 \left(1 + \frac{P_i h_{ij}(t)}{N_0 B_{ij}(t)} \right), \quad (3.11)$$

其中， P_i 为节点 i 的发送功率， $h_{ij}(t)$ 为信道增益， N_0 为噪声功率谱密度。相应传输时延为

$$D_{k,ij}^{\text{tx}}(t) = \frac{s_k}{R_{ij}(t)} + d_{ij}^{\text{prop}}(t). \quad (3.12)$$

若 $D_{k,ij}^{\text{tx}}(t)$ 已超过链路剩余可见窗口或任务截止期，则节点 j 不应进入任务 T_k 的可行候选集合。由此，链路模型不仅提供时延计算依据，也参与候选节点筛选。

3.3.5 本地计算与星间卸载模型

若任务在发起节点 i 本地执行，其完成时延为

$$D_{k,i}^{\text{loc}}(t) = W_i(t) + \frac{c_k}{f_{k,i}^{\text{alloc}}(t)}, \quad (3.13)$$

其中， $W_i(t)$ 为排队等待时延， $f_{k,i}^{\text{alloc}}(t)$ 为节点 i 分配给任务 T_k 的有效计算频率。

若任务卸载至节点 j ，则需要同时考虑传输、排队、执行和并发竞争。由于星载操作系统调度、任务类型异构和多任务资源共享机制较为复杂，单纯依靠解析公式难以准确给出新任务与存量任务的实际资源分配。为此，本文用资源竞争映射函数 $g_j(\cdot)$ 描述新任务加入后目标节点 j 的资源分配结果：

$$(f_{k,j}^{\text{new}}(t), \{f_{u,j}^{\text{rem}}(t)\}_{T_u \in \mathcal{Q}_j(t)}) = g_j(T_k, \mathcal{Q}_j(t), R_j(t), \ell_{ij}(t)), \quad (3.14)$$

其中， $f_{k,j}^{\text{new}}(t)$ 表示节点 j 分配给新任务 T_k 的有效计算频率， $f_{u,j}^{\text{rem}}(t)$ 表示新任务加入后节点 j 分配给存量任务 T_u 的有效计算频率。函数 $g_j(\cdot)$ 反映调度策略、任务类型、

当前队列和节点资源状态共同作用下的资源竞争结果。该函数在统一模型中作为未知但存在的竞争映射，后续可通过数据驱动模型进行近似。

在新任务视角下，卸载至节点 j 的端到端完成时延写为

$$D_{k,ij}^{\text{off}}(t) = D_{k,ij}^{\text{tx}}(t) + W_j(t) + \frac{C_k}{f_{k,j}^{\text{new}}(t)} + \Delta_{k,j}^{\text{new}}(t), \quad (3.15)$$

其中， $\Delta_{k,j}^{\text{new}}(t)$ 表示由于资源竞争、上下文切换、缓存扰动或调度开销等因素给新任务自身带来的额外完成时延。与式(3.13)相比，式(3.15)不仅包含跨节点传输时延，还包含目标节点已有负载对新任务执行过程的影响。

从系统视角看，并发开销还包括新任务加入后对存量任务的扰动。若不接纳新任务 T_k ，存量任务 T_u 在节点 j 上的剩余完成时延记为 $D_{u,j}^{\text{rem},0}(t)$ ；若接纳新任务，剩余完成时延记为 $D_{u,j}^{\text{rem},k}(t)$ 。则任务 T_k 对存量任务 T_u 造成的剩余时延增量为

$$\Delta_{u|k,j}^{\text{rem}}(t) = \max \left\{ D_{u,j}^{\text{rem},k}(t) - D_{u,j}^{\text{rem},0}(t), 0 \right\}. \quad (3.16)$$

由此，任务 T_k 卸载至节点 j 引起的总并发开销定义为

$$CO_{k,j}(t) = \Delta_{k,j}^{\text{new}}(t) + \sum_{T_u \in \mathcal{Q}_j(t)} \Delta_{u|k,j}^{\text{rem}}(t). \quad (3.17)$$

该定义明确区分了两类影响：一类是新任务自身的额外时延，另一类是对已有任务剩余执行过程的扰动。前者直接影响新任务的端到端完成时间，后者反映系统层面的外部性。若忽略第二类影响，卸载策略可能倾向于把任务集中分配给短期看似高性能的节点，从而牺牲正在执行任务的完成质量；若忽略第一类影响，则会低估新任务在高负载节点上的真实等待和调度代价。这正是图3.2中将并发资源竞争模型作为代价层核心强调块单独刻画的原因。

本地执行能耗可近似表示为

$$E_{k,i}^{\text{loc}}(t) = \kappa_i c_k (f_{k,i}^{\text{alloc}}(t))^2, \quad (3.18)$$

其中， κ_i 为节点 i 的有效电容系数。卸载执行能耗可表示为

$$E_{k,ij}^{\text{off}}(t) = P_i \frac{s_k}{R_{ij}(t)} + \kappa_j c_k (f_{k,j}^{\text{new}}(t))^2 + E_{k,ij}^{\text{wait}}(t), \quad (3.19)$$

其中， $E_{k,ij}^{\text{wait}}(t)$ 表示等待和连接维持过程中的额外能耗。

上述模型给出了天基协同卸载中的基础代价构成。需要说明的是， $g_j(\cdot)$ 、 $\Delta_{k,j}^{\text{new}}(t)$

和 $CO_{k,j}(t)$ 往往难以完全由解析模型闭式计算, 原因在于它们同时受任务组合、节点调度策略、缓存状态和动态负载影响。因此, 本章只给出物理含义与形式化边界, 后续方法可在该定义基础上采用学习模型对并发开销进行估计。

3.3.6 联盟链结构与区块结构

考虑到天基协同计算环境中节点身份相对受控、共识效率约束严格、不同业务事件之间存在频次与时效差异, 本文采用联盟链方式组织区块链可信控制平面, 并对其网络组成、链上链下数据划分以及区块结构进行形式化描述。

3.3.6.1 联盟链网络组成

设区块链网络由一组授权账本节点 $\mathcal{V}_{\text{chain}} \subseteq \mathcal{V}$ 构成。按照账本维护权限, 可将其划分为共识节点集合 $\mathcal{V}_{\text{con}}$ 和账本接入节点集合 $\mathcal{V}_{\text{cli}}$ 。其中, $\mathcal{V}_{\text{con}}$ 负责区块定序、交易校验与状态广播, 是账本一致性的直接维护方; $\mathcal{V}_{\text{cli}}$ 不参与区块生成, 但可进行状态读取、事件提交与本地校验。二者满足 $\mathcal{V}_{\text{con}} \cap \mathcal{V}_{\text{cli}} = \emptyset$ 且 $\mathcal{V}_{\text{con}} \cup \mathcal{V}_{\text{cli}} = \mathcal{V}_{\text{chain}}$ 。这里的 $\mathcal{V}_{\text{cli}}$ 仅表示联盟链中的账本访问身份, 与任务执行节点集合 $\mathcal{V}_{\text{exe}}$ 属于不同维度, 二者不构成排斥关系。

考虑到原始任务输入、完整模型参数和详细执行日志在体量上显著高于状态摘要类数据, 本文采用链上摘要与链下存储相结合的方式: 联盟链账本仅承载低维可信信息, 原始实体对象由链下存储节点 $\mathcal{V}_{\text{sto}}$ 维护, 并通过哈希指针与链上摘要建立映射。链上维护的数据集合可表示为

$$\mathcal{D}_{\text{on}} = \{D_{\text{res}}, D_{\text{task}}, D_{\text{rep}}, D_{\text{model}}, D_{\text{audit}}\}, \quad (3.20)$$

其中, D_{res} 为节点资源状态摘要集合, D_{task} 为任务生命周期事件集合, D_{rep} 为信誉记录集合, D_{model} 为模型版本摘要集合, D_{audit} 为行为审计记录集合。链下数据集合 $\mathcal{D}_{\text{off}}$ 主要包括原始任务输入数据片段、完整模型参数文件、训练样本索引和详细执行日志等。

链上摘要与链下对象之间通过哈希指针建立可验证映射。设链下对象为 D_j , 对象地址为 $\text{Loc}(D_j)$, 时间戳为 t_j , 则其哈希摘要为

$$\text{digest}_j = H(D_j \parallel \text{Loc}(D_j) \parallel t_j), \quad (3.21)$$

链上仅记录 digest_j 、对象类型、访问权限和索引信息。当节点读取链下对象时, 先经

权限校验获取对象地址，再从链下存储读取对象并重新计算哈希；若与链上摘要一致，则确认对象未遭篡改。该机制使链上数据规模与原始任务数据规模解耦，账本增长速度可控。

3.3.6.2 区块结构定义

为支撑多类摘要事件的统一组织与高效校验，本文采用“区块头—区块体”双段式结构。设第 h 个区块为 B^h ，其结构定义为

$$B^h = (\text{Header}^h, \text{Body}^h), \quad (3.22)$$

其中区块头 Header^h 承载区块元信息与共识凭据，区块体 Body^h 承载本区块包含的事件集合。

区块头进一步定义为

$$\text{Header}^h = (h, t_h, H(B^{h-1}), \text{Root}^h, \text{Ver}, \text{Sig}_{\text{Vcon}}^h), \quad (3.23)$$

其中各字段含义见表3.1。区块头中的前块哈希字段使所有区块通过哈希指针构成顺序链式结构，任一历史区块被篡改都将导致后续所有区块的哈希校验失败，从而保证账本不可篡改性；默克尔根字段则为区块体中事件集合的紧凑承诺，支持任意事件的轻量级存在性证明。

表 3.1 区块头字段定义

字段	名称	含义
h	区块高度	当前区块在账本中的序号，单调递增
t_h	时间戳	区块生成时间，用于事件时序对齐
$H(B^{h-1})$	前块哈希	前一区块的哈希指针，构成链式结构
Root^h	默克尔根	区块体中所有事件的默克尔树根，用于完整性校验
Ver	版本号	账本协议版本与区块结构版本标识
$\text{Sig}_{\text{Vcon}}^h$	共识签名	共识节点对本区块的多签集合，作为共识完成凭据

区块体由本区块所收录的链上事件按类型分组组织：

$$\text{Body}^h = \bigcup_{\kappa \in \{\text{res}, \text{start}, \text{end}, \text{rep}, \text{model}, \text{audit}\}} \mathcal{E}_{\kappa}^h, \quad (3.24)$$

其中， $\mathcal{E}_{\text{res}}^h$ 为节点资源摘要事件集合， $\mathcal{E}_{\text{start}}^h$ 为任务开始事件集合， $\mathcal{E}_{\text{end}}^h$ 为任务结束事件

集合, $\mathcal{E}_{\text{rep}}^h$ 为信誉变更事件集合, $\mathcal{E}_{\text{model}}^h$ 为模型版本更新事件集合, $\mathcal{E}_{\text{audit}}^h$ 为行为审计事件集合。任务开始事件和任务结束事件共同构成 D_{task} 的主要来源, 使任务从进入执行到完成反馈的全过程具备链上可追溯性。

通过上述结构, 联盟链实现三方面作用: 其一, 所有上链事件以默克尔树形式承诺于区块头并经共识签名固化, 具备完整性与不可篡改性; 其二, 区块体按事件类型分组, 便于上层方法按类索引和组合查询; 其三, 链上摘要与链下实体通过哈希指针解耦, 使区块链作为可信控制平面承载低维状态共享与治理事件, 而不直接承载高维原始任务数据。

3.3.7 链上状态摘要模型

原始资源状态 $R_i(t)$ 维度较高、采样较为频繁, 若全部上链将迅速突破链路与存储预算。为此, 本子模型给出 $R_i(t)$ 的低维摘要化表示, 使节点状态既可在链上共享, 又不显著增加共识与同步负担。

节点 i 在时刻 t 上链的状态摘要定义为

$$\Sigma_i(t) = (\hat{F}_i(t), \hat{Q}_i(t), \hat{E}_i(t), \hat{B}_i(t), \hat{\rho}_i(t), \text{Rep}_i(t), \theta_i^{\text{ts}}), \quad (3.25)$$

其中各分量分别为算力、队列长度、剩余能量、链路统计、资源利用率经摘要化处理后的可信表示, θ_i^{ts} 为摘要时间戳。摘要可采用分位数压缩、滑动窗口平均或事件触发上链等方式生成, 使每次上链数据量远小于原始观测序列。

由各节点摘要进一步聚合得到链上公共摘要:

$$G(t) = (\bar{L}(t), \sigma_L^2(t), D^{\text{task}}(t), R^{\text{rep}}(t), \hat{D}_{\text{chain}}(t), T^{\text{stat}}(t)), \quad (3.26)$$

其中, $\bar{L}(t)$ 为全局平均负载, $\sigma_L^2(t)$ 为负载方差, $D^{\text{task}}(t)$ 为任务分布摘要, $R^{\text{rep}}(t)$ 为信誉评分向量, $\hat{D}_{\text{chain}}(t)$ 为链上同步延迟估计, $T^{\text{stat}}(t)$ 为吞吐统计摘要。 $G(t)$ 反映的是经共识确认后的可信公共视图, 而不是任一节点的实时完整状态。

模型版本凭据由链上数据集中的 D_{model} 单独维护。为描述预测模型的版本一致性与可追溯性, 本文定义模型摘要为

$$M(t) = (V^{\text{model}}(t), H^{\text{model}}(t), C^{\text{model}}(t), \theta_{\text{ts}}^{\text{model}}), \quad (3.27)$$

其中, $V^{\text{model}}(t)$ 表示当前模型版本号, $H^{\text{model}}(t)$ 表示模型参数或模型文件的哈希摘要, $C^{\text{model}}(t)$ 表示模型所属簇或适用节点集合, $\theta_{\text{ts}}^{\text{model}}$ 表示模型摘要上链时间戳。完整模型

参数不直接写入账本，而由链下存储节点或联邦协调单元维护；链上仅保存与版本一致性、完整性校验和溯源审计相关的低维凭据。

因此，任务到达时可用的可信公共信息可表示为系统状态摘要与模型版本摘要的组合：

$$G^{\text{task}}(t) = (G(t), M(t)). \quad (3.28)$$

其中， $G(t)$ 提供负载、信誉、任务统计和链上延迟等公共上下文， $M(t)$ 提供预测模型的版本号、哈希和适用范围。由于 $G(t)$ 和 $G^{\text{task}}(t)$ 都经过共识确认和广播同步，它们具有可信性和可审计性，但相对于真实运行状态存在时滞。该特性正是后续任务层决策需要同时结合链上摘要、本地观测和并发开销估计的原因。

3.4 本章小结

本章围绕天基网络可信协同计算卸载问题，按照“系统角色—链上账本—任务生命周期—基础代价模型—可信状态摘要”的叙事顺序建立了统一基础模型。首先，本章明确了卫星终端、卫星边缘节点、地面控制中心和区块链可信控制平面四类参与角色，说明了链上账本在协同卸载中承担可信但非实时的公共上下文维护功能，并将任务执行过程描述为由状态读取、候选筛选、卸载决策、任务开始、任务完成和反馈更新构成的闭环。随后，本章建立了网络拓扑、节点资源、任务属性、链路传输、本地计算、星间卸载和能耗模型，并重点刻画了新任务与目标节点存量任务之间的并发资源竞争关系。通过引入存量任务集合 $Q_j(t)$ 、资源竞争映射 $g_j(\cdot)$ 以及总并发开销 $CO_{k,j}(t)$ ，本章将新任务自身额外时延与其对存量任务剩余完成时延的扰动区分开来，从而为后续并发感知卸载方法提供更清晰的物理解释。最后，本章对联盟链网络组成、链上链下数据划分、区块头—区块体结构和链上状态摘要进行了形式化描述。区块链账本仅维护资源摘要、任务开始与结束事件、信誉记录、模型版本摘要和审计凭据等低维可信信息，原始任务数据、完整模型参数和详细执行日志则通过链下存储与哈希指针方式进行关联。由此，区块链可信控制平面既能提供可追溯的公共状态，又不会承担高频实时调度和大规模原始数据存储职责。

本章为后续方法章节提供统一的基础建模。第4章将在较长时间尺度上研究多节点系统层协同资源分配；第5章将在单任务到达的短时间尺度上研究并发开销感知的任务层实时卸载。二者均建立在本章给出的模型之上。

4 基于区块链与多智能体强化学习的系统层协同资源分配方法

第3章已经建立了天基网络可信协同计算卸载的场景描述、基础模型与可信状态刻画，为系统层协同资源分配和任务层实时卸载决策提供了统一的符号体系。本章在此基础上聚焦系统层协同资源分配问题，重点研究多个异构卫星边缘节点在去中心化、信息不完全和资源竞争并存条件下的长期可信协同机制。

与上一章侧重统一建模基础不同，本章沿着“资源竞争如何产生、局部自利为何导致全局失衡、可信共享如何提供系统级上下文、学习算法如何形成长期协同策略”的逻辑展开。依托第3章给出的节点资源、链路状态、任务分布和链上公共摘要，本章将系统层资源分配过程形式化为部分可观测的多智能体马尔可夫博弈，并进一步设计区块链增强的集中训练一分散执行多智能体强化学习方法。

4.1 引言

随着低轨卫星互联网、在轨智能处理与星间协同计算的发展，天基计算网络正在从“以通信为主”的基础设施演化为“通信、计算、存储、智能处理一体化”的分布式服务平台。不同轨道层、不同载荷能力以及不同链路条件的卫星节点，通过时变星间链路构成动态互联的在轨计算网络，共同承担遥感影像预处理、目标检测、轨道态势分析、数据压缩转发、任务规划等多类任务。与传统“先回传、后处理”的地面中心化模式相比，在轨协同处理能够降低原始数据的大规模回传压力，缩短任务响应路径，并提升系统在时敏型任务下的自主运行能力。因此，如何对异构卫星节点进行高效、可信、持续的协同资源分配，成为影响天基网络整体服务能力的关键问题。

这一问题首先来自资源竞争。天基计算节点的计算能力、可用存储、剩余能量和热控条件均受平台约束，无法像地面云数据中心那样通过快速扩容缓解局部过载；星间链路又受轨道位置、可见窗口和瞬时拥塞状态影响，导致拓扑与通信条件持续变化。同时，任务负载并非平稳到达，不同任务在计算量、数据规模和时延约束上差异显著，突发重型任务容易在短时间内形成局部瓶颈。也就是说，系统层协同资源分配不是一次性的静态映射，而是一个伴随任务到达、资源消耗、链路变化和节点行为演化不断推进的连续序贯决策过程。

更为关键的是，上述资源竞争发生在缺乏长期稳定全局协调者的去中心化环境

中。任一节点只能直接掌握本地高频状态，而对远端节点的任务队列、资源占用、信誉水平和协作意愿，只能通过有限的公共摘要间接感知。在这种条件下，节点天然倾向于优先保障本地高价值任务、选择性接纳外部卸载任务，甚至通过策略性上报影响任务流向。其结果是，能力强节点被高收益任务持续吸引而逐渐拥塞，能力弱节点则因协作价值难以体现而长期闲置，最终诱发“局部理性—全局失衡”的公地悲剧。可见，本章要解决的核心矛盾，并不只是“如何更快地做调度”，而是“如何在去中心化、自利行为和不完全共存条件下维持持续协同”。

为了直观说明上述局部自利行为如何在系统层累积为负载失衡，图 4.1对比了无可信协调机制和引入可信共享与协同激励机制两种资源分配状态。




图 4.1 天基协同资源分配中局部自利与全局协同差异示意

图 4.1从资源流向和节点负载状态两个角度刻画了天基协同资源分配中的局部自利与全局协同差异。图左侧表示缺乏可信协调机制的局部自利场景：高收益任务 $H1$ 、 $H2$ 吸引大量请求集中流向少数强节点，导致强节点队列堆积形成热点拥塞，部分弱节点则因协作价值难以体现而长期闲置，呈现“强节点过载、弱节点闲置”的局部最优与全局失衡。

优陷阱。图右侧给出引入可信共享与协同激励后的分配效果：任务流向依据公共信息板中的全局负载、任务分布和信誉评分进行综合分配，信誉机制将历史协作行为反馈到后续收益中，使诚实节点获得长期正向激励，从而在多个异构节点之间形成更均衡的负载分布。该图进一步说明，若缺少可信共享和激励约束机制，节点局部理性行为容易累积为系统层负载失衡。

围绕图 4.1 所揭示的问题，现有研究主要存在三方面不足。第一类方法依赖集中式全局优化，通常假设系统能够实时收集所有节点的完整状态，并据此统一求解全局最优调度策略。这类方法在小规模、静态网络中具有一定理论优势，但在天基网络中面临状态同步代价高、链路时延大和全局视图易过期等现实障碍。第二类方法采用启发式或局部规则进行分布式调度，实现简单、开销较低，但缺乏对多节点长期博弈关系和系统级公平性的统一刻画，容易在高负载场景下重新形成热点拥塞。第三类方法引入强化学习进行自适应策略求解，但若仍以单智能体视角建模，就会把其他节点的策略变化等价于环境扰动，难以表达多主体之间“策略—环境”双向耦合的本质。

因此，要有效解决天基协同资源分配问题，需要回答三个层面的研究问题：其一，如何以统一的动态博弈模型刻画多个异构节点之间兼具竞争与合作特征的长期交互关系；其二，在缺乏中心协调者的条件下，如何使节点获得可信且可审计的系统级上下文，避免完全依赖不可靠的私有感知；其三，如何设计兼顾任务处理效率、全局公平性与长期协作意愿的激励机制，使节点在追求自身长期回报的同时逐步逼近系统总体更优的协同状态。这三个问题分别对应“博弈建模”“可信共享”和“信誉治理”，构成本章方法设计的主线。

基于上述认识，本章提出区块链增强的集中训练—分散执行多智能体强化学习方法 BC-CTDE-MAPPO。该方法并不试图构造一个持续在线的中心调度器，而是将联盟链作为可信公共信息板，在系统层周期内记录和广播节点负载、任务分布、信誉评分与审计摘要；在此基础上，将多个异构卫星节点之间的资源竞争与协同行为建模为部分可观测多智能体马尔可夫博弈，并通过集中式 Critic 学习联合价值函数、分散式 Actor 执行本地协同决策。进一步地，本文将任务完成质量、负载公平性和信誉变化统一纳入混合奖励函数，使节点在追求长期收益时同时考虑本地效率、系统均衡与协作可信性。

从全文结构来看，第3章给出了统一的场景假设、符号体系与可信状态刻画，但并不预先展开具体优化目标和双层问题求解。本章在该基础上承担系统层方法设计与

求解的任务。后续第5章的任务级实时卸载，需要建立在一个能够稳定共享状态、约束自利行为并维持长期负载均衡的系统层机制之上。因此，本章不直接追求单个任务在微观时间尺度上的最优执行，而是从系统层时间尺度出发，回答多个理性节点如何在长期运行中形成可信协同关系这一问题。

本章后续内容按照“系统框架—多智能体马尔可夫博弈建模—算法设计—实验分析”的逻辑展开。第4.2节给出系统框架与协同流程；第4.3节建立多智能体马尔可夫博弈模型；第4.4节介绍BC-CTDE-MAPPO算法设计；第4.5节通过多场景仿真实验验证所提方法在收敛性、负载均衡、任务完成率及抗自私行为方面的有效性；最后在第4.6节进行本章总结。

4.2 系统框架

本节先回答“系统由谁参与、信息如何共享、协同动作如何形成”三个问题，再为后续建模说明状态、动作、奖励以及联盟链摘要的来源。与中心式资源调度不同，本文考虑的系统层协同过程由本地节点、联盟链公共信息板和训练阶段的集中评估模块共同构成：节点在执行阶段只依赖本地观测和链上摘要进行自治决策，联盟链负责可信状态共享和行为留痕，集中训练模块仅在训练阶段用于联合价值评估。

4.2.1 系统组成

本章考虑的天基计算网络由四类核心参与者共同构成：执行在轨任务的异构计算节点、负责状态记账与摘要广播的联盟链节点、承担本地调度与协同决策的智能体模块，以及在训练阶段负责全局价值评估的集中式训练协调器。四者既分工明确，又通过任务流、状态流与信誉流形成紧密耦合。

第一类参与者是异构计算节点。它们分布在不同轨道层和不同星座拓扑位置上，具备差异化的计算、存储、能量和通信能力，是在轨任务执行的直接承担者。对系统而言，每个节点既可能处理本地生成的任务，也可能接收其他节点卸载而来的任务，因此天然兼具“任务生产者”和“任务处理者”双重身份。

第二类参与者是联盟链节点。它们共同维护系统级公共摘要，包括节点负载、信誉评分、链路统计与历史行为记录等信息。联盟链并不替代实时调度器，而是充当“可信公共信息板”：一方面为各节点提供可审计、可验证、可追溯的系统级上下文；另一方面通过链上信誉累积和行为留痕机制，为后续的激励约束提供可信依据。

第三类参与者是局部决策智能体。每个计算节点内部均部署一个策略模块，依据本地私有状态与链上公共摘要确定系统层统计窗口内的任务流向偏好、资源投入比例以及外部任务接收意愿。由于执行阶段无法依赖中心控制器，各节点必须在部分可观测条件下保持自主决策能力。

第四类参与者是集中训练协调器。它只在训练阶段存在，用于整合联合状态和联合动作，对多智能体策略进行价值评估与参数更新；在实际执行阶段，各节点仅保留各自的局部 Actor 网络，实现分散执行。这样的结构兼顾了训练阶段的信息利用效率与执行阶段的去中心化自治要求。




图 4.2 系统层协同资源分配框架的层次结构与信息流

图 4.2给出了本章所提框架的层次结构与信息流转关系。最上层为任务与资源环境层，包含动态任务到达、异构节点资源、时变链路拓扑和执行结果反馈，反映任务负载、节点资源和通信条件随时间共同演化的系统事实。中间层为公共信息板，对来自环境侧和节点侧的状态摘要进行聚合、存证与广播，提供全局平均负载、负载方差、任务分布、信誉评分向量、链同步时延估计和吞吐统计等低维摘要，避免在链上直接存储高维原始任务数据。底层为局部智能体决策层：每个卫星节点部署一个 Actor 策

略网络，输入由本地私有状态 l_t^i 和链上公共摘要 g_t 共同构成，即 $o_t^i = (l_t^i, g_t)$ ，输出系统层统计窗口内的任务流向偏好、资源比例和接收意愿，记为混合动作 a_t^i 。图右侧的集中训练调度器将各节点轨迹汇聚为联合状态，输入集中式 Critic 进行价值估计，并通过 GAE 和 PPO 更新参数；该模块仅在训练阶段使用联合信息，执行阶段各节点仅依赖本地观测和链上公共摘要进行分散决策。该图体现了“链上可信共享、节点局部自治、训练阶段集中评估、执行阶段分散决策”的总体结构。

4.2.2 公共信息板与协同流程

在上述系统组成基础上，本章将协同资源分配过程描述为一个持续演化的闭环。不同于传统中心调度模式中“中心收集全局状态—中心下发动作”的单向控制链条，本章强调由联盟链维护公共上下文，由节点依据局部观测自主形成协同动作，并将执行反馈重新汇入系统状态，从而在可信共享与分散自治之间建立联系。

该协同流程可概括为以下五个阶段。首先是任务到达与本地感知，节点在任务持续到达过程中更新本地队列长度、CPU/内存利用率、剩余能量和当前工作负载等高频状态。其次是链上摘要获取，节点从联盟链读取全局平均负载、负载方差、链路统计、信誉评分和链上时延估计等低频但可信的公共摘要，以补充局部感知中难以直接获得的系统级信息。再次是局部协同决策，策略网络基于“本地私有状态 + 链上公共摘要”生成任务流向偏好、资源分配比例和接收意愿等系统层动作。随后是执行反馈与信誉更新，动作作用于环境后，系统获得任务完成情况、平均时延、能耗、负载变化和协作质量等反馈，并据此更新节点信誉和系统负载摘要。最后是链上记账与参数迭代，联盟链将关键行为结果与信誉变化写入账本，在训练阶段服务于全局价值评估和参数更新，在执行阶段为下一轮协同决策提供新的可信上下文。

上述协同流程强调了三个关键闭环：一是“任务到达—局部决策—执行反馈”的任务闭环，决定了系统的实时响应能力；二是“状态汇总—链上广播—节点读取”的信息闭环，决定了多节点之间能否在缺乏中心调度器的情况下获得统一的协同上下文；三是“协作行为—信誉变化—后续激励”的治理闭环，决定了系统能否对长期自利与机会主义偏离形成可持续约束。三者共同构成了本章后续博弈建模与强化学习求解的系统基础。

4.2.3 协同难点

在上述框架下，本章关注的核心问题可表述为：当任务持续动态到达系统后，多个异构节点如何在不依赖中心调度器的条件下，联合确定系统层统计窗口内的任务流向、资源投入比例和外部任务接收意愿，使系统整体在任务完成率、平均时延、能耗开销、负载均衡和协同可信性之间取得更优平衡。换言之，本章研究的不是静态任务指派问题，而是一个随任务流、资源状态、链路关系和信誉轨迹不断演化的多主体序贯决策问题。

这一问题之所以困难，主要来自四类耦合难点。其一是资源异构与收益非一致性：相同任务在不同节点上的执行代价、完成收益和机会成本并不相同，局部最优动作往往会诱导全局失衡。其二是任务到达与链路状态的时变性：任务负载具有突发与长尾特征，链路可用性则随轨道位置和拥塞条件动态变化，使得调度策略必须具备在线适应能力。其三是可信共享信息的时效性约束：联盟链提供了可验证的系统级上下文，但链上信息同步本身存在时延，节点决策必须同时考虑“信息可信”与“信息陈旧”两种因素。其四是自利行为与长期治理问题：节点会根据局部收益结构动态调整行为，若缺少信誉约束和公共审计机制，系统容易重新滑向任务热点聚集与协作退化。

因此，从方法论角度看，后续建模必须同时满足三点要求：一是能够刻画多节点之间“策略—环境”双向耦合的动态交互；二是能够把联盟链提供的可信公共摘要纳入状态建模与激励设计；三是能够在训练阶段充分利用联合信息、在执行阶段保持局部自治。基于这一认识，下一节将进一步把上述系统框架形式化为多智能体马尔可夫博弈模型，并为后续的区块链增强 CTDE 求解方法奠定数学基础。

4.3 多智能体马尔可夫博弈建模

第 4.2 节说明了系统层协同资源分配的运行框架。本节进一步回答“如何把上述交互过程形式化”的问题。由于节点的任务接收、资源投入和协作意愿会直接改变自身负载状态，并通过链上公共摘要和信誉变化影响其他节点后续的协作选择，因此该问题不能被视为一次性静态优化，而应被建模为当前联合动作持续影响未来状态和未来收益的多主体序贯决策过程。基于这一认识，本文采用多智能体马尔可夫博弈 (Multi-Agent Markov Game, MAMG) 刻画系统层协同资源分配过程，并将联盟链公共信息板与信誉反馈纳入状态与奖励设计。

4.3.1 问题形式化

在将协同资源分配问题映射到数学框架之前，有必要首先说明为何采用马尔可夫博弈而非标准形式博弈或重复博弈。标准形式博弈仅适用于一次性策略选择，无法表达资源状态随时间演化的序贯特征；重复博弈虽考虑多轮交互，但默认每一轮都在相同阶段博弈上重复进行，并不显式刻画系统状态随联合动作变化而转移的机制。然而，在天基计算网络中，任一系统层协同动作都会改变后续统计窗口内的队列长度、资源占用率、链路可用性与信誉演化轨迹，即当前动作会通过状态转移持续影响未来收益。因此，该问题本质上是一个多主体、序贯式、状态相关的动态博弈问题。

基于上述认识，本文将 N 个异构边缘计算节点的协同调度问题形式化为如下七元组：

$$\mathcal{G} = \langle N, S, \{A^i\}, P, \{R^i\}, \gamma, \{O^i\} \rangle, \quad (4.1)$$

其中， N 表示智能体集合， S 表示全局状态空间， A^i 表示节点 i 的动作空间， P 表示联合状态转移函数， R^i 表示节点 i 的即时奖励函数， $\gamma \in [0, 1)$ 为折扣因子， O^i 表示局部观测函数。

需要特别指出的是，天基计算网络并不满足完全信息博弈假设。受限于星间链路的间歇连通性、有限带宽和状态同步代价，任何单个节点都不可能实时获得所有远端节点的完整原始状态。因此，本文将该问题进一步建模为部分可观测的多智能体马尔可夫博弈。对节点 i 而言，其在时刻 t 的观测表示为

$$o_t^i = O^i(s_t), \quad (4.2)$$

其中 s_t 表示时刻 t 的全局状态， o_t^i 属于节点 i 的局部观测空间 Ω^i 。相应地，每个节点维护一个随机化策略 $\pi^i : \Omega^i \rightarrow \Delta(A^i)$ ，并以最大化期望累积折扣回报为目标：

$$J^i(\pi^i, \pi^{-i}) = \mathbb{E} \left[\sum_t \gamma^t R^i(s_t, a_t^i, a_t^{-i}, s_{t+1}) \mid \pi^i, \pi^{-i} \right], \quad (4.3)$$

这里 π^{-i} 表示除节点 i 之外其余所有节点的联合策略。上述目标函数表明，节点 i 的收益不仅取决于自身策略，还显式依赖于其他节点的策略组合，这也是单智能体强化学习框架难以直接适配该问题的根本原因。

本文从天基协同资源分配问题到 MAMG 模型的建模推导遵循以下逻辑。原始问题具有动态任务到达、节点资源异构、星间链路时变和去中心化自治等关键特征，决

定了它不能被简单处理为静态任务指派问题，而应被视为一个随任务流、资源占用和节点行为持续变化的序贯决策问题。从博弈视角看，节点在确定外部任务接收意愿、窗口级任务流向以及资源投入比例时，既存在对高收益任务和有限资源的竞争，也存在通过协同分担提升整体效率的合作；同时，由于各节点只能获得本地状态和链上摘要，系统具有部分可观测性，且当前动作会影响后续队列、能耗和信誉状态，呈现明显的长期序贯特征。这些因素决定了标准形式博弈无法表达状态演化、重复博弈难以刻画动作引起的状态转移、单智能体 MDP 又无法描述多主体策略耦合，因此需要采用 MAMG 进行统一建模。相应地，系统要素映射为七元组的形式化表示为：观测 $o_t^i = (l_t^i, g_t)$ 、动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ 以及混合奖励 $r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i$ 。

4.3.2 状态、动作与奖励

在明确了博弈形式之后，接下来需要回答一个更具体的问题：节点究竟基于什么信息决策、能够采取哪些行动，以及系统希望通过何种奖励塑形引导节点从个体理性走向集体理性。对此，本文分别从状态空间、动作空间和奖励机制三个层面进行设计。

首先，在状态空间设计上，需要在“信息充分性”和“维度可控性”之间取得平衡。若观测过于贫乏，节点将因缺乏必要上下文而难以形成有效策略；但若直接纳入过多原始任务级信息，又会导致状态维度膨胀，增加训练难度与通信开销。

为保持全文符号一致性，本章沿用第3章定义的节点资源状态 $R_i(t)$ （见式(3.5)）和链上公共摘要 $G(t)$ （见式(3.26)）。具体而言，节点 i 在时刻 t 的观测结构化为“本地私有状态 + 链上公共摘要”两部分：

$$o_t^i = (l_t^i, g_t), \quad (4.4)$$

其中，本地私有状态 l_t^i 由节点对 $R_i(t)$ 进行投影并补充工作负载特征得到：

$$l_t^i = \text{Proj}(R_i(t)) \cup \{h_i, w_t^i\} = (Q_t^i, \rho_{\text{cpu}}^i(t), \rho_{\text{mem}}^i(t), E_t^i, h_i, w_t^i), \quad (4.5)$$

这里 Q_t^i 、 $\rho_{\text{cpu}}^i(t)$ 、 $\rho_{\text{mem}}^i(t)$ 与 E_t^i 分别为式(3.5)中队列长度 $Q_i(t)$ 、资源利用率 $\rho_i(t)$ 的 CPU 与内存分量、剩余能量 $E_i(t)$ 在本章的实例化； h_i 为节点静态硬件特征向量，主要包括峰值计算能力、缓存容量和链路接入能力等相对稳定的属性； w_t^i 则概括当前工作负载信息，可由队列中不同任务类型占比、平均剩余计算量和平均截止期松弛度等窗口统计量构成。这样既避免直接暴露逐任务原始数据，又保留系统层协同决策所

需的负载结构信息。

链上公共摘要由第3章式(3.26)中的 $G(t)$ 给出，即

$$g_t = G(t) = \left(\bar{L}_t, \sigma_L^2(t), D_t^{\text{task}}, R_t^{\text{rep}}, \hat{D}_{\text{chain}}(t), T_t^{\text{stat}} \right), \quad (4.6)$$

其中各分量含义与第3章式(3.26)保持一致。为便于后续状态建模、策略输入和实验分析中的变量对照，表 4.1 对链上公共摘要的主要分量及其作用进行汇总。为保持记号简洁，本章后续图示与公式中均以 g_t 表示系统层链上公共摘要 $G(t)$ ，以 l_t^i 表示式(4.5)给出的本地私有状态。

表 4.1 链上公共摘要分量说明

分量	名称	说明
$\bar{L}_t$	全局平均负载	所有节点队列长度的加权均值，反映系统整体繁忙程度
$\sigma_L^2(t)$	负载方差	各节点负载的离散程度，衡量系统均衡性
D_t^{task}	任务分布摘要	各类型任务在网络中的分布统计，用于感知业务结构变化
R_t^{rep}	信誉评分向量	各节点的链上信誉评分，反映历史行为质量
$\hat{D}_{\text{chain}}(t)$	链上延迟估计	共识与数据同步的当前延迟估计值，用于补偿信息滞后
T_t^{stat}	吞吐量统计	近期各节点及系统整体吞吐量的滑动统计，用于辅助协同判断

由表 4.1 可见，链上公共摘要并非完整全局状态，而是面向系统层协同决策的低维可信统计量。其中， R_t^{rep} 为信誉约束提供可信输入， $\hat{D}_{\text{chain}}(t)$ 的显式纳入使节点能够感知当前信息时效性，并在策略中对链上同步滞后进行自适应补偿。

其次，在动作空间设计上，系统层协同决策天然包含离散与连续两类分量：节点既要给出统计窗口内的任务流向偏好，也要决定本地资源分配比例以及外部任务接收意愿。若直接将逐任务优先级向量作为动作输出，其维度会随队列长度变化，不利于神经网络策略表示与训练稳定性。因此，本文采用固定维混合动作表示：

$$a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i), \quad (4.7)$$

其中 $a_{\text{off},t}^i$ 表示系统层统计窗口内的任务流向偏好或候选约束选择，而非针对某一新到达任务的最终卸载动作；其候选集合由本地处理选项与当前可见邻居集合 $\mathcal{N}_i(t)$ 共

同构成。对不可见链路、带宽不足链路或不满足剩余可见窗口约束的目标，策略输出阶段通过动作掩码将其置为不可选，以避免产生物理不可行动作。 $a_{\text{res},t}^i \in [0, 1]$ 表示本地资源分配比例， $a_{\text{acc},t}^i \in [0, 1]$ 表示接收外部任务的意愿系数。对于本地队列内部的细粒度排序，本文不再将其直接作为策略网络输出，而是通过基于任务时延约束、计算量和信誉补偿的规则化排序机制在节点本地完成。由此，系统层策略负责学习协同趋势与资源配置倾向，节点本地机制负责完成队列内部排序，从而实现不同决策粒度之间的结构化解耦。

从决策粒度看，本章动作 $a_{\text{off},t}^i$ 面向系统层统计窗口，其作用在于调节较长时间尺度上的任务流向、资源投入和外部任务接收意愿，并为第5章的任务层实时卸载提供候选集合、资源约束与信誉上下文。第5章中的动作则面向单个任务到达瞬间，用于在系统层给出的候选节点集合内选择本地执行或具体卸载目标。二者分别对应“窗口级协同约束”和“任务级执行动作”，因此在决策粒度和优化边界上相互承接而非重复。

最后，在奖励机制设计上，若仅以本地吞吐或完成收益作为奖励，节点策略将自然倾向于争抢高价值任务并规避低收益协作，从而重演前文所分析的公地悲剧。为此，本文构建融合效率、公平与可信性的三维混合奖励函数：

$$r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i, \quad (4.8)$$

其中 $w_q, w_f, w_c \geq 0$ 且 $w_q + w_f + w_c = 1$ 。效率项用于刻画节点自身任务处理质量，可写为

$$r_{q,t}^i = \alpha_1 \text{Succ}_t^i - \alpha_2 \text{Delay}_t^i - \alpha_3 \text{Energy}_t^i, \quad (4.9)$$

其中 Succ_t^i 为成功完成任务数， Delay_t^i 为平均完成时延， Energy_t^i 为单位时间能耗。式(4.9)中各代价分量由第3章本地执行/卸载执行的时延能耗模型（式(3.13)—(3.19)）按窗口聚合得到。公平项用于引导系统整体负载均衡，本文在系统层统计窗口内定义 Jain 公平指数^[39]：

$$J_t = \frac{(\sum_i x_i(t))^2}{N \sum_i x_i^2(t)}, \quad (4.10)$$

其中 $x_i(t)$ 表示节点 i 在统计窗口内归一化后的有效服务率，具体可由单位时间完成任务数按节点峰值计算能力归一化得到；采用该定义可以避免高性能节点因承担更多

任务而被误判为“不公平”，使公平项更关注相对负载承担是否均衡。进而定义

$$r_{f,t}^i = J_t - \beta \max \{0, \rho_i(t) - \rho_{th}\}. \quad (4.11)$$

可信性项将节点历史行为纳入激励闭环。第3章将信誉评分作为节点资源状态和链上公共摘要中的基础变量，本章在系统层时间尺度上进一步刻画其演化规则：

$$\text{Rep}_i(t+1) = \lambda_r \text{Rep}_i(t) + (1 - \lambda_r) \Phi_i(t), \quad (4.12)$$

其中 $\Phi_i(t)$ 表示节点 i 在当前统计窗口内的综合执行评分，可由任务完成率、时延达标率、能耗表现和协作一致性等指标加权得到。本章实验中取 $\lambda_r = 0.8$ 。基于式(4.12)可得本步信誉增量 $\Delta \text{Rep}_i(t) = \text{Rep}_i(t+1) - \text{Rep}_i(t)$ ，进而构造可信性奖励项：

$$r_{c,t}^i = \gamma_1 \Delta \text{Rep}_i(t) - \gamma_2 \delta_i(t), \quad (4.13)$$

其中 $\delta_i(t)$ 表示节点 i 当前上报状态与链上审计状态之间的偏差度。为避免概念化描述，本文在实验中采用归一化绝对偏差进行近似计算：

$$\delta_i(t) = \frac{|L_i^{\text{report}}(t) - L_i^{\text{audit}}(t)|}{L_i^{\text{audit}}(t) + \varepsilon}, \quad (4.14)$$

其中 $L_i^{\text{report}}(t)$ 为节点上报负载， $L_i^{\text{audit}}(t)$ 由链上任务开始/结束事件、执行回执和资源摘要交叉估计得到， ε 为防止分母为零的小常数。考虑链上同步存在附加时延，合约并非对单次轻微偏差立即惩罚，而是在 $\delta_i(t) > \delta_{th}$ 且持续超过预设窗口时触发信誉扣减。诚实上报与积极协同的节点 $\Delta \text{Rep}_i(t) > 0$ ，将获得正向激励；虚报状态或拒绝协作的节点 $\Delta \text{Rep}_i(t) < 0$ 且 $\delta_i(t) > 0$ ，将受到双重惩罚。

为降低不同量纲对策略学习的影响，式(4.8)中的成功数、时延、能耗、Jain 指数、信誉增量和偏差惩罚在进入奖励函数前均按滑动窗口进行归一化或裁剪处理，使各子项处于相近数值范围内。这样， w_q 、 w_f 与 w_c 主要反映优化偏好，而不是被指标尺度差异所主导。本文默认奖励权重及其对应作用如表 4.2 所示。

表 4.2 中的默认设置体现了“效率优先、兼顾公平与可信治理”的设计原则：效率项保证任务处理性能，公平项抑制强节点热点拥塞，可信项则将链上审计与信誉变化反馈到长期策略学习中。后续实验部分将以该组权重作为默认配置，并通过消融分析验证公平项和可信项的边际贡献。

表 4.2 奖励权重与作用说明

权重	对应项	核心作用	默认值
w_q	效率项 r_q	保证任务完成率、时延与能耗三者的局部效率优化	0.5
w_f	公平项 r_f	抑制热点拥塞，提升系统负载均衡与长期稳定性	0.3
w_c	可信项 r_c	将信誉增量与负载偏差反馈到策略更新中，约束欺骗行为	0.2

4.3.3 约束与性质分析

作为一个面向真实天基计算网络的协同调度模型，上述博弈并非在抽象无限制环境中运行，而必须满足物理资源约束与通信可行性约束。对任意节点 i 而言，首先有基本的本地资源约束：

$$0 \leq a_{\text{res},t}^i \leq 1, \quad (4.15)$$

$$C_i^{\text{used}}(t) \leq C_i^{\text{max}}, \quad B_i^{\text{used}}(t) \leq B_i^{\text{max}}, \quad E_i^{\text{used}}(t) \leq E_i^{\text{cap}}, \quad (4.16)$$

其中 $C_i^{\text{used}}(t)$ 、 $B_i^{\text{used}}(t)$ 、 $E_i^{\text{used}}(t)$ 分别表示时刻 t 的计算资源占用、带宽占用和能量消耗。当节点选择执行卸载动作时，相应任务的数据传输量还必须满足链路带宽预算和可见窗口约束。本文在环境层通过动作可行性检查与不可行动作惩罚共同保证策略学习始终发生在物理可行域内。

在满足上述约束的前提下，还需要讨论模型在理论上的可解释性。需要说明的是，原始问题同时包含离散卸载选择与连续资源比例控制，严格意义上的全局均衡求解较为困难。因此，本文并不试图对原始离散—连续混合博弈给出过强的解析结论，而是在混合策略和连续松弛意义下给出两个性质说明。

性质 4.1（连续松弛下的均衡存在性） 在各智能体采用混合策略、奖励函数对联合策略连续，且连续动作空间为非空紧凸集的条件下，所构造的松弛博弈至少存在一个混合策略纳什均衡^[40]。

该结论可由 Glicksberg 不动点定理得到。需要强调的是，这里讨论的是连续松弛后的策略博弈，其意义在于说明本文设计的奖励结构与策略表示不会破坏均衡存在性，而非声称原始混合动作博弈在所有条件下都可被直接解析求解。

性质 4.2（局部稳定性说明） 若在某一局部邻域内，联合策略更新可近似表示为

对某个光滑潜在函数的上升过程，且学习率足够小，则策略迭代在该邻域内具有局部稳定性。

该性质为后续采用 MAPPO 求解提供理论直觉：通过将公平项与信誉项嵌入奖励函数，不同节点的局部优化方向在一定程度上得到对齐，从而减弱了纯竞争博弈中常见的剧烈震荡现象。这里给出的并非严格的全局收敛证明，而是对训练稳定性来源的性质解释。

在上述状态、动作、奖励与约束设计的基础上，本节从信息来源、动作形式和激励机制三个方面完成了系统层协同资源分配问题的数学抽象。换言之，第 4.3 节完成的是问题求解对象的数学抽象：它把第 4.2 节中的系统角色、链上公共摘要与信誉治理机制统一映射为一个部分可观测、多主体、序贯式的动态博弈模型，并说明了该模型在物理可行域内的基本性质。

但仅有建模仍不足以直接应用于天基网络的在线协同决策。原因在于：第一，联合状态与联合动作维度随节点数量增长而迅速膨胀；第二，Actor 在执行阶段只能访问局部观测与链上摘要，不能依赖训练期的全局信息；第三，链上公共信息板虽然提供了可信共享与审计能力，但其时延、更新周期和信誉回写机制必须被纳入具体的学习与执行流程，才能转化为策略性能增益。因此，下一节将从“如何求解”而非“如何建模”的角度出发，把上述马尔可夫博弈进一步映射为区块链增强的集中训练一分散执行多智能体强化学习框架，并说明策略参数更新、链上共享、信誉反馈和在线部署之间的耦合关系。

4.4 算法设计

上一节给出了系统层协同资源分配的多智能体马尔可夫博弈模型，但该模型仍面临三个求解困难：第一，执行阶段各节点无法获得完整实时全局状态；第二，多节点策略同步变化会导致环境非平稳；第三，若仅优化任务完成收益，节点仍可能出现拒绝协作、选择性接收任务或虚报状态等自利行为。为此，本文将联盟链公共信息板、集中训练一分散执行结构和信誉驱动奖励结合起来，形成 BC-CTDE-MAPPO 算法框架。

该框架的核心思想是：联盟链提供可信但低频的系统级上下文，集中式 Critic 在训练阶段利用联合状态进行全局价值评估，局部 Actor 在执行阶段仅依赖本地观测与链上摘要进行自治决策；同时，链上审计结果和信誉变化被回写到奖励函数中，使

“可信共享—联合评估—分散执行—信誉反馈”形成闭环。本节依次介绍链上共享与信誉反馈、CTDE-MAPPO 框架、策略表示与参数更新，以及训练与在线执行流程。

4.4.1 链上共享与信誉反馈

在给出博弈模型及其内部要素之后，还需要进一步说明公共状态信息的来源。在缺乏中心协调者的天基网络中，公平项、信誉项和全局负载统计均依赖跨节点共享信息；若各节点仅依赖局部观测，则难以获得稳定一致的系统级上下文；若人为引入中心汇聚节点，又会削弱去中心化鲁棒性，并带来单点故障与数据篡改风险。为此，本文引入联盟链作为可信公共状态层，使节点能够在无需完全信任彼此的前提下共享经验验证的系统级摘要信息。考虑许可链环境下的部署可行性，本文采用轻量级联盟链架构，并参考 Hyperledger Fabric 等许可链系统中“成员管理 + 摘要共享 + 审计可追溯”的设计思想^[41]。

设节点上报交易经本地验证后进入待共识池，则某次公共状态写入的总延迟可近似表示为

$$D_{\text{chain}}(t) = D_{\text{consensus}}(t) + D_{\text{broadcast}}(t) + D_{\text{verify}}(t), \quad (4.17)$$

其中 $D_{\text{consensus}}(t)$ 为子链或主链共识延迟， $D_{\text{broadcast}}(t)$ 为区块广播传播延迟， $D_{\text{verify}}(t)$ 为本地验证与状态解析延迟。默认实验中账本同步平均附加延迟设为 1.0 s，并在敏感性分析中扩展到 0.5–3.0 s 的范围。结合 $\Delta t_{\text{sys}} = 10$ s 的系统层决策周期可知， $D_{\text{chain}}/\Delta t_{\text{sys}}$ 始终远小于 1，因此链上摘要在系统层时间尺度上可被视为近实时的全局视图。

为使链上数据能够支撑博弈观测与合约审计，本文将区块载荷划分为五类记录：资源状态记录块、任务摘要记录块、信誉更新记录块、策略审计记录块以及子链聚合摘要块。通过上述字段设计，链上账本既保留博弈求解所需的最小充分统计量，又避免直接存储高维原始任务数据，从而控制存储与传输开销。链上仅记录窗口级负载、任务类型计数、执行结果哈希、信誉增量和审计标记等摘要信息，原始任务数据、完整遥感载荷数据和逐任务中间特征均保留在节点本地或任务层缓存中。因此，链上通信开销随节点数近似线性增长，主要由每个系统层周期的节点状态摘要和少量事件回执构成，不会随原始任务数据规模同步膨胀。

图 4.3 进一步说明联盟链在本章方法中的功能定位和分层职责。图上方异构节点持续产生资源状态、任务事件、局部执行结果和行为审计记录等信息，这些信息通过




图 4.3 分层联盟链与公共信息板职责示意

状态与事件上报机制写入分层联盟链，形成可验证、可追溯的公共状态来源。图中部展示联盟链的两级结构：子链采用较短更新周期，承担任务事件流和局部资源状态的快速记录；主链采用较长更新周期，主要承担节点身份管理、信誉锚定与累积、治理规则维护以及跨子链监管。图中子链与主链之间的双向箭头表示子链将局部摘要聚合上链至主链，主链将治理规则和审计结果下发到各子链，形成跨层协同治理机制。图下方的公共信息板是面向智能体决策的摘要输出层，提供 $\bar{L}_t$ 、 $\sigma_L^2(t)$ 、 D_t^{task} 、 R_t^{rep} 、 $\hat{D}_{\text{chain}}(t)$ 和 T_t^{stat} 等公共上下文，为节点在部分可观测条件下提供系统级协同依据；图中智能合约治理模块用于异常识别、一致性检查、信誉扣奖、权限更新和策略审计，并将审计结果反馈给信息板和节点策略。该图强调联盟链不是简单的数据存储模块，而是连接状态共享、行为审计和信誉治理的可信公共信息基础设施。为进一步明确不同链上模块在时间尺度和服务对象上的分工，表 4.3 对分层联盟链的职责划分进行概括。

由表 4.3 可以看出，主链、子链、公共信息板和智能合约分别对应慢时标治理、快时标事件记录、中时标状态聚合和事件驱动审计。该分工使联盟链既能为智能体提供

表 4.3 分层联盟链职责划分

层级 / 模块	主要职责	更新周期	主要服务对象
主链 / 资源审计链	身份管理、信誉锚定、治理规则与跨链监管	慢时标	监管与系统层策略更新
子链 / 任务指令链	任务开始/结束事件、资源摘要、局部审计	快时标	节点侧调度与局部反馈
公共信息板聚合层	输出全局平均负载、负载方差、任务分布与信誉向量	中时标	多智能体协同决策
智能合约	执行异常识别、信誉扣奖、策略审计与权限更新	事件驱动	系统治理与行为约束

可用的公共摘要，又避免将所有高频原始状态直接写入主链，从而在可信性、时效性和开销之间取得折中。

在信誉机制方面，本文采用“链上记录 + 合约审计 + 奖励回写”的闭环方式。对节点 i ，其信誉值 $\text{Rep}_i(t)$ 按式(4.12) 随诚实性、协同贡献与异常惩罚动态演化。若节点长期夸大繁忙程度、拒收外部任务或低报负载吸引高收益业务，则审计合约会根据链上任务事件与资源摘要的一致性检查结果触发信誉惩戒，并将惩罚结果回写到后续奖励中。这意味着区块链在本文中的作用不应被简单理解为“天然提升性能”，而应理解为：它为可信共享、行为审计与中长期激励执行提供统一机制，使系统在面对自私与欺骗行为时具备可持续协同的条件。

图 4.4刻画节点信誉值的动态演化机制。 $\text{Reputation}_i(t)$ 不是静态标签，而是由节点长期行为、任务执行质量、协同贡献和链上审计结果共同决定的动态变量；它一方面作为公共摘要的一部分进入节点观测，影响后续任务分配和协同优先级，另一方面通过奖励函数中的可信性项反馈到策略更新过程，形成长期激励约束。图中外圈按时间顺序描述信誉闭环的六个阶段：状态观测（节点形成当前观测）、动作决策（决定接收/卸载/资源比例/上报方式）、行为执行（系统记录执行结果与协同贡献）、链上审计（智能合约依据任务事件与资源摘要进行一致性检查）、信誉更新（诚实协同提升信誉、虚报或异常触发惩罚）以及奖励回写（信誉变化进入可信性奖励项，影响后续协作机会和策略学习方向）。绿色箭头表示正向协同循环，红色箭头表示负向惩罚循




图 4.4 信誉驱动的状态—动作—审计—反馈闭环

环。该机制将一次性的任务收益扩展为跨时间的长期行为约束，使自利节点在最大化长期回报时必须考虑信誉损失和未来协作机会，从而解释了联盟链如何从“可信记录工具”进一步转化为“协同治理工具”。

上述分析明确了链上信息的来源、进入策略的方式以及信誉对奖励和治理的反向作用，为后续算法设计奠定了基础。下面进一步介绍算法总体框架和参数更新机制。

4.4.2 CTDE-MAPPO 框架

设节点 i 的 Actor 参数为 θ_i ，共享 Critic 参数为 ϕ 。在时刻 t ，节点首先从本地环境与联盟链中读取观测 $o_t^i = (l_t^i, g_t)$ ，然后按照当前策略采样混合动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ 。环境执行联合动作 $a_t = (a_t^1, \dots, a_t^N)$ 后，更新任务队列、链路状态、能耗状态与信誉中间量，并将新的链上摘要写入公共信息板。随后，系统依据式(4.8)定义的三维奖励函数计算各节点即时回报 r_t^i ，并将交互轨迹存入 rollout 缓冲区。一个 rollout 周期结束后，集中训练模块基于联合轨迹估计优势函数并更新 Actor/Critic 参数。

其中，集中式 Critic 的输入为全局状态近似表示

$$s_t^{\text{ctr}} = (l_t^1, \dots, l_t^N, g_t), \quad (4.18)$$

输出价值估计 $V_\phi(s_t^{\text{ctr}})$ 。考虑到天基网络拓扑随时间动态变化，本文在状态编码阶段引入图结构聚合器，用于对邻接节点状态和链路关系进行表征学习。为此，将时刻 t 的天基网络表示为动态图 $\mathcal{G}_t = (\mathcal{V}, \mathcal{E}_t)$ ，其中节点集合 $\mathcal{V}$ 对应卫星计算节点，边集合 $\mathcal{E}_t$ 由当前可见星间链路决定；节点特征由 l_t^i 与信誉摘要拼接得到，边特征可包含链路带宽、传播时延和剩余可见窗口等统计量。集中式 Critic 先对邻居状态进行图聚合，再与链上公共摘要 g_t 拼接进行价值估计。这样，一方面能够避免简单拼接带来的维度膨胀，另一方面也使价值网络具备对拓扑动态变化的敏感性。




图 4.5 BC-CTDE-MAPPO 总体流程图

图 4.5 给出了 BC-CTDE-MAPPO 的训练—执行一体化流程，按时间顺序划分为八个步骤。左侧在线执行阶段在无中心调度器参与的情况下完成节点局部决策和环境交互：节点先构造观测 $o_t^i = (l_t^i, g_t)$ （步骤 1），将观测输入策略网络 π_{θ_i} 输出混合动作 a_t^i （步骤 2），多个节点的动作共同作用于任务队列、资源占用、链路状态和能耗状态，推动系统由 t 转移到 $t+1$ （步骤 3）；执行结果经联盟链记录后生成下一时刻摘要 g_{t+1} （步骤 4），系统根据任务完成质量、负载公平性和信誉变化计算混合奖励 r_t^i ，并将 $(o_t^i, a_t^i, r_t^i, o_{t+1}^i)$ 保存到 rollout buffer（步骤 5）。该缓存用于 on-policy 轨迹收集而非离线经验回放池，每轮参数更新完成后旧轨迹将被丢弃，以满足 MAPPO 的训练设定。右侧集中训练阶段中，集中式 Critic 接收联合状态 $s_t^{\text{ctr}} = (l_t^1, \dots, l_t^N, g_t)$ 输出价值估计 $V_\phi(s_t^{\text{ctr}})$ （步骤 6），通过 GAE 计算优势函数 $\hat{A}_t^i$ （步骤 7），采用 PPO 裁剪目标对 Actor 和 Critic 进行多轮小批量更新（步骤 8）。更新完成后各节点仅部署更新后的局部 Actor 参数 θ_i ，在下一轮中继续依据本地观测和链上公共摘要进行分散决策。该图

完整展示了本文方法将联盟链可信共享、信誉反馈、集中价值评估和分散执行整合为统一闭环的过程。

上述总体框架体现了训练阶段与执行阶段的信息边界：集中式 Critic 在训练阶段吸收联合状态与联合动作中的耦合信息，局部 Actor 在执行阶段依据“本地观测 + 链上摘要”完成自治决策，联盟链则持续提供可信上下文与行为留痕。接下来，本文进一步说明混合动作策略的参数化方式、优势函数构造以及 Actor / Critic 在去中心化执行约束下的稳定更新机制。

4.4.3 策略表示与参数更新

由于动作同时包含离散卸载选择与连续资源控制两类分量，本文采用混合参数化 Actor。其中，对离散动作 $a_{\text{off},t}^i$ 输出 categorical 分布，对连续动作 $a_{\text{res},t}^i$ 和 $a_{\text{acc},t}^i$ 输出高斯分布参数，其联合策略可写为

$$\pi_{\theta}^i(a_t^i | o_t^i) = \pi_{\theta,d}^i(a_{\text{off},t}^i | o_t^i) \cdot \pi_{\theta,c}^i(a_{\text{res},t}^i, a_{\text{acc},t}^i | o_t^i). \quad (4.19)$$

其中连续分量经 sigmoid 映射后投影到 $[0, 1]$ 区间，以保证动作满足物理可行性约束。为了增强探索能力，训练初期在连续分量上保留较高的熵正则项，随后随训练过程逐步衰减。

在参数更新方面，本文沿用 PPO 的裁剪目标^[42-43]。对节点 i 定义策略比值

$$\rho_t^i(\theta_i) = \frac{\pi_{\theta_i}(a_t^i | o_t^i)}{\pi_{\theta_i^{\text{old}}}(a_t^i | o_t^i)}, \quad (4.20)$$

则其裁剪目标函数为

$$L_i^{\text{clip}}(\theta_i) = \mathbb{E}_t \left[\min \left(\rho_t^i(\theta_i) \hat{A}_t^i, \text{clip}(\rho_t^i(\theta_i), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^i \right) \right], \quad (4.21)$$

其中 $\hat{A}_t^i$ 为优势估计。本文采用广义优势估计（GAE）构造该项：

$$\hat{A}_t^i = \sum_{l=0}^{T-1} (\gamma \lambda)^l \delta_{t+l}^i, \quad \delta_t^i = r_t^i + \gamma V_{\phi}(s_{t+1}^{\text{ctr}}) - V_{\phi}(s_t^{\text{ctr}}). \quad (4.22)$$

Critic 则通过最小化时序差分误差进行更新：

$$L_V(\phi) = \mathbb{E}_t \left[\left(V_{\phi}(s_t^{\text{ctr}}) - \hat{V}_t \right)^2 \right]. \quad (4.23)$$

需要强调的是，本文方法属于严格的 on-policy 学习流程。也就是说，系统采用

“采样一批 rollout $\rightarrow$ 计算优势 $\rightarrow$ 多轮小批量更新 $\rightarrow$ 丢弃旧轨迹”的训练方式，而不使用大规模经验回放池，从而与 MAPPO 的理论设定保持一致。

基于此，最后需要将 Actor 采样、环境交互、链上更新和集中式参数优化组织成统一的时间序列流程。为此，下面给出 BC-CTDE-MAPPO 的训练与在线执行伪代码，用于描述本章方法的完整实现流程。

4.4.4 训练与执行流程

为进一步明确算法执行顺序，本文将 BC-CTDE-MAPPO 的训练与在线部署过程整理为算法 1。该算法体现了“链上信息更新—环境状态转移—策略参数优化”三者并行耦合的特点：链上公共信息板为每轮决策提供可信上下文，环境根据联合动作更新队列与能耗状态，而集中训练模块则利用全局状态近似表示更新参数。

算法 1 BC-CTDE-MAPPO 协同资源分配算法

Require: 节点集合 N ；本地观测 $o_t^i = (l_t^i, g_t)$ ；奖励权重 (w_q, w_f, w_c) ；训练轮数 E ；rollout 长度 T

Ensure: 每个节点的协同策略 π_θ^i 与共享价值函数 V_ϕ

```

1: 初始化各节点 Actor 参数  $\theta_i$ 、共享 Critic 参数  $\phi$ 、联盟链账本状态与信誉值  $\text{Rep}_i(0)$ 
2: for  $\text{episode} = 1, \dots, E$  do
3:   for  $t = 1, \dots, T$  do
4:     for 每个节点  $i$  do
5:       读取本地私有状态  $l_t^i$  与最新链上公共摘要  $g_t$ ，构造观测  $o_t^i$ 
6:       按策略  $\pi_\theta^i(a_t^i | o_t^i)$  采样混合动作  $a_t^i$ 
7:     end for
8:     环境执行联合动作  $a_t$ ，更新任务队列、链路状态、能耗状态与信誉中间量
9:     联盟链写入资源摘要、任务摘要与审计记录，生成新的公共状态  $g_{t+1}$ 
10:    按式(4.8) 计算各节点即时奖励  $r_t^i$ 
11:    将  $\{o_t^i, a_t^i, r_t^i, o_{t+1}^i\}$  存入 rollout 缓冲区
12:  end for
13:  基于联合轨迹计算优势函数  $\hat{A}_t^i$  与目标价值  $\hat{V}_t$ 
14:  多轮小批量优化 Actor 与 Critic，更新  $\theta_i, \phi$ 
15: end for
16: return 训练完成的  $\pi_\theta^i$  与  $V_\phi$ 

```

4.5 实验分析

本节按照“训练是否稳定—性能是否提升—机制是否有效—压力场景是否鲁棒”的顺序展开实验验证。与只报告平均性能不同，本文重点分析链上可信共享、CTDE 训练机制、公平奖励和信誉约束分别在何种场景下产生作用，以及这些增益是否能够在高负载、规模扩展、链上延迟和异常节点存在时持续成立。为保证结果的统计可靠性，所有实验均独立运行 5 次，报告均值与标准差。

4.5.1 实验设置

实验场景中包含 20 个异构卫星计算节点，分布在 3 个轨道层上，系统共考虑 4 类在轨任务（遥感预处理、目标检测、压缩转发与任务规划）。为验证算法在不同业务压力下的适应性，本文将任务到达率 λ 从 0.3 逐步增加至 1.1（单位：task/(slot·node)），训练总回合数为 500，每回合包含 200 个时隙。系统层决策周期统一取 $\Delta t_{\text{sys}} = 10 \text{ s}$ 。敏感性实验进一步将节点规模扩展至 20–80 个，以评估算法的可扩展性。为提高实验可复现性，表 4.4 汇总了主要仿真与训练参数。

表 4.4 主要实验参数设置

参数	取值	参数	取值
默认节点数	20	规模扩展范围	20–80
轨道层数	3	任务类型数	4
任务到达率 λ	0.3–1.1 task/(slot·node)	系统层周期 Δt_{sys}	10 s
训练回合数	500	每回合时隙数	200
子链出块周期	1 s	主链聚合周期	5 s
平均链上附加延迟	1.0 s	敏感性延迟范围	0.5–3.0 s
奖励权重 (w_q, w_f, w_c)	(0.5, 0.3, 0.2)	独立运行次数	5

默认采用“子链 + 主链”的分层联盟链结构。子链出块周期设为 1 s，主链聚合周期设为 5 s，账本同步平均附加延迟为 1.0 s。为评估链上时延对策略性能的影响，在敏感性实验中进一步将平均附加延迟扩展至 0.5–3.0 s。链上记录采用摘要化设计，每个系统层周期主要上传节点级负载摘要、任务计数、执行结果哈希和信誉增量，原始任务数据不直接上链。信誉机制采用指数平滑更新方式，其中 $\lambda_r = 0.8$ ，诚实性、协同贡献和异常惩罚的系数分别设置为 $\xi_1 = 0.4$ 、 $\xi_2 = 0.3$ 、 $\xi_3 = 0.3$ 。对于存在明显负载虚报行为的节点，当式(4.14)所定义的偏差度 δ_i 超过阈值 $\delta_{\text{th}} = 0.2$ 时触发惩罚与限权流程。

本文方法基于 MAPPO 实现，训练配置如下：折扣因子 $\gamma = 0.99$ ，GAE 系数 $\lambda = 0.95$ ，PPO 裁剪系数 $\epsilon = 0.2$ ，Actor 学习率 3×10^{-4} ，Critic 学习率 1×10^{-3} ，策略更新 epoch 数为 10，小批量大小为 256。奖励权重默认设置为 $w_q = 0.5$ 、 $w_f = 0.3$ 、 $w_c = 0.2$ 。为保证对比的完整性，本文选取以下四种基线方法：（1）MAPPO，采用标准集中训练一分散执行框架但不引入区块链与信誉机制；（2）MADDPG，采用集中式

Critic 与确定性策略梯度的多智能体方法；(3) IPPO (Independent PPO)，各节点独立训练，不使用集中式 Critic 或公共状态共享；(4) Greedy，基于局部即时收益的启发式调度策略；(5) Random，随机卸载与资源分配策略。此外，在鲁棒性实验中将自私节点比例从 0% 增加至 40%。

4.5.2 收敛性分析

首先考察不同方法在训练过程中的收敛性。图 4.6 (a) 给出了不同训练算法在 500 回合中的平均回报收敛曲线，其中阴影区域为 5 次独立运行的 $\pm 1\sigma$ 标准差范围，体现了结果的统计可靠性。可以看出，随着训练回合增加，各算法的平均回报整体呈现逐步上升并最终趋于稳定的趋势。其中，BC-CTDE-MAPPO 在约 200 回合后已进入稳定收敛区间，且最终平均回报 (88.4 ± 2.1) 明显高于其余基线方法，阴影带也最窄，表明训练方差最小；相比之下，MAPPO 的收敛速度略慢 (260 回合)，MADDPG 与 IPPO 则表现出更明显的波动和更低的稳态回报。这表明，在引入区块链公共信息板和可信激励机制后，智能体在训练阶段能够更充分地利用系统级上下文，从而降低多智能体环境中的非平稳性。

图 4.6 (b) 以误差棒形式进一步比较了不同算法的收敛回合数，误差棒大小根据各算法后 50 回合的回报标准差等比缩放，反映各方法收敛的稳定程度。BC-CTDE-MAPPO 的收敛回合最少，仅为 210 回合；MAPPO、MADDPG 和 IPPO 分别需要 260、330 和 360 回合才达到稳定状态。




图 4.6 不同训练算法的收敛性对比

表 4.5 不同训练算法的收敛性统计对比

算法	最终平均回报	收敛回合	后 50 回合回报标准差	$\lambda = 0.9$ 时任务完成率 (%)
BC-CTDE-MAPPO	88.4	210	2.1	92.3
MAPPO	77.6	260	3.4	88.1
MADDPG	70.2	330	4.2	84.2
IPPO	66.8	360	4.8	82.9

结合表 4.5 中的统计结果可知，BC-CTDE-MAPPO 在最终平均回报、收敛速度及后 50 回合回报标准差等指标上均优于对比方法。尤其是在任务到达率 $\lambda = 0.9$ 的场景下，其任务完成率达到 92.3%，分别高于 MAPPO 的 88.1% (+4.2pp) 和 MADDPG 的 84.2% (+8.1pp)。这说明所提方法不仅具备更快的收敛速度，而且在收敛后仍能保持较高的策略稳定性。

从机理上看，链上可信摘要主要缓解系统级状态不可见问题，CTDE-MAPPO 主要缓解多智能体训练不稳定问题，三维奖励则用于约束策略学习中的局部自利倾向。三者缺一不可。若只有公共摘要而没有集中式价值估计，则策略仍可能在局部探索中震荡；若只有 MAPPO 而没有可信共享，则价值函数将长期暴露于陈旧或片面的状态信息；若缺少公平和信誉激励，即便训练可以收敛，也很容易收敛到对局部强节点有利但对系统整体不友好的策略结构。

4.5.3 性能对比

为考察算法在不同业务压力下的适应能力，本文进一步比较了各方法在任务到达率 $\lambda \in \{0.3, 0.5, 0.7, 0.9, 1.1\}$ 下的任务完成率、平均任务时延和 Jain 公平指数，结果如图 4.7 和表 4.6 所示。从图 4.7 (a) 可以看出，随着任务到达率由 0.3 增加到 1.1，所有算法的任务完成率均有所下降，图中误差棒为 5 次独立运行的 $\pm 1\sigma$ 标准差。这是因为系统负载持续增加后，节点的局部队列长度和资源竞争程度显著提升。然而，BC-CTDE-MAPPO 在整个负载区间内始终保持最优性能，其任务完成率由 98.2% 下降至 89.1%，下降幅度 (9.1pp) 明显小于 MAPPO (13.5pp) 和 Greedy (23.6pp)。值得重点关注的是图中以背景色块标注的高负载区间 ($\lambda = 0.9 \sim 1.1$)：低负载时 ($\lambda \leq 0.5$) 所有方法均能维持 90% 以上的完成率，各方法间差距在 4pp 以内；而在 $\lambda = 1.1$ 的高负载条件下，BC-CTDE-MAPPO (89.1%) 与 Greedy (70.8%) 相差近 18.3pp，与 Random (58.9%) 相差逾 30pp，方法间差距显著拉大。这说明多智能体协同调度与负




图 4.7 不同任务到达率下的系统性能对比

载均衡机制的核心价值在高竞争场景中才得到充分体现，低负载环境下各方法的性能差异相对有限。

图 4.7 (b) 给出了不同负载水平下的平均任务时延变化趋势，高负载区间同样以背景色块标注。BC-CTDE-MAPPO 的增长最缓，在 $\lambda = 0.9$ 和 $\lambda = 1.1$ 时分别仅为 178 ms 和 214 ms，显著低于 MAPPO (203 ms / 249 ms) 和 MADDPG (228 ms / 278 ms)。这说明所提方法能够通过链上公共摘要感知全局负载状态，并在协同调度时主动规避热点节点，从而降低拥塞传播对系统时延的影响。

表 4.6 不同任务到达率下各算法的 Jain 公平指数

算法	$\lambda = 0.3$	$\lambda = 0.5$	$\lambda = 0.7$	$\lambda = 0.9$	$\lambda = 1.1$
BC-CTDE-MAPPO	0.966	0.951	0.936	0.918	0.897
MAPPO	0.951	0.932	0.904	0.878	0.846
MADDPG	0.943	0.918	0.887	0.853	0.821
Greedy	0.931	0.886	0.843	0.781	0.724
Random	0.881	0.834	0.786	0.731	0.679

除效率指标外，本文还使用 Jain 公平指数评价不同算法的负载均衡能力。表 4.6 表明，BC-CTDE-MAPPO 在各负载水平下均保持最高公平指数。例如，当 $\lambda = 0.9$ 时，其 Jain 公平指数为 0.918，而 MAPPO 和 MADDPG 分别为 0.878 和 0.853，Greedy 与

Random 则仅为 0.781 和 0.731。这说明混合奖励中的公平项能够有效抑制“强节点持续抢占高收益任务”的现象，引导系统逐步形成更均衡的任务分担格局。

4.5.4 规模与时延敏感性分析

为评估方法的可扩展性，本文将节点规模从 20 逐步扩展至 40、60 和 80，并在各规模下重新训练策略。图 4.8 (a) 给出了不同网络规模下各算法的任务完成率 ($\lambda = 0.9$)。随着节点规模增大，所有方法的完成率均有所下降，但 BC-CTDE-MAPPO 的下降最缓 (从 92.3% 降至 86.8%，降幅 5.5pp)，而 IPPO 和 Greedy 分别下降了 12.1pp 和 14.3pp。这说明 BC-CTDE-MAPPO 的策略并未过度依赖固定规模下的拓扑结构，而是通过链上公共摘要与图结构建模学习到了更稳定的协同模式。

图 4.8 (b) 给出了链上附加时延对任务完成率的影响。当链上附加延迟位于 0.5–2.0 s 区间时，任务完成率下降较为平缓 (从 93.1% 降至 90.4%)，这表明本文方法对中等程度的信息陈旧具有一定容忍性；这与“在 $\Delta t_{\text{sys}} = 10$ s 的尺度上，1–2 s 量级的链上时延仍可视作可容忍小量”的结论一致。但当延迟继续上升至 2.5–3.0 s 后，性能开始显著恶化 (降至 85.2%)，说明公共摘要一旦过时，策略将难以及时修正热点拥塞。




图 4.8 规模扩展与参数敏感性分析结果

4.5.5 消融分析

为识别各模块的边际贡献，本文在 $\lambda = 0.9$ 的场景下进一步开展消融实验，结果如图 4.9 与表 4.7 所示。图 4.9 (a) 和 (b) 分别展示了各方法变体在任务完成率与 Jain

公平指数上的差异，每个柱子均附有 $\pm 1\sigma$ 误差棒 ($n=5$)，图 4.9 (a) 中左侧实色柱为全场景均值，右侧斜线柱为 30% 自私节点场景下的结果，以同时体现效率维度与抗异常维度的贡献。与完整 BC-CTDE-MAPPO 相比，去除区块链公共信息板后，任务完成率由 92.3% 降至 89.1% (全场景 -3.2pp ，30% 自私节点下 -6.7pp)，说明可信共享的系统级上下文是整套方法的核心增益来源，且在异常节点存在时作用更为关键。去除公平奖励项后，系统的 Jain 公平指数从 0.918 大幅降至 0.842 (-0.076)，表明公平激励对抑制负载失衡尤为重要。去除可信奖励项后，虽然平均任务时延变化不大，但在 30% 自私节点场景下的任务完成率下降至 84.1% (-5.3pp)，反映出信誉约束在抗自私行为中发挥了不可替代的作用。公平项与可信项分别作用于不同维度，缺一不可。




图 4.9 任务完成率与 Jain 公平指数贡献

表 4.7 消融实验结果

方法变体	任务完成率 (%)	平均任务时延 (ms)	Jain 公平指数	30% 自私节点下任务完成率 (%)
完整 BC-CTDE-MAPPO	92.3±0.8	178	0.918±0.008	89.4±1.0
去除区块链公共信息板	89.1±1.3	194	0.889±0.013	82.7±1.6
去除公平奖励项	90.4±1.0	186	0.842±0.016	86.5±1.3
去除可信奖励项	90.8±1.1	183	0.901±0.010	84.1±1.4

从这一组结果可以进一步推断：本文方法的性能提升不是由某一个“万能组件”单独带来，而是由“链上摘要提供全局上下文、公平奖励约束热点行为、信誉机制抑制策略投机、图结构提升多节点关系建模能力”共同构成的系统性增益。

4.5.6 鲁棒性与敏感性分析

为检验所提方法在非合作环境中的鲁棒性，本文设置不同自私节点比例（0%–40%），并比较各算法的任务完成率与 Jain 公平指数，结果如图 4.10 和表 4.8 所示。

实验中，自私节点的异常行为模型定义如下：节点以概率 $p_s = 0.7$ 拒绝接受来自其他节点的卸载任务（任务拒收），同时以均值 $\mu_f = -0.3$ 的偏移量虚报自身当前负载（虚报负载），在接受任务时优先选择计算量小、收益高的任务（偏好高收益任务）。三类异常行为同时激活，共同模拟机会主义节点在去中心化网络中的典型偏离策略；仿真中通过随机选取一定比例的卫星节点激活上述行为，横轴表示自私节点在总节点中的占比。

从图 4.10（a）可以看出，随着自私节点比例从 0% 提高到 40%，所有算法的任务完成率均呈下降趋势，图中误差棒为 5 次独立运行的 $\pm 1\sigma$ 标准差。这是因为自私节点倾向于拒绝外部卸载或虚报自身状态，从而削弱系统整体协作效率。然而，BC-CTDE-MAPPO 的性能退化最小，其任务完成率仅由 93.2% 下降至 87.2%（降幅 6.0pp）；相比之下，MAPPO 从 89.6% 下降至 78.4%（降幅 11.2pp），Greedy 和 Random 则下降得更加明显。这表明，所提方法通过区块链的可审计共享和信誉惩罚机制，能够有效缓解自私行为对系统性能的破坏。

图 4.10（b）显示了不同自私节点比例下的 Jain 公平指数变化情况，同样附有 $\pm 1\sigma$ 误差棒。随着自私节点增多，所有方法的公平指数均有所下降，但 BC-CTDE-MAPPO 始终保持最高水平。例如，在 30% 自私节点条件下，BC-CTDE-MAPPO 的公平指数仍达到 0.886（ ± 0.011 ），而 MAPPO、Greedy 和 Random 分别下降至 0.816、0.722 和 0.659，说明链上信誉机制能够有效抑制自私行为对系统公平性的破坏。这说明所提方法不仅能够在效率层面维持更高的任务完成率，也能够在此类场景下保持更稳定的全局负载均衡。

表 4.8 不同自私节点比例下的鲁棒性对比

算法	0%	10%	20%	30%	40%
BC-CTDE-MAPPO	93.2	92.3	90.9	89.4	87.2
MAPPO	89.6	87.2	84.6	81.6	78.4
Greedy	82.1	78.6	74.8	71.1	67.2
Random	68.9	64.1	60.3	55.6	51.9




图 4.10 不同自私节点比例下的系统鲁棒性对比

同时,为进一步验证信誉机制的治理效果,本文展示了合作节点与自私节点的链上信誉演化过程。在仿真中,合作节点持续诚实上报状态并积极响应协同请求,自私节点则以一定概率拒收外部任务或虚报负载。实验结果表明,合作节点的信誉值随时间步增加逐渐上升,并最终稳定在 0.90 以上;自私节点的信誉值则从初始值 0.50 持续下降至 0.20 以下。该结果说明,链上信誉反馈机制能够有效区分合作行为与机会主义偏离行为,并将其结果持续回写到后续决策激励中,从而形成“状态感知—策略执行—链上审计—信誉更新”的闭环治理机制。

4.5.7 结果讨论

综合以上结果可以得到三点核心结论。

第一,天基协同资源分配问题的主要难点不仅在于“如何找一个更优分配”,更在于“如何让多个理性节点在长期演化中持续愿意协同”。因此,可信共享与信誉约束在长期运行中比单步优化的启发式策略更为关键。

第二,区块链在本文中的作用并非简单地提供一个“额外模块”,而是为公共状态共享、行为审计和激励兑现提供了统一执行媒介,使奖励塑形具备现实落点。消融实验表明,链上摘要、公平奖励和可信奖励分别作用于全局上下文获取、负载均衡约束和异常行为抑制,三者共同构成方法性能提升的主要来源。

第三,本文方法的优势在高负载、强异构和异常节点存在时更加明显。这说明 BC-

CTDE-MAPPO 更适合被理解为一种“压力场景下优势更突出的系统层协同方法”，而不是仅在轻负载环境下追求微小平均收益提升的局部优化技巧。

4.6 本章小结

本章面向第3章统一模型与可信状态基础所支撑的系统层协同资源分配问题，重点研究多个异构卫星节点在去中心化、信息不完全和自利行为共存条件下的长期可信协同机制。在统一符号体系基础上，本章明确了 $\Delta t_{\text{sys}} = 10 \text{ s}$ 的系统层时间尺度，构建了系统层状态空间、动作空间、奖励函数和资源约束，并将多节点资源协同过程建模为部分可观测的多智能体马尔可夫博弈。

围绕该博弈模型，本章进一步引入联盟链公共信息板维护节点负载、链路统计、信誉评分和历史行为等可信摘要，设计了基于集中训练—分散执行的 BC-CTDE-MAPPO 算法。该算法在训练阶段利用联合状态进行全局价值评估，在执行阶段仅依赖本地观测和链上公共摘要进行自治决策，并通过任务完成质量、负载公平性和信誉激励的混合奖励机制，引导节点在长期交互中形成稳定协同。

实验结果表明，所提方法在收敛稳定性、任务完成率、平均时延、负载均衡和抗自私行为方面均优于对比方法，尤其在高负载、规模扩展和异常节点存在的压力场景下优势更加明显。本章解决的是较长时间尺度下的系统层协同问题，其输出的候选节点集合、资源约束、信誉状态和公共摘要将作为第5章任务层实时卸载决策的重要输入。

5 基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法

第3章已经建立天基网络可信协同计算卸载的统一场景、基础模型与可信状态刻画，第4章进一步从系统层研究多节点长期可信协同，为任务层提供候选节点约束、负载均衡导向和信誉上下文。在此基础上，本章将研究对象收缩到单个任务到达瞬间的节点侧卸载决策，重点回答卫星终端如何在有限观测条件下选择本地执行或卸载至具体候选节点。

任务层决策面临的关键矛盾是：链上公共摘要可信且可追溯，但受共识、传播和确认过程影响，并不能等同于实时全局状态；本地观测更新快，却只能反映局部资源和链路条件；候选边缘节点上的并发开销又会随任务组合、资源争用和背景负载动态变化，难以依靠固定解析模型准确刻画。因此，本章采用“聚类联邦学习预测 + DQN 在线决策”的分层方法：前者在不上传原始执行日志的前提下学习候选节点的并发风险，后者将预测开销及其不确定性转化为任务到达瞬间的离散卸载动作。

本章按“任务层问题提出—代价与并发建模—并发开销预测—在线卸载决策—实验验证”的顺序展开。第 5.2 节给出系统框架、任务代价模型和并发开销建模；第 5.3 节介绍基于聚类联邦学习的并发开销预测方法；第 5.4 节给出 FL-DQN 卸载决策算法；第 5.5 节从预测精度、卸载性能、消融和鲁棒性等方面验证所提方法的有效性。

5.1 引言

在轨试验、遥感预处理、异常事件检测和应急响应等业务持续向天基网络侧延伸，卫星终端正从单纯的数据采集与转发节点，演化为具备本地处理与协同计算能力的智能边缘实体。然而，受星载平台体积、功耗、抗辐照设计和载荷预算的制约，终端侧可用计算资源仍然有限。当计算密集型、时延敏感型任务持续到达时，仅依赖本地执行难以同时满足实时性、能耗约束与任务完成质量。将任务动态卸载至具备更强处理能力的卫星边缘节点（Satellite Edge Node, SEN），由此成为提升天基分布式计算效率的重要途径。

任务层卸载的难点并不只是“是否存在可卸载节点”，而是“当前任务应被放到哪里才不会引发新的拥塞”。新任务到达卫星终端（Satellite Terminal, ST）后，终端需要在很短时间窗内综合任务计算量、输入规模、截止期、本地资源余量、链路可达

性和候选节点状态，判断任务应本地执行还是卸载至某个 SEN。与地面有线或稳定无线环境不同，星间链路带宽、传播时延和可见窗口随轨道运动持续变化，节点状态感知存在天然滞后。因此，不少调度方法所默认的“调度器能够获得候选节点准确、即时、全局一致状态”的前提，在天基场景下并不成立；继续沿用依赖完美状态信息的集中式思路，实际部署时往往面临观测滞后、通信开销高和模型泛化不足等问题。

并发开销是任务层卸载中最容易被低估、却又最直接决定卸载效果的隐藏变量。当多个任务在同一候选 SEN 上并发执行时，新任务的进入不仅会延长自身完成时延，还会通过 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队等机制干扰既有任务的推进，造成执行队列的系统级性能退化。也就是说，并发开销不是附着于新任务的单一额外代价，而是同时作用于新任务与存量任务的耦合扰动。如果卸载策略仍仅依据候选节点平均负载、瞬时 CPU 利用率或链上静态摘要做判断，就容易把任务送往“表面空闲、实际竞争严重”的目标节点，最终导致时延放大、能耗增加和拥塞累积。

因此，本章不再重复求解第4章已经讨论的系统层协同资源分配问题，而是在其候选约束、负载均衡导向和信誉上下文基础上，进一步研究单任务到达时的节点侧动作选择。第四章回答“哪些节点在当前系统状态下适合作为候选协同对象”，本章则回答“当前具体任务应本地执行还是卸载至哪个候选节点”。联盟链在本章中的作用相应转变为可信状态与模型凭据维护：链上公共摘要 $G(t)$ 提供候选节点负载、信誉和账本延迟等系统级信息，模型摘要 $M(t)$ 维护联邦预测模型的版本号、哈希和所属簇信息。二者共同构成任务层可利用的扩展摘要 $G^{\text{task}}(t)$ ，但并不消除传播、确认和同步过程带来的信息陈旧性。

传统集中式训练或集中式调度同样难以直接适用于该场景。任务执行日志、运行轨迹和资源利用信息往往携带敏感业务特征，不适合长期集中上传；星间链路带宽有限且可用性随轨道变化波动，持续传输原始样本代价高；不同节点还普遍存在明显的 Non-IID 数据分布，使统一集中模型难以稳定泛化。表 5.1 总结了集中式思路在本场景中的主要局限。

表 5.1 集中式学习在天基网络中的主要局限

问题维度	具体表现	直接影响
数据隐私	任务日志、运行时轨迹及资源占用明细不适合长期集中上传	降低可部署性
通信带宽	星间链路带宽有限，持续传输原始样本代价高	增加训练成本
链路时延	星地/星间传播时延明显，集中同步存在先天滞后	难以在线更新
链路可用性	卫星运动导致链路存在窗口限制和随机中断	影响训练稳定性
数据异构性	不同节点硬件能力、业务形态和负载模式差异显著	集中式模型泛化受限

针对上述约束，本章采用“并发开销预测 + 在线卸载决策”的分层思路。聚类式联邦学习在不上传原始执行日志的前提下训练并发开销预测模型，学习候选节点在不同任务组合和运行背景下的潜在拥塞风险；预测得到的并发开销及其不确定性，与任务特征、本地状态和链上扩展摘要共同输入深度 Q 网络（Deep Q-Network, DQN）代理，生成节点侧离散卸载动作。采用“预测—决策”分层结构的原因在于：并发开销同时受硬件架构、任务类型和执行上下文影响，固定解析公式难以稳定刻画；与此同时，天基任务卸载的候选动作集合通常有限，DQN 能够在保持较低在线推理开销的同时，将预测先验转化为面向单任务决策的策略增益。

本章的主要贡献体现在三个方面。首先，从任务层视角形式化刻画并发开销，将新任务进入成本与存量任务受扰成本同时纳入代价表达；其次，构建适用于 Non-IID 与隐私受限场景的分层聚类联邦学习框架，并借助链上模型摘要维护预测模型的版本一致性与可追溯性；最后，将并发开销预测值及其不确定性显式融入 DQN 状态空间与奖励设计，使节点侧策略具备面向潜在资源竞争的前瞻感知能力。

从运行过程看，历史执行日志首先被转化为并发开销监督样本，用于聚类联邦训练与簇内模型聚合；当新任务到达时，ST 提取任务属性、采样本地状态、读取链上候选节点摘要和模型摘要，并依据目标节点所属簇调用相应预测模型，估计各候选动作的并发开销，最终由 DQN 输出本地执行或目标节点卸载动作。由此，后台异步训练、前台快速推理和链上模型版本维护被组织为面向任务到达瞬间的并发感知卸载机制。

5.2 系统框架与问题建模

本节先说明任务层方法如何在前台卸载决策与后台模型维护之间协同运行，再给出单任务本地执行和边缘卸载的代价表达。在此基础上，本节进一步刻画并发开销这一关键隐藏变量，并将任务特征、本地观测、链上摘要和预测先验整理为统一状态表征，为后续联邦预测与 DQN 决策提供建模基础。

5.2.1 系统组成与卸载流程

天基分布式计算系统由若干卫星终端 ST、卫星边缘节点 SEN、联盟链账本以及联邦协调单元共同构成。终端节点负责业务接入、本地状态采样与卸载动作执行；边缘节点负责外部任务的接收、排队和执行；联盟链账本负责维护资源状态区块、任务开始区块、任务结束区块以及模型版本摘要；联邦协调单元负责预测模型的簇划分、参数聚合与版本下发。上述角色划分承接了第3章建立的可信控制平面和状态摘要体系，同时将第4章的系统层协同结果进一步落实到节点侧单任务决策过程。

为说明任务层方法如何在“前台快速卸载决策”和“后台异步模型维护”之间协同运行，图 5.1 给出了任务级卸载的双时间尺度结构。图中数字 1–5 表示单任务到达后的在线卸载链路，包括账本检查、模型版本确认、任务卸载、任务计算和任务结束上链；字母 a–e 表示历史日志驱动的联邦模型维护链路，包括初始模型分发、本地训练、模型聚合、模型更新和区块上链。前者要求低时延推理，后者允许在较长时间尺度上完成模型训练、聚合和链上存证。




图 5.1 任务级卸载的系统级双时间尺度架构与信息交互流程

在该结构中，联盟链并不替代终端进行实时卸载决策，而是提供可信但非实时的链上公共摘要和模型版本凭据；联邦协调单元也不直接接管任务执行，而是在后台完成预测模型的簇内聚合与版本维护。表 5.2 总结了任务级卸载框架中的主要参与者及其职责。

表 5.2 任务级卸载框架中的角色划分

角色	主要职责
卫星终端 ST	生成新任务、采集本地 CPU/队列/剩余能量状态、读取链上扩展摘要、获得并发开销预测并执行本地/卸载动作
卫星边缘节点 SEN	接收外部任务、维护执行队列、反馈任务完成状态、沉淀历史执行日志并参与联邦训练
联盟链账本	维护候选节点摘要、任务开始区块、任务结束区块、模型版本号与哈希摘要，提供异步非实时全局视图
联邦协调单元	根据负载模式进行簇划分、完成簇内聚合与异常更新筛选、下发最新预测模型
DQN 决策代理	将任务特征、本地状态、链上扩展摘要和预测先验映射为离散卸载动作，并通过经验回放优化策略

从任务生命周期看，节点侧卸载决策主要包括以下阶段：1) 新任务到达后，终端提取计算量、输入规模、截止期与优先级等属性；2) 采样本地资源状态，并从链上公共摘要 $G(t)$ 读取候选节点负载、信誉和账本延迟等状态；3) 依据链上模型摘要 $M(t)$ 确认候选目标所属簇及对应预测模型版本；4) 调用联邦预测模型估计各候选动作对应的并发开销；5) 将任务特征、本地观测、链上扩展摘要和预测先验拼接为状态向量；6) 由 DQN 输出本地执行或目标节点卸载动作；7) 任务执行结束后，真实时延、能耗、完成状态和模型版本信息继续写入链上记录，为后续状态更新和模型维护提供依据。

5.2.2 任务代价模型

在明确系统组成与卸载流程后，还需要给出节点侧动作选择所依据的任务代价模型。该模型不试图重新求解系统层资源分配，而是面向当前到达任务，分别刻画本地执行与边缘卸载两类动作的时延、能耗以及后续并发扰动来源。

对任意时刻到达终端的一个新任务，记其描述为

$$T_i = (C_i, S_i, D_i, \tau_i, \zeta_i), \quad (5.1)$$

其中, C_i 表示任务计算量, S_i 表示输入数据大小, D_i 为最大可接受完成时延或截止期, τ_i 为任务类型编码, ζ_i 为任务优先级。这里使用 D_i 表示时延约束, 是为了避免与任务符号 T_i 发生混淆。

为保持与第3章任务模型的一致性, 本章仅在任务层单任务决策视角下调整记号。第3章中的 $T_k = (s_k, c_k, d_k, \tau_k, \zeta_k, t_k^{\text{arr}})$ 强调整体系统中的任务属性和到达时刻; 本章中的 $T_i = (C_i, S_i, D_i, \tau_i, \zeta_i)$ 则突出当前到达任务的计算量、输入规模和截止期等决策特征, 其中到达时间由当前决策时刻 t 隐含。两章任务符号的对应关系如表 5.3 所示。

表 5.3 任务符号对应关系

第3章符号	本章符号	含义说明
s_k	S_i	任务输入数据规模
c_k	C_i	完成任务所需计算量或 CPU 周期数
d_k	D_i	最大可接受完成时延或截止期
τ_k	τ_i	任务类型编码
ζ_k	ζ_i	任务优先级
t_k^{arr}	当前决策时刻 t	任务到达时间; 在任务层单任务决策中由时刻 t 隐含

与第4章面向较长时间尺度的系统层可信协同不同, 本章关注的是单任务在到达瞬间面临的局部动作选择。设候选动作集合为

$$\mathcal{A} = \{0, 1, 2, \dots, N_c\}, \quad (5.2)$$

其中, 动作 0 表示本地执行, 动作 $n \in \{1, \dots, N_c\}$ 表示卸载至第 n 个可达候选边缘节点。候选集合并非全网节点集合, 而是由第4章系统层协同资源分配结果、当前链路可达性和信誉阈值共同过滤得到。节点侧决策需要在极短时间窗口内完成, 因此策略不仅要追求较低的任务代价, 还需要满足在线推理开销约束。

需要强调的是, 式(5.2)中的动作是任务层单任务到达瞬间的最终执行动作, 其候选节点集合已经受到第4章系统层输出的任务流向偏好、资源约束和信誉门限限制。换言之, 第四章决定“哪些节点在当前系统状态下适合作为候选协同对象”, 本章进一步决定“当前具体任务是否本地执行以及卸载至哪个候选节点”。二者分别对应系统层统计窗口内的协同约束和任务层到达瞬间的执行选择。

为支撑后续奖励函数和评价指标设计，本节先给出单任务在本地执行和边缘卸载两种情形下的时延、能耗模型。需要说明的是，本章的时延与能耗表达是在第3章基础执行代价模型上的任务层细化：第3章给出了本地计算、星间传输、远端执行和等待维持能耗的统一形式，本章进一步面向单任务实时卸载，将本地等待期间的空闲维持功耗显式写入本地能耗，并用系数 η_n 将候选边缘节点侧执行能耗折算为任务代价。该处理不改变基础模型的物理含义，而是服务于任务层总代价函数和 DQN 奖励反馈的构造。

若任务在本地执行，则其完成时延由本地等待时延和本地计算时延共同构成：

$$L_i^{\text{loc}}(t) = W_i^{\text{loc}}(t) + \frac{C_i}{f_i^{\text{loc}}(t)}, \quad (5.3)$$

其中， $W_i^{\text{loc}}(t)$ 表示任务进入本地队列后的等待时间， $f_i^{\text{loc}}(t)$ 为终端在当前时刻可分配给该任务的有效计算频率。相应地，本地执行能耗可写为

$$E_i^{\text{loc}}(t) = \kappa_i C_i (f_i^{\text{loc}}(t))^2 + P_i^{\text{idle}} W_i^{\text{loc}}(t), \quad (5.4)$$

其中， κ_i 为设备有效电容系数， P_i^{idle} 用于近似本地等待期间的空闲维持功耗。若不考虑本地排队或等待能耗，上式可退化为常见的动态功耗模型。

若任务卸载到候选边缘节点 n ，则其端到端完成时延可分解为上行传输时延、传播时延、边缘基础排队时延、边缘计算时延和并发扰动时延五部分，即

$$L_i^{\text{off}}(n, t) = \frac{S_i}{R_{i,n}^{\text{up}}(t)} + d_{i,n}^{\text{prop}}(t) + W_n^{\text{edge}}(t) + \frac{C_i}{F_n(t)} + \Delta_i(n, t), \quad (5.5)$$

其中， $R_{i,n}^{\text{up}}(t)$ 为上行传输速率， $d_{i,n}^{\text{prop}}(t)$ 为传播时延， $W_n^{\text{edge}}(t)$ 为不考虑新任务扰动时目标节点已有队列造成的基础等待时间， $F_n(t)$ 为目标节点当前可用计算能力， $\Delta_i(n, t)$ 为将新任务放置到节点 n 后额外产生的并发开销。该写法将“已有队列导致的常规等待”和“新任务加入后造成的资源竞争扰动”分开，有助于后续突出并发开销预测模块的作用。

相应地，卸载能耗可写为

$$E_i^{\text{off}}(n, t) = P_i^{\text{tx}} \frac{S_i}{R_{i,n}^{\text{up}}(t)} + P_i^{\text{idle}} (d_{i,n}^{\text{prop}}(t) + W_n^{\text{edge}}(t)) + \eta_n \frac{C_i}{F_n(t)}, \quad (5.6)$$

其中， P_i^{tx} 为终端发射功率， η_n 为将目标节点执行能耗折算回任务代价的系数。式 (5.6) 不仅刻画了传输能耗，也保留了等待和边缘侧执行的代价信息，从而避免策略一味追

求低时延卸载而忽略系统整体能源消耗。进一步地, $\eta_n C_i / F_n(t)$ 可理解为第3章远端执行能耗项在任务层决策中的折算形式; 若需要更精细的硬件功耗刻画, 也可替换为第3章给出的动态功耗表达。

上述变量具有明确的层次来源。任务计算量、输入数据规模、截止期和优先级来自业务层任务描述; 本地 CPU 占用、队列长度、剩余能量和可用频率由终端实时采样获得; 候选节点平均负载、负载方差和信誉评分等信息来自第3章定义的链上公共摘要 $G(t)$, 模型版本号、模型哈希和所属簇信息来自链上模型摘要 $M(t)$, 二者共同构成任务层扩展摘要 $G^{\text{task}}(t)$; 执行中任务剩余工作量、上下文切换强度和资源争用统计则由边缘节点日志沉淀, 并在联邦训练阶段转化为监督样本。与此同时, 式 (5.5) 与式 (5.6) 建立在以下建模假设之上: 其一, 任务到达可用泊松流或离散事件过程近似; 其二, 边缘节点在短时间窗内的标称算力变化相对平缓; 其三, 链上摘要虽然可能存在陈旧性, 但版本顺序和摘要内容具有可信性与可验证性。后续实验中的链上摘要滞后敏感性分析, 将进一步讨论上述假设对策略性能的影响。

5.2.3 并发开销建模

传统任务卸载模型通常重点刻画传输时延、排队时延和计算时延, 但在候选节点并发执行多个任务时, 仅靠这些基础代价仍不足以描述真实卸载后果。并发开销是本章区别于传统卸载模型的关键变量。设在时刻 t , 目标节点 n 上已有执行中任务集合 $\mathcal{T}_n^{\text{exec}}(t)$, 新任务 T_i 被放置到该节点后, 系统会因 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队而出现额外时延。为了同时刻画新任务自身被拖慢和存量任务被扰动两类影响, 将任务 T_i 产生的并发开销定义为

$$CO_i(n, t) = [L_i^{\text{conc}}(n, t) - L_i^{\text{base}}(n, t)] + \sum_{e \in \mathcal{T}_n^{\text{exec}}(t)} [\tilde{L}_e^{\text{conc}}(n, t) - \tilde{L}_e^{\text{base}}(n, t)], \quad (5.7)$$

其中, $L_i^{\text{base}}(n, t)$ 表示新任务在目标节点不受额外并发扰动时的基准完成时延, $L_i^{\text{conc}}(n, t)$ 表示新任务加入真实并发环境后的完成时延; $\tilde{L}_e^{\text{base}}(n, t)$ 表示存量任务 e 在没有新任务 T_i 加入时的预计剩余完成时延, $\tilde{L}_e^{\text{conc}}(n, t)$ 表示新任务加入后该存量任务的剩余完成时延。与只关注新任务自身时延的定义相比, 式 (5.7) 同时计入了新任务进入成本与存量任务受扰成本, 因此更符合节点侧真实的资源竞争机制。为避免符号混淆, 后文中 $CO_i(n, t)$ 用作并发开销的完整定义, $\Delta_i(n, t)$ 表示进入时延模型和总代价函数的并发扰动项, $\hat{\Delta}_i(n, t)$ 表示联邦预测模型给出的估计值。

图 5.2 展示了并发开销的形成机理。该图应与式 (5.7) 对应理解：左侧表示无新任务加入时存量任务按相对稳定的资源份额推进；右侧表示新任务进入后，CPU、Cache、Memory 和 I/O 等共享资源被重新分配，存量任务出现受扰延迟，新任务也因竞争产生额外等待。因而，并发开销不是单个任务的固定附加项，而是由任务组合、资源瓶颈和执行上下文共同决定的耦合代价。




图 5.2 并发开销的形成机理与资源争用示意

在实现过程中，式 (5.7) 所涉及的未来并发时延难以在决策瞬间直接获得，因此还需构造一个可学习、可预测的近似表达。记目标节点当前并发任务数为 $k_n(t)$ ，节点当前可用计算能力为 $F_n(t)$ ，执行中任务 e 的剩余计算量为 $C_e^{\text{rem}}(t)$ ，并用 $\chi_{i,e} \in [0, 1]$ 表示新任务与存量任务在资源需求类型上的竞争强度，则并发扰动可近似写为

$$\Delta_i(n, t) \approx \frac{(k_n(t) - 1) C_i}{F_n(t)} + \sum_{e \in \mathcal{T}_n^{\text{exec}}(t)} \frac{\chi_{i,e} C_e^{\text{rem}}(t)}{F_n(t)}, \quad (5.8)$$

该表达式揭示了并发开销与新任务计算量、当前并发任务数、存量任务剩余工作量以及任务间资源竞争强度之间的正相关关系，便于在后续样本标注、特征选择和模型解释中使用。当缺少细粒度资源画像时，可令 $\chi_{i,e} = 1$ 得到保守估计。

从统计学习角度可以将并发开销写为

$$CO_i(n, t) \approx F_{\text{new}}(T_i, n, \text{obs}) + G_{\text{exec}}(\mathcal{T}_n^{\text{exec}}(t), n, \text{obs}) + R_i(n, t), \quad (5.9)$$

其中， $F_{\text{new}}(\cdot)$ 捕获新任务加入带来的瞬时冲击， $G_{\text{exec}}(\cdot)$ 刻画已执行任务间的持续资

源竞争, $R_i(n, t)$ 表示未建模的高阶耦合残差。该可分解表达虽不直接用于在线推理, 却有助于解释为何联邦模型在轻负载和重负载场景下会表现出不同的误差模式: 前者更依赖新任务特征, 后者更依赖存量任务组合和运行背景。

考虑时延、能耗和并发扰动三类代价, 本章将动作 a_t 对应的单任务总代价定义为

$$J_i(a_t) = \omega_L L_i(a_t) + \omega_E E_i(a_t) + \omega_C \Delta_i(a_t), \quad \omega_L + \omega_E + \omega_C = 1, \quad (5.10)$$

其中, $L_i(a_t)$ 为动作执行后的端到端完成时延, $E_i(a_t)$ 为对应能耗, $\Delta_i(a_t)$ 表示动作引起的并发扰动; 对于本地执行动作, 可令 $\Delta_i(a_t)$ 表示本地队列中存量任务受到的额外扰动, 也可在只关注边缘并发时取零。三个权重参数可根据业务偏好灵活调整: 对实时业务可提高 ω_L , 对能源敏感任务可提高 ω_E , 对高拥塞控制场景则可适当增加 ω_C 。采用 ω 作为代价权重, 是为了避免与后续 DQN 中的折扣因子符号混用。

式 (5.10) 的意义并不仅在于给出加权求和目标, 更重要的是为后续 DQN 奖励函数设计提供统一的任务层优化视角。第4章关注较长时间尺度下的系统层协同资源分配, 本章则将优化边界收缩到节点侧单任务决策, 从而在保持跨层方法链连贯性的同时, 避免重复求解上一章已经讨论过的系统层资源协同问题。

5.2.4 状态表征与 MDP 建模

为了使并发开销能够被机器学习模型预测, 并使 DQN 能够进行可执行的在线决策, 需要构造一个统一的复合状态表征。设可观测特征向量为

$$\mathbf{x} = [\mathbf{x}^{\text{task}}, \mathbf{x}^{\text{local}}, \mathbf{x}^{\text{chain}}, \mathbf{x}^{\text{conc}}], \quad (5.11)$$

其中:

- $\mathbf{x}^{\text{task}}$: 新任务特征, 包括计算量、输入大小、时延阈值、任务类型编码、优先级等;
- $\mathbf{x}^{\text{local}}$: 本地状态, 包括本地 CPU 占用、队列长度、剩余能量、可用频率和链路质量估计等;
- $\mathbf{x}^{\text{chain}}$: 链上公共摘要 $G(t)$ 的任务层相关分量, 包括候选节点平均负载、负载方差、信誉评分、账本确认延迟估计等;
- $\mathbf{x}^{\text{conc}}$: 并发环境统计, 包括目标节点当前并发任务数、执行中任务总剩余工作

量、平均内存占用和上下文切换强度等。

所有连续特征在进入模型前都进行标准化处理，即

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j + \varepsilon}, \quad (5.12)$$

其中， μ_j 和 σ_j 分别为训练集统计均值和标准差， ε 为数值稳定常数。

节点侧观测天然不完全：本地节点只能直接观测自身状态，难以获取其他候选节点的细粒度实时轨迹；链上公共摘要虽然提供一致且可追溯的系统级视图，时间戳却可能早于当前决策时刻。因此，本章卸载问题本质上是部分可观测、带滞后信息的序贯决策问题。引入 FL 预测模块的意义，正在于利用历史数据学习并发风险先验，在缺乏完整实时信息的条件下补充节点侧观测。

在上述状态表征基础上，节点侧任务卸载进一步被建模为马尔可夫决策过程

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle. \quad (5.13)$$

其中：

- 状态空间 $\mathcal{S}$ 由任务特征、本地资源状态、链上扩展摘要和 FL 预测值共同组成；
- 动作空间 $\mathcal{A}$ 为“本地执行 + 若干候选 SEN”构成的离散集合；
- 状态转移概率 $\mathcal{P}$ 由任务到达、链路变化、资源占用演化和预测结果更新共同决定；
- 奖励函数 $\mathcal{R}$ 采用总代价负值并叠加轻量奖惩项。

严格而言，该过程具有部分可观测特征。本文将本地观测、链上扩展摘要和预测先验拼接为扩展状态，并以该扩展状态近似满足马尔可夫性，从而采用 DQN 进行求解。

考虑到任务层在线推理的时延约束，本章选择基于离散动作值函数的 DQN，而非连续动作策略梯度方法。本场景的动作集合有限，DQN 具有较高的推理效率和较低的实现复杂度；同时，将主要模型复杂度集中于并发开销预测环节，比在在线决策阶段引入更复杂的连续动作网络更符合本章的问题结构。

5.3 并发开销预测方法

第 5.2 节已经说明并发开销为何会影响任务层卸载质量。本节进一步回答如何学习这一隐藏变量。并发开销虽然可以通过历史执行日志标注，但这些日志分散在不同 SEN 上，并包含任务类型、执行轨迹和资源占用等敏感信息；若集中上传，通信和隐私代价较高；若各节点只依赖本地样本，又容易因样本规模有限和数据分布偏置导致预测不稳定。为此，本节采用聚类联邦学习，在不上传原始日志的前提下，使负载模式相近的节点共享模型能力。

5.3.1 预测目标与样本构造

并发开销预测本质上是一个监督回归问题。其输入为式 (5.11) 定义的多维特征，输出为目标节点在接受新任务后的并发开销估计值 $\hat{\Delta}$ 及其不确定性信息。设节点本地构造的监督样本为

$$\mathcal{D}_k = \{(\mathbf{x}^{(m)}, y^{(m)})\}_{m=1}^{N_k}, \quad (5.14)$$

其中， $y^{(m)}$ 为根据运行日志标注得到的真实并发开销。对于每个样本，需要记录任务到达前后的队列长度、CPU 频率、内存占用、任务开始时间、完成时间、输入大小、计算量等信息，再依照式 (5.7) 或式 (5.8) 计算标签。

为了使预测模型尽可能覆盖多样化的竞争形态，本章采用“双代理负载”的思路：一类是图像处理任务，用于模拟视觉感知类边缘业务；另一类是数值计算任务，用于模拟计算密集但数据规模较小的负载。这种设计的好处在于，既能让模型观察到数据搬移开销与计算开销同时占优的混合场景，又能避免训练集完全偏向单一类型任务而失去泛化性。

5.3.2 预测模型设计

考虑到输入特征既包含结构化统计量，也可能包含短时间窗内的序列信息，本章在模型结构上兼容两类实现：

- 1) MLP 结构：适用于结构化向量输入。模型通常由 3–5 个全连接隐藏层构成，每层采用 ReLU 激活并可结合 Dropout 抑制过拟合；
- 2) 1D-CNN 结构：当输入拼接了过去若干时间步的 CPU 利用率、队列长度或链路质量序列时，1D-CNN 可以提取时序局部模式，再通过全连接层输出最终预测

值。

为了使预测结果能够在决策阶段发挥更稳健的作用，本章采用均值 + 方差双输出的设计，即网络输出

$$f_{\theta}(\mathbf{x}) = \left(\hat{\Delta}, \hat{\sigma}^2 \right), \quad (5.15)$$

其中， $\hat{\Delta}$ 为并发开销点估计， $\hat{\sigma}^2$ 为预测方差估计。增加不确定性分支后，DQN 状态空间中能够带入“模型对该预测是否有把握”的额外信息；在高异构、弱覆盖的样本区间内，不确定性也提醒策略不要过度依赖单一预测值。

预测器本身不追求过深或过重的网络结构，而强调对结构化特征、短时间窗统计序列和不确定性信息的统一表达。本章关心的是“并发开销感知如何服务任务级决策”，模型结构因此保留轻量、可部署和可解释的设计原则，并不把网络复杂度本身列为创新点。

在损失函数设计上，若仅关注点估计，可使用均方误差

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{m=1}^N \left(\hat{\Delta}^{(m)} - \Delta^{(m)} \right)^2. \quad (5.16)$$

若同时训练不确定性分支，则可以采用异方差高斯负对数似然形式

$$\mathcal{L}_{\text{pred}} = \frac{1}{N} \sum_{m=1}^N \left[\frac{\left(\hat{\Delta}^{(m)} - \Delta^{(m)} \right)^2}{2\hat{\sigma}^{2(m)}} + \frac{1}{2} \log \hat{\sigma}^{2(m)} \right]. \quad (5.17)$$

该损失函数允许模型在噪声较大的区域给出更高的不确定性估计，从而避免对本就难以准确预测的样本过度拟合。

5.3.3 聚类联邦训练

不同边缘卫星节点的本地样本分布具有显著 Non-IID 特征：高性能节点可能长期承载视觉类任务，资源受限节点则更多面对轻量计算或转发类任务。若直接使用统一 FedAvg 训练单一全局模型，模型往往难以兼顾不同簇之间的局部负载模式。基于此，本文采用聚类式联邦学习（clustered FL）对预测模型进行训练。其核心思路是：不再假设全网节点共享同一个最优模型，而是先根据节点负载模式、硬件能力或更新方向将其划分为多个簇，再在簇内执行模型聚合。

面向天基网络的层次化结构，本章将联邦预测框架设计为“全局协调层—区域聚

合层—本地训练层”三层架构。与参考章节中“系统组成—工作流程—算法设计”的写法一致，这里先说明各层角色，再给出训练流程与簇内聚合规则。

三层架构的职责分工如表 5.4 所示。

表 5.4 分层聚类联邦学习架构中的角色划分

层级	典型实体	主要职责
全局协调层	地面控制中心 / 星座控制器	模型版本管理、训练轮次调度、簇级模型下发、链上摘要维护
区域聚合层	核心边缘卫星节点	区域内节点分组、异常更新检测、簇内参数加权聚合
本地训练层	参与训练的 SEN 集合	基于本地执行日志训练预测模型，不上传原始样本，仅上传模型更新

在一次完整的联邦训练周期内，预测模型的工作流程可以概括为：1) 全局协调层根据节点历史负载模式完成簇划分并下发初始化模型；2) 本地训练层在各自执行日志上完成若干轮本地更新；3) 区域聚合层对上传参数执行一致性检查、异常更新筛选与簇内加权聚合；4) 聚合后的模型版本号和参数哈希写入联盟链，供后续在线推理时进行版本校验与追溯；5) 最新簇模型再次下发至簇内节点，进入下一轮训练。上述流程使预测模型的训练、维护和可信存证形成统一流程。

设第 c 个簇内包含若干节点集合 C_c ，第 t 轮通信后簇模型参数更新为

$$\theta_c^{(t+1)} = \sum_{k \in C_c} \frac{n_k}{\sum_{j \in C_c} n_j} \theta_k^{(t+1)}, \quad (5.18)$$

其中， n_k 为节点 k 的本地样本量， $\theta_k^{(t+1)}$ 为节点本地更新后的参数。与传统 FedAvg 相比，式 (5.18) 的改进并不体现在加权形式本身，而在于聚合只在“样本分布相近的节点簇内”进行，因此更容易捕捉局部任务模式。

在实现层面，聚类式联邦训练不仅是将 FedAvg 改为簇内聚合，还需要与区块链可信控制平面形成一致的状态维护关系。具体而言，区域聚合层在每轮簇内聚合后，可将模型版本号、参数哈希和训练轮次摘要写入联盟链，形成第3章中模型摘要 $M(t)$ 的具体内容，用于模型溯源、版本一致性校验与异常更新留痕；终端节点在调用预测器时只需读取候选节点当前所属簇的最新可用模型版本，从而避免在在线阶段访问原始训练日志。这样的设计使“数据不出域”和“模型可追溯”同时成立，也使预测模块能够自然嵌入前文建立的可信状态体系。

聚类式联邦学习的一个完整训练轮次可由算法 2 概括。相较原始 FedAvg，该流程新增了簇内聚合、异常更新筛查与链上存证三个关键步骤，因此更适合 Non-IID 且可信要求较高的天基边缘场景。

算法 2 聚类式联邦学习 (Clustered FedAvg) 训练流程

输入：簇划分集合 $\{C_1, \dots, C_K\}$ ，本地数据集 $\mathcal{D}_k$ ，本地训练轮数 E ，通信轮数 T 。
 输出：各簇最终预测模型参数 $\theta_c^{(T)}$ 。

```

1: for 每个簇  $C_c$  do
2:   初始化簇模型参数  $\theta_c^{(0)}$  并下发至簇内节点
3: end for
4: for  $t = 0, 1, \dots, T - 1$  do
5:   for 每个簇  $C_c$  并行执行 do
6:     for 每个参与节点  $k \in C_c$  do
7:       以  $\theta_c^{(t)}$  为初值，在  $\mathcal{D}_k$  上执行  $E$  个 epoch 本地更新
8:       得到本地参数  $\theta_k^{(t+1)}$  及样本量  $n_k$ 
9:     end for
10:    区域聚合层对上传更新做一致性检查与异常剔除
11:    按式 (5.18) 聚合得到新的簇模型  $\theta_c^{(t+1)}$ 
12:    将模型版本号、参数哈希及训练轮次摘要写入联盟链
13:   end for
14: end for
  
```

在线推理阶段，终端节点并不直接参与联邦训练，而是在需要决策时调用候选边缘节点所属簇的最新预测模型，对每个候选动作的并发开销进行快速估计。这一点十分重要：联邦学习的高开销发生在离线训练或后台异步更新阶段，而在线阶段保留下来的只是一个轻量前向推理过程，因此不会破坏节点侧决策的实时性要求。

5.3.4 模型可信维护

设单个本地预测模型包含 P_f 个参数、每轮训练使用 B_f 个 mini-batch，则节点单轮本地训练复杂度约为 $\mathcal{O}(B_f P_f)$ ，簇内聚合本质是参数加权求和、复杂度为 $\mathcal{O}(|C_c| P_f)$ 。聚类式 FL 把全局聚合拆解为若干簇内聚合，单轮同步对全网连通性的要求因此低于统一 FedAvg。在线阶段只保留一次前向推理，预测模块部署时的主要成本不在计算本身，而在模型版本刷新与链上摘要读取的调度。

通信开销上，联邦学习阶段只需在节点与聚合层之间传递参数摘要，无需传输原始日志，“模型移动而非数据移动”在带宽受限、链路可用性波动的天基环境中收益明显；区域聚合层则把大规模全局同步进一步拆为局部同步，降低对全网连通性的苛刻要求。

把模型可信维护纳入考虑后，每轮额外链上开销主要来自模型哈希写入和版本确

认，这部分复杂度与模型参数规模无关，只取决于摘要长度和交易确认时延。也就是说，区块链不会显著增加训练算力负担，但会通过信息年龄影响在线可用模型版本的新鲜度。后续实验中的“链上确认延迟敏感性”正是针对这一约束的量化验证。

5.4 FL-DQN 卸载决策算法

并发开销预测本身并不是任务层卸载的最终目标。预测模型只回答“某个候选动作可能带来多大额外扰动”，而节点仍需在本地执行和多个候选卸载目标之间做出离散选择。为此，本节将预测值及其不确定性作为扩展状态输入 DQN，使策略能够在当前任务特征、本地状态、链上摘要和预测先验之间进行综合权衡。

5.4.1 状态、动作与奖励

在获得并发开销预测能力后，节点侧还需解决“面对新任务应当本地执行还是卸载到哪个候选节点”的决策问题。本文将单个 ST 的卸载过程建模为 MDP，其状态向量定义为

$$s_t = [s_t^{\text{task}}, s_t^{\text{local}}, s_t^{\text{chain}}, s_t^{\text{FL}}], \quad (5.19)$$

其中， s_t^{task} 包含任务计算量、数据规模、截止期、任务类型编码与优先级； s_t^{local} 包含本地 CPU 占用、队列长度、剩余能量与链路质量估计； s_t^{chain} 来自链上公共摘要 $G(t)$ 中的候选节点状态； s_t^{FL} 则由并发开销预测模型给出，包括各候选动作的 $\hat{\Delta}_i(n, t)$ 及其不确定性 $\hat{\sigma}_i^2(n, t)$ 。模型版本号、模型哈希和所属簇信息由模型摘要 $M(t)$ 提供，主要用于确定预测模型版本与适用范围。实际部署中，候选节点数量会随链路可达性变化。本文设定最大候选数 $N_c^{\max}$ ：当实际候选数不足时采用零填充并设置动作掩码，当候选数超过上限时根据信誉、链路质量和基础负载筛选前 $N_c^{\max}$ 个候选节点，从而保持 DQN 输入输出维度固定。

表 5.5 总结了复合状态空间的设计。

表 5.5 节点侧决策的复合状态空间设计

状态分量	主要内容	作用
任务特征向量	任务计算量、输入数据大小、截止期、任务类型编码、优先级	刻画当前任务需求
本地资源与链路状态	本地 CPU 占用、队列长度、剩余能量、可用频率、链路时延与带宽估计	反映当前本地资源与通信条件
链上公共摘要 $G(t)$	候选节点平均负载、负载方差、信誉评分、账本延迟估计	提供可信但非实时的系统级上下文
FL 预测先验	各候选动作的并发开销预测值与不确定性	显式表征卸载后的额外风险

奖励函数在总代价负值的基础上引入轻量奖惩机制：

$$r_t = -(\omega_L L_i^{\text{obs}} + \omega_E E_i^{\text{obs}} + \omega_C \Delta_i^{\text{obs}}) - \lambda_b P_{\text{imbalance}} - \lambda_u \bar{\sigma}_t + R_{\text{succ}}, \quad (5.20)$$

其中， L_i^{obs} 、 E_i^{obs} 和 Δ_i^{obs} 分别表示任务执行后观测到的真实时延、能耗和并发扰动； $P_{\text{imbalance}}$ 表示负载不均衡惩罚项，用于抑制任务长期集中到少数高性能边缘节点； $\bar{\sigma}_t$ 表示当前被选动作或候选动作集合上的平均预测不确定性，用于避免策略在高不确定区域过度激进； R_{succ} 为任务在截止期内完成、满足优先级约束或成功避开高拥塞节点时给予的正向奖励。由于 Δ_i^{obs} 只有在任务完成后才能准确计算，在线训练时采用两阶段奖励更新：动作执行后先根据 $\hat{\Delta}_i$ 给出临时塑形奖励，任务结束后再用观测到的真实并发扰动修正对应经验样本。这样既保留了预测先验对动作选择的前瞻作用，又避免把预测值误认为最终真实奖励。

FL 预测先验在机制上同时承担两类作用——作为扩展状态的一部分，它帮助智能体在动作选择前识别潜在拥塞；作为奖励塑形与不确定性惩罚的输入，它在候选节点当前负载相近但未来并发开销不同时，引导策略选择更低风险的动作。再加上 $P_{\text{imbalance}}$ 的负载均衡约束，策略不再只追求单次动作收益，而能够兼顾较长时间尺度上的节点利用均衡。

5.4.2 DQN 网络训练

由于动作空间是有限离散集合，本文采用 DQN 学习最优动作价值函数 $Q^*(s, a)$ 。令主网络参数为 θ_q ，目标网络参数为 θ_q^- ，DQN 的 Bellman 目标值写为

$$y_t = r_t + \rho \max_{a'} Q(s_{t+1}, a'; \theta_q^-), \quad (5.21)$$

损失函数为

$$\mathcal{L}_{\text{DQN}}(\theta_q) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}) \sim \mathcal{B}} [(y_t - Q(s_t, a_t; \theta_q))^2], \quad (5.22)$$

其中， $\mathcal{B}$ 为经验回放池， $\rho \in [0, 1)$ 为折扣因子。这里将折扣因子记为 ρ ，以避免与式 (5.10) 中的代价权重混淆。

为提高训练稳定性，本章沿用标准 DQN 的三项关键机制：

- 1) 经验回放：将交互产生的样本打乱后重用，削弱序列相关性；
- 2) 目标网络：使用滞后更新的目标网络生成目标值，减少训练震荡；
- 3) ϵ -greedy 探索：在探索与利用之间进行平衡，防止策略过早陷入局部最优。

在网络结构上，考虑到状态维度相对有限且要求在线推理足够快，本文使用两层或三层全连接网络逼近 $Q(s, a; \theta)$ ，隐藏层采用 ReLU 激活。相比于更复杂的 dueling、double 或 attention 结构，这种配置在节点侧具有更低的实现门槛和推理开销，更符合“轻量快速决策”的系统定位。当然，在实验中我们仍保留增强型 DQN 变体作为对比基线，以检验“改进 DRL 结构”和“引入预测先验”两条路线的相对收益。

5.4.3 在线决策流程

在完成并发开销预测模型构建与 DQN 卸载策略设计之后，本节进一步说明二者在节点侧在线决策过程中的协同方式。与图 5.1 所展示的系统级双时间尺度架构不同，图 5.3 聚焦于单个任务到达时的实时卸载决策闭环。其核心思想是：当新任务到达节点后，节点首先融合任务特征、本地资源状态、链上公共摘要 $G(t)$ 以及模型摘要 $M(t)$ ，确定当前可行动作集合；随后，依据候选目标节点所属簇调用最新的联邦并发开销预测模型，对每个候选动作产生并发开销估计及其不确定性；最后，将预测先验与原始状态特征共同输入 DQN，由 DQN 输出本地执行或星间卸载动作。




图 5.3 融合并发开销预测先验的 FL-DQN 在线卸载决策流程

如图 5.3 所示，FL-DQN 的在线决策过程可以理解为“状态感知—预测增强—动作选择—反馈更新”的闭环。首先，任务到达后，节点提取任务规模、计算量、截止期、任务类型和优先级等特征，并同步读取本地 CPU、内存、队列长度、剩余能量和链路状态等高频状态信息。与此同时，节点从链上公共摘要 $G(t)$ 中获取候选边缘节点的低频可信状态，包括负载水平、信誉信息、链路统计和链上时延估计等，并根据模型摘要 $M(t)$ 确认当前可用的预测模型版本。

在获得候选动作集合后，节点并不直接将原始状态输入 DQN 进行动作选择，而是先针对每个候选动作 $a \in \mathcal{A}$ 构造动作相关特征向量 $\mathbf{x}(s_t, a)$ 。该特征向量同时包含新任务属性、候选目标节点状态、链路条件以及链上摘要信息。随后，节点根据候选目标所属簇调用对应的联邦并发开销预测模型 f_{θ_f} ，快速推理得到该动作可能引入的并发开销预测值 $\hat{\Delta}_i(s_t, a)$ 及其不确定性 $\hat{\sigma}_i^2(s_t, a)$ 。这些预测结果刻画了新任务被接纳或卸载后可能造成的额外队列竞争、调度扰动和存量任务影响。

完成预测后，节点将任务特征、本地资源状态、链上扩展摘要以及各候选动作对应的预测先验进行拼接，形成扩展状态表示 s_t 。DQN 主网络 $Q(\cdot; \theta_q)$ 在该扩展状态上

计算各候选动作的动作价值，并按照 ε -greedy 规则选择本地执行或目标节点卸载动作。动作执行后，环境返回任务完成时延、能耗、并发扰动和完成结果，系统据此计算即时奖励 r_t ，并将交互样本 (s_t, a_t, r_t, s_{t+1}) 写入经验回放池。随后，DQN 从经验池中采样 mini-batch 更新主网络，并按照固定步长同步目标网络参数，从而在持续交互中逐步优化节点侧卸载策略。

上述流程的关键在于，并发开销预测模型并不直接替代卸载策略，而是作为前瞻性先验增强 DQN 的状态表征。传统 DQN 通常基于当前可观测状态进行动作价值估计，难以显式感知新任务接纳后对自身队列和存量任务造成的潜在扰动。本文通过将候选动作对应的并发开销预测值 $\hat{\Delta}_i(s_t, a)$ 及不确定性 $\hat{\sigma}_i^2(s_t, a)$ 纳入扩展状态，使 DQN 在估计动作价值时能够同时考虑即时资源状态和未来竞争风险。由此，在线卸载决策从单纯的反应式选择转化为融合预测先验的前瞻式动作评估。

为了更清楚地展示“预测先验如何进入在线动作选择”，算法 3 对 FL-DQN 的节点侧执行流程给出伪代码描述。与图 5.3 相比，算法描述更强调实现层面的控制流：即先针对候选动作逐一构造动作相关特征并调用预测模型，再将预测结果拼接进扩展状态，最后依据 DQN 完成动作选择和参数更新。

算法 3 FL-DQN 在线任务卸载决策流程

输入：最新可用联邦预测模型 f_{θ_f} ，DQN 主网络 $Q(\cdot; \theta_q)$ ，目标网络 $Q(\cdot; \theta_q^-)$ ，经验回放池 $\mathcal{B}$ 。
 输出：收敛后的节点侧卸载策略。

```

1: for 每个决策周期 do
2:   接收新任务并提取任务特征、本地资源状态与链上扩展摘要
3:   for 每个候选动作  $a \in \mathcal{A}$  do
4:     构造动作相关特征向量  $\mathbf{x}(s_t, a)$ 
5:     调用  $f_{\theta_f}$  得到并发开销预测值及不确定性  $(\hat{\Delta}_i(s_t, a), \hat{\sigma}_i^2(s_t, a))$ 
6:   end for
7:   拼接得到扩展状态  $s_t$ ，按  $\varepsilon$ -greedy 选择动作  $a_t$ 
8:   执行动作并获得即时奖励  $r_t$  与下一状态  $s_{t+1}$ 
9:   将  $(s_t, a_t, r_t, s_{t+1})$  写入经验回放池  $\mathcal{B}$ 
10:  if 经验池样本数量足够 then
11:    从  $\mathcal{B}$  随机采样 mini-batch，并按式 (5.21) 更新主网络
12:    每隔固定步长同步目标网络参数  $\theta_q^- \leftarrow \theta_q$ 
13:  end if
14: end for

```

5.4.4 复杂度分析

对于单次在线决策，若候选边缘节点数量为 N_c ，预测模型前向推理复杂度为 $\mathcal{O}(P_f)$ ，Q 网络前向推理复杂度为 $\mathcal{O}(P_q)$ ，则单次决策复杂度近似为

$$\mathcal{O}(N_c P_f + P_q). \quad (5.23)$$

由于 N_c 通常远小于全网节点数，且 P_f 和 P_q 均来自轻量级 MLP/1D-CNN 结构，因此该复杂度满足节点侧实时部署需求。

训练阶段则需对大小为 B_q 的 mini-batch 执行前向与反向传播，复杂度约为 $\mathcal{O}(B_q P_q)$ ；容量为 $|\mathcal{B}|$ 的经验回放池空间复杂度为 $\mathcal{O}(|\mathcal{B}| d_s)$ ， d_s 为状态维度。这部分额外存储相对引入预测先验带来的性能收益是可控的。预测模型本身异步更新，节点侧只维护最近一次下发的副本，联邦训练的成本因此不会直接叠加到每次在线动作上。

作为对照，让中心控制器收集全网细粒度状态再统一决策的做法，通信开销更高，也难以满足天基网络的时延约束——链上摘要的确认延迟和候选节点可达性的轨道波动只会让信息年龄问题被进一步放大。FL-DQN 用“链上扩展摘要 + 本地观测 + 预测先验”的组合，在分布式条件下保留了较高的动作质量。

5.5 实验设计与结果分析

为验证 FL-DQN 任务卸载方法的有效性，本节围绕四个问题展开实验：第一，聚类联邦学习能否在 Non-IID 样本下提升并发开销预测精度；第二，引入预测先验后，DQN 是否能够降低平均时延和尾时延，并提高吞吐量与 SLA 完成率；第三，去除预测先验、并发惩罚、经验回放或奖励塑形后，各模块贡献如何变化；第四，在链上摘要滞后、任务负载升高和节点异构增强时，所提方法是否仍保持稳定。

受限于真实在轨天基边缘计算环境难以直接部署和复现实验，本文实验部分采用模型驱动的离散事件仿真方式进行验证。仿真参数依据前文建立的任务层时延模型、能耗模型和并发开销模型设定，并结合图像处理类任务与数值计算类任务构造不同并发强度下的资源竞争场景。实验结果主要用于比较不同策略在相同约束条件下的相对性能差异，而不代表某一具体星载平台的绝对实测性能。

5.5.1 实验设置

实验场景模拟由若干卫星终端 ST、候选卫星边缘节点 SEN、联盟链账本和联邦协调单元共同组成的天基分布式计算系统。终端侧任务按照离散事件方式持续到达，每个任务包含计算量、输入数据大小、时延约束、任务类型和优先级等属性；候选边缘节点具有不同的计算能力、队列长度、背景负载和并发任务数；链上公共摘要 $G(t)$ 以固定周期更新，用于提供候选节点的平均负载、负载方差和信誉评分；模型摘要 $M(t)$ 用于维护预测模型版本号、参数哈希和所属簇信息。为模拟天基网络中的状态滞后现象，实验设置可控的链上摘要延迟，并考察不同延迟条件下各策略的性能变化。

并发开销预测数据由两类代理任务构造：一类为图像处理任务，用于模拟遥感预处理、轻量识别和视觉感知类边缘负载；另一类为数值计算任务，用于模拟输入规模较小但计算强度较高的计算密集型负载。每条样本记录任务类型、输入规模、估计计算量、节点 CPU 状态、并发任务数、执行中任务剩余工作量、上下文切换强度以及实际完成时延，并根据前文定义的并发开销表达式构造监督标签。这样既能够覆盖数据搬移和计算争用同时存在的混合场景，也能够避免训练样本过度偏向单一任务类型。

对比方法包括以下几类：FL-DQN 表示本文提出的完整方法；DQN-only 表示不引入联邦预测先验，仅依靠即时状态训练 DQN 策略；FL-only 表示使用联邦预测结果辅助启发式卸载，但不进行强化学习策略优化；Centralized-DQN 表示在理想条件下能够获得全局实时状态的集中式 DQN，可视为性能上界参考；Heuristic 表示基于当前负载、链路质量和队列长度的启发式卸载策略。对于预测层实验，额外比较 Clustered FL、FedAvg、Centralized 和 Local-only 四类训练方式，以验证聚类式联邦学习在 Non-IID 数据分布下的优势。

评价指标分为预测层指标和决策层指标。预测层采用 MAE、RMSE 和预测-真实拟合关系衡量并发开销预测精度，同时通过置信校准结果分析模型输出不确定性的有效性。决策层采用平均任务时延、系统吞吐量、SLA 完成率、P99 尾时延、在线决策开销、跨轮次波动和 Jain 公平性指数等指标衡量卸载策略的综合表现。其中，平均任务时延反映整体服务效率，P99 尾时延反映极端拥塞条件下的稳定性，SLA 完成率反映任务时延约束满足能力，Jain 公平性指数用于衡量任务分配在不同候选节点之间的均衡程度。

5.5.2 预测性能分析

策略能否提前规避拥塞，取决于并发开销预测模块能否提供稳定的风险先验。本节先独立验证这一模块。图 5.4 从训练收敛过程、预测-真实散点密度、置信度校准和不同异构强度下的测试误差四个角度展示了它的综合性能。




图 5.4 并发开销预测模块的多维性能结果

从训练过程看，图 5.4 (a) 中各类训练方式的验证集 MAE 都随通信轮次增加而下降，说明模型确实能够从历史执行日志中学习并发开销与任务特征、节点状态和资源竞争之间的映射关系。Clustered FL 的下降速度明显快于 FedAvg 和 Local-only，训练后期也稳定在更低水平——节点负载模式和任务分布存在差异时，先按负载聚类、再做簇内聚合，可有效缓解统一全局模型在多峰分布下的偏移。

预测精度分布层面，图 5.4 (b) 的散点大多集中在对角线附近，预测与真实值总体一致；低并发区域分布紧凑、误差小，高并发区域散点略有扩散——这与高并发下资源争用的不确定性更强的事实一致，但模型对各负载区间下的风险差异仍保持较好的趋势跟踪能力。

图 5.4 (c) 反映了不确定性的校准意义：预测不确定性增加时经验误差总体上升，模型自我评估的“高不确定”样本确实更容易出现大误差。这一性质对后续 DQN 至关重要——除并发开销点估计外，DQN 还可以读取不确定性来判断预测是否可靠，避免在高风险、高不确定区域过度依赖单一预测值。

图 5.4 (d) 比较了不同异构强度下的测试 MAE。IID 场景下各方法差距有限；分布从轻度向重度 Non-IID 推进时，FedAvg 与 Local-only 的误差快速增长，Clustered FL 的上升幅度则明显更小。FedAvg 在节点负载模式差异较大时易受全局平均效应拖累，而聚类式联邦学习借助簇内聚合保留了局部负载特征，并发开销估计因而更稳定。

总的来看，聚类式联邦学习既提升了并发开销预测精度，也改善了异构环境下的收敛稳定性与置信表达，为 FL-DQN 把预测先验注入状态空间和奖励函数奠定了基础。

5.5.3 卸载性能对比

预测层能提供风险先验只是前提，仍需进一步回答的问题是：这些先验能否转化为任务级卸载性能的实际提升。本文在不同平均并发任务数下，对 FL-DQN 与多种基线方法在平均任务时延、系统吞吐量、SLA 完成率和 P99 尾时延四项指标上做了对比。其中，平均任务时延与系统吞吐量结果见图 5.5，SLA 完成率与 P99 尾时延结果见图 5.6。






图 5.5 不同并发强度下的卸载决策性能

表 5.6 不同并发强度下各卸载策略的端到端性能汇总

方法	低并发 $\bar{k} = 4$				中并发 $\bar{k} = 8$				高并发 $\bar{k} = 12$			
	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓	Avg. Delay ↓	Thr. ↑	SLA ↑	P99 ↓
Heuristic	160	53	93.9	253	240	40	82.3	399	361	28	65.6	612
DQN-only	145	56	95.5	228	222	44	86.9	368	334	32	72.3	548
FL-only	141	57	96.2	219	208	48	89.3	331	296	36	77.1	489
FL-DQN	134	59	97.3	211	188	52	93.1	284	256	43	84.7	401
Centralized-DQN	130	61	97.7	202	181	54	94.0	273	247	46	86.5	387



(c) SLA 完成率



(d) P99 尾时延

图 5.6 不同并发强度下的卸载决策稳定性

为给出典型并发区间下的定量对比，表 5.6 汇总了低并发、中并发和高并发条件下各方法的关键指标。其中， $\bar{k}$ 表示平均并发任务数，Avg. Delay 表示平均任务时延，Thr. 表示系统吞吐量，SLA 表示 SLA 完成率，P99 表示尾部时延。表中红色表示最优结果，蓝色表示次优结果。需要指出的是，Centralized-DQN 假设能够获得全局实时状态，因此主要作为理想性能上界；FL-DQN 则是在分布式、状态滞后和隐私受限条件下可部署的节点侧策略。

图 5.5 (a) 显示，平均并发任务数增加时所有方法的平均时延都在上升——并发越高，候选节点内部的 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队就越严重，端到端完成时间因此持续增加。但不同方法的时延增长斜率差距明显：Heuristic 和 DQN-only 在高并发区间上升较快，仅靠当前负载或即时观测状态难以准确判断候选节点的未来拥塞；FL-DQN 的曲线则平缓得多，因为预测先验让策略在卸载前就能

识别潜在拥塞节点，把任务被送往“表面空闲但实际竞争严重”目标的概率压低了。

表 5.6 给出了三个典型工作点的定量对比。Centralized-DQN 凭借理想化的全局实时状态在多数指标上取得最优，可作为性能上界参考；FL-DQN 在所有并发强度下均为次优，且明显优于 DQN-only、FL-only 和 Heuristic。高并发下尤其如此——FL-DQN 的平均时延为 256 ms，远低于 DQN-only 的 334 ms 和 Heuristic 的 361 ms；SLA 完成率 84.7% 也明显高于 DQN-only 和 Heuristic。可见在分布式可部署约束下，FL-DQN 能够较好地逼近集中式策略的上界。

吞吐量方面，图 5.5 (b) 显示，并发增加导致各方法的吞吐量都不同程度下降，原因是节点队列积压和任务执行时间延长压低了单位时间任务完成数。Centralized-DQN 整体最高，FL-DQN 紧随其后，且明显优于其余三类——这说明“链上扩展摘要 + 本地观测 + 联邦预测先验”的组合在不依赖全局实时透明信息的前提下已经接近集中式策略的处理能力。

SLA 完成率方面，图 5.6 (c) 显示，低并发区间各方法差距很小，资源较充足时大多数任务的时延约束本就容易满足；并发持续增大后，Heuristic 和 DQN-only 的完成率下降最快，反映其在高负载下更容易出现拥塞误判和任务超时。FL-DQN 的下降斜率最缓，预测先验提前规避高风险动作的效果在资源竞争加剧时尤为明显。

P99 尾时延方面，图 5.6 (d) 关注的是最差那部分任务的完成情况，对时延敏感型天基业务尤其关键。所有方法的尾时延都随并发任务数上升，但 FL-DQN 的增幅相对较小，在高并发区间显著低于 DQN-only 与 Heuristic——其改善的不仅是平均服务质量，也包括对极端拥塞样本的稳定性抑制。

把图 5.5、图 5.6 与表 5.6 放在一起看，FL-DQN 的优势在中高并发区间更突出。这与方法设计目标一致：轻载下候选节点之间的资源竞争尚不显著，预测模块带来的边际收益有限；负载逼近拥塞边界时，并发开销预测才能为 DQN 提供有效的前瞻信息，让策略在时延、吞吐、SLA 与尾时延上都表现出更好的稳定性。

5.5.4 消融分析

为厘清完整方法中各模块的具体作用，本文分别移除联邦预测模块、并发惩罚项、经验回放和奖励塑形项，与完整 FL-DQN 做对比。除被移除模块外，其余训练参数、任务到达过程、候选节点配置和评价指标都保持一致，以保证可比性。表 5.7 汇总了平均并发任务数 $\bar{k} = 16$ 处的关键指标，其中 Avg. Delay 与 SLA 取自图 5.7 (a) (b)

的高并发点，Online Cost 与 Std. Dev. 对应图 5.8 的双纵轴统计结果，红色为最优、蓝色为次优。

表 5.7 FL-DQN 各模块消融实验结果

方法变体	Avg. Delay ↓	SLA ↑	Online Cost ↓	Std. Dev. ↓	结果说明
FL-DQN	209	91.2	3.8	5.1	完整方法，综合性能最优
-FL 预测	284	80.1	3.1	9.6	缺少并发开销先验，退化最明显
-并发惩罚	243	84.7	3.6	8.1	拥塞规避约束减弱
-经验回放	256	86.4	2.4	11.2	开销最低但训练波动最大
-奖励塑形	238	87.9	3.4	7.3	收敛引导能力减弱

图 5.7 从平均时延、SLA 完成率两个角度展示了消融实验结果，图 5.8 则给出“在线决策开销-跨轮次波动”联合对比。




图 5.7 消融实验结果




图 5.8 在线决策开销与跨轮次波动联合对比

平均时延方面，图 5.7 (a) 显示，完整 FL-DQN 在所有并发水平下都最低；移除 FL 预测模块后时延显著上升，且并发越高、劣化越明显——预测模块正是性能优势的核心来源，缺少先验后 DQN 只能依靠当前观测状态和链上扩展摘要做反应式决策，高并发下更容易产生错误卸载。移除并发惩罚项时延也有上升，但幅度小于移除 FL 预测：并发惩罚负责强化拥塞规避偏好，预测模块决定了策略是否拥有风险前瞻能力，二者所处的位置不同。

SLA 完成率方面，图 5.7 (b) 显示，完整 FL-DQN 始终最高，并发增强时下降也最平缓。移除 FL 预测后完成率下降最明显，缺少并发开销估计直接影响任务能否在时延阈值内完成；移除并发惩罚同样把完成率压低，仅将预测值作为状态输入并不足以完全引导策略规避拥塞，还需在奖励中显式体现并发开销代价，让智能体在训练中形成对高风险动作的惩罚记忆。

在线开销与跨轮次波动方面，图 5.8 反映了“效率-稳定性”维度。完整 FL-DQN 的在线开销略高于移除 FL 预测或经验回放的简化版本——决策前需调用预测模型并完成 DQN 动作价值计算——但仍处于毫秒级，能够满足节点侧实时决策需求。与此同时，它的跨轮次标准差最低，多次独立运行下表现更稳定。移除经验回放后在线开销最低，代价却是跨轮次波动显著放大；移除 FL 预测后波动同样明显增大，缺乏稳定的风险先验会削弱策略一致性。完整方法在“决策效率-训练稳定性”之间取得了更优的综合折中。

综合三组结果，FL 预测模块决定了策略的风险前瞻能力，是降低高并发时延、维

持 SLA 完成率的关键；并发惩罚项强化了对拥塞节点的规避，让预测信息更直接地转化为优化目标；经验回放主要降低跨轮次波动；奖励塑形改善收敛方向和任务完成质量。FL-DQN 的性能提升不是单个模块的堆叠效果，而是预测先验、奖励约束和强化学习稳定机制相互协同的产物。

5.5.5 鲁棒性与敏感性分析

仅靠平均时延或完成率不足以判断方法是否可部署。天基网络链路窗口有限、链上摘要要有确认延迟，节点状态难免陈旧；可部署的卸载策略还需要具备可解释的动作选择行为，并在效率、能耗与节点均衡之间取得合理折中。下面从摘要陈旧性敏感性、动作选择偏好、效率-公平性折中三个角度展开分析，结果见图 5.9 与图 5.10。




图 5.9 鲁棒性与动作偏好结果




图 5.10 多目标折中结果

图 5.9 (a) 显示，摘要延迟增加时，所有方法的平均时延都在上升——摘要越陈旧，节点负载状态偏离真实运行状态的概率越高，错误卸载也随之增多。但 FL-DQN

的退化幅度明显小于其余方法。这是因为它并不完全依赖链上摘要：本地实时观测与联邦预测模型对状态陈旧性形成了一定补偿，链上摘要无法准确反映当前节点状态时，预测模块仍能基于历史负载模式与并发环境特征估计潜在风险。

图 5.9 (b) 的动作选择热力图通过策略收敛后测试集中的动作选择频次按风险区间归一化得到。负载风险较低时，策略偏好本地执行或风险较低的候选边缘节点；候选节点负载风险升高后，动作选择逐步向其他节点分散，智能体会根据风险变化动态调整卸载目标，而不是长期锁定某个高性能节点。FL-DQN 学到的不是“选当前负载最低的节点”这种简单规则，而是结合任务属性、链上扩展摘要和并发开销预测的自适应卸载行为。

图 5.10 展示了 EDP 与 Jain 公平性指数之间的折中关系，气泡大小表示任务完成率。EDP 越低，时延-能耗的综合效率越好；Jain 指数越高，任务在不同节点之间分配越均衡。Centralized-DQN 凭借理想全局状态在两项指标上均表现较好，但全局实时信息假设让它的实际部署难度也较高；FL-DQN 在 EDP 与公平性之间取得了较优折中，公平性虽略低于集中式上界，仍明显优于 DQN-only、FL-only 和 Heuristic，并保持较高的任务完成率。Heuristic 和 DQN-only 更容易把任务集中到少数表面负载较低的节点，公平性因而下降，能时积也增大。

放在一起看，FL-DQN 的优势不仅体现在平均性能上，也体现在对链上摘要滞后的适应能力、动作选择行为的合理性以及多目标折中能力上——这与天基分布式计算“信息不完全、状态存在滞后、节点负载动态变化”的部署现实更契合。

5.5.6 本节小结

围绕并发感知任务卸载方法的有效性，本节做了分层实验验证。聚类式联邦学习在不集中上传原始日志的前提下能够学到候选节点的并发开销变化规律，并在 Non-IID 环境下保持稳定的预测精度与收敛性；把预测值及其不确定性引入 DQN 后，节点侧策略在平均时延、吞吐量、SLA 完成率和 P99 尾时延等指标上都优于分布式基线方法，中高并发下尤为突出。鲁棒性分析显示 FL-DQN 在链上摘要陈旧时性能退化更平缓，动作选择也符合风险变化规律；消融实验进一步明确了各模块的不同贡献。

实验整体表明，本文所提的 FL-DQN 方法在隐私受限、状态滞后和负载异构的天基分布式计算环境中，能够把联邦学习得到的并发开销预测有效转化为节点侧实时卸载决策的收益，在时延、吞吐量、完成率、尾部稳定性和负载均衡之间取得更合理的

折中。

5.6 本章小结

本章围绕天基网络任务层实时卸载问题，提出了面向并发开销的“联邦预测 + DQN 决策”方法。与第4章面向较长时间尺度的系统层可信协同不同，本章进一步聚焦节点侧，以单任务到达瞬间的快速动作选择为核心，处理链上摘要滞后、隐私受限、负载动态变化和并发资源竞争等问题，将系统层形成的候选约束、信誉上下文和可信状态基础转化为任务层实时执行能力。

方法层面，本章先从任务层视角统一了时延、能耗与并发开销的代价表达，并给出了并发开销的形式化定义与可计算近似；为应对节点本地日志难以集中上传且样本高度异构的问题，本章采用分层聚类联邦学习框架实现预测模型的隐私友好训练；预测值及其不确定性被显式纳入 DQN 状态空间，并通过并发代价约束、不确定性惩罚和负载均衡惩罚作用于奖励反馈，使卸载策略具备对潜在并发开销的前瞻感知能力。在中等并发工作点 $\bar{k} = 8$ 下，FL-DQN 相比 DQN-only 的平均任务时延下降约 15.3%、P99 时延下降约 22.8%、吞吐量提升约 18.2%、SLA 完成率提高约 6.2 个百分点；高并发工作点 $\bar{k} = 12$ 下，优势继续扩大，链上摘要滞后条件下也保持着更平缓的退化趋势。

这些结果验证了三点判断：并发开销是影响天基任务级卸载质量的关键隐藏变量，不能被平均负载简单替代；聚类式联邦学习能够在不上传原始数据的前提下有效建模这一变量，为节点侧决策提供风险先验；将预测先验与强化学习决策深度耦合，可以显著增强策略在信息不完全与高并发场景下的鲁棒性。结合第3章的统一建模与可信状态刻画，以及第4章的系统层可信协同机制，本章在任务层给出了面向单任务到达瞬间的实时决策方法，使全文形成了从统一建模、系统层协同到任务层执行的跨层方法链，也为后续讨论跨层联合优化、多智能体协同决策或星地协同边缘智能等方向留出了延伸空间。

结论与展望

随着天地一体化信息网络、低轨卫星星座和在轨智能处理技术的发展,天基网络正在由传统的数据传输网络向集通信、计算、存储和智能处理于一体的分布式协同计算网络演进。在灾害应急通信、遥感快速处理、空间态势感知、区域目标识别和边远区域信息服务等典型场景中,天基网络不仅需要完成数据采集与远程传输,还需要在星地链路受限、星间拓扑高动态、节点资源异构和任务负载突发变化的条件下,实现任务接入、资源协调、计算处理与结果反馈的快速闭环。然而,传统星地集中处理模式容易受到星地链路时延、可见窗口和回传带宽限制,单星本地处理模式又受限于星载平台的算力、能量、功耗和存储资源,难以持续支撑高并发、高时敏和高自治要求的计算任务。因此,如何在高动态、资源受限和去中心化的天基网络环境中,实现可信、高效的多星协同计算卸载,成为提升天基网络智能服务能力的重要问题。

本文围绕高动态天基网络中的可信协同计算卸载问题,按照“统一建模—系统层协同—任务层卸载”的研究主线展开。首先,构建包含动态网络、异构资源、任务生命周期和区块链账本可信状态共享的统一建模框架,并将总体问题分解为系统层协同资源分配和任务层并发开销感知卸载两个子问题;随后,分别设计基于区块链与多智能体强化学习的系统层协同资源分配方法,以及基于聚类联邦学习与 DQN 的任务层实时卸载方法,从而形成由统一建模支撑、双层方法展开、执行反馈闭环更新的研究体系。全文主要研究工作总结如下。

(1) 构建了天基网络可信协同计算卸载统一建模框架。针对天基网络中节点异构、链路时变、任务随机到达和状态共享可信性不足等问题,本文建立了包含卫星终端、卫星边缘节点、地面控制中心和区块链账本的协同计算模型,分别刻画了网络拓扑、节点资源、任务属性、链路传输、本地计算、星间卸载、能耗开销和并发开销等关键要素。在此基础上,本文将区块链账本抽象为可信状态共享与反馈机制,通过链上摘要与链下实体数据分离的方式维护节点状态摘要、任务生命周期记录、节点信誉和模型版本凭据。进一步地,本文建立了统一协同计算卸载优化目标,并将其分解为系统层协同资源分配子问题和任务层并发开销感知卸载子问题,为后续章节提供了统一符号体系、状态接口和问题边界。

(2) 提出了基于区块链与多智能体强化学习的系统层协同资源分配方法。针对去

中心化天基计算网络中节点能力异构、任务到达非平稳、链路状态动态变化以及节点自利行为导致的资源竞争和负载失衡问题, 本文将系统层协同资源分配问题建模为多智能体马尔可夫博弈, 并提出区块链增强的集中训练—分散执行多智能体强化学习框架。该方法利用联盟链作为可信公共信息板, 维护节点负载、链路状态、信誉评分和历史行为记录等系统级公共摘要, 在不依赖长期稳定中心控制器的条件下, 为各卫星节点提供可验证、可追溯的协同上下文。同时, 本文设计了融合任务完成质量、系统公平性和信誉激励的混合奖励函数, 引导自利节点在长期交互中形成更接近系统最优的协同策略。仿真实验表明, 该方法能够提升任务完成率和系统吞吐量, 改善负载均衡效果, 并增强系统对自利行为和不完全信息环境的适应能力。

(3) 提出了基于聚类联邦学习与 DQN 的并发感知任务层计算卸载方法。在系统层实现可信协同的基础上, 本文进一步关注任务到达瞬间的节点侧实时卸载决策问题。针对多任务并发执行过程中 CPU 时间片、缓存、内存带宽和 I/O 队列竞争所导致的隐性并发开销, 本文建立了任务级并发开销建模方法, 将新任务自身计算时延和存量任务剩余时延增加统一纳入任务层代价模型。考虑到天基网络中任务执行日志不适合集中上传、节点数据分布具有明显 Non-IID 特征、区块链账本维护的可信公共摘要存在时滞等问题, 本文提出了“聚类式联邦学习预测 + DQN 卸载决策”的闭环机制。该方法通过聚类式联邦学习在不共享原始任务数据的前提下训练并发开销预测模型, 并通过区块链账本维护并发开销预测模型版本和可信摘要; 随后将预测结果、本地观测状态和区块链账本维护的可信公共摘要共同输入深度 Q 网络, 实现低开销、实时化且具备并发开销前瞻能力的任务卸载决策。实验结果表明, 该方法能够有效降低高并发场景下的任务时延和能耗, 提高任务完成率与系统稳定性。

综上, 本文面向天基网络中的可信协同计算卸载需求, 形成了由统一建模、系统层协同资源分配和任务层并发开销感知卸载构成的方法体系。研究表明, 区块链账本能够为去中心化天基网络提供可信状态共享、任务生命周期记录、信誉维护和并发开销预测模型版本管理能力; 多智能体强化学习能够有效支撑系统层多节点协同资源分配; 聚类式联邦学习与 DQN 的结合能够在隐私受限、状态滞后和负载异构条件下提升任务层卸载决策的实时性与准确性。相关研究可为未来构建高效、智能、可信的天基边缘计算网络提供理论依据和方法支撑。

在本文研究基础上, 仍有以下方向值得进一步深入探索。

(1) 更真实轨道与链路环境下的模型验证。本文主要通过仿真方式验证所提方法,

后续可结合真实星座轨道数据、星间链路测量数据和任务负载数据，对模型进行进一步校准。同时，可引入更精细的轨道动力学模型、星间链路中断模型、太阳能充放电模型、热控约束模型和多业务混合到达模型，使统一建模更加贴近真实星座运行环境。

（2）面向大规模星座的轻量化协同优化。随着节点规模扩大，多智能体训练复杂度、区块链账本维护的可信公共摘要维护开销和候选节点筛选成本将进一步增加。后续可研究图神经网络、参数共享、分层策略、模型压缩和边缘推理加速等方式提升可扩展性，使系统能够在更大规模星座中保持较低通信开销和较高协同效率。

（3）区块链可信机制与实时卸载决策的深度融合。本文将区块链主要用于状态摘要、任务生命周期记录、信誉维护和模型版本管理，后续可进一步研究更轻量的共识机制、跨链状态压缩方法、面向时敏任务的可信状态快速确认机制以及链上事件与强化学习奖励之间的自适应耦合方法，从而在可信性和实时性之间取得更优平衡。

参考文献

- [1] Kodheli O, Lagunas E, Maturo N, et al. Satellite Communications in the New Space Era: A Survey and Future Challenges[J]. IEEE Communications Surveys & Tutorials, 2021, 23(1): 70-109.
- [2] Wang F, Zhang S, Yang H, et al. Non-Terrestrial Networking for 6G: Evolution, Opportunities, and Future Directions[J]. IEEE Network, 2024.
- [3] Hu X, Liu S, Chen R, et al. A Survey of Satellite Edge Computing: Architecture, Enabling Techniques, and Applications[J]. IEEE Network, 2023, 37(6): 158-165.
- [4] Guo Z, et al. Computation Offloading and Resource Allocation for E2E Tasks in Satellite Edge Computing Networks[J]. Space: Science & Technology, 2024, 4: 0144.
- [5] Yin Z, Wu C, Guo C, et al. A Comprehensive Survey of Orbital Edge Computing: Systems, Applications, and Algorithms[J]. Chinese Journal of Aeronautics, 2025, 38(7): 103316.
- [6] Gao Y, Ji Z, Zhao K, et al. Game-Based Computation Offloading and Power Allocation for LEO Constellation Networks in Distributed and Dynamic Environment[J]. IEEE Internet of Things Journal, 2024, 11(4): 7040-7058.
- [7] Jia M, Wu J, Wang X, et al. Federated Deep Reinforcement Learning Based Computation Offloading in a Low Earth Orbit Satellite Edge Computing System[J]. Frontiers of Information Technology & Electronic Engineering, 2025, 26(5): 805-815.
- [8] Li H, Yu J, Cao L, et al. Multi-agent Reinforcement Learning Based Computation Offloading and Resource Allocation for LEO Satellite Edge Computing Networks[J]. Computer Communications, 2024, 222: 268-276.
- [9] Shuai Q, Wang X, Hao W, et al. Q-Learning-Based Computation Offloading for Satellite Edge Computing Networks[J]. IEEE Wireless Communications Letters, 2024, 13(5): 1328-1332.
- [10] Tang Y, Chen N, Zhang L, et al. Task Offloading and Resource Allocation for Satellite-Terrestrial Integrated Networks[J]. IEEE Transactions on Communications, 2024, 72(12): 7840-7855.
- [11] Wang J, Xiu L, et al. Task-Oriented Multiobjective Computation Offloading in LEO Mega-Constellation Edge Computing Network[J]. International Journal of Satellite Communications and Networking, 2025, 43(5): 392-409.
- [12] Zhong L, Li Y, Ge M F, et al. Joint Task Offloading and Resource Allocation for LEO Satellite-Based Mobile Edge Computing Systems With Heterogeneous Task Demands[J]. IEEE Transactions on Vehicular Technology, 2025, 74(7): 11337-11352.
- [13] Xiu Q, Liu J, Liu X, et al. Computation Offloading and Resource Allocation in Satellite Edge Computing Networks: A Multi-Agent Reinforcement Learning Approach[J]. Computer Networks, 2025,

- 272: 111680.
- [14] Rao Z, Zhu Z, Yao Y, et al. Computation-Offloading Optimization for Satellite Edge Computing via Diffusion and Lyapunov-Based Deep Reinforcement Learning[J]. IEEE Internet of Things Journal, 2025, 12(18): 37747-37762.
 - [15] Wu J, Jia M, Guo Q, et al. Multi-Agent Deep Reinforcement Learning-Based Offloading Computation in LEO Satellite Networks[C]. Proceedings of IEEE VTC 2025-Spring. 2025: 1-6.
 - [16] Adu E, Lee Y, Moon J, et al. Decentralized Computation Offloading Strategy via Multi-Agent Deep Reinforcement Learning for Multi-Access Edge Computing Systems[J]. Sensors, 2026, 26(3): 914.
 - [17] Elmahallawy M, Akbarfam A J. Decentralized Trust for Space AI: Blockchain-Based Federated Learning Across Multi-Vendor LEO Satellite Networks[J]. arXiv preprint arXiv:2512.08882, 2025.
 - [18] Zhai Z, Wu Q, Yu S, et al. FedLEO: An Offloading-Assisted Decentralized Federated Learning Framework for Low Earth Orbit Satellite Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(5): 5260-5279.
 - [19] Du R, Chen T, Tian J, et al. StarCross: Redactable Blockchain-Based Secure and Lightweight Data Sharing Framework for Satellite-Based IoT[J]. Computer Networks, 2024, 253: 110718.
 - [20] Gong Y, Yao H, Xiong Z, et al. Blockchain-Aided Digital Twin Offloading Mechanism in Space-Air-Ground Networks[J]. IEEE Transactions on Mobile Computing, 2025, 24(1): 183-197.
 - [21] Liu X, et al. NetTopoBFT: Network Topology-Aware Byzantine Fault Tolerance for High-Coverage Consortium Blockchains[J]. Sensors, 2025.
 - [22] Tang M, Wong V W S. Deep Reinforcement Learning for Task Offloading in Mobile Edge Computing Systems[J]. IEEE Transactions on Mobile Computing, 2022, 21(6): 1985-1997.
 - [23] Qin P, Fu X, Wang X. Multi-Agent Reinforcement Learning-Based Computation Offloading in Integrated Satellite-Terrestrial Networks[J]. IEEE Transactions on Sustainable Computing, 2023, 8(3): 706-718.
 - [24] Bonawitz K, Eichner H, Grieskamp W, et al. Towards Federated Learning at Scale: System Design [J]. Proceedings of Machine Learning and Systems, 2019, 1: 374-388.
 - [25] Matthiesen B, Razmi N, Leyva-Mayorga I, et al. Federated Learning in Satellite Constellations[J]. IEEE Network, 2024, 38(2): 232-239.
 - [26] Wu C, Han S, Chen Q, et al. Enhancing LEO Mega-Constellations with Inter-Satellite Links: Vision and Challenges[J]. IEEE Wireless Communications, 2024.
 - [27] Sun Y, et al. Mobility-Aware Computation Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024.
 - [28] Lim D, Lee W, Kim W T, et al. DRL-OS: A Deep Reinforcement Learning-Based Offloading Scheduler in Mobile Edge Computing[J]. Sensors, 2022, 22(23): 9212.

- [29] Tomasin S, et al. Blockchain for Federated Learning in the Internet of Things: Trustworthy Adaptation, Standards, and the Road Ahead[J]. IEEE Communications Standards Magazine, 2025.
- [30] Odeh A, Taleb A A. Federated Learning and Blockchain Framework for Scalable and Secure IoT Access Control[J]. Computers, Materials & Continua, 2025, 84(1): 447-461.
- [31] Zhang Y, et al. A Sharded Blockchain-Based Secure Federated Learning Framework for LEO Satellite Networks[J]. arXiv preprint arXiv:2411.06137, 2024.
- [32] Li X, Huang K, Yang W, et al. On the Convergence of FedAvg on Non-IID Data[J]. Proceedings of the International Conference on Learning Representations (ICLR), 2020.
- [33] Zou L, Park Y M, Thwal C M, et al. Towards Satellite Non-IID Imagery: A Spectral Clustering-Assisted Federated Learning Approach[J]. arXiv preprint arXiv:2410.13602, 2024.
- [34] Li D, Xie W, Li Y, et al. FedFusion: Manifold Driven Federated Learning for Multi-Satellite and Multi-Modality Fusion[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024.
- [35] Amato C. An Introduction to Centralized Training for Decentralized Execution in Cooperative Multi-Agent Reinforcement Learning[J]. arXiv preprint arXiv:2409.03052, 2024.
- [36] Liu L, Jiang W, Wang Y. Tacit Learning with Adaptive Information Selection for Cooperative Multi-Agent Reinforcement Learning[C]. Proceedings of the International Conference on Autonomous Agents and Multiagent Systems (AAMAS). 2025: 1-9.
- [37] Yu C, Velu A, Vinitsky E, et al. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games[C]. Advances in Neural Information Processing Systems: vol. 35. 2022: 24611-24624.
- [38] Li T, Shi D, Jin S, et al. Multi-Agent Hierarchical Graph Attention Actor-Critic Reinforcement Learning[J]. Entropy, 2024, 27(1): 4.
- [39] Jain R K, Chiu D W, Hawe W R. A Quantitative Measure of Fairness and Discrimination for Resource Allocation in Shared Computer Systems[R]. TR-301. DEC Research Report, 1984.
- [40] Glicksberg I L. A Further Generalization of the Kakutani Fixed Point Theorem, with Application to Nash Equilibrium Points[J]. Proceedings of the American Mathematical Society, 1952, 3(1): 170-174.
- [41] Androulaki E, Barger A, Bortnikov V, et al. Hyperledger Fabric: A Distributed Operating System for Permissioned Blockchains[C]. Proceedings of the Thirteenth EuroSys Conference. 2018: 1-15.
- [42] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.
- [43] Yu C, Velu A, Vinitsky E, et al. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games[J]. Advances in Neural Information Processing Systems, 2022, 35: 24611-24624.

附录 A

基于区块链的试验数据存证原型软件测试补充材料

本附录汇总基于区块链的试验数据存证原型软件测试材料，用于补充说明第三章中区块链可信状态共享模型的工程实现基础和测试指标分析。该原型系统面向分布式外场试验与多主体协同场景，采用主链与多子链结合的联盟链架构，支持数据导入、上链存证、查询检索、完整性校验、历史追溯、数据导出、权限控制和智能合约管理等功能。

A.1 功能测试用例汇总

表A.1汇总原型系统功能测试用例。测试内容覆盖分层多域联盟链构建、节点受控准入准出、链生命周期管理、链码部署、数据存证、查询、校验、溯源和导出等关键功能，能够与第三章的链上链下数据划分、任务生命周期存证和节点信誉审计机制形成对应。

A.2 性能指标测试汇总

表A.2汇总原型系统性能指标测试结果。测试项目从吞吐能力、响应时延、查询规模、用户规模、多链扩展和多类型数据兼容性等方面，为本文平台的工程可部署性提供支撑。

A.3 接口与工程实现基础

原型系统采用分层、松耦合的软件架构。前端服务层基于 Vue 3、Element Plus 和 ECharts 构建可视化界面；接口服务层采用 RESTful API、JWT 鉴权与 Swagger UI 实现接口访问、身份认证和文档化管理；后台服务层结合 Python Django 与 Golang Gin 处理业务逻辑；区块链网络层基于 Hyperledger Fabric 联盟链框架构建主链与子链，并采用 Raft 类共识机制；数据持久层综合使用 IPFS、PostgreSQL 与 Neo4j，分别支撑文件对象存储、结构化数据存储和关联关系管理。

接口测试内容覆盖终端管理套件接口、自动化测试系统接口和数字化联合仿真系

表 A.1 原型系统功能测试用例汇总

测试编号	测试项目	测试内容	结论
BC-01	分层多域联盟链构建	验证主链与子链创建、节点加入联盟、区块链浏览器中主链和子链节点在线状态。	通过
BC-02	用户访问控制与权限管理	验证系统管理员、主链用户、子链用户等角色设置，身份认证、会话有效期管理、操作日志审计和权限控制。	通过
BC-03	区块链生命周期管理	验证区块链创建、新增区块、数据上链、链码销毁和已销毁链码查看等管理操作。	通过
BC-04	智能合约部署与冲突检测	验证 Raft 类共识配置、链码部署状态、主链与子链节点在线状态，以及基于智能合约的数据冲突检测能力。	通过
BC-05	数据导入与存证	验证试验任务规划数据、试验日志等数据的手动导入和上链存证能力，支持文档类、表格类和图片类数据。	通过
BC-06	数据查询与检索	验证按任务、终端、时间范围、操作类型、试验状态和上链状态等条件进行数据查询与检索。	通过
BC-07	数据完整性校验与溯源	验证已上链数据的哈希完整性校验、篡改检测、历史修改记录查看和操作追溯能力。	通过
BC-08	数据导出功能	验证对已上链数据下载完整数据包和导出文件的能力。	通过

表 A.2 原型系统性能指标测试汇总

测试编号	测试项目	指标要求与测试说明	结论
BC-09	上链吞吐量测试	带宽充足条件下，试验数据上链吞吐量不低于 2000 TPS；测试使用 Tape 工具对联盟链交易处理能力进行压测。	通过
BC-10	数据存证响应时间	数据大小不超过 1 MB、网络延时不超过 100 ms 条件下，数据存证请求响应时间小于 1 s。	通过
BC-11	大规模数据查询	支持 10 万条以上数据存储与查询，查询时间小于 10 s。	通过
BC-12	用户规模支撑能力	支持不少于 150 个用户管理，能够显示总用户数、活跃用户数等管理信息。	通过
BC-13	区块链数量创建能力	支持不少于 4 条区块链创建与管理，可在节点管理页面查看多条链及对应链码信息。	通过
BC-14	多类型数据上链能力	支持不少于 3 类试验活动数据上链，覆盖文档类、表格类和图片类等数据。	通过

统接口。系统可处理终端状态、日志、任务规划信息等结构化或半结构化数据，并通过统一接口完成数据导入、上链存证、查询、校验和导出。该接口能力与本文平台中任务发布、状态摘要维护、执行结果回流和审计查询等模块相对应。

A.4 原型系统运行界面与测试截图

图A.1展示了原型系统采用的分层联盟链架构。主链承担任务调度、全局摘要、跨链锚定和关键治理职责；子链承担业务域内数据存证、局部状态维护和快速查询职责；链下设备层保存原始数据、模型参数和详细日志等大规模对象。该结构能够避免单链承载全部交易导致的吞吐下降，并通过子链水平扩展实现任务与数据解耦。

图A.2至图A.5给出了原型系统运行界面与测试过程截图，覆盖系统管理、链上数据存证、查询检索、校验溯源和性能测试等典型环节。这些截图用于说明平台具备可视化管理、状态观测、测试验证和审计追溯能力。




图 A.1 分层联盟链架构设计图




图 A.2 原型系统运行与管理界面截图（二）




图 A.3 原型系统运行与管理界面截图（三）




图 A.4 原型系统运行与管理界面截图（四）



图 A.5 原型系统运行单个节点服务器

攻读学位期间发表论文与研究成果清单

一、期刊论文

- [1] . Manage On-Road Services With Chains: A Distributed Vehicular Task Offloading Approach Based on Blockchain Technology[J]. IEEE Transactions on Vehicular Technology, 2026, 75(4): 6689-6704, (SCI Q1, 导师第一作者, 学生第二作者).

二、申请专利

- [1] . 基于联邦学习的车辆任务卸载系统与方法: ZL 2025 1 0074060.6[P]. 发明专利. (已授权, 导师第一作者, 学生第二作者)
- [2] . 一种基于 DQN 的车辆任务卸载系统与方法: 202510074061.0[P]. 发明专利. (已申请, 导师第一作者, 学生第二作者)

三、参与的科研项目

- [1] 基层社区治理一感多识监测预警技术装备研究与应用示范. 国家重点研发计划项目. 2024.12–2027.11
- [2] 天基网络分布式试验智能管控与数据分析技术研究. 中国卫星网络应用研究院企业横向合作项目. 2024.4–2025.11