

基于区块链的卫星终端试验任务数据管理与计算卸载技 术研究

姓名： 毛心璐

学号： 3220231823

学院： 网络空间安全学院

2022 年 6 月

④

基于区块链的卫星终端试验任务数据管理与计算卸载技术研究 毛心璐 北京理工大学

中图分类号：TQ028.1

UDC 分类号：540

基于区块链的卫星终端试验任务数据管理与计算卸载技
术研究

作 者 姓 名	毛心璐
学 院 名 称	网络空间安全学院
指 导 教 师	朱超
行业合作导师	朱超
答辩委员会主席	张涛
申 请 类 别	工学硕士
学 位 领 域	网络与信息安全
学位授予单位	北京理工大学
论文答辩日期	2026 年 6 月

**Data Management and Computing Offloading
Technology Scheme for Satellite Terminal Test Task
Based on Blockchain**

Candidate Name:	<u>Xinlu Mao</u>
School or Department:	<u>School of Network Space Security</u>
Faculty Mentor:	<u>Prof. Zhu Chao</u>
Industry Collaboration Mentor:	<u>Prof. Zhu Chao</u>
Chair, Thesis Committee:	<u>Prof. Zhang Tao</u>
Degree Applied:	<u>Master of Engineering</u>
Major:	<u>Network and Information Security</u>
Degree by:	<u>Beijing Institute of Technology</u>
The Date of Defence:	<u>June, 2026</u>

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的科研成果。文中所撰写内容符合以下学术规范（请勾选）：

☒ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☒ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☒ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☒ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☒ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签 名：

日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的，复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名：

日 期：

导师签名：

日 期：

摘要

近年来,随着天地一体化信息网络与“新基建”战略的深入推进,天基网络正经历从单一通信传输向边缘智能计算的跨越式转变。卫星终端作为天基数据的感知与处理前哨,在偏远地区监测、应急响应及各类在轨试验中发挥着不可替代的作用。然而,面对日益复杂的计算密集型试验任务,受限于星载设备的体积、功耗及抗辐射设计,卫星终端的计算资源极其有限。当海量任务并发产生时,传统的计算卸载方案往往忽视了资源竞争带来的“并发开销”,且依赖地面集中式决策导致的高时延与信令开销,已难以满足天基试验任务的实时性与可靠性需求。

针对上述挑战,本文提出了一种融合区块链、联邦学习(Federated Learning, FL)与深度强化学习(DRL)的卫星终端智能管控与计算卸载架构。该架构旨在利用联邦学习打破数据孤岛,在保护隐私的前提下实现协作式环境感知;利用区块链构建可信协作底座,解决分布式环境下的信任与状态同步问题。本文的主要研究内容与创新点如下:

(1) 基于区块链的卫星试验任务可信存证与协同管理:针对多源异构试验数据的安全与一致性问题,设计了基于联盟链的分层式数据管理架构。利用智能合约实现试验任务全生命周期的自动化记录与防篡改存证,并构建非实时全局状态共享机制,为分布式协同计算提供可信的数据底座,确保了任务执行过程的可追溯性与多方协作的安全性。

(2) 基于联邦学习的并发开销预测与卸载决策优化:针对多任务并发场景下的资源竞争难题,提出了一种基于 FL 与深度 Q 网络(DQN)的分布式卸载策略。通过在卫星终端间开展联邦协同训练,构建高精度的任务并发开销预测模型,使终端能够在不共享原始任务数据的前提下感知全局负载压力,从而实现任务卸载决策的智能化与隐私保护,有效解决了资源竞争导致的时延剧增问题。

(3) 基于深度强化学习的动态资源调度与节点优选:针对天基网络拓扑高动态变化及星间链路不稳定的特性,设计了基于改进 PPO/DQN 算法的动态资源调度模型。该模型将时延、能耗、负载均衡度纳入多目标优化函数,通过智能体与环境的持续交互,实现复杂动态约束下的计算资源自适应分配与最优卸载节点选择。

(4) 天基分布式试验智能管控平台的设计与验证:基于上述理论成果,设计并研制了包含卫星终端模拟、区块链网络、智能调度引擎及可视化监控的一体化演示验证

平台。在典型的卫星试验任务场景下进行了系统级测试，实验结果表明，本文提出的方案在降低平均任务时延、提升系统吞吐量及保障数据隐私方面均优于传统基准算法，验证了所提架构的有效性与优越性。

本研究探索了区块链与人工智能技术在天基网络中的深度融合应用，有效提升了受限资源下卫星终端的任务处理效能与数据安全水平，为未来构建高效、智能、可信的天基边缘计算网络提供了重要的理论依据与技术支撑。

关键词：区块链；卫星网络；强化学习；计算卸载；联邦学习

Abstract

In recent years, with the in-depth advancement of space-ground integrated information networks and "New Infrastructure" strategies, space-based networks are undergoing a leapfrog transition from simple communication transmission to edge intelligent computing. As the forward outpost for space-based data perception and processing, satellite terminals play an irreplaceable role in remote area monitoring, emergency response, and various on-orbit experiments. However, faced with increasingly complex computation-intensive test tasks, satellite terminals are severely constrained by the size, weight, and power (SWaP) limitations of onboard equipment. When massive tasks are generated concurrently, traditional computation offloading schemes often overlook the "concurrency overhead" caused by resource competition. Furthermore, reliance on ground-based centralized decision-making leads to high latency and signaling overhead, making it difficult to meet the real-time and reliability requirements of space-based test tasks.

To address these challenges, this thesis proposes an intelligent management and computation offloading architecture for satellite terminals, fusing Blockchain, Federated Learning (FL), and Deep Reinforcement Learning (DRL). This architecture aims to utilize FL to break data silos and achieve collaborative environmental perception while preserving privacy; simultaneously, it leverages blockchain to build a trusted collaboration foundation, resolving trust and state synchronization issues in distributed environments. The main research contents and innovations are as follows:

(1) Trusted Storage and Collaborative Management of Satellite Test Tasks Based on Blockchain: Addressing the security and consistency issues of multi-source heterogeneous test data, a hierarchical data management architecture based on consortium blockchain is designed. Smart contracts are utilized to realize automated recording and tamper-proof storage of the entire lifecycle of test tasks. Additionally, a non-real-time global state sharing mechanism is constructed to provide a trusted data foundation for distributed collaborative computing, ensuring the traceability of the execution process and the security of multi-party collaboration.

(2) Concurrency Overhead Prediction and Offloading Decision Optimization Based on Federated Learning: Targeting the resource competition problem in multi-task concurrency

scenarios, a distributed offloading strategy based on FL and Deep Q-Network (DQN) is proposed. By conducting federated collaborative training among satellite terminals, a high-precision prediction model for task concurrency overhead is constructed. This enables terminals to perceive global load pressure without sharing raw task data, thereby achieving intelligent and privacy-preserving offloading decisions and effectively solving the latency surge caused by resource competition.

(3) Dynamic Resource Scheduling and Node Selection Based on Deep Reinforcement Learning: Addressing the highly dynamic topology of space-based networks and the instability of inter-satellite links, a dynamic resource scheduling model based on improved PPO/DQN algorithms is designed. This model incorporates latency, energy consumption, and load balance into a multi-objective optimization function. Through continuous interaction between the agent and the environment, adaptive allocation of computing resources and optimal offloading node selection under complex dynamic constraints are achieved.

(4) Design and Verification of Space-based Distributed Test Intelligent Management Platform: Based on the above theoretical results, an integrated demonstration and verification platform containing satellite terminal simulation, blockchain network, intelligent scheduling engine, and visual monitoring is designed and developed. System-level tests under typical satellite test task scenarios demonstrate that the proposed scheme outperforms traditional benchmark algorithms in reducing average task latency, improving system throughput, and guaranteeing data privacy, verifying the effectiveness and superiority of the proposed architecture.

This research explores the deep integration and application of blockchain and artificial intelligence technologies in space-based networks, effectively improving the task processing efficiency and data security level of satellite terminals under resource-constrained conditions, providing important theoretical basis and technical support for building efficient, intelligent, and trusted space-based edge computing networks in the future.

Key Words: Blockchain; Satellite Network; Reinforcement Learning; Computing Offloading; Federated Learning

目录

第 1 章	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状与发展趋势	4
1.2.1	天基网络与卫星边缘计算研究现状	4
1.2.2	动态环境下智能调度与多智能体协同研究现状	5
1.2.3	区块链协同与隐私保护学习研究现状	8
1.2.4	现有研究存在的主要问题与挑战	10
1.3	本文主要研究内容与论文结构	11
第 2 章	天基网络计算卸载的技术基础与系统建模	13
2.1	天基网络协同计算场景与体系结构	13
2.1.1	天基网络协同计算场景分析	13
2.1.2	节点类型与功能划分	14
2.1.3	链路特性与资源受限特征	15
2.2	计算卸载与智能管控相关技术基础	16
2.2.1	计算卸载基本模式与性能指标	16
2.2.2	轨道边缘计算与星座协同处理基础	17
2.2.3	可信状态同步与分布式协同基础	18
2.2.4	多智能体强化学习的系统层协同决策基础	19
2.2.5	联邦学习与深度强化学习的任务层决策基础	20
2.3	系统建模与双层问题描述	21
2.3.1	系统模型	21
2.3.2	任务模型与代价建模	22
2.3.3	双层智能管控问题形式化描述	24
2.4	本章小结	26
第 3 章	基于区块链与多智能体强化学习的天基计算网络协同资源分配方法	27
3.1	引言	27

3.2	系统框架概述	31
3.2.1	系统组成与角色划分	31
3.2.2	联盟链公共信息板与协同流程	32
3.2.3	建模目标与协同难点	33
3.3	基于多智能体马尔可夫博弈的协同资源分配模型	34
3.3.1	建模动机与博弈形式化	34
3.3.2	状态、动作与奖励机制设计	35
3.3.3	约束条件与性质分析	38
3.4	区块链增强的多智能体协同资源分配算法设计	39
3.4.1	算法总体框架	40
3.4.2	参数化策略与更新机制	41
3.4.3	区块链共享与信誉反馈机制	42
3.4.4	训练与执行算法流程	44
3.5	实验设计与结果分析	45
3.5.1	实验设置、对比基线与评价指标	45
3.5.2	收敛过程与主要性能分析	46
3.5.3	规模扩展、异构适应与消融分析	48
3.5.4	对抗鲁棒性与结果讨论	49
3.6	本章小结	50
第 4 章	基于联邦学习与深度强化学习的并发感知任务层计算卸载方法	52
4.1	引言	53
4.2	系统框架与任务层卸载问题建模	57
4.2.1	系统组成、工作流程与综合代价模型	57
4.2.2	并发开销建模	59
4.2.3	状态表征构造	61
4.2.4	任务层卸载问题的马尔可夫决策过程建模	62
4.3	基于联邦学习的并发开销预测方法	62
4.3.1	预测目标与样本构造	63

4.3.2	预测模型结构设计	63
4.3.3	分层聚类联邦架构与训练流程	64
4.3.4	可信维护与复杂度分析	67
4.4	FL-DQN 卸载决策算法设计	67
4.4.1	状态、动作与奖励函数设计	67
4.4.2	Q 网络结构与训练策略	69
4.4.3	在线决策流程与闭环机制	69
4.4.4	算法复杂度与可实现性分析	72
4.5	实验设计与结果分析	72
4.5.1	实验场景、对比基线与评价指标	72
4.5.2	预测模块结果分析	75
4.5.3	端到端性能与鲁棒性分析	76
4.5.4	消融实验与结果讨论	79
4.6	本章小结	80
结论		82
参考文献		83
附录 A	仿真参数与环境配置	87
附录 B	关键模型推导与补充说明	88
附录 C	附录内容说明	89
C.1	附录内容组织说明	89
C.1.1	后续补充建议	89
攻读学位期间发表论文与研究成果清单		90
致谢		91
作者简介		92

插图

图 1.1	天基网络协同计算卸载应用场景	3
图 1.2	2024—2026 年相关研究演进与本文定位	8
图 1.3	本论文研究思路及文章结构	12
图 3.1	天基协同资源分配中局部自利与全局协同差异示意	30
图 3.2	第三章协同资源分配框架的层次结构与信息流	32
图 3.3	基于联盟链公共信息板的任务—状态—信誉闭环协同流程	33
图 3.4	从系统优化问题到多智能体马尔可夫博弈的建模推导路径	35
图 3.5	BC-CTDE-MAPPO 总体流程图	41
图 3.6	分层联盟链与公共信息板职责示意	43
图 3.7	信誉驱动的状态—动作—审计—反馈闭环	44
图 3.8	收敛稳定性对比	47
图 3.9	主要性能指标对比	47
图 3.10	不同网络规模、任务负载与异构程度下的性能对比	48
图 3.11	消融实验与参数敏感性分析结果	49
图 3.12	自私行为与欺骗行为场景下的鲁棒性对比	50
图 4.1	第四章在全文中的功能定位	55
图 4.2	并发开销的直观示意	60
图 4.3	并发开销预测模型结构	64
图 4.4	分层聚类联邦学习架构	65
图 4.5	FL-DQN 总体框架与在线闭环机制	70
图 4.6	并发开销预测模块的精度、收敛性与异构鲁棒性	76
图 4.7	不同负载强度下各策略的服务质量与尾部性能对比	77
图 4.8	卸载策略的鲁棒性、动作偏好与效率—公平折中关系	78
图 4.9	消融实验：预测先验、奖励约束与训练稳定性的边际贡献	79

表格

表 1.1 典型天基网络计算模式及其技术特点 2

表 1.2 2024—2026 年天基计算卸载与智能调度代表研究 6

表 1.3 可信协同与隐私保护相关代表研究 9

表 3.1 链上公共摘要分量说明 36

表 3.2 奖励权重与作用说明 38

表 3.3 分层联盟链职责划分 43

表 3.4 实验设置与评价指标概要 46

表 4.1 集中式学习在天基网络中的主要局限 55

表 4.2 任务级卸载框架中的角色划分 57

表 4.3 分层聚类联邦学习架构中的角色划分 65

表 4.4 节点侧决策的复合状态空间设计 68

表 4.5 FL-DQN 在线卸载决策流程 71

表 4.6 预测层与决策层实验环境配置 74

表 4.7 不同训练方式下并发开销预测精度对比 75

表 4.8 中等并发工作点下各方法综合性能对比 78

表 4.9 消融实验的详细结果 80

主要符号对照表

ST	卫星终端 (Satellite Terminal)
SEN	卫星边缘节点 (Satellite Edge Node)
FL	联邦学习 (Federated Learning)
DQN	深度 Q 网络 (Deep Q-Network)
MDP	马尔可夫决策过程 (Markov Decision Process)
T_i	第 i 个任务
C_i	任务 T_i 的计算量
S_i	任务 T_i 的输入数据规模
D_i	任务 T_i 的时延约束 (截止期)
τ_i	任务类型编码
ζ_i	任务优先级
$\mathcal{A}$	卸载动作集合
L_i^{loc}	任务本地执行完成时延
E_i^{loc}	任务本地执行能耗
L_i^{off}	任务卸载执行完成时延
E_i^{off}	任务卸载执行能耗
$R_{i,n}^{\text{up}}$	任务 T_i 到候选节点 n 的上行传输速率
F_n	候选节点 n 的可用计算能力
W_n^{edge}	候选节点 n 的基础排队时延
$\Delta_i(n, t)$	任务 T_i 在节点 n 上的并发扰动时延
$CO_i(n, t)$	任务 T_i 在节点 n 上的并发开销
$J_i(a_t)$	动作 a_t 对应的单任务综合代价
$\omega_L, \omega_E, \omega_C$	时延、能耗与并发扰动代价权重

第1章 绪论

1.1 研究背景与意义

天地一体化信息网络是支撑未来空天信息服务的核心基础设施，也是实现广域通信、全球感知、智能处理与应急保障能力协同提升的关键技术底座。随着低轨卫星星座持续部署、星间链路逐步成熟以及星载处理平台能力不断增强，天基网络正由传统“透明转发”模式加速演进为集通信、感知、计算与控制于一体的综合信息平台^[1-3]。在此趋势下，卫星节点的角色已不再局限于简单的数据中继，而是逐步承担数据预处理、在轨分析、协同计算和任务自治决策等更高层级功能。

从应用需求看，天基网络面向的业务场景正快速向高时敏、高并发和智能化方向演进。在灾害应急通信、广域遥感快速处理、目标监测识别、空间态势分析和在轨服务编排等典型场景中，系统往往需要在有限时间窗口内完成大规模任务的接入、处理与反馈。若仍延续“星上初步处理——地面集中分析”的传统模式，则受星地链路时延、可见窗口受限以及回传带宽紧张等因素制约，难以满足业务闭环的实时性要求^[2,4]。因此，将部分计算能力前移至卫星侧并在多颗卫星之间实现资源协同，已成为天基网络智能化发展的核心趋势之一。

然而，天基网络中的计算资源具有比地面云计算或传统边缘计算环境更强的受限性。单颗卫星受平台尺寸、载荷重量、功耗预算、热设计能力以及轨道能量循环等多重约束，难以长期支撑高强度、多任务并发的计算需求。尤其在突发任务集中到达时，单星本地处理极易出现排队积压、时延抬升和任务失效等问题。进一步地，不同卫星节点在剩余算力、存储容量、链路条件和能量水平方面通常存在显著异质性，使得任务应当本地执行、迁移至邻近卫星还是延后处理，成为一个高度依赖实时环境状态的动态决策问题。

在此背景下，计算卸载逐渐成为突破单星算力瓶颈、提升系统整体处理能力的关键技术手段。其核心思想是：当任务节点本地资源不足或执行代价过高时，通过星间链路将任务迁移至资源更充裕的协同节点执行，从而在更大范围内实现算力共享与任务分担^[1,5]。相较于星地集中处理和单星本地处理，计算卸载能够更灵活地调度分布式资源，在提升资源利用率、降低任务时延和增强系统弹性方面具有显著优势。典型天基网络计算模式的技术特点对比如表 1.1所示。

表 1.1 典型天基网络计算模式及其技术特点

计算模式	核心支撑	主要能力	典型局限
星地集中处理	地面中心、馈电链路	适合离线分析与统一调度	受星地时延、可见窗口和回传带宽限制
星上本地处理	星载处理器、单星资源	支持任务就地预处理与快速响应	受单星算力、功耗与能量循环约束
星间协同处理	星间链路、多星协同	支持跨节点算力共享与任务迁移	动态拓扑下状态获取与决策复杂
分布式智能管控	区块链、MARL、FL、DRL	支持可信共享、协同博弈与智能卸载	需同时解决共识开销、协同稳定与代价预测问题

然而，天基网络中的计算卸载面临的挑战远超一般性分布式调度问题。**其一**，卫星高速运动导致网络拓扑、链路质量和可见关系持续变化，系统环境天然具有高动态性和强不确定性；**其二**，大规模分布式节点仅能掌握局部状态，难以及时获取完整、准确、可信的全网信息；**其三**，任务到达具有突发性，多颗卫星同时扮演任务发起方与算力提供方的双重角色，节点之间存在明显的资源竞争与收益博弈关系。上述因素共同决定了天基计算卸载本质上是一个“高动态环境中的去中心化协同决策问题”，而非传统意义上的静态调度问题。

围绕这一核心问题进一步分析，可以辨识出从状态共享到决策执行的四个关键子问题，它们构成了本文研究的技术逻辑链条。

第一，可信状态共享问题。卸载决策的有效性高度依赖于全网状态感知，包括节点算力、剩余能量、链路连通性、任务排队状况以及近期资源占用变化等。然而在天基网络中，若依靠频繁广播维持实时全局同步，不仅会引入大量额外通信开销，还可能因状态传播时延导致信息失真。更关键的是，去中心化网络缺乏稳定的中心控制节点，若共享状态存在滞后、篡改或不一致，后续卸载决策将失去可靠依据。基于此，本文引入区块链技术构建轻量级分布式状态账本。区块链的核心价值在于利用其去中心化、一致性维护和不可篡改特性，为多节点资源共享提供可追溯、可验证的公共信息平面^[6-8]。这使得各卫星节点在进行卸载和资源协调时，能够基于全网共同维护的公共状态快照进行判断，而非完全依赖瞬时、零散的点对点消息。

第二，系统层多节点协同博弈问题。当多个节点同时发起卸载请求时，优质节点迅速成为竞争焦点。若各节点均从自身收益出发进行局部贪婪选择，则极易出现策略

震荡、热点聚集和负载失衡。传统启发式方法或单智能体学习方法虽擅长优化个体即时收益，却难以刻画多节点相互作用下的协同演化过程。因此，本文在系统层引入多智能体强化学习方法，尤其是以 PPO 为代表的策略优化框架。天基网络中的资源分配天然具有多主体博弈属性——每个节点既是资源请求者又可能是资源提供者，其决策直接影响其他节点的可选空间和全局负载分布。MARL 能够通过持续交互学习形成稳定的协同策略，在吞吐量、任务时延、公平性和负载均衡等多个目标之间取得合理折中^[1-3]。

第三，并发执行代价建模问题。现有许多计算卸载研究在估计任务开销时，往往仅考虑传输时延和纯计算时间，并隐含假设任务进入节点后可按预期稳定执行。然而在真实系统中，节点内部通常同时运行多个任务，新任务的到来不仅影响自身完成时间，还对已执行任务造成排队延迟、上下文切换、缓存竞争、内存争用和能耗波动等额外扰动。这种并发开销很难依靠解析模型精确刻画——不同节点的硬件条件、负载状态和任务组合模式差异显著，相同任务在不同节点上的真实执行代价往往大相径庭。此外，天基网络中的训练数据天然分散在各节点，且包含任务类型、资源占用和运行状态等敏感信息，既不适合频繁原始上传，也不宜集中统一训练。基于此，本文引入联邦学习机制，在“数据不出域”的前提下完成跨节点协同建模^[9-10]，以获得兼具泛化能力和隐私保护特性的并发开销预测模型。

第四，任务层卸载决策问题。在获得可信公共状态和更准确的代价预测之后，仍需一种方法将这些输入转化为面向具体任务的卸载动作。任务层决策面对高维状态空间、离散动作集合以及持续变化的环境反馈，传统规则法难以覆盖复杂场景，静态优化法亦难以适应长期交互过程。基于此，本文在任务层采用 DQN 构建卸载决策模型，使其在高维状态条件下学习“任务特征——链上状态——并发开销——卸载动作”之间的非线性映射关系，并通过与环境持续交互逐步逼近更优策略^[11]。

综上，本文构建的区块链、MARL/PPO、联邦学习与 DQN 并非简单叠加的技术组合，而是围绕天基网络计算卸载在不同层级上的关键瓶颈展开的有机整体：区块链用于构建可信共享基础，MARL/PPO 用于处理系统层多节点协同博弈，联邦学习用于支撑隐私保护条件下的并发开销建模，DQN 用于完成任务层的具体卸载决策。基于此，本文旨在构建一套“系统层可信协同—任务层高效卸载”的双层智能管控框架。

图 1.1 天基网络协同计算卸载应用场景

1.2 国内外研究现状与发展趋势

围绕天基网络协同计算卸载问题，国内外研究已从体系架构、任务卸载、智能调度、去中心化协同以及隐私保护建模等多个角度展开探索。总体来看，相关工作正沿两个方向并行推进：一方面，卫星边缘计算与星间协同处理不断走向实用化，任务卸载与资源调度问题逐渐从静态建模转向动态学习；另一方面，随着网络规模扩张和节点自治能力增强，可信共享、分布式共识和隐私保护联邦学习等支撑机制日益成为研究重点。基于这一认识，本节从天基边缘计算与卸载、面向动态环境的智能调度、多节点可信协同与隐私保护三个方面进行梳理。

1.2.1 天基网络与卫星边缘计算研究现状

随着低轨卫星星座的快速发展，卫星边缘计算已成为天基网络研究中的热点方向。已有研究普遍认为，未来卫星网络不应仅承担透明转发功能，而应具备在轨预处理、局部协同分析和边缘服务承载能力，以缓解地面中心压力并提升实时响应能力^[1,4]。围绕这一目标，学界先后提出星地协同、星间协同和天地融合等多种计算架构，试图根据任务复杂度、时延要求和资源约束，在终端、卫星与地面之间灵活划分处理位置。

在具体卸载方法方面，早期研究多采用解析优化、启发式搜索或博弈论方法，对时延、能耗和资源利用率进行联合建模。此类方法在问题规模较小且假设条件较强时具有较好的可解释性，但当网络拓扑频繁变化、链路状态动态波动或任务到达呈突发性时，其模型有效性往往难以保持。例如，Gao 等针对 LEO 星座网络中的分布式动态卸载问题，基于博弈论建立了联合计算卸载与功率分配模型，在分布式环境下优化了资源利用效率，但该方法的求解过程依赖较强的信道静态假设^[12]。

2024 年以来，相关研究开始更加重视卸载问题中的时变信道、队列状态和动态负载因素。Jia 等提出面向卫星边缘计算的深度多智能体强化学习方法 MATORA，将任务卸载与资源分配拆分求解，在动态负载条件下提高了时延优化能力^[3]；Li 等针对 LEO 卫星边缘计算网络研究了基于 MADDPG 的联合卸载与资源分配问题，通过分布式学习处理高动态环境中的能耗与时延折中^[2]。此外，Shuai 等讨论了基于 Q-learning 的卫星边缘计算卸载策略，进一步验证了强化学习方法在动态卫星场景中的适应性^[5]。同年，Tang 等在 IEEE Transactions on Communications 中研究了基于星间链路的星地一体化网络任务卸载与资源分配问题，提出混合云与卫星多层多接入边缘计算架构，

通过联合优化节点选择、卸载比率和算力分配实现了网络资源的动态管理^[13]。

进入 2025 年以后,研究重点进一步从“是否卸载”扩展至“如何在多目标条件下稳定卸载”。Xu 等提出面向卫星边缘计算的多目标强化学习卸载方法,将时延、资源利用率和负载均衡纳入统一优化目标,改善了复杂任务场景下的综合性能^[14]; Ma 等则着重分析了任务优先级、资源竞争和联合分配之间的耦合关系,指出卸载研究正在从单一指标优化转向优先级感知、服务质量约束和多资源联合编排^[15]。值得注意的是, Wang 等在 *Computer Networks* 中提出了 MARATD3 算法,将循环神经网络与多头注意力机制引入多智能体深度确定性策略梯度框架,在部分可观测条件下实现了跨时隙的动态卸载与资源分配联合优化,为高动态卫星环境中的序贯决策问题提供了新的建模范式^[16]。此外, Jia 等在 *Frontiers of Information Technology & Electronic Engineering* 中探索了联邦深度强化学习在低轨卫星边缘计算中的应用,将联邦学习与 DRL 相结合以保护用户数据隐私的同时优化计算卸载策略,指出联邦学习不仅能保护隐私,更可作为卸载策略训练的分布式支撑手段^[17]。

这些研究表明,卫星边缘计算与任务卸载已由概念验证阶段逐步迈向细粒度建模与智能优化阶段。2024—2026 年天基计算卸载与智能调度领域的代表性研究如表 1.2 所示。

尽管进展显著,现有研究仍存在两方面关键局限。**其一**,多数工作默认系统能够获得较准确的全局或准全局状态,对高动态拓扑下的状态不一致、信息失真和分布式认知偏差问题考虑不足。**其二**,大量模型仍将任务代价简化为传输时间与纯计算时间的线性叠加,对多任务并发带来的内部竞争和执行扰动刻画不够充分。换言之,天基计算卸载虽已从静态优化走向动态学习,但在“可信共享”和“并发感知”两个维度上仍有待深入研究。

1.2.2 动态环境下智能调度与多智能体协同研究现状

天基网络环境具有高动态、强耦合和多主体并存等特征,面向动态环境的智能调度已成为近年来相关研究的核心方向。深度强化学习之所以被广泛引入,在于其能够在缺乏精确解析模型的条件下,通过与环境持续交互形成状态到动作的映射关系,从而有效处理链路波动、任务到达随机性和资源时变性等问题^[11]。

在单智能体强化学习阶段,研究通常聚焦单节点视角下的卸载动作、功率控制或链路选择,通过 DQN、DDQN、D3QN 等方法提升策略对复杂状态的适应能力。此类

表 1.2 2024—2026 年天基计算卸载与智能调度代表研究

研究方向	代表文献	主要内容	不足或启示
卫星边缘计算架构	[1,4]	从星地融合、星间协同和天地一体化角度讨论卫星边缘计算架构与业务承载方式	侧重体系层面描述，对协同决策机制的讨论不足
博弈论与优化方法	[12-13]	利用博弈论、凸优化或分层架构处理卸载与资源联合分配	依赖较强的信道平稳或全局信息可获得假设
单智能体 RL 卸载	[5,14]	利用 Q-learning、DQN 及其改进模型优化卸载时延和资源利用率	多从单节点或单任务视角建模，难以处理多节点博弈
MARL 联合优化	[2-3,15-16]	将多颗卫星建模为多智能体，联合优化卸载、功率、带宽和资源分配	通常假设状态可获得，可信共享基础偏弱
联邦学习辅助卸载	[17]	将联邦学习与 DRL 结合，保护隐私同时优化卸载策略	联邦学习与卸载决策的闭环耦合仍待深化
2026 新趋势	[18]	引入大模型处理复杂状态下的卸载与资源分配	表明卸载研究向更复杂决策模型演进，但对系统层信任问题涉及较少

方法在小规模、中心化或弱耦合场景中效果较好，但当多个卫星节点同时参与决策时，其隐含的“环境平稳”假设不再成立——对任一节点而言，其他节点的动作会持续改变其观测环境和收益分布，导致单智能体方法面临显著的环境非平稳性问题。

正是基于这一认识，多智能体强化学习在天基计算调度中日益受到重视。2024 年以后，多项研究明确将多颗卫星建模为多智能体系统，通过集中训练分布执行（CTDE）或共享奖励等机制处理节点间的策略耦合关系^[2-3]。在 CTDE 范式的具体实现方面，Wu 等在 IEEE VTC 2025-Spring 上提出了面向 LEO 卫星网络的多智能体深度强化学习卸载与路由联合优化方法，将计算和路由需求同时纳入多智能体建模框架，在动态负载和拓扑变化条件下展现了分布式决策的灵活性^[19]。Qin 等在 IEEE Transactions on Sustainable Computing 中更早地从可持续计算角度出发，利用 MARL 解决星地一体化网络中的计算卸载问题，强调全局奖励设计在多智能体收敛中的关键作用^[1]。

此类方法的核心优势在于能够同时考虑局部选择与全局负载之间的关系，使卸载策略从局部最优逐步逼近系统层协调。从当前发展趋势看，MARL 在天基网络中的定位已从辅助优化工具转变为描述多节点协同演化的方法论基础。这一趋势在 2025—2026 年间表现得尤为明显。在卫星对地观测调度领域，AAAI 2025 接收的一篇工作将 MARL 应用于大规模序贯卫星任务分配问题，通过从多项式时间贪心求解器引导学习并结合分布式最优分配机制，成功扩展至数百个智能体和任务的规模，显著超越了先前方法^[20]。此外，2026 年的一项研究提出了时空感知的 MAPPO 方法用于周期性重访约束下的多星观测调度，通过多目标奖励函数平衡任务完成率、首次观测时效性和重访均匀度^[21]。这些工作进一步表明，MARL 不仅适用于通信层面的资源分配，也正在向观测调度、联合计算与通信优化等更广泛的星上任务管控领域扩展。

需要特别指出的是，近年来出现了将强化学习与联邦学习相结合的新趋势，以解决天基网络中分布式决策的隐私和通信效率问题。Han 等在 IEEE Journal on Selected Areas in Communications 中研究了星地一体化网络中联邦学习的合作卸载问题，联合优化本地计算和数据卸载策略，为联邦学习在天基协同场景中的部署提供了理论框架^[22]。这一方向的出现，意味着智能调度正从“集中式学习后分布式部署”向“训练与部署全程分布式”演进。

然而，现有智能调度研究仍存在两个值得关注的问题。**第一**，许多研究虽采用多智能体框架，却仍默认节点间可以高效、真实地共享状态信息，对分布式系统中的虚假共享、状态滞后和认知不一致问题讨论不足。**第二**，部分工作侧重于算法收敛与指

标提升，对“高动态去中心化环境为何必须采用多智能体协同而非中心化控制”的论证不够充分。实际上，MARL 在天基网络中的核心价值不仅在于提升数值性能，更在于为去中心化资源博弈提供了统一的建模与求解框架。

图 1.2 2024—2026 年相关研究演进与本文定位

1.2.3 区块链协同与隐私保护学习研究现状

随着天基网络从封闭体系向开放协同体系演进，可信共享与去中心化协同问题日益突出。传统中心控制模式虽便于统一管理，但在大规模低轨星座和多主体参与环境下，容易面临单点失效、扩展性不足以及状态采集开销过高等问题。为此，近年来研究开始尝试引入区块链、分布式共识和自治网络协议，为天基网络构建新型协同机制。

2024 年以来，该方向的代表性工作明显增多。Oh 等提出去中心化多方低轨网络（MP-LEO）设想，强调通过分布式控制和多方协同共享冗余能力，提升未来卫星网络的鲁棒性与可用性^[6]；Yan 等从网络协议层面提出面向通信卫星服务的去中心化协议，利用区块链式状态发布机制提升全网信息的透明度和公平性^[7]。与此同时，面向空天地一体化网络的区块链安全通信研究也在增加，Zhang 等利用区块链改善 SAGIN 中数据传输的信任问题，并探索低轨卫星承担去中心化账本维护与分布式记录的可行性^[8]。

在区块链与计算卸载的结合方面，2025 年的一项重要进展值得关注。相关研究在 IEEE Transactions on Mobile Computing 上提出了区块链辅助的数字孪生卸载机制，在空天地异构网络中构建了 SAG 数字孪生集成区块链模型，利用区块链保障数据安全与隐私的同时，通过数字孪生实现网络状态的实时映射与优化，并给出了高效的业务卸载与资源分配联合算法^[23]。该工作将区块链从“外部安全模块”推进至“与卸载决策紧密耦合的状态底座”，与本文的核心理念高度契合。此外，面向卫星物联网的 StarCross 框架在 Computer Networks 上提出了可编辑区块链跨分片交易方案，在 LEO 辅助的分片区块链架构下将吞吐量提升至基线的 260.9%，交易确认延迟降低 79.7%，说明通过架构创新可以有效缓解卫星网络中区块链的性能瓶颈^[24]。

进入 2025—2026 年，研究重点从“能否去中心化”转向“如何在高动态卫星网络中实现更稳健的共识与控制”。2026 年的 DSH-Raft 研究针对卫星网络中带宽受限、计算能力异构和拓扑波动显著等问题，提出动态分层 Raft 共识算法，表明传统地面分布式共识机制无法直接移植到卫星环境，而必须围绕链路质量、节点能力和覆盖约束

进行针对性重构^[25]。这一趋势表明，去中心化卫星网络研究已从宏观愿景逐步走向面向工程实现的机制设计阶段。可信协同与隐私保护领域的代表性研究如表 1.3 所示。

表 1.3 可信协同与隐私保护相关代表研究

研究方向	代表文献	主要内容	对本文的启示
去中心化卫星网络	[6-7]	提出多方参与、分布控制的卫星网络愿景与协议雏形	可信共享和自治控制将成为星座协同的重要基础
区块链支撑通信/协同	[8,23-25]	利用区块链、数字孪生和改进共识提高空地网络中的数据可信传输与一致性维护	区块链应从安全附加层转变为资源调度的状态底座
区块链与联邦学习融合	[26]	在 LEO 网络中构建分片区块链联邦学习框架以应对恶意模型攻击	区块链可为联邦学习提供可信聚合与安全保障
隐私保护联邦学习	[9-10,17,27-28]	围绕层次聚合、分裂联邦、轨道感知和异构适配等机制提升卫星环境中的协同学习能力	联邦学习不仅可保护隐私，更可作为并发代价建模的训练支撑

尽管如此，当前关于去中心化卫星网络和区块链协同的研究仍主要集中在安全、协议和网络治理层面，与天基计算卸载的深度耦合尚不充分。已有工作回答了“为什么需要去中心化”和“如何构建分布式信任机制”，但这些机制如何有效服务于具体的计算卸载、资源协调和任务调度，仍缺少系统性讨论。本文正是在这一研究空白上进一步推进，将区块链从“外部安全模块”转化为“系统层可信状态共享底座”。

在隐私保护协同建模方面，联邦学习逐渐成为支撑天基网络分布式智能建模的重要方案。与传统集中式学习相比，联邦学习允许各节点在本地完成训练，仅交换模型参数或梯度，在“数据不出域”的前提下实现跨节点协同优化^[9,29]。

在卫星及星地融合场景中，联邦学习研究近两年呈现出两条清晰路径：一是围绕具体业务构建面向天基环境的协同学习框架，二是围绕高动态、异构和隐私约束条件改进联邦学习机制本身。前者如 Jiang 等将联邦学习与分裂学习结合，提出适用于卫星—地面融合网络（STIN）的分裂后联邦框架，证明在卫星链路和边缘服务器并存条件下可通过结构改造减少传输压力并保护局部数据^[10]；后者如 Li 等提出 HiSatFL，通过轨道感知层次聚合和跨域隐私自适应机制，专门针对卫星网络的动态拓扑、多维异

构和隐私保护需求进行设计^[9]。此外，2025 年前后有关卫星 ISAC 网络中的联邦学习研究也开始关注收敛效率、传输开销与协同增益之间的平衡^[27]。

在联邦学习框架的可扩展性方面，近两年出现了多项面向 LEO 异构星座的代表性工作。FedLEO 是一个面向 LEO 卫星网络的卸载辅助去中心化联邦学习框架，发表于 IEEE Transactions on Mobile Computing (2024)，通过利用 LEO 星座的拓扑特征设计卸载机制，有效缓解了卫星间计算能力不均衡带来的掉队者效应和统计异质性问题^[28]。同期，FedSN 框架在同一期刊上提出了面向异构 LEO 卫星网络的通用联邦学习方案 (2025)，通过子结构方案支持不同计算、内存和通信能力的异构本地模型训练，并在真实卫星数据上验证了精度和开销方面的显著优势。这些工作进一步说明，联邦学习在天基网络中已进入面向实际工程约束的精细化设计阶段。

更进一步地，区块链与联邦学习的融合成为 2024 年以来的新兴方向。Wu 等提出了面向 LEO 网络的分片区块链联邦学习框架 SBFL-LEO，利用矿工卫星通过余弦相似度和 DBSCAN 算法检测恶意模型，并通过卫星间互相监督提升聚合安全性，在模型精度和能效方面均显著优于基线方法^[26]。这一研究表明，区块链不仅可以为资源状态提供可信底座，还能为联邦学习的模型聚合过程提供安全保障——这对于天基网络中缺乏可信中心的分布式训练场景具有重要意义。

总体而言，隐私保护联邦学习在卫星网络中的已有研究证明：联邦学习不仅能够降低原始数据汇聚压力，还能在异构节点条件下提升模型泛化能力。然而，多数现有工作仍停留在“如何将联邦学习部署到卫星网络”这一层面，较少深入讨论其与上层任务调度、代价预测和决策优化之间的闭环联动。本文认为，联邦学习在天基计算卸载中的核心价值不仅在于隐私保护，更在于为并发开销预测提供了可扩展的分布式训练手段。只有当代价模型在多节点历史数据支持下持续迭代，任务层的卸载策略才能真正逼近复杂环境中的真实执行代价。因此，将联邦学习与任务层卸载决策进行闭环耦合，是现有研究亟待突破的重要方向。

1.2.4 现有研究存在的主要问题与挑战

综合上述研究现状，当前围绕天基网络计算卸载的研究虽已从静态优化迈向智能化与分布式化，但仍存在以下四个方面的关键不足：

(1) **全网状态共享基础薄弱**。现有计算卸载与智能调度研究往往默认节点能够获取较为准确的全局状态，却较少考虑高动态拓扑下的信息时延、认知偏差和共享可信

性问题，使得诸多算法建立在偏理想化的前提之上。

(2) **系统层协同博弈与可信共享机制之间存在割裂。**多智能体强化学习能够处理多节点资源竞争，但若缺少可信状态支撑，策略学习极易受到不一致观测的干扰；区块链和分布式共识虽能提供可信共享，却往往未能进一步服务于卸载决策过程，两者之间缺少有效的协同设计。

(3) **任务层执行代价建模偏于静态。**现有大量研究仍将任务代价简化为传输时延与计算时长之和，对并发任务间的资源争用、排队延迟和性能退化考虑不足，导致算法在高负载场景下的实际适用性受到限制。

(4) **联邦学习与任务卸载尚未形成完整闭环。**已有工作已证明联邦学习适用于卫星网络部署，但其与并发开销预测、状态感知及任务层强化学习决策之间如何紧密耦合，仍缺乏系统性的集成框架。

基于上述问题，本文从系统层与任务层两个层级同时切入：在系统层，利用区块链和 MARL/PPO 构建可信协同资源博弈机制；在任务层，利用联邦学习和 DQN 建立并发感知卸载决策机制。通过“双层协同、分层求解”的设计思路，系统性地回应当前研究中的上述关键不足。

1.3 本文主要研究内容与论文结构

针对天基网络中状态感知困难、多节点协同博弈复杂以及并发执行代价难以准确刻画等问题，本文围绕“系统层可信协同”和“任务层高效卸载”两个核心目标展开研究，构建融合区块链、多智能体强化学习、联邦学习和深度强化学习的双层智能管控框架。主要研究内容如下：

(1) **构建面向天基网络计算卸载的双层智能决策框架。**将复杂的协同计算卸载问题划分为系统层资源协同与任务层卸载执行两个层级——前者负责多节点状态共享与资源协调，后者负责面向单任务的具体卸载决策——从而降低整体求解复杂度并实现层间解耦。

(2) **研究基于区块链与 MARL/PPO 的系统层协同资源博弈方法。**围绕天基网络中状态可信共享不足和多节点竞争失序的问题，利用区块链构建公共状态账本，并将各节点建模为多智能体，通过 PPO 策略优化实现系统层的资源协调与负载均衡。

(3) **研究基于联邦学习与 DQN 的任务层并发感知卸载方法。**针对高并发环境下执行代价难以精确建模的问题，通过联邦学习训练并发开销预测模型，并将其输出与

DQN 决策过程深度结合，实现更贴合真实系统状态的任务卸载优化。

（4）搭建典型天基协同计算场景并进行综合性能评估。从任务完成时延、系统吞吐量、资源利用率和负载均衡度等维度验证所提方法的有效性，并通过对比实验和消融实验系统分析各关键模块的贡献。

图 1.3 本论文研究思路及文章结构

本文的章节结构安排如图 1.3 所示。第一章为绪论，介绍研究背景、国内外研究现状、存在问题及本文研究内容；第二章建立系统模型并梳理相关理论基础；第三章研究系统层可信协同资源博弈方法；第四章研究任务层并发感知卸载方法；第五章开展仿真实验与性能评估；第六章总结全文并展望后续研究方向。

第 2 章 天基网络计算卸载的技术基础与系统建模

2.1 天基网络协同计算场景与体系结构

2.1.1 天基网络协同计算场景分析

随着低轨卫星星座规模化部署、星间链路能力增强以及星上异构计算载荷逐步成熟,天基网络的功能定位正在由传统的“广域覆盖与信息转发”扩展到“通信、计算与智能协同服务”的综合平台。近年来,非地面网络(Non-Terrestrial Networks, NTN)已经从补盲式接入手段演进为 6G 体系中的关键组成部分。围绕 3GPP Release 17/18 的最新研究表明,卫星接入、再生式载荷、回传一体化以及天地融合组网正在推动卫星系统从专用通信体制走向与蜂窝网络深度耦合的统一架构^[30-32]。这意味着天基网络不再仅承担“把数据送回来”的传输角色,而开始承担“在何处处理、如何协同处理、何时返回结果”的计算与控制角色。

在这一背景下,轨道边缘计算(Orbital Edge Computing, OEC)成为天基网络的重要演进方向。与传统“天感地算”模式相比,OEC 强调在卫星侧、跨星链路侧以及天地协同侧完成数据预处理、任务调度与智能推理,其目标是在降低星地回传压力的同时,缩短端到端任务闭环时间^[33-34]。特别是在遥感感知、海洋监测、应急救援、边远区域物联网和全球连续感知等场景中,数据源与地面中心之间存在天然的空间分离,而业务又常常具有“数据量大、计算量大、实时性强”的复合特征。如果仍将全部原始数据下传至地面统一处理,则会受到星地链路容量、回传路径长度以及地面调度时延的共同制约,难以满足分钟级甚至秒级的任务响应要求^[35-37]。

进一步地,天基网络业务形态正在从“连接驱动”走向“任务驱动”。传统卫星通信业务更多强调链路连通性和广域可达性,而面向 6G 的新型业务则更关注从任务生成、任务传输、任务执行到结果反馈的端到端闭环性能。例如,在广域遥感与地球观测任务中,往往需要多颗卫星对大范围区域进行协同观测,并进一步完成图像路由、计算处理和结果下发,此时任务调度已经不再是单纯的数据回传问题,而是观测、转发、计算和资源编排的一体化问题^[35]。类似地,在远洋 IoT、灾害应急和偏远地区智能巡检等场景中,业务往往既依赖卫星提供广域接入,又依赖卫星边缘侧提供就近计算、模型推理和局部缓存能力^[37-38]。

然而,相较于地面边缘计算,天基网络协同计算场景具有更强的动态性、异构性

和资源约束。一方面，低轨卫星高速运行导致节点覆盖关系、可见窗口和路由拓扑持续变化；另一方面，星上计算、缓存和能量资源远弱于地面数据中心，节点间能力差异显著，且业务需求在时延容忍、任务规模、能耗预算和优先级等方面高度异构。此外，跨星协同和多任务并发还会引入服务部署、任务迁移、资源竞争和队列耦合等新问题^[39-41]。因此，天基网络中的计算卸载不应被简单理解为“本地执行”与“远端执行”之间的二元选择，而应被视为一个面向动态拓扑、异构资源和时变业务的多层协同优化问题。

基于上述认识，本文将天基网络计算卸载问题划分为两个相互关联的层次：其一是系统层资源协同问题，关注星座尺度上的资源组织、状态同步、服务部署与长期运行效率；其二是任务层计算卸载问题，关注单任务或局部任务集在当前环境中的执行位置选择及其时延、能耗与可靠性收益。这样的分层处理既符合天基网络“全局慢变量演化、局部快变量决策”的运行规律，也为后续分别研究系统层协同控制与任务层智能卸载提供了清晰的问题入口。

2.1.2 节点类型与功能划分

为清晰刻画天基网络中的协同计算体系，本文将参与任务处理与资源调控的节点划分为三类：卫星终端（Satellite Terminal, ST）、卫星边缘节点（Satellite Edge Node, SEN）以及地面控制中心（Constellation Controller, CC）。

卫星终端通常位于业务源头，是系统中计算任务的产生者。终端可以是边远区域的传感设备、海上浮标、无人平台、野外监测站，也可以是通过卫星接入网络的移动终端。这类节点具备基础感知、通信与轻量处理能力，但本地算力、电池容量和持续通信能力通常有限，难以独立承担复杂的模型推理、图像分析或多模态信息融合任务。因此，终端既是业务输入入口，也是任务卸载决策的直接触发点。

卫星边缘节点是指具备一定在轨计算与缓存能力、能够为终端提供近端计算服务的星上节点。与传统仅负责信号中继的通信卫星不同，SEN 具备任务预处理、AI 推理、缓存协同、跨星转发以及局部资源编排能力，是 OEC 场景中的核心计算承载实体^[33-34]。近年来，相关研究已从单星边缘处理逐步扩展到多星协同处理、星间任务转发和同轨/异轨资源共享，这说明 SEN 的角色正在从“边缘执行器”发展为“分布式协同计算节点”^[39-40]。但需要强调的是，SEN 仍受制于星上功耗、存储、热控和能量预算，其服务能力随实时负载、服务部署状态和可用链路条件而显著变化。

地面控制中心则是系统中的强算力支撑节点和全局协调实体。一方面, CC 具备更高等级的计算、存储和模型训练能力, 可承担复杂任务处理、长期策略训练、全局状态融合和跨域控制等功能; 另一方面, 它还负责星座资源编排、全局策略下发与系统运行维护。相比 SEN, CC 在资源规模和运行环境稳定性上具有显著优势, 但其处理路径更长, 通常需要经历额外的星地传输与调度开销, 因此并不总适合承担强实时业务。

由此可见, 本文所研究的天基协同计算体系本质上形成了“终端—星上—边缘—地面中心”的三级协同结构: 终端侧强调任务生成与本地快速响应, 边缘侧强调近端处理与局部协同, 地面侧强调强算力支撑与全局控制。该结构既符合当前天基网络向“通算智融合”演进的发展趋势, 也为后续双层智能管控框架的构建提供了直接依据。

2.1.3 链路特性与资源受限特征

在天基网络中, 计算卸载与协同处理能力不仅取决于节点自身算力, 还受到通信链路条件和资源约束的共同影响。与地面固定网络相比, 星地链路和星间链路在可见窗口、传播路径、带宽波动和拓扑稳定性方面均存在显著差异, 因此任务处理问题天然具有更强的动态耦合特征^[33,41]。

首先, 链路可见性的时变性是天基网络区别于地面网络的核心特征之一。低轨卫星高速运行导致终端与卫星之间、卫星与卫星之间的可达关系不断变化, 任务上传、转发和回传必须受到可见窗口约束。某一任务即便在当前时刻可以完成上传, 也未必能够在同一链路窗口内完成结果回传, 尤其当任务还伴随跨星转发或服务迁移时, 这种时变性会进一步放大^[35,41]。因此, 卸载决策不能只依赖静态路径假设, 而必须同时考虑链路存在性、持续时间与后继路由可达性。

其次, 链路带宽和质量具有明显的时间依赖性。卫星相对位置变化、链路负载波动以及环境扰动共同决定了有效带宽和传输时延的动态变化。对同一任务而言, 在不同时间片、不同可达卫星或不同转发路径上, 其通信代价可能存在显著差异。进一步地, 星上计算资源与链路资源往往不是彼此独立的: 链路拥塞会导致排队和调度开销上升, 而节点过载又可能触发任务迁移、跨星协同或服务重新部署, 从而反过来影响网络负载分布^[39,42]。

最后, 资源受限性贯穿于终端、卫星边缘和地面协同的全过程。终端面临算力不足和能耗受限问题; SEN 则同时面临算力、缓存、能量与服务槽位约束, 且不同卫星

上的服务实例部署状态并不一致；地面中心虽然资源充足，但在路径时延与回传开销方面存在天然劣势^[43-45]。这意味着，天基网络计算卸载的本质并不是“谁更强就给谁算”，而是在链路可达性、资源剩余量、服务可用性以及任务 QoS 需求共同约束下，对执行位置进行动态选择。

综上，天基网络中的计算卸载本质上是由计算资源、通信资源、服务部署状态与时间窗口共同耦合的复杂优化问题。链路的动态可见性决定任务是否具备卸载条件，通信能力的时变性决定任务传输代价，节点资源受限特征决定任务是否能够稳定执行，而服务部署与跨星协同能力则进一步影响系统的长期收益。因此，有必要在后续建模中将上述因素统一纳入系统模型与任务模型。

2.2 计算卸载与智能管控相关技术基础

2.2.1 计算卸载基本模式与性能指标

计算卸载的基本思想，是将资源受限节点上的任务全部或部分迁移至外部节点执行，以缓解本地算力不足、降低终端能耗并改善服务时延。在天基网络场景中，由于终端、卫星边缘节点和地面控制中心在计算能力、链路条件和资源成本上存在显著差异，卸载机制不再只是简单的“本地执行”与“远端执行”二元选择，而是演化为多层异构节点之间的动态协同过程^[41,44]。

从执行位置看，本文考虑三种基本处理方式：一是由源终端本地执行；二是卸载至可达的卫星边缘节点执行；三是进一步卸载至地面控制中心执行。本地执行避免了传输开销，但受限于终端资源能力；边缘执行能够在较近位置提供计算服务，通常能在时延与能耗之间取得更优平衡；地面中心执行依托强大算力适合复杂任务，但需承担更长路径和更高回传代价。因此，如何在三级执行方式之间作出合理选择，是天基网络任务卸载的核心。

从任务粒度看，现有研究通常区分为全卸载、部分卸载和协同卸载三类模式。全卸载适用于本地能力严重不足且链路条件较好的场景；部分卸载强调任务可拆分与模块化执行，但在卫星网络中会受到多路径传输与子任务同步成本的额外影响；协同卸载则强调多个节点共同参与任务处理，需要联合考虑路由、服务部署、带宽分配和计算资源分配等多个维度^[36,39]。近期研究进一步表明，在卫星边缘计算网络中，卸载问题往往需要与服务部署、路由选择、跨星协同和长期系统成本一并考虑，这使得卸载

优化从单一决策问题演化为多变量耦合问题^[39,42]。

评价卸载策略优劣的核心指标通常包括任务完成时延、终端能耗、任务成功率、系统吞吐量、资源利用率和负载均衡程度等。其中，任务时延与终端能耗是最基本也是最关键的两类指标：时延刻画任务从生成、上传、执行到结果回传全过程的总耗时，直接反映业务实时性；能耗则刻画任务在本地执行或传输过程中对终端资源的消耗，对于能源受限终端尤为重要^[40-41]。此外，在动态天基网络中，服务稳定性、任务成功率、节点公平性和长期系统成本也逐渐成为重要补充指标^[43-44]。

总体上看，计算卸载问题已经从传统的规则匹配、凸优化和启发式搜索，逐步扩展到多智能体强化学习、联邦学习、两时间尺度优化以及数据驱动的环境感知建模框架^[42,46-48]。这说明在天基网络环境中，计算卸载不仅是资源分配问题，更是面向动态复杂系统的智能决策问题。

2.2.2 轨道边缘计算与星座协同处理基础

轨道边缘计算是理解天基网络计算卸载问题的重要理论基础。现有综述研究普遍指出，OEC 的核心特征可以概括为“三强一限”：即轨道移动性强、节点异构性强、任务空间耦合强，以及星上计算/存储/能量资源受限^[33]。这与传统地面 MEC 存在本质差异，决定了天基任务卸载不能照搬地面边缘计算中的静态建模与局部最优思路。

首先，OEC 并非单星能力增强的简单延伸，而是星座尺度上的协同处理体系。随着大规模 LEO 星座成为未来网络的重要基础设施，研究重点已从单星上运行 AI 推理扩展到跨星资源共享、任务迁移、协同感知、服务部署和网络计算一体化管理^[34,39]。例如，针对大范围地球观测任务，SECO 工作提出将多星观测协同、图像路由与边缘计算联合优化，从而使“观测—传输—处理”闭环在卫星网络内部尽可能完成^[35]。这说明面向星座的协同处理已成为天基网络计算服务能力提升的关键方向。

其次，OEC 中“服务部署”与“任务卸载”往往同时存在。在地面 MEC 中，服务实例通常部署于固定基站或边缘云，任务主要决定卸载位置；而在天基网络中，不同卫星可承载的服务实例种类与数量受到载荷资源和时变业务分布影响，必须通过服务部署与服务迁移机制动态适配热点区域^[39,42]。因此，系统层不仅需要感知“哪颗卫星空闲”，还需要感知“哪颗卫星上是否存在所需服务、部署代价有多高、迁移收益是否值得”，这使得系统层资源协同具有显著的长期性和结构性。

再次，OEC 的任务处理通常伴随跨星协同。当地面用户分布不均、热点区域突发

业务集中或单星负载过高时，仅依赖当前可见卫星可能导致局部拥塞和资源浪费。近期研究已经开始从“单跳卫星卸载”转向“星—星—地”协同，联合考虑任务转发比率、跨星资源分配和服务成功率最大化问题^[40,45]。这表明天基网络中的资源协同对象，不应局限于终端与某一颗卫星之间，而应扩展为覆盖多个卫星节点和地面中心的多层协同系统。

因此，在本文研究框架中，轨道边缘计算不仅是应用背景，更是问题建模的重要出发点。它说明天基计算卸载必须同时关注任务执行位置、服务可用性、链路时变性和跨星协同处理机制，进而为系统层与任务层的双层智能管控提供理论支撑。

2.2.3 可信状态同步与分布式协同基础

在天基网络的协同计算过程中，资源调度与任务卸载的有效性高度依赖系统状态信息的准确性、时效性与一致性。然而，由于卫星节点空间分布广、链路窗口短且拓扑动态变化显著，系统中的不同节点通常只能获得局部观测信息，难以及时形成完整一致的全局状态视图。这种状态不对称和不同步会直接导致错误卸载、资源竞争失衡和服务冲突。

因此，从系统层视角看，需要构建一种可信、可共享、可追溯且适配时变链路环境的状态同步机制。这里的“可信状态同步”并不局限于某一种具体技术实现，其核心目标是保证关键系统状态（如节点负载、服务部署、链路可达性、缓存与队列占用等）在多节点之间能够以可验证、低开销和可容错的方式传播。对天基网络而言，状态同步的重点不在于追求绝对实时和绝对全局，而在于在受限资源条件下实现“足够可信、足够一致、足够可用”的系统视图。

从机制设计看，这类状态同步通常需要满足四点要求：一是轻量化，不能显著占用星上计算与带宽资源；二是容错性，能够容忍链路间歇中断和局部网络分区；三是可追溯性，便于后续系统审计与策略回溯；四是可扩展性，能够适应大规模星座环境下的节点增长与业务扩展。围绕这些要求，已有研究在卫星边缘计算中开始关注系统层的服务部署、资源共享、长时间尺度优化与分布式协同问题^[39,42]。这说明，仅靠任务层即时决策难以保证系统长期稳定运行，必须有系统层状态同步与协同支撑作为基础。

在本文中，可信状态同步的定位并不是独立研究目标，而是系统层资源协同的前置条件：只有当节点对关键状态形成相对一致的认知，系统层策略才可能有效引导后

续任务层的局部决策。因此，本文后续将其视为双层管控体系中的系统支撑能力，而非单纯的安全附加模块。

2.2.4 多智能体强化学习的系统层协同决策基础

强化学习通过“状态—动作—奖励”交互机制学习最优策略，能够在环境模型难以精确建立、系统状态快速变化的复杂问题中体现较强适应能力。然而，在天基网络协同计算场景中，系统天然具有多主体特征：多个卫星边缘节点需要共同承担任务接入、处理、缓存、服务迁移和转发等功能，局部决策之间存在显著耦合，因此单智能体框架难以充分刻画这种分布式协同过程。

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）将多个自治实体抽象为多个交互智能体，使各智能体在局部观测条件下学习协同或竞争策略。特别是中心化训练、分布式执行（CTDE）框架，非常适配天基网络的特点：训练阶段可以利用较完整的全局信息学习协同策略，而执行阶段每个智能体只需依据本地状态和有限邻域信息完成在线决策，从而降低对实时全局通信的依赖^[46-47]。

对于系统层资源协同而言，MARL 的价值主要体现在三个方面。其一，卫星节点天然具备多主体结构，不同 SEN 既共享系统环境，又在局部服务承载与资源竞争上存在独立决策需求，因此适合建模为多智能体协同控制问题。其二，系统层状态通常是局部可观测的，单节点难以完整掌握全局资源分布，而 MARL 能够较好处理此类部分可观测马尔可夫决策过程。其三，卫星网络环境具有显著非平稳性，传统静态规则难以长期保持有效，而多智能体学习方法能够通过持续交互更新策略，从而适应时变业务和动态拓扑^[46-47,49]。

近期研究已经将 MARL 应用于 LEO 卫星边缘计算中的计算卸载、资源分配和任务协同问题。例如，Li 等人在 *Computer Communications* 2024 中利用 MADDPG 联合优化发射功率、CPU 频率、比特分配、卸载决策和带宽分配^[46]；Xiu 等人在 *Computer Networks* 2025 中引入 RNN 和记忆注意力机制以提升多时隙动态环境中的状态建模能力^[47]；围绕分布式卫星边缘智能的研究还进一步探索了“学习—服务—资源”耦合优化框架^[43]。这些工作共同表明，MARL 已成为处理系统层全局协同与长期收益优化的重要技术路线。

因此，在本文技术框架中，多智能体强化学习主要被视为系统层资源协同的重要理论基础。该方法能够将星座尺度的全局协同问题抽象为多个边缘节点在共享环境中

的联合学习问题，从而更自然地适应天基网络分布式、动态化与局部观测受限的运行特征。

2.2.5 联邦学习与深度强化学习的任务层决策基础

除系统层的全局协同外，任务层计算卸载同样需要在动态环境中进行自适应决策。由于任务到达过程随机、链路状态时变、节点负载持续波动且多任务并发扰动难以精确解析，传统基于固定规则或静态参数的任务选择方法难以在复杂环境中长期保持稳定性能。因此，联邦学习（Federated Learning, FL）与深度强化学习（Deep Reinforcement Learning, DRL）逐渐成为卫星边缘智能研究中的重要技术路径^[43,48,50]。

联邦学习的核心思想是各参与节点利用本地数据训练模型，仅上传模型参数或梯度进行聚合，而不直接共享原始数据。对于天基网络而言，FL 的价值主要体现在两个方面：其一，星地链路资源宝贵，大规模原始样本汇聚代价高昂，而联邦参数聚合能够显著降低通信负担；其二，不同卫星节点所积累的任务执行轨迹、队列变化、资源利用率和失败样本具有较高价值，若能通过联邦方式整合，有助于提升环境代价模型或状态预测模型的泛化能力^[50]。因此，在本文研究中，联邦学习更适合作为“环境感知模型”的训练机制，而非直接替代在线决策本身。

深度强化学习则通过神经网络逼近策略函数或值函数，使强化学习能够处理高维状态输入和复杂动作映射问题。在任务层计算卸载场景中，DRL 可以根据任务规模、工作量、时延门限、节点负载、链路状态、服务可用性以及并发扰动估计，学习输出长期收益更优的执行位置选择策略^[41,43-44]。相较于传统优化方法，DRL 更适合处理动态环境下的序贯决策问题，尤其适用于卫星网络这种拓扑时变、状态相关性强、解析建模困难的场景。

进一步地，2025–2026 年的研究趋势表明，任务层智能决策正从“经典 DRL”继续向更复杂的数据驱动范式扩展：一类工作引入扩散模型、Lyapunov 优化或图神经网络以增强策略稳定性和约束满足能力^[48]；另一类工作则开始尝试将大模型或语义先验用于任务卸载与资源配置，以降低策略设计复杂度并增强策略泛化性^[38]。这些新进展说明，任务层计算卸载已经从单纯的动作选择问题，演化为环境表征、策略学习与结构先验联合驱动的问题。

从技术关系看，联邦学习与深度强化学习并不是相互替代，而更适合作为“环境感知—策略决策”的组合框架：前者利用多节点历史数据训练环境相关模型，后者利

用当前状态进行在线序贯决策。对本文所研究的任务层问题而言，这种组合既符合天基网络“数据分布分散、环境动态复杂”的特点，也为后续构建基于联邦学习与深度强化学习的分布式卸载方法提供了理论基础。

2.3 系统建模与双层问题描述

在前文场景分析与技术基础之上，本节构建面向天基网络计算卸载的完整数学建模框架，并对双层智能管控问题进行形式化描述，为后续章节的方法设计提供统一的符号体系与问题接口。

2.3.1 系统模型

符号约定与整体架构。除特殊说明外，下标 k 表示任务索引，下标 i, j 表示节点索引， n 表示任意候选执行节点； $\mathcal{N}$ 表示系统节点集合， $\mathcal{M}(t)$ 表示时刻 t 的任务集合， $\mathcal{L}(t)$ 表示时刻 t 的链路集合； T 与 E 分别表示时延与能耗相关量， $\mathcal{S}$ 与 Π 分别表示系统状态与决策策略。

本文考虑由卫星终端、卫星边缘节点与地面控制中心共同构成的天基网络协同计算系统，定义节点集合为

$$\mathcal{N} = \mathcal{N}_S \cup \mathcal{N}_E \cup \{n_{CC}\}, \quad (2.1)$$

其中 $\mathcal{N}_S$ 、 $\mathcal{N}_E$ 分别表示终端节点集合与卫星边缘节点集合， n_{CC} 表示地面控制中心。由于低轨卫星持续运动，将系统在时刻 t 的拓扑抽象为动态图

$$\mathcal{G}(t) = (\mathcal{N}, \mathcal{L}(t)), \quad (2.2)$$

以统一刻画节点连通关系与资源状态的时变演化。

节点计算资源与服务状态。设节点 n 的标称处理能力为 $f_n^{\max}$ ，时刻 t 的资源占用率为 $\rho_n(t) \in [0, 1)$ ，则当前可分配的有效算力为

$$f_n(t) = (1 - \rho_n(t)) f_n^{\max}. \quad (2.3)$$

考虑到并非所有卫星在任意时刻均部署有目标服务，引入服务可用状态变量 $\sigma_n^{(r)}(t) \in \{0, 1\}$ ，其中 $\sigma_n^{(r)}(t) = 1$ 表示节点 n 在时刻 t 已部署任务类型 r 所需的服务实例。该变量显式刻画了系统层服务部署与任务层卸载之间的耦合：即便节点算力充足，若目标

服务未就绪，仍需承担服务拉起、迁移或远端转发的额外代价^[39,42]。

链路模型与可见性约束。定义节点 n_i 与 n_j 在时刻 t 的可见性变量为

$$\phi_{ij}(t) = \begin{cases} 1, & \text{若两节点在时刻 } t \text{ 可建立有效通信链路} \\ 0, & \text{否则.} \end{cases} \quad (2.4)$$

在链路可见的前提下，记节点间可用带宽为 $B_{ij}(t)$ ，传播时延为 $D_{ij}^{\text{prop}}(t)$ ，链路剩余可见窗口为 $\tau_{ij}(t)$ 。其中 $\tau_{ij}(t)$ 构成卸载可行性的硬约束：若任务在窗口内无法完成数据交互，则该链路对应的卸载动作应从候选集中剔除。链路状态因此既决定通信代价，也直接界定可行动作空间。

2.3.2 任务模型与代价建模

任务属性定义。设时刻 t 的任务集合为 $\mathcal{M}(t) = \{m_1, \dots, m_{M(t)}\}$ 。对任一任务 m_k ，定义其属性六元组为

$$m_k = (L_k, W_k, T_k^{\max}, p_k, s_k, r_k), \quad (2.5)$$

其中 L_k 为输入数据量， W_k 为计算工作量， $T_k^{\max}$ 为最大可容忍时延， p_k 为调度优先级， s_k 为源节点， r_k 为服务依赖类型。该六元组从通信、计算、QoS 与服务依赖四个维度统一刻画了任务特征，并通过 r_k 与系统层服务状态 $\sigma_n^{(r)}(t)$ 建立直接关联。

卸载决策变量。本文考虑本地执行、卸载至卫星边缘节点以及卸载至地面控制中心三种执行方式，引入统一决策变量

$$x_k \in \{0\} \cup \mathcal{N}_E \cup \{n_{\text{CC}}\}, \quad (2.6)$$

其中 $x_k = 0$ 表示本地执行， $x_k = e_j$ 表示卸载至边缘节点 e_j ， $x_k = n_{\text{CC}}$ 表示卸载至地面中心。若任务存在服务依赖，则 $x_k = e_j$ 时还需满足 $\sigma_{e_j}^{(r_k)}(t) = 1$ ，否则将产生额外部署或转发代价。

通信时延模型。任务 m_k 从源节点 s_k 上传至目标节点 n_j 的传输时延为

$$T_{s_k, j}^{\text{trans}}(k, t) = \frac{L_k}{B_{s_k, j}(t)} + D_{s_k, j}^{\text{prop}}(t), \quad (2.7)$$

结果回传时延为

$$T_{j, s_k}^{\text{back}}(k, t) = \frac{L_k^{\text{out}}}{B_{j, s_k}(t)} + D_{j, s_k}^{\text{prop}}(t). \quad (2.8)$$

对于跨星转发场景，以端到端等效带宽 $\hat{B}_{s_k j}(t)$ 和等效传播时延 $\hat{D}_{s_k j}^{\text{prop}}(t)$ 替代多跳展开，保持表达式结构统一。此外，链路窗口硬约束要求

$$\frac{L_k}{B_{s_k j}(t)} \leq \tau_{s_k j}(t), \quad (2.9)$$

否则该链路在当前时刻不构成可行卸载路径。

计算时延模型。不考虑并发干扰时，任务 m_k 在节点 n 上的基础执行时延为

$$T_{n, \text{base}}^{\text{exec}}(k) = \frac{W_k}{f_n(t)}. \quad (2.10)$$

实际场景中，排队积压、CPU 争用、缓存冲突和调度扰动会导致执行时延偏离基础值。考虑到星上资源受限、任务异构且调度策略多样，直接采用封闭排队解析模型（如 M/G/1 队列）往往难以准确刻画实际波动，且会将建模过早绑定于强分布假设。因此，本文将上述多种并发干扰的综合影响统一抽象为附加时延项 $\Delta_n(k, t)$ ，实际执行时延写为

$$\tilde{T}_n^{\text{exec}}(k, t) = T_{n, \text{base}}^{\text{exec}}(k) + \Delta_n(k, t), \quad (2.11)$$

其中 $\Delta_n(k, t) \geq 0$ 是依赖节点实时状态与并发任务集合的随机量，可由历史样本估计并通过联邦学习感知，为后续“代价建模—策略决策”耦合框架预留接口^[46-47]。综合三种执行模式，端到端总时延统一表示为

$$T_k^{\text{total}} = \begin{cases} \tilde{T}_{s_k}^{\text{exec}}(k, t), & x_k = 0, \\ T_{s_k, e_j}^{\text{trans}}(k, t) + \tilde{T}_{e_j}^{\text{exec}}(k, t) + T_{e_j, s_k}^{\text{back}}(k, t), & x_k = e_j, \\ T_{s_k, n_{\text{CC}}}^{\text{trans}}(k, t) + \tilde{T}_{n_{\text{CC}}}^{\text{exec}}(k, t) + T_{n_{\text{CC}}, s_k}^{\text{back}}(k, t), & x_k = n_{\text{CC}}. \end{cases} \quad (2.12)$$

能耗模型。能耗从任务发起终端的视角衡量。本地执行时，计算能耗为

$$E_n^{\text{comp}}(k) = \kappa_n W_k (f_n(t))^2, \quad (2.13)$$

其中 κ_n 为单位计算能耗系数。选择卸载时，终端承担上传传输能耗

$$E_{ij}^{\text{trans}}(k, t) = P_{ij}^{\text{tx}} \cdot T_{ij}^{\text{trans}}(k, t), \quad (2.14)$$

以及等待结果回传期间的空闲监听能耗

$$E_{s_k}^{\text{idle}}(k, t) = P_{s_k}^{\text{idle}} \cdot \left(\tilde{T}_n^{\text{exec}}(k, t) + T_{n, s_k}^{\text{back}}(k, t) \right). \quad (2.15)$$

综合两者，任务总能耗为

$$E_k^{\text{total}} = \begin{cases} E_{s_k}^{\text{comp}}(k), & x_k = 0, \\ E_{s_k, e_j}^{\text{trans}}(k, t) + E_{s_k}^{\text{idle}}(k, t), & x_k = e_j, \\ E_{s_k, n_{\text{CC}}}^{\text{trans}}(k, t) + E_{s_k}^{\text{idle}}(k, t), & x_k = n_{\text{CC}}. \end{cases} \quad (2.16)$$

本地执行能耗随算力需求非线性增长（正比于 f_n^2 ），而卸载执行能耗主要由传输与等待时长决定，与链路条件和目标节点负载紧密耦合，两类代价结构的本质差异为后续策略对比提供了统一基准。

2.3.3 双层智能管控问题形式化描述

系统层资源协同问题。系统层以全局视角运行，目标不是最小化单一任务的瞬时代价，而是在动态拓扑与异构资源约束下持续提升资源利用效率、负载均衡水平和服务稳定性。将时刻 t 的全局状态记为

$$\mathcal{S}^{\text{sys}}(t) = \{\rho_n(t), f_n(t), \sigma_n^{(r)}(t), \phi_{ij}(t), B_{ij}(t), Q_n(t)\}, \quad (2.17)$$

以 $U(t)$ 、 $L(t)$ 、 $R(t)$ 分别表示资源利用率、负载均衡度和系统稳定性，系统层优化目标为

$$\max_{\Pi_{\text{sys}}} \mathbb{E} \left[\sum_t (\lambda_1 U(t) + \lambda_2 L(t) + \lambda_3 R(t)) \right], \quad (2.18)$$

其中 $\lambda_1, \lambda_2, \lambda_3$ 为权重系数。该问题本质上是一个面向长期收益的动态协同优化问题，适合采用多智能体强化学习与两时间尺度优化框架求解^[39,42,47]。

任务层计算卸载问题。任务层聚焦于单任务在给定环境下的实时执行位置选择，目标是在满足 QoS 约束的前提下降低综合代价。定义任务 m_k 的观测状态为

$$\mathcal{S}_k^{\text{task}}(t) = \{L_k, W_k, T_k^{\text{max}}, p_k, r_k, \mathcal{C}_k(t)\}, \quad (2.19)$$

其中 $\mathcal{C}_k(t) = \{f_n(t), \sigma_n^{(r_k)}(t), \phi_{s_k n}(t), B_{s_k n}(t), Q_n(t)\}_{n \in \mathcal{N}_E \cup \{n_{\text{CC}}\}}$ 为当前所有候选节点的环境上下文。任务综合代价函数为

$$J_k = \omega_T \cdot \frac{T_k^{\text{total}}}{T_k^{\text{max}}} + \omega_E \cdot \frac{E_k^{\text{total}}}{E_k^{\text{budget}}}, \quad (2.20)$$

任务层目标即为在动态环境中学习策略 Π_{task} ，使长期平均综合代价最低。

统一优化目标与约束条件。综合两层，本文研究问题的统一形式为

$$\min_{\Pi_{\text{sys}}, \Pi_{\text{task}}} \eta_1 \mathcal{J}_{\text{sys}} + \eta_2 \sum_{m_k \in \mathcal{M}(t)} J_k, \quad (2.21)$$

其中 η_1, η_2 为两层目标权重。该问题需满足以下约束：

1. 卸载可行性约束： $x_k \in \{0\} \cup \mathcal{N}_E \cup \{n_{\text{CC}}\}$;
2. 链路可达性约束：卸载至节点 n_j 时需满足 $\phi_{s_k j}(t) = 1$;
3. 服务可用性约束：卸载至边缘节点 e_j 时需满足 $\sigma_{e_j}^{(r_k)}(t) = 1$ ，或额外计入服务部署/迁移代价，该约束将系统层服务状态直接耦合至任务层可行动作集合；
4. 计算资源容量约束： $\sum_{m_k \in \mathcal{M}_n(t)} f_{n,k}(t) \leq f_n^{\text{max}}$;
5. 链路带宽约束： $\sum_{m_k \in \mathcal{M}_{ij}(t)} b_{ij}^{(k)}(t) \leq B_{ij}(t)$;
6. 任务时延约束： $T_k^{\text{total}} \leq T_k^{\text{max}}$;
7. 任务能耗约束： $E_k^{\text{total}} \leq E_k^{\text{budget}}$ 。

上述约束从动作合法性、物理可达性、服务依赖、资源容量与 QoS 五个层面共同界定了问题的可行解空间。

两层问题的关联关系。系统层与任务层在时间尺度上存在差异——前者关注秒级至分钟级的长期资源演化，后者关注毫秒级的即时任务决策——但两者通过双向耦合形成闭环。一方面，系统层通过资源分布、服务部署和负载均衡塑造任务层的决策环境：系统运行稳定时，任务层更易选到优质执行节点；反之，若服务部署滞后或节点过载，任务层的局部最优选择也可能因目标节点不可用而退化。另一方面，任务层的每次卸载动作均会改变节点负载与链路占用，这些局部行为在时间上累积后反过来重塑系统层的资源格局，例如大量终端集中卸载至同一卫星会诱发热点并触发服务重部署^[39,42]。由此，两层之间形成如下反馈闭环：

$$\mathcal{S}^{\text{sys}}(t) \rightarrow \mathcal{S}_k^{\text{task}}(t) \rightarrow x_k \rightarrow \mathcal{S}^{\text{sys}}(t+1). \quad (2.22)$$

这一结构决定了两层既不能完全解耦，也不宜合并为单一超大规模问题，而应通过分层协作的智能管控架构兼顾全局长期收益与局部即时性能。本文后续章节将沿此逻辑分别展开系统层与任务层的方法研究。

2.4 本章小结

本章围绕天基网络计算卸载问题，系统构建了关键技术基础、系统模型与问题描述框架。首先，从 NTN、OEC 和卫星边缘智能的发展趋势出发，分析了低轨卫星协同计算环境下的动态拓扑、异构节点与资源受限特征，明确了天基网络正在由“通信支撑平台”向“通算智融合平台”演进^[30-31,33]。其次，围绕计算卸载、轨道边缘计算、可信状态同步、多智能体强化学习以及联邦学习与深度强化学习等关键技术，梳理了本文后续方法设计所依赖的理论基础，并结合 2024–2026 年代表性研究归纳了当前研究主线与趋势^[39,42-43,46,50]。

在此基础上，本章建立了系统模型、任务模型以及通信时延、计算时延（含并发附加扰动）、终端能耗等代价模型，并将研究问题形式化为由系统层资源协同与任务层计算卸载共同构成的双层智能管控问题。通过明确约束条件的物理意义和两层问题的反馈闭环结构，本章清晰揭示了该问题由通信、计算、服务部署与资源竞争多维耦合的本质特征，为第三章的系统层协同优化方法和第四章的任务层分布式卸载策略提供了统一的问题描述基础与数学建模接口。

第3章 基于区块链与多智能体强化学习的天基计算网络协同资源分配方法

随着天基计算网络的规模化部署，分布式资源协同调度已成为支撑在轨实时任务处理的核心瓶颈。在无全局中心协调者的去中心化环境中，异构计算节点受自身效用最大化的理性决策驱动，往往倾向于争抢高价值任务、回避低收益负载，进而引发“单节点最优、系统全局劣化”的公地悲剧困境。这一困境在节点能力高度异构、任务到达过程非平稳、星间链路带宽受限等多维复杂性的耦合叠加下进一步加剧，导致传统集中式优化方法与简单启发式策略均难以有效适配。

针对上述挑战，本章将系统层协同资源分配问题建模为多智能体马尔可夫博弈，在理论上刻画节点间竞争—合作并存的交互结构，并提出一种区块链增强的集中训练—分散执行（Centralized Training and Decentralized Execution, CTDE）多智能体强化学习框架。该框架以联盟链作为“公共博弈信息板”，在保障去中心化自治的同时，实现全局状态的可信共享与策略审计；在奖励机制层面，设计融合任务完成质量、系统公平性与信誉激励的三维混合奖励函数，引导自利节点在纳什均衡方向上趋近社会最优。本章通过多场景仿真实验，从收敛性、负载均衡、任务完成率及抗自私攻击能力等维度验证所提方法的有效性与鲁棒性，为后续章节中服务层与任务层的协同优化奠定系统层基础。与近年来卫星边缘计算中的多智能体卸载研究相比，本章更强调“可信共享 + 博弈求解 + 信誉治理”的统一闭环^[1-3]。

3.1 引言

随着低轨卫星互联网、在轨智能处理与星间协同计算的发展，天基计算网络正在从“以通信为主”的基础设施演化为“通信、计算、存储、智能处理一体化”的分布式服务平台。不同轨道层、不同载荷能力以及不同链路条件的卫星节点，通过时变星间链路构成动态互联的在轨计算网络，共同承担遥感影像预处理、目标检测、轨道态势分析、数据压缩转发、任务规划等多类任务。与传统“先回传、后处理”的地面中心化模式相比，这种在轨协同处理方式能够显著降低原始数据的大规模回传压力，缩短任务响应路径，并提高系统在时敏型任务下的自主运行能力。因此，系统是否能够对异构节点进行高效、可信、持续的协同资源分配，已成为影响网络整体服务能力的关键

基础问题。

然而，天基计算网络与地面云边协同系统相比存在更加突出的资源受限性和环境不确定性。首先，卫星节点的计算能力、可用存储、剩余能量和热控条件天然受限，无法简单通过横向扩容方式缓解局部过载；其次，星间链路的建立与维持高度依赖可见关系、轨道位置和瞬时拥塞状态，导致网络拓扑和通信条件持续变化；再次，任务负载并非平稳到达，不同类型任务在计算量、数据规模和时延约束上差异显著，突发重型任务常常会在短时间内形成局部瓶颈。也就是说，天基协同资源分配并不是一个静态的资源映射问题，而是一个伴随任务到达、资源消耗、链路波动和节点行为演化不断变化的连续序贯决策问题。

更为重要的是，该问题通常发生在缺乏长期稳定全局协调者的去中心化环境中。任一节点只能直接掌握本地高频状态，而对远端节点的任务队列、资源占用、信誉水平和协作意愿，通常只能通过有限的公共摘要进行间接感知。在这种条件下，节点天然会优先追求本地效用最大化，例如优先保障本地高价值任务、拒绝低收益协作、选择性接纳外部卸载任务，甚至通过策略性上报影响任务流向。由此带来的后果是：能力强节点被高收益任务持续吸引而逐渐拥塞，能力弱节点则因为处理效率低或协作收益不足而长期闲置，最终诱发“局部理性—全局失衡”的公地悲剧。可见，第三章要解决的核心矛盾，并不只是“如何更快地做调度”，而是“如何在去中心化、自利行为和信息不完全共存条件下维持持续协同”。

现有研究在面对这一类问题时，往往存在三方面不足。第一类方法依赖集中式全局优化，假设系统能够实时收集所有节点的完整状态，并据此统一求解全局最优调度策略。这类方法在小规模、静态网络中具有一定理论优势，但在天基网络中往往面临状态同步代价高、链路时延大、全局视图易过期等现实障碍。第二类方法采用启发式或局部规则进行分布式调度，其优点是实现简单、开销较低，但由于缺乏对多节点长期博弈关系和系统级公平性的统一刻画，通常只能在局部场景下取得较好的即时效果。第三类方法引入强化学习进行自适应策略求解，但若仍以单智能体视角建模，便会把其他节点的策略变化等价为环境扰动，难以准确表达多主体之间“策略—环境”双向耦合的本质。

因此，要有效解决天基协同资源分配问题，至少需要回答三个层面的研究问题：其一，如何以统一的动态博弈模型刻画多个异构节点之间兼具竞争与合作特征的长期交互关系；其二，在缺乏中心协调者的条件下，如何使节点获得可信且可审计的系统

级上下文，避免完全依赖不可靠的私有感知；其三，如何设计兼顾任务处理效率、全局公平性与长期协作意愿的激励机制，使节点在追求自身长期回报的同时逐步逼近系统总体更优的协同状态。这三个问题分别对应“建模”“共享”“治理”三个层面，也是本章方法设计的主线。

基于上述认识，本章提出一种区块链增强的集中训练—分散执行多智能体强化学习框架 BC-CTDE-MAPPO。其核心思想是：以联盟链作为系统级可信公共信息板，实现全局状态摘要、信誉信息与策略行为的可验证共享；以多智能体马尔可夫博弈统一刻画异构节点之间的竞争—合作关系；以集中训练—分散执行机制支持训练阶段的全局价值评估和执行阶段的局部自治决策；并通过混合奖励设计把任务完成质量、系统公平性和信誉激励耦合进同一学习闭环，从而在不依赖中心调度器的条件下，引导自利节点逐步收敛到更接近系统最优的协同策略。与现有仅强调“提高吞吐量”或“降低时延”的调度方法相比，本章更强调“可信共享 + 博弈求解 + 信誉治理”的统一闭环，这也是它与后续服务层、任务层优化章节之间的重要衔接点。

从全文结构来看，第三章承担的是“系统层协同基础”的角色。后续章节中，无论是服务级协同还是任务级实时卸载，都需要建立在一个能够稳定共享状态、约束自利行为、维持长期负载均衡的系统层机制之上。因此，本章并不直接关注单个任务在微观时间尺度上的最优执行，而是从更宏观的系统层角度，回答“多个理性节点如何在长期运行中形成可信协同关系”这一更基础的问题。只有这一层机制成立，后续章节中的更细粒度卸载、预测和调度方法才具备可落地的运行前提。

图 3.1 从问题层面说明了本章研究对象的本质差异：在缺乏协调机制时，多个节点会同时追逐少量高收益任务，导致热点拥塞与资源浪费并存；而在可信共享与协同激励共同作用下，节点可形成更合理的任务分工、资源补偿与风险分摊关系，从而提升任务完成率、负载均衡度和长期运行稳定性。这一差异并不是简单的“调度策略优劣”问题，而是系统是否具备可靠公共上下文、是否存在长期激励约束、以及节点是否能够在动态环境中形成稳定协作关系的综合体现。

本章后续内容按照“系统框架—博弈建模—算法求解—实验验证”的逻辑展开。第 3.2 节首先给出系统参与者、联盟链公共信息板与协同流程的整体框架；第 3.3 节在此基础上建立多智能体马尔可夫博弈模型；第 3.4 节介绍区块链增强的 CTDE 多智能体强化学习求解方法；第 3.5 节通过多场景仿真实验验证所提方法在收敛性、负载均衡、任务完成率及抗自私行为方面的有效性；最后在第 3.6 节进行本章总结。




图 3.1 天基协同资源分配中局部自利与全局协同差异示意

3.2 系统框架概述

为使后续建模与算法推导建立在清晰一致的系统图景之上，本节首先从系统组成、信息流转和协同目标三个方面，对本章所研究的天基协同资源分配框架进行概述。相较于直接进入公式化建模，这种“先框架、后抽象”的展开方式，更有助于说明各类状态、动作、奖励与联盟链要素在系统中的实际来源与功能定位。

3.2.1 系统组成与角色划分

本章考虑的天基计算网络由四类核心参与者共同构成：执行在轨任务的异构计算节点、负责状态记账与摘要广播的联盟链节点、承担本地调度与协同决策的智能体模块，以及在训练阶段负责全局价值评估的集中式训练协调器。四者既分工明确，又通过任务流、状态流与信誉流形成紧密耦合。

第一类参与者是**异构计算节点**。它们分布在不同轨道层和不同星座拓扑位置上，具备差异化的计算、存储、能量和通信能力，是在轨任务执行的直接承担者。对系统而言，每个节点既可能处理本地生成的任务，也可能接收其他节点卸载而来的任务，因此天然兼具“任务生产者”和“任务处理者”双重身份。

第二类参与者是**联盟链节点**。它们共同维护系统级公共摘要，包括节点负载、信誉评分、链路统计与历史行为记录等信息。联盟链并不替代实时调度器，而是充当“可信公共信息板”：一方面为各节点提供可审计、可验证、可追溯的系统级上下文；另一方面通过链上信誉累积和行为留痕机制，为后续的激励约束提供可信依据。

第三类参与者是**局部决策智能体**。每个计算节点内部均部署一个策略模块，依据本地私有状态与链上公共摘要联合决定任务是否本地执行、向哪个邻居卸载、投入多少本地资源以及是否接收外部任务。由于执行阶段无法依赖中心控制器，各节点必须具备在部分可观测条件下独立做出近实时决策的能力。

第四类参与者是**集中训练协调器**。它只在训练阶段存在，用于整合联合状态和联合动作，对多智能体策略进行价值评估与参数更新；在实际执行阶段，各节点仅保留各自的局部 Actor 网络，实现分散执行。这样的结构兼顾了训练阶段的信息利用效率与执行阶段的去中心化自治要求。

图 3.2 给出了本章方法的整体层次结构。最上层为任务与资源环境层，描述任务持续到达、节点异构与链路变化等系统事实；中间层为联盟链公共信息板，负责对全局状态摘要、信誉演化与关键决策结果进行可信记录与广播；底层为各异构节点上的




图 3.2 第三章协同资源分配框架的层次结构与信息流

局部智能体，它们依据”本地观测 + 链上摘要”进行协同调度决策。训练阶段，集中式价值评估器通过汇聚联合信息更新策略参数；执行阶段，节点仅凭局部观测自主运行，从而形成”集中训练—分散执行”的闭环。

3.2.2 联盟链公共信息板与协同流程

在上述系统组成基础上，本章将协同资源分配过程组织为一个持续循环的闭环流程。不同于传统中心调度模式中”中心收集全局状态—中心下发动作”的单向控制链条，本章方法强调由联盟链维持公共上下文，由节点完成局部决策，再将执行反馈重新写回系统，从而实现可信共享与自主协同的统一。

具体而言，该协同流程可以概括为以下五个步骤。首先，**任务到达与本地感知**：当节点感知到新任务到达时，实时更新本地队列长度、CPU/内存利用率、剩余能量和当前工作负载等高频状态。其次，**链上摘要获取**：节点从联盟链读取全局平均负载、负载方差、链路统计、信誉评分和链上时延估计等低频但可信的公共摘要，用以补充局部感知中难以直接获得的系统级信息。再次，**局部协同决策**：策略网络基于”本地私有状态 + 链上公共摘要”输出卸载目标、资源分配比例和接收意愿等动作，并作用于当前节点。随后，**执行反馈与信誉更新**：动作执行后，系统会获得任务完成情况、平均时延、能耗、负载变化和协作质量等反馈，并据此更新节点信誉和系统负载摘要。最后，**链上记账与参数迭代**：联盟链将关键行为结果与信誉变化写入账本，在训练阶段进一步服务于全局价值评估和参数更新，在执行阶段则为下一轮协同决策提供新的

可信上下文。




图 3.3 基于联盟链公共信息板的任务—状态—信誉闭环协同流程

图 3.3 强调了三个关键闭环：一是”任务到达—局部决策—执行反馈”的任务闭环，决定了系统的实时响应能力；二是”状态汇总—链上广播—节点读取”的信息闭环，决定了多节点之间能否在缺乏中心调度器的情况下获得统一的协同上下文；三是”协作行为—信誉变化—后续激励”的治理闭环，决定了系统能否对长期自利与机会主义偏离形成可持续约束。三者共同构成了本章后续博弈建模与强化学习求解的系统基础。

3.2.3 建模目标与协同难点

在上述框架下，本章关注的核心问题可以概括为：当任务持续动态到达系统后，多个异构节点如何在不依赖中心调度器的条件下，联合决定任务由谁处理、何时处理、是否接纳外部卸载以及投入多少本地资源，使系统整体在任务完成率、平均时延、能耗开销、负载均衡和协同可信性之间取得更优平衡。换言之，本章研究的不是静态任务指派问题，而是一个随任务流、资源状态、链路关系和信誉轨迹不断演化的多主体序贯决策问题。

这一问题之所以困难，主要来自四类耦合难点。其一是**资源异构与收益非一致性**：相同任务在不同节点上的执行代价、完成收益和机会成本并不相同，局部最优动作往往会诱导全局失衡。其二是**任务到达与链路状态的时变性**：任务负载具有突发与长尾特征，链路可用性则随轨道位置和拥塞条件动态变化，使得调度策略必须具备在线适应能力。其三是**可信共享信息的时效性约束**：联盟链提供了可验证的系统级上下文，但链上信息同步本身存在时延，节点决策必须同时考虑”信息可信”与”信息陈旧”两种因素。其四是**自利行为与长期治理问题**：节点会根据局部收益结构动态调整行为，若缺少信誉约束和公共审计机制，系统容易重新滑向任务热点聚集与协作退化。

因此，从方法论角度看，后续建模必须同时满足三点要求：一是能够刻画多节点之间”策略—环境”双向耦合的动态交互；二是能够把联盟链提供的可信公共摘要纳入状态建模与激励设计；三是能够在训练阶段充分利用联合信息、在执行阶段保持局部自治。基于这一认识，下一节将进一步把上述系统框架形式化为多智能体马尔可夫博弈模型，并为后续的区块链增强 CTDE 求解方法奠定数学基础。

3.3 基于多智能体马尔可夫博弈的协同资源分配模型

第 3.2 节已经从系统组成、联盟链公共信息板与任务—状态—信誉闭环流程三个方面，建立了本章方法的整体框架，并指出该问题的核心困难不仅在于组合优化层面的计算压力，更在于多个理性决策主体在信息不对称、利益冲突和长期收益耦合条件下的策略交互。由此可见，若仅依赖集中式全局优化方法，虽然理论上能够给出某种最优解，但其对全局信息实时可获取性的要求与天基网络固有的去中心化约束形成根本矛盾；若采用单智能体马尔可夫决策过程（MDP），又会将其他节点的策略变化等价地视为环境扰动，从而无法刻画多节点之间”策略—环境”双向耦合的本质。因此，本文选择以多智能体马尔可夫博弈（Multi-Agent Markov Game, MAMG）作为系统层协同资源分配的统一建模框架，并在此基础上进一步引入区块链公共信息板与信誉驱动机制，使抽象博弈模型能够在去中心化场景中落地执行。

3.3.1 建模动机与博弈形式化

在将协同资源分配问题映射到数学框架之前，有必要首先说明为何采用马尔可夫博弈而非标准形式博弈或重复博弈。标准形式博弈仅适用于一次性策略选择，无法表达资源状态随时间演化的序贯特征；重复博弈虽考虑多轮交互，但默认每一轮都在相同阶段博弈上重复进行，并不显式刻画系统状态随联合动作变化而转移的机制。然而，在天基计算网络中，任何一次任务卸载决策都会改变后续时刻的队列长度、资源占用率、链路可用性与信誉演化轨迹，即当前动作会通过状态转移持续影响未来收益。因此，该问题本质上是一个多主体、序贯式、状态相关的动态博弈问题。

基于上述认识，本文将 N 个异构边缘计算节点的协同调度问题形式化为如下七元组：

$$\mathcal{G} = \langle N, S, \{A^i\}, P, \{R^i\}, \gamma, \{O^i\} \rangle, \quad (3.1)$$

其中, N 表示智能体集合, S 表示全局状态空间, A^i 表示节点 i 的动作空间, P 表示联合状态转移函数, R^i 表示节点 i 的即时奖励函数, $\gamma \in [0, 1)$ 为折扣因子, O^i 表示局部观测函数。

需要特别指出的是, 天基计算网络并不满足完全信息博弈假设。受限于星间链路的间歇连通性、有限带宽和状态同步代价, 任何单个节点都不可能实时获得所有远端节点的完整原始状态。因此, 本文将该问题进一步建模为部分可观测的多智能体马尔可夫博弈。对节点 i 而言, 其在时刻 t 的观测表示为

$$o_t^i = O^i(s_t), \quad (3.2)$$

其中 s_t 表示时刻 t 的全局状态, o_t^i 属于节点 i 的局部观测空间 Ω^i 。相应地, 每个节点维护一个随机化策略 $\pi^i : \Omega^i \rightarrow \Delta(A^i)$, 并以最大化期望累积折扣回报为目标:

$$J^i(\pi^i, \pi^{-i}) = \mathbb{E} \left[\sum_t \gamma^t R^i(s_t, a_t^i, a_t^{-i}, s_{t+1}) \mid \pi^i, \pi^{-i} \right], \quad (3.3)$$

这里 π^{-i} 表示除节点 i 之外其余所有节点的联合策略。上述目标函数表明, 节点 i 的收益不仅取决于自身策略, 还显式依赖于其他节点的策略组合, 这也是单智能体强化学习框架难以直接适配该问题的根本原因。

从系统优化问题到多智能体马尔可夫博弈的建模推导路径



图 3.4 从系统优化问题到多智能体马尔可夫博弈的建模推导路径

3.3.2 状态、动作与奖励机制设计

在明确了博弈形式之后, 接下来需要回答一个更具体的问题: 节点究竟基于什么信息决策、能够采取哪些行动, 以及系统希望通过何种奖励塑形引导节点从个体理性走向集体理性。对此, 本文分别从状态空间、动作空间和奖励机制三个层面进行设计。

首先, 在状态空间设计上, 需要在”信息充分性”和”维度可控性”之间取得平衡。

若观测过于贫乏，节点将因缺乏必要上下文而难以形成有效策略；但若直接纳入过多原始任务级信息，又会导致状态维度膨胀，增加训练难度与通信开销。为此，本文将节点 i 在时刻 t 的观测结构化分为“本地私有状态 + 链上公共摘要”两部分：

$$o_t^i = (l_t^i, g_t), \quad (3.4)$$

其中，本地私有状态 l_t^i 由节点自行采集，表示为

$$l_t^i = (Q_t^i, \rho_{\text{cpu}}^i(t), \rho_{\text{mem}}^i(t), E_t^i, h_i, w_t^i), \quad (3.5)$$

这里 Q_t^i 为本地队列长度， $\rho_{\text{cpu}}^i(t)$ 和 $\rho_{\text{mem}}^i(t)$ 分别为 CPU 与内存利用率， E_t^i 表示剩余能量预算或累计能耗， h_i 为节点静态硬件特征向量， w_t^i 概括当前工作负载信息。另一方面，链上公共摘要 g_t 由联盟链周期性聚合并广播，表示为

$$g_t = (\bar{L}_t, \sigma_L^2(t), D_t^{\text{task}}, R_t^{\text{rep}}, \hat{D}_{\text{chain}}(t), T_t^{\text{stat}}), \quad (3.6)$$

其中 $\bar{L}_t$ 表示全局平均负载， $\sigma_L^2(t)$ 表示负载方差， D_t^{task} 为任务分布摘要， R_t^{rep} 为信誉评分向量， $\hat{D}_{\text{chain}}(t)$ 为链上同步延迟估计， T_t^{stat} 为吞吐量统计摘要。

表 3.1 链上公共摘要分量说明

分量	名称	说明
$\bar{L}_t$	全局平均负载	所有节点队列长度的加权均值，反映系统整体繁忙程度
$\sigma_L^2(t)$	负载方差	各节点负载的离散程度，衡量系统均衡性
D_t^{task}	任务分布摘要	各类型任务在网络中的分布统计，用于感知业务结构变化
R_t^{rep}	信誉评分向量	各节点的链上信誉评分，反映历史行为质量
$\hat{D}_{\text{chain}}(t)$	链上延迟估计	共识与数据同步的当前延迟估计值，用于补偿信息滞后
T_t^{stat}	吞吐量统计	近期各节点及系统整体吞吐量的滑动统计，用于辅助协同判断

值得注意的是， R_t^{rep} 为信誉约束提供了可信输入，而 $\hat{D}_{\text{chain}}(t)$ 的显式纳入使节点能够感知当前信息时效性，并在策略中对链上同步滞后进行自适应补偿。

其次，在动作空间设计上，原始调度决策天然包含离散与连续两类分量：节点既要决定任务是本地执行还是卸载给哪个邻居，也要决定本地资源分配比例以及是否愿

意接收外部任务。若直接将”逐任务优先级向量”作为动作输出，其维度会随队列长度变化，不利于神经网络策略表示与训练稳定性。因此，本文采用固定维混合动作表示：

$$a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i), \quad (3.7)$$

其中 $a_{\text{off},t}^i$ 表示卸载目标选择， $a_{\text{res},t}^i \in [0, 1]$ 表示本地资源分配比例， $a_{\text{acc},t}^i \in [0, 1]$ 表示接收外部任务的意愿系数。对于本地队列内部的细粒度排序，本文不再将其直接作为策略网络输出，而是通过一个基于任务时延约束、计算量和信誉补偿的规则化排序器在节点本地生成。这样既能保持 Actor 输出维度固定，又实现了”高层学协同、低层做排序”的结构化解耦。

最后，在奖励机制设计上，若仅以本地吞吐或完成收益作为奖励，节点策略将自然倾向于争抢高价值任务并规避低收益协作，从而重演前文所分析的公地悲剧。为此，本文构建融合效率、公平与可信性的三维混合奖励函数：

$$r_t^i = w_q r_{q,t}^i + w_f r_{f,t}^i + w_c r_{c,t}^i, \quad (3.8)$$

其中 $w_q, w_f, w_c \geq 0$ 且 $w_q + w_f + w_c = 1$ 。效率项用于刻画节点自身任务处理质量，可写为

$$r_{q,t}^i = \alpha_1 \text{Succ}_t^i - \alpha_2 \text{Delay}_t^i - \alpha_3 \text{Energy}_t^i, \quad (3.9)$$

其中 Succ_t^i 为成功完成任务数， Delay_t^i 为平均完成时延， Energy_t^i 为单位时间能耗。公平项用于引导系统整体负载均衡，本文采用基于 Jain 公平指数的全局度量^[6]：

$$J_t = \frac{(\sum_i x_i(t))^2}{N \sum_i x_i^2(t)}, \quad (3.10)$$

其中 $x_i(t)$ 表示节点 i 的有效服务率或负载承担量，进而定义

$$r_{f,t}^i = J_t - \beta \max \{0, \rho_i(t) - \rho_{\text{th}}\}. \quad (3.11)$$

可信性项则将节点历史行为纳入激励闭环：

$$r_{c,t}^i = \gamma_1 \Delta \text{Rep}_i(t) - \gamma_2 \delta_i(t), \quad (3.12)$$

其中 $\Delta \text{Rep}_i(t)$ 表示信誉增量， $\delta_i(t)$ 表示负载偏差度。诚实上报与积极协同的节点将

获得正向激励，虚报状态和拒绝协作的节点则受到惩罚。

表 3.2 奖励权重与作用说明

权重	对应项	核心作用	默认值
w_q	效率项 r_q	保证任务完成率、时延与能耗三者的局部效率优化	0.5
w_f	公平项 r_f	抑制热点拥塞，提升系统负载均衡与长期稳定性	0.3
w_c	可信项 r_c	将信誉增量与负载偏差反馈到策略更新中，约束欺骗行为	0.2

3.3.3 约束条件与性质分析

作为一个面向真实天基计算网络的协同调度模型，上述博弈并非在抽象无限制环境中运行，而必须满足物理资源约束与通信可行性约束。对任意节点 i 而言，首先有基本的本地资源约束：

$$0 \leq a_{\text{res},t}^i \leq 1, \quad (3.13)$$

$$C_i^{\text{used}}(t) \leq C_i^{\text{max}}, \quad B_i^{\text{used}}(t) \leq B_i^{\text{max}}, \quad E_i^{\text{used}}(t) \leq E_i^{\text{cap}}, \quad (3.14)$$

其中 $C_i^{\text{used}}(t)$ 、 $B_i^{\text{used}}(t)$ 、 $E_i^{\text{used}}(t)$ 分别表示时刻 t 的计算资源占用、带宽占用和能量消耗。当节点选择执行卸载动作时，相应任务的数据传输量还必须满足链路带宽预算和可见窗口约束。本文在环境层通过动作可行性检查与不可行动作惩罚共同保证策略学习始终发生在物理可行域内。

在满足上述约束的前提下，还需要讨论模型在理论上的可解释性。需要说明的是，原始问题同时包含离散卸载选择与连续资源比例控制，严格意义上的全局均衡求解较为困难。因此，本文并不试图对原始离散—连续混合博弈给出过强的解析结论，而是在混合策略和连续松弛意义下给出两个性质说明。

定理 3.1（连续松弛下的均衡存在性） 在各智能体采用混合策略、奖励函数对联合策略连续，且连续动作空间为非空紧凸集的条件下，所构造的松弛博弈至少存在一个混合策略纳什均衡^[7]。

该结论可由 Glicksberg 不动点定理得到。需要强调的是，这里讨论的是连续松弛后的策略博弈，其意义在于说明本文设计的奖励结构与策略表示不会破坏均衡存在性，而非声称原始混合动作博弈在所有条件下都可直接解析求解。

定理 3.2（局部稳定性说明） 若在某一局部邻域内，联合策略更新可近似表示为对某个光滑潜在函数的上升过程，且学习率足够小，则策略迭代在该邻域内具有局部稳定性。

该性质为后续采用 MAPPO 求解提供理论直觉：通过将公平项与信誉项嵌入奖励函数，不同节点的局部优化方向在一定程度上得到对齐，从而减弱了纯竞争博弈中常见的剧烈震荡现象。这里给出的并非严格的全局收敛证明，而是对训练稳定性来源的性质解释。

在上述状态、动作、奖励与约束设计的基础上，本节已经回答了‘系统希望节点依据什么信息决策、能够采取哪些行动、以及为何通过混合奖励塑形来抑制公地悲剧’这三个核心问题。换言之，第 3.3 节完成的是**问题求解对象的数学抽象**：它把第 3.2 节中的系统角色、链上公共摘要与信誉治理机制统一映射为一个部分可观测、多主体、序贯式的动态博弈模型，并说明了该模型在物理可行域内的基本性质。

但仅有建模仍不足以直接落地到天基网络的在线协同决策。原因在于：第一，联合状态与联合动作维度随节点数量增长而迅速膨胀；第二，Actor 在执行阶段只能访问局部观测与链上摘要，不能依赖训练期的全局信息；第三，链上公共信息板虽然提供了可信共享与审计能力，但其时延、更新周期和信誉回写机制必须被纳入具体的学习与执行流程，才能真正转化为策略性能增益。因此，下一节将从”如何求解”而非”如何建模”的角度出发，把上述马尔可夫博弈进一步映射为区块链增强的集中训练一分散执行多智能体强化学习框架，并说明策略参数更新、链上共享、信誉反馈和在线部署之间的耦合关系。

3.4 区块链增强的多智能体协同资源分配算法设计

上一节从系统约束、局部观测、混合动作和三维奖励塑形四个方面完成了协同资源分配问题的博弈建模，但这仍停留在”优化目标与交互结构已被定义”的层面。要使该模型真正用于天基网络在线运行，还需要进一步解决两个实现性问题：其一，在多节点联合策略持续变化的条件下，如何缓解多智能体学习中的环境非平稳性；其二，链上公共摘要与信誉反馈如何嵌入参数更新与在线执行过程，而不是停留在建模假设中。基于此，本节从求解层面对第 3.3 节的博弈模型进行算法化实现，构建区块链增强的集中训练一分散执行多智能体强化学习框架 BC-CTDE-MAPPO。

该框架的核心思想是：在训练阶段，利用联合状态近似表示、链上公共摘要与全

局回报信号构造集中式 Critic，以降低多智能体环境中的策略漂移；在执行阶段，各节点仅保留本地私有状态与联盟链广播的可信摘要作为决策输入，维持去中心化自治；同时，链上公共信息板不仅提供系统级上下文，还承担信誉更新、行为审计与异常约束的反馈通道，使“可信共享—策略优化—治理回写”三者形成统一闭环。按照这一思路，本节依次介绍算法总体框架、混合动作策略与参数更新机制、区块链共享与信誉反馈机制，以及训练—执行一体化流程。

3.4.1 算法总体框架

设节点 i 的 Actor 参数为 θ_i ，共享 Critic 参数为 ϕ 。在时刻 t ，节点首先从本地环境与联盟链中读取观测 $o_t^i = (l_t^i, g_t)$ ，然后按照当前策略采样混合动作 $a_t^i = (a_{\text{off},t}^i, a_{\text{res},t}^i, a_{\text{acc},t}^i)$ 。环境执行联合动作 $a_t = (a_t^1, \dots, a_t^N)$ 后，更新任务队列、链路状态、能耗状态与信誉中间量，并将新的链上摘要写入公共信息板。随后，系统依据式 (3.8) 定义的三维奖励函数计算各节点即时回报 r_t^i ，并将交互轨迹存入 rollout 缓冲区。一个 rollout 周期结束后，集中训练模块基于联合轨迹估计优势函数并更新 Actor/Critic 参数。

其中，集中式 Critic 的输入为全局状态近似表示

$$s_t^{\text{ctr}} = (l_t^1, \dots, l_t^N, g_t), \quad (3.15)$$

输出价值估计 $V_\phi(s_t^{\text{ctr}})$ 。考虑到天基网络拓扑随时间动态变化，本文在状态编码阶段引入图结构聚合器，用于对邻接节点状态和链路关系进行表征学习。这样，一方面能够避免简单拼接带来的维度膨胀，另一方面也使价值网络具备对拓扑动态变化的敏感性。

上述总体框架强调的是“谁在什么阶段使用哪些信息完成何种功能”：集中式 Critic 负责在训练阶段吸收联合状态与联合动作中的耦合信息，局部 Actor 负责在执行阶段依据“本地观测 + 链上摘要”完成自治决策，而联盟链则持续提供可信上下文与行为留痕。接下来，本文进一步说明这一框架在参数层面如何被具体实现，即混合动作策略如何表示、优势函数如何构造，以及 Actor / Critic 如何在破坏去中心化执行约束的前提下完成稳定更新。




图 3.5 BC-CTDE-MAPPO 总体流程图

3.4.2 参数化策略与更新机制

由于动作同时包含离散卸载选择与连续资源控制两类分量，本文采用混合参数化 Actor。具体而言，对离散动作 $a_{\text{off},t}^i$ 输出 categorical 分布，对连续动作 $a_{\text{res},t}^i$ 和 $a_{\text{acc},t}^i$ 输出高斯分布参数，其联合策略可写为

$$\pi_{\theta}^i(a_t^i | o_t^i) = \pi_{\theta,d}^i(a_{\text{off},t}^i | o_t^i) \cdot \pi_{\theta,c}^i(a_{\text{res},t}^i, a_{\text{acc},t}^i | o_t^i). \quad (3.16)$$

其中连续分量经 sigmoid 映射后投影到 $[0, 1]$ 区间，以保证动作满足物理可行性约束。为了增强探索能力，训练初期在连续分量上保留较高的熵正则项，随后随训练过程逐步衰减。

在参数更新方面，本文沿用 PPO 的裁剪目标^[4-5,51]。对节点 i 定义策略比值

$$\rho_t^i(\theta_i) = \frac{\pi_{\theta_i}(a_t^i | o_t^i)}{\pi_{\theta_i^{\text{old}}}(a_t^i | o_t^i)}, \quad (3.17)$$

则其裁剪目标函数为

$$L_i^{\text{clip}}(\theta_i) = \mathbb{E}_t \left[\min \left(\rho_t^i(\theta_i) \hat{A}_t^i, \text{clip}(\rho_t^i(\theta_i), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^i \right) \right], \quad (3.18)$$

其中 $\hat{A}_t^i$ 为优势估计。本文采用广义优势估计（GAE）构造该项：

$$\hat{A}_t^i = \sum_{l=0}^{T-1} (\gamma \lambda)^l \delta_{t+l}^i, \quad \delta_t^i = r_t^i + \gamma V_{\phi}(s_{t+1}^{\text{ctr}}) - V_{\phi}(s_t^{\text{ctr}}). \quad (3.19)$$

Critic 则通过最小化时序差分误差进行更新：

$$L_V(\phi) = \mathbb{E}_t \left[\left(V_\phi(s_t^{\text{ctr}}) - \hat{V}_t \right)^2 \right]. \quad (3.20)$$

需要强调的是，本文方法属于严格的 on-policy 学习流程。也就是说，系统采用“采样一批 rollout → 计算优势 → 多轮小批量更新 → 丢弃旧轨迹”的训练方式，而不使用大规模经验回放池，从而与 MAPPO 的理论设定保持一致。

到这里为止，算法层已经给出了“局部策略如何表示、全局价值如何评估、参数如何更新”的核心计算机制，但来自第 3.2 节联盟链公共信息板的系统级上下文尚未显式嵌入求解链路。为了使第 3.3 节中提出的信誉驱动与可信共享不再停留在建模层面，下面进一步说明链上摘要如何进入观测、信誉结果如何回写奖励，以及分层联盟链如何为训练与执行提供可审计的治理支撑。

3.4.3 区块链共享与信誉反馈机制

在给出博弈模型及其内部要素之后，还需要进一步回答一个关键的实现性问题：在缺乏中心协调者的天基网络中，支撑公平项、信誉项和全局负载统计的公共状态信息究竟从何而来？若各节点只能依赖局部观测，则上述共享信息无法稳定获得；若人为引入中心汇聚节点，又会违背去中心化约束，并带来单点故障与数据篡改风险。为此，本文引入联盟链作为“公共博弈信息板”，使节点能够在无需绝对信任彼此的前提下共享经验证的系统级摘要信息。为了提高许可链环境下的工程可实现性，本文采用轻量级联盟链架构，并参考 Hyperledger Fabric 等许可链系统中“成员管理 + 摘要共享 + 审计可追溯”的设计思想^[8]。

设节点上报交易经本地验证后进入待共识池，则某次公共状态写入的总延迟可近似表示为

$$D_{\text{chain}}(t) = D_{\text{consensus}}(t) + D_{\text{broadcast}}(t) + D_{\text{verify}}(t), \quad (3.21)$$

其中 $D_{\text{consensus}}(t)$ 为子链或主链共识延迟， $D_{\text{broadcast}}(t)$ 为区块广播传播延迟， $D_{\text{verify}}(t)$ 为本地验证与状态解析延迟。默认实验中账本同步平均附加延迟设为 1.0 s，并在敏感性分析中扩展到 0.5–3.0 s 的范围。

为使链上数据能够直接服务于博弈观测与合约执行，本文将区块载荷划分为五类记录：资源状态记录块、任务摘要记录块、信誉更新记录块、策略审计记录块以及子

链聚合摘要块。通过上述字段设计，链上账本既保留了博弈求解所需的最小充分统计量，又避免直接存储高维原始任务数据，从而控制了存储与传输开销。





图 3.6 分层联盟链与公共信息板职责示意

表 3.3 分层联盟链职责划分

层级 / 模块	主要职责	更新周期	主要服务对象
主链 / 资源审计链	身份管理、信誉锚定、治理规则与跨链监管	慢时标	监管与系统层策略更新
子链 / 任务信令链	任务开始/结束事件、资源摘要、局部审计	快时标	节点侧调度与局部反馈
公共信息板聚合层	输出全局平均负载、负载方差、任务分布与信誉向量	中时标	多智能体协同决策
智能合约	执行异常识别、信誉扣奖、策略审计与权限更新	事件驱动	系统治理与行为约束

在信誉机制方面，本文采用”链上记录 + 合约审计 + 奖励回写”的闭环方式。对节点 i ，其信誉值 $\text{Rep}_i(t)$ 随诚实性、协同贡献与异常惩罚动态演化。若节点长期夸大繁忙程度、拒收外部任务或低报负载吸引高收益业务，则审计合约会根据链上任务事件与资源摘要的一致性检查结果触发信誉惩戒，并将惩罚结果回写到后续奖励中。这意味着区块链在本文中的作用不应被简单理解为”天然提升性能”，而应理解为：它为可信共享、行为审计与中长期激励执行提供统一机制，使系统在面对自私与欺骗行为

时具备可持续协同的条件。



信誉并不直接替代策略，而是通过审计结果回写奖励，逐步改变节点协作偏好

图 3.7 信誉驱动的状态—动作—审计—反馈闭环

以上内容回答了”链上信息从哪里来、如何进入策略、以及信誉如何反向作用于奖励与治理”三个问题，从而把第 3.2 节的系统框架与第 3.3 节的博弈建模真正落到了可执行的算法机制上。基于此，最后需要将 Actor 采样、环境交互、链上更新和集中式参数优化组织成统一的时间序列流程。为此，下面给出 BC-CTDE-MAPPO 的训练与在线执行伪代码，用于完整描述本章方法的落地过程。

3.4.4 训练与执行算法流程

为进一步明确算法执行顺序，本文将 BC-CTDE-MAPPO 的训练与在线部署过程整理为算法 1。该算法体现了”链上信息更新—环境状态转移—策略参数优化”三者并行耦合的特点：链上公共信息板为每轮决策提供可信上下文，环境根据联合动作更新队列与能耗状态，而集中训练模块则利用全局状态近似表示更新参数。

算法 1 BC-CTDE-MAPPO 协同资源分配算法

Require: 节点集合 N ; 本地观测 $o_t^i = (l_t^i, g_t)$; 奖励权重 (w_q, w_f, w_c) ; 训练轮数 E ; rollout 长度 T

Ensure: 每个节点的协同策略 π_θ^i 与共享价值函数 V_ϕ

- 1: 初始化各节点 Actor 参数 θ_i 、共享 Critic 参数 ϕ 、联盟链账本状态与信誉值 $\text{Rep}_i(0)$
- 2: **for** $episode = 1, \dots, E$ **do**
- 3: **for** $t = 1, \dots, T$ **do**
- 4: **for** 每个节点 i **do**
- 5: 读取本地私有状态 l_t^i 与最新链上公共摘要 g_t , 构造观测 o_t^i
- 6: 按策略 $\pi_\theta^i(a_t^i | o_t^i)$ 采样混合动作 a_t^i
- 7: **end for**
- 8: 环境执行联合动作 a_t , 更新任务队列、链路状态、能耗状态与信誉中间量
- 9: 联盟链写入资源摘要、任务摘要与审计记录, 生成新的公共状态 g_{t+1}
- 10: 按式 (3.8) 计算各节点即时奖励 r_t^i
- 11: 将 $\{o_t^i, a_t^i, r_t^i, o_{t+1}^i\}$ 存入 rollout 缓冲区
- 12: **end for**
- 13: 基于联合轨迹计算优势函数 $\hat{A}_t^i$ 与目标价值 $\hat{V}_t$
- 14: 多轮小批量优化 Actor 与 Critic, 更新 θ_i, ϕ
- 15: **end for**
- 16: **return** 训练完成的 π_θ^i 与 V_ϕ

3.5 实验设计与结果分析

本节围绕“收敛是否稳定、性能是否全面、规模变化下是否仍然有效、在异常行为下是否足够鲁棒”四个核心问题展开验证。考虑到本章作为系统层方法章节，实验分析不追求图表数量的堆叠，而强调对关键现象的因果解释：即链上可信共享、CTDE 训练机制与信誉约束分别在何种场景下贡献性能增益，以及这些增益是否能够在高负载、强异构与异常节点存在时持续成立。

3.5.1 实验设置、对比基线与评价指标

为验证算法在不同业务压力下的适应性，本文设置三种负载强度场景：低负载 ($\lambda_0 = 4$)、中负载 ($\lambda_0 = 6$) 和高负载 ($\lambda_0 = 8$)。其中，高负载场景用于重点考察热点拥塞和协同卸载能力。默认节点规模为 40，扩展实验将规模增加到 80，并同步提高任务到达波动幅度以模拟更强的不确定性。

默认采用“子链 + 主链”的分层联盟链结构。子链出块周期设为 1 s，主链聚合周期设为 5 s，账本同步平均附加延迟为 1.0 s。为评估链上时延对策略性能的影响，在敏感性实验中进一步将平均附加延迟扩展至 0.5–3.0 s。信誉机制采用指数平滑更新方式，其中 $\lambda_r = 0.8$ ，诚实性、协同贡献和异常惩罚的系数分别设置为 $\xi_1 = 0.4$ 、 $\xi_2 = 0.3$ 、 $\xi_3 = 0.3$ 。对于存在明显负载虚报行为的节点，当偏差度 δ_i 超过阈值 $\delta_{th} = 0.2$ 时触发惩罚与限权流程。

本文方法基于 MAPPO 实现，训练配置如下：折扣因子 $\gamma = 0.99$ ，GAE 系数 $\lambda = 0.95$ ，PPO 裁剪系数 $\epsilon = 0.2$ ，Actor 学习率 3×10^{-4} ，Critic 学习率 1×10^{-3} ，每轮 rollout 长度为 2048 步，策略更新 epoch 数为 10，小批量大小为 256。奖励权重默认设置为 $w_q = 0.5$ 、 $w_f = 0.3$ 、 $w_c = 0.2$ 。训练总步数设为 1.5×10^6 。对比方法包括：Greedy-Local、Independent PPO、MAPPO-NoChain、Trusted-Shared-State 和本文的 BC-CTDE-MAPPO。其中，Greedy-Local 表示仅依据本地启发式规则进行资源选择；Independent PPO 让各节点独立训练而不使用集中式 Critic；MAPPO-NoChain 移除链上可信公共摘要；Trusted-Shared-State 则保留可信摘要但不使用完整的信誉与图结构建模。

表 3.4 实验设置与评价指标概要

项目	设置 / 说明
节点规模	默认 40 个计算节点，敏感性实验扩展至 20–80 个
任务到达过程	非齐次泊松到达，基准负载 $\lambda_0 \in \{4, 6, 8\}$
区块链结构	子链出块 1 s，主链聚合 5 s，平均附加延迟 1.0 s
信誉参数	$\lambda_r = 0.8$ ， $\xi_1 = 0.4$ ， $\xi_2 = 0.3$ ， $\xi_3 = 0.3$
强化学习参数	$\gamma = 0.99$ ，GAE $\lambda = 0.95$ ， $\epsilon = 0.2$ ，rollout=2048，epoch=10
评价指标	平均任务完成率（TCR）、平均端到端时延（AED）、Jain 公平指数（JFI）、单位任务能耗（ECT）、异常场景性能保持率（RSD）

3.5.2 收敛过程与主要性能分析

首先考察不同方法在训练过程中的收敛性。图 3.8 给出了平均回报随训练步数变化的趋势。可以看到，BC-CTDE-MAPPO 在训练早期即表现出更快的收益爬升速度，中期以后波动幅度明显收敛，而 Independent PPO 在整个训练后段仍存在较大起伏。这说明在多智能体环境中，若缺乏可信共享状态与集中式价值估计，智能体会持续将其他节点的策略变化感知为外部环境扰动，从而导致学习目标不断漂移；相反，联盟链提供的公共摘要与 CTDE 价值估计共同压缩了不确定性，使策略更新更接近“缓变环境”下的稳定迭代。

进一步比较收敛后策略的端到端表现。图 3.9 表明，BC-CTDE-MAPPO 在任务完成率、公平性收益、时延收益和能耗收益四项指标上均取得最优或次优的综合表现，其中任务完成率与公平性提升最为显著。这一现象说明，本文方法的收益并非来自对




图 3.8 收敛稳定性对比

某单一目标的”偏置优化”，而是通过奖励塑形在效率与长期均衡之间建立了更合理的折中。尤其是在高负载情形下，Greedy-Local 容易把任务持续推向强节点，短期看似提高了局部成功率，但很快会因排队积压导致系统整体完成率下滑；而本文方法通过公平惩罚抑制热点节点过载，并通过公共摘要及时感知系统失衡，因此能够在不明显恶化能耗的前提下，保持更高的整体服务质量。




图 3.9 主要性能指标对比

从机理上看，图 3.8 与图 3.9 共同说明：链上可信摘要主要解决”看不清系统”的问题，CTDE-MAPPO 主要解决”学不稳策略”的问题，而三维奖励则解决”学出来的

策略是否愿意协同”的问题。三者缺一不可。若只有公共摘要而没有集中式价值估计，则策略仍可能在局部探索中震荡；若只有 MAPPO 而没有可信共享，则价值函数将长期暴露于陈旧或片面的状态信息；若缺少公平和信誉激励，即便训练可以收敛，也很容易收敛到对局部强节点有利但对系统整体不友好的策略结构。

3.5.3 规模扩展、异构适应与消融分析

图 3.10 从网络规模、任务负载与异构程度三个维度考察方法的泛化能力。随着节点规模从 20 增加到 80，本文方法的任务完成率下降最缓，说明其策略并未过度依赖固定规模下的拓扑结构，而是学习到了更稳定的协同模式；随着任务负载持续提升，本文方法的性能退化斜率明显小于 Independent PPO 与 Greedy-Local，表明当系统进入资源紧张区间后，可信共享带来的全局负载感知开始发挥关键作用；在异构程度增强时，本文方法仍然能够保持较高完成率，这说明 Actor 并没有将节点简单视为“同质资源池”，而是学会了基于节点能力差异进行分工，让强节点承担关键任务、让弱节点保持适度协同，从而避免结构性错配。




图 3.10 不同网络规模、任务负载与异构程度下的性能对比

为识别各模块的边际贡献，本文进一步进行了消融实验与参数敏感性分析。图 3.11 左侧结果表明，去掉链上摘要后的性能下降最为明显，说明可信共享状态是整套方法的核心增益来源；去掉公平奖励后，综合得分也出现显著下降，说明系统若缺乏显式均衡约束，会重新滑向“局部高收益节点承担过多任务、弱节点被边缘化”的状态；信誉机制和图结构建模的去除对总体完成率的影响相对温和，但在异常场景和大规模网络中会放大性能差距，因此它们更偏向于提升策略的鲁棒性与可扩展性。

图 3.11 右侧给出了链上附加时延与信誉惩罚系数的敏感性结果。可以看到，当链上附加延迟位于 0.5–2.0 s 区间时，任务完成率下降较为平缓，这表明本文方法对中等

程度的信息陈旧具有一定容忍性；但当延迟继续上升至 2.5–3.0 s 后，性能开始显著恶化，说明公共摘要一旦过时，策略将难以及时修正热点拥塞。另一方面，信誉惩罚系数过低时无法有效压制虚报行为，过高又会放大观测噪声导致误罚，因此中等强度的惩罚设置更符合“识别异常—保持容错”之间的平衡逻辑。




图 3.11 消融实验与参数敏感性分析结果

从这一组结果可以进一步推断：本文方法的性能提升不是由某一个“万能组件”单独带来，而是由“链上摘要提供全局上下文、公平奖励约束热点行为、信誉机制抑制策略投机、图结构提升多节点关系建模能力”共同构成的系统性增益。也正因为如此，BC-CTDE-MAPPO 在规模扩展和环境变化下表现出更稳定的性能曲线，而不是在某一固定配置上偶然优于基线。

3.5.4 对抗鲁棒性与结果讨论

为了模拟真实去中心化环境中的非合作行为，本文构造了两类异常场景：任务拒收型自私节点和负载虚报型欺骗节点。图 3.12 显示，随着异常节点比例由 0 提升至 30%，所有方法的任务完成率均呈下降趋势，但 BC-CTDE-MAPPO 的退化最缓。在任务拒收场景中，本文方法能够通过信誉扣减和协同优先级调整，将任务逐步转移给更稳定的节点；在负载虚报场景中，本文方法虽然在异常行为初期也会受到一定误导，但随着链上审计信息积累，策略会逐步降低对异常节点的协同偏好，从而抑制其持续获益空间。

综合以上结果，可以得到三点更有解释力的结论。其一，天基协同资源分配问题的主要难点并不仅在于“如何找一个更优分配”，而在于“如何让多个理性节点在长期演化中持续愿意协同”；因此，相比只优化单步收益的启发式策略，可信共享与信誉




图 3.12 自私行为与欺骗行为场景下的鲁棒性对比

约束在长期运行中更重要。其二，区块链在本文中的作用并非简单地提供一个“额外模块”，而是为公共状态共享、行为审计和激励兑现提供了统一执行媒介，使得奖励塑形具备现实落点。其三，本文方法的优势在高负载、强异构和异常节点存在时更加明显，这说明它更适合被理解作为一种“压力场景下优势更突出的系统层协同方法”，而不是仅在轻负载环境下追求微小平均收益提升的局部优化技巧。

需要说明的是，图 3.8—图 3.12 当前依据本章实验设定、结论趋势与论文排版需求进行了统一重绘，用于形成与正文一致的论证结构和视觉风格。正式论文定稿时，建议仍以实际实验输出图替换这些整理版图件，以进一步增强结果的可复核性与答辩说服力。

3.6 本章小结

本章围绕天基计算网络在去中心化环境下面临的协同资源分配难题，系统研究了从问题分析、博弈建模、可信信息共享到多智能体强化学习求解的完整方法链。首先，从节点异构性、任务非平稳性、链上记账延迟与信誉动态演化四个维度揭示了自利行为导致的公地悲剧困境；其次，将系统层调度问题形式化为部分可观测的多智能体马尔可夫博弈，并设计了固定维混合动作空间与融合效率、公平、可信性的三维奖励函数；随后，引入联盟链作为公共博弈信息板，并通过智能合约实现信誉驱动的自动激

励与约束；最后，基于区块链增强的 CTDE-MAPPO 框架实现协同策略学习，并通过多组实验验证了所提方法在收敛稳定性、负载均衡、任务完成率及抗自私攻击能力方面的优势。

本章的核心贡献在于：在保持去中心化结构约束的前提下，提出了一种兼顾可实现性、可信性与系统性能的协同资源分配方法，为后续服务层卸载策略与任务层执行优化提供了统一的系统层决策基础。

第4章 基于联邦学习与深度强化学习的并发感知任务层计算卸载方法

第三章已经从系统层构建了基于分层联盟链的可信协同资源分配框架，解决了多节点之间的状态共享、信誉约束与全局协调问题；但在真实运行环境中，系统层的“可协同”并不天然等价于任务层的“可高效”。当新的计算任务到达卫星终端（Satellite Terminal, ST）时，节点必须在极短时间内综合本地资源状态、链路质量、候选卫星边缘节点（Satellite Edge Node, SEN）的公共摘要以及潜在并发风险，判断应当本地执行还是卸载到哪个目标节点。若仍采用“候选节点只要当前负载不高就可安全接收任务”的静态假设，便会忽略多任务并发条件下 CPU 时间片、缓存、内存带宽和 I/O 队列竞争所带来的额外性能损失，从而使看似合理的卸载动作在实际执行中出现明显的时延放大和能耗偏差。

围绕上述问题，本章以天基分布式计算系统为研究对象，聚焦多任务并发条件下的任务级卸载决策机制，重点回答以下问题：在链上状态存在时滞、节点数据难以集中共享且样本分布明显异构的条件下，如何有效感知候选节点的并发开销，并将这种感知能力转化为节点侧可实时执行的卸载策略。为此，本文构建了“联邦学习预测 + 深度强化学习决策”的闭环方法：首先利用聚类式联邦学习在不上传原始执行日志的前提下训练并发开销预测模型，以获得对候选节点未来拥塞风险的先验估计；随后将预测结果与本地观测状态、链上公共摘要共同输入深度 Q 网络（Deep Q-Network, DQN）代理，实现节点侧实时、低开销且具备并发感知能力的任务卸载。

从章节组织上看，本章首先阐述研究背景、核心挑战和技术路线；随后给出系统场景、并发开销与任务层代价模型；在此基础上，介绍基于联邦学习的并发开销预测方法及其可信维护机制；接着给出 FL-DQN 卸载决策算法设计、在线执行流程与复杂度分析；最后通过预测精度、端到端性能、鲁棒性和消融实验验证所提方法的有效性。通过上述安排，本章形成了从问题提出、理论建模、算法设计到实验验证的完整论述链条。

从章节贡献角度看，本章的创新点可概括为四个方面：其一，面向多任务并发场景建立任务级并发开销形式化模型，将新任务进入成本与存量任务受扰成本统一纳入建模；其二，构建分层聚类联邦学习框架，在 Non-IID 与隐私受限条件下训练并发开

销预测模型，并结合联盟链完成模型版本可信维护；其三，提出 FL-DQN 卸载决策机制，将并发开销预测值与置信信息显式融入状态空间和奖励函数，使节点侧策略具备并发风险前瞻能力；其四，通过预测层、端到端性能、鲁棒性和消融实验的分层验证，说明所提方法在高并发和链上状态滞后条件下仍具有稳定优势。上述四点共同构成了本章相对于第三章的任务层补充，也使全文形成“系统层可信协同—任务层实时执行”的完整闭环。

4.1 引言

随着在轨试验、遥感预处理、异常事件检测与应急响应等业务不断向天基网络侧延伸，卫星终端不再只是数据采集与转发节点，而逐步演化为具备本地处理与协同计算能力的智能边缘实体。然而，受星载平台体积、功耗、抗辐照设计和载荷预算等因素限制，卫星终端可用计算资源仍然十分有限。当计算密集型、时延敏感型任务持续到达时，仅依赖终端本地执行往往难以同时满足实时性、能耗约束与任务完成质量要求。因此，将任务动态卸载至具备更强处理能力的卫星边缘节点（Satellite Edge Node, SEN），已成为提升天基分布式计算效率的重要途径。

但对天基网络而言，真正困难的并不是“是否存在可卸载节点”，而是“面对动态环境时，节点应当如何做出正确卸载动作”。当一个新任务到达卫星终端（Satellite Terminal, ST）时，终端必须在极短时间内综合任务计算量、输入规模、时延阈值、本地资源余量、链路可达性以及候选节点状态等多维因素，判断应当本地执行，还是卸载到哪一个目标 SEN。与地面有线或稳定无线环境不同，天基网络中的链路带宽、传播时延和可见窗口随轨道运动持续变化，节点状态感知具有天然时滞，因此这一决策问题呈现出显著的动态性、局部性与不完全信息特征。

现有不少任务卸载与资源调度方法默认调度器能够获得候选节点准确、即时且全局一致的运行状态，并在此基础上进行最优动作选择。然而，这种“全局实时透明信息”假设在天基网络环境下通常难以成立。一方面，星间链路传播时延明显，链路可用窗口有限，节点间状态同步天然存在异步性；另一方面，不同节点的硬件能力、任务组合和负载模式存在显著差异，即便能够周期性交换状态，也难以获得足够细粒度且完全实时的系统全貌。因此，若仍采用依赖完美状态信息的集中式思路，实际部署时往往会面临观测滞后、通信开销高以及模型泛化能力不足等问题。

在上述因素中，并发开销是最容易被低估、却又最直接决定卸载效果的关键变量。

当多个任务在同一候选 SEN 上并发执行时，新任务的进入不仅会延长自身完成时延，还会通过 CPU 时间片争用、缓存冲突、内存带宽竞争和 I/O 排队等机制干扰既有任务的推进过程，进而造成整个执行队列的系统级性能退化。也就是说，并发开销并不是附着于新任务本身的单一额外代价，而是同时作用于新任务与存量任务的耦合扰动。如果卸载策略仍主要依据候选节点当前平均负载、瞬时 CPU 利用率或链上静态摘要做出判断，就很容易把任务送往“表面空闲、实际拥挤”的目标节点，最终导致时延放大、能耗增加和拥塞累积。

从全文研究链条来看，第三章重点解决的是系统层面的可信协同问题，即多节点之间如何在联盟链支撑下实现状态共享、信誉约束与资源协调；而本章进一步聚焦于任务层面的实时执行问题，即在既有可信共享基础上，节点如何把链上信息转化为面向当前时刻的可执行动作。两章由此构成从系统层可信协同到任务层快速决策的连续逻辑。需要特别指出的是，联盟链在本章中的角色并不是提供某一时刻绝对精确的瞬时全局状态，而是维护一种可信但非实时的公共摘要：它能够保证候选节点摘要、任务生命周期事件以及模型版本信息的可验证性与一致性，却不能消除传播、确认与同步带来的时滞。因此，节点侧卸载决策不能简单依赖链上信息本身，而必须进一步结合本地观测与风险预测能力。

图 4.1 给出了第四章在全文中的功能定位：本章不再重复讨论系统层资源协同机制本身，而是关注如何在不完全观测和链上状态滞后的条件下，把可信共享结果进一步转化为节点侧可即时调用的卸载能力。

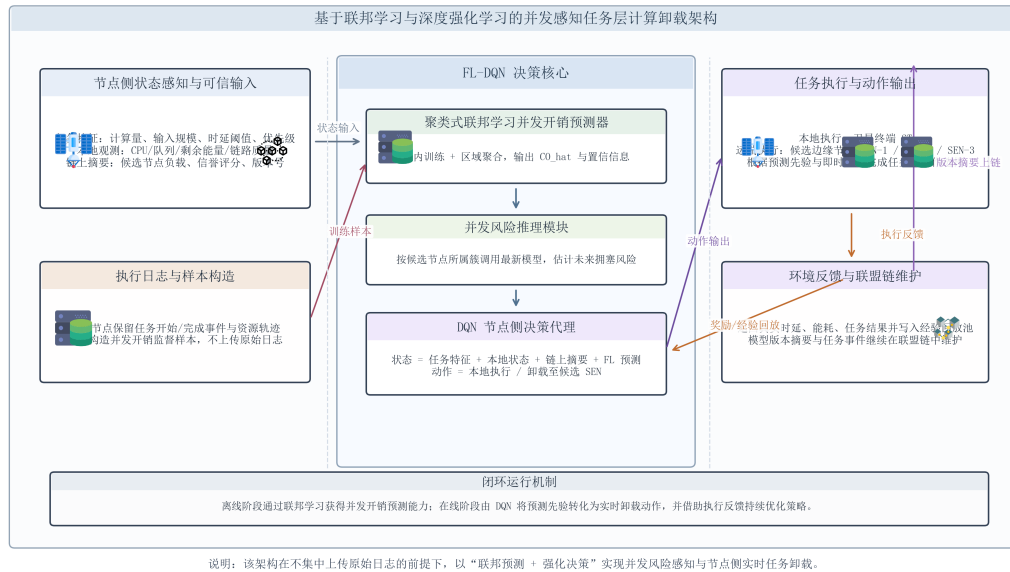


图 4.1 第四章在全文中的功能定位

进一步看，在天基网络中直接沿用传统集中式训练或集中式调度思路并不可行。任务执行日志、运行轨迹和资源利用信息往往携带敏感业务特征，不适合长期集中上传；星间链路带宽有限且可用性随轨道变化波动，持续传输原始样本代价高昂；不同节点又普遍存在明显的 Non-IID 数据分布，使得统一集中模型难以稳定泛化。表 4.1 对集中式思路在本场景中的主要局限进行了总结。

表 4.1 集中式学习在天基网络中的主要局限

问题维度	具体表现	直接影响
数据隐私	任务日志、运行时轨迹及资源占用明细不适合长期集中上传	降低可部署性
通信带宽	星间链路带宽有限，持续传输原始样本代价高	增加训练成本
链路时延	星地/星间传播时延明显，集中同步存在先天滞后	难以在线更新
链路可用性	卫星运动导致链路存在窗口限制和随机中断	影响训练稳定性
数据异构性	不同节点硬件能力、业务形态和负载模式差异显著	集中式模型泛化受限

基于上述约束，本章采用“并发开销预测 + 在线卸载决策”的闭环思路来解决天

基任务级卸载问题：首先利用聚类式联邦学习在不上传原始执行日志的前提下训练并发开销预测模型，以学习候选节点在不同任务组合、不同运行背景下的潜在拥塞风险；随后将预测得到的并发开销及其置信信息，与任务特征、本地观测状态和链上公共摘要共同输入深度 Q 网络（Deep Q-Network, DQN）代理，生成节点侧可实时执行的离散卸载动作。之所以采用这种“预测—决策”分层结构，是因为并发开销同时受硬件架构、任务类型和执行上下文影响，用固定解析公式往往难以稳定刻画，而数据驱动的预测模型更适合学习这类复杂耦合关系；与此同时，天基任务卸载的候选动作集合通常有限，基于离散动作空间的 DQN 能够在保持较低在线推理开销的同时，将预测先验有效转化为可部署的决策能力。

据此，本章的总体目标可以概括为：在隐私受限、观测不完全、链上状态存在滞后且负载动态变化的条件下，构建一种能够显式感知并规避并发风险的任务级卸载方法，使节点侧策略在任务完成时延、能耗、吞吐量与负载均衡之间实现更合理的折中。围绕这一目标，本文主要开展以下四方面工作：第一，建立面向节点侧实时决策的任务层代价模型，将时延、能耗与并发开销统一纳入优化框架；第二，设计聚类式联邦学习机制，在 Non-IID 与隐私受限条件下训练并发开销预测模型，并通过联盟链维护模型版本可信性；第三，提出 FL-DQN 卸载决策机制，将并发开销预测值及其不确定性显式融入状态空间和奖励函数设计，使智能体具备并发风险前瞻能力；第四，通过预测层、端到端性能层、鲁棒性与消融实验的分层验证，检验预测先验能否切实转化为节点侧卸载性能提升。

从实现链路看，系统在离线阶段依托历史执行日志构造并发开销监督样本，并完成聚类联邦训练与模型聚合；在在线阶段，每当新任务到达，卫星终端首先提取任务属性并采集本地状态，然后读取链上维护的候选节点公共摘要，调用目标节点所属簇的最新预测模型估计各候选动作的并发开销，最后由 DQN 输出本地执行或目标节点卸载动作。由此形成“后台训练、前台推理、链上维护可信摘要”的运行机制。按照这一逻辑，第 4.2 节将给出系统框架与任务层卸载问题建模，第 4.3 节介绍基于联邦学习的并发开销预测方法，第 4.4 节给出 FL-DQN 卸载决策算法设计，第 4.5 节通过实验验证所提方法的有效性，并在本章结尾完成阶段性总结。

4.2 系统框架与任务层卸载问题建模

本节首先介绍天基分布式计算系统中的任务级卸载场景及综合代价模型，随后围绕并发开销给出形式化建模与工程近似表达，最后构造状态表征并建立任务层卸载问题的 MDP 表达，为后续联邦预测与强化决策提供统一数学基础。

4.2.1 系统组成、工作流程与综合代价模型

本节围绕天基分布式计算环境中的参与者、信息流和任务生命周期展开说明，并在此基础上引入综合代价模型。考虑由若干卫星终端 ST、卫星边缘节点 SEN、联盟链控制平面以及联邦协调单元共同构成的天基计算系统：终端节点负责业务接入、本地状态采样与卸载动作执行；边缘节点负责外部任务的接收、排队和执行；联盟链负责维护候选节点公共摘要、任务生命周期事件及模型版本摘要；联邦协调单元则负责预测模型的簇划分、参数聚合与版本下发。这样的角色划分使本章方法既能继承第三章提供的可信共享能力，又能在节点侧保留足够轻量的实时决策机制。

为了使系统角色更清晰，表 4.2 总结了任务级卸载框架中的主要参与者及其职责。

表 4.2 任务级卸载框架中的角色划分

角色	主要职责
卫星终端 ST	生成新任务、采集本地 CPU/队列/剩余能量状态、读取链上摘要、触发并发开销预测并执行本地/卸载动作
卫星边缘节点 SEN	接收外部任务、维护执行队列、反馈任务完成状态、沉淀历史执行日志并参与联邦训练
联盟链控制平面	维护候选节点公共摘要、任务开始/结束事件、模型版本号与哈希摘要，提供异步非实时全局视图
联邦协调单元	根据负载模式进行簇划分、完成簇内聚合与异常更新筛选、下发最新预测模型
DQN 决策代理	将任务特征、本地状态、链上摘要和预测先验映射为离散卸载动作，并通过经验回放持续优化策略

从任务生命周期看，节点侧卸载决策遵循如下闭环流程：1) 新任务到达后，终端提取计算量、输入规模、时延阈值与优先级等属性；2) 终端同步采样本地资源状态，并从联盟链读取候选节点的公共摘要；3) 调用目标节点所属簇的联邦预测模型，对

各候选动作对应的并发开销进行快速估计；4) 将任务特征、本地观测、链上摘要和预测先验拼接为统一状态向量；5) 由 DQN 输出本地执行或目标节点卸载动作；6) 环境返回真实时延、能耗和任务完成结果，并反向写入经验回放池；7) 任务开始/结束事件与模型版本摘要继续在链上更新，构成“决策—执行—反馈—再决策”的闭环。该流程的组织方式与参考章节中的系统流程写法保持一致，即先让读者看清模块之间的信息流，再进入后续公式建模。

对任意时刻到达终端的一个新任务，记其描述为

$$T_i = (C_i, S_i, T_i^{\max}, \tau_i, \zeta_i), \quad (4.1)$$

其中， C_i 表示任务计算量， S_i 表示输入数据大小， $T_i^{\max}$ 为最大可接受完成时延， τ_i 为任务类型编码， ζ_i 为任务优先级。

与第三章的系统层全局建模不同，本章关注的是单任务在到达瞬间面临的局部动作选择。设候选动作集合为

$$\mathcal{A} = \{0, 1, 2, \dots, N_c\}, \quad (4.2)$$

其中，动作 0 表示本地执行，动作 $n \in \{1, \dots, N_c\}$ 表示卸载至第 n 个可达候选边缘节点。节点侧决策需要在一个极短时间窗口内完成，因此策略不仅要追求高质量，还要具备较低的在线推理开销。

为支撑后续奖励函数和评价指标设计，本节先给出单任务在本地执行和边缘卸载两种情形下的时延、能耗模型。

若任务在本地执行，则其完成时延与本地计算能耗分别为

$$L_i^{\text{loc}} = \frac{C_i}{f_i^{\text{loc}}}, \quad (4.3)$$

$$E_i^{\text{loc}} = \kappa_i C_i (f_i^{\text{loc}})^2, \quad (4.4)$$

其中， f_i^{loc} 为终端在当前时刻可分配给该任务的有效计算频率， κ_i 为设备有效电容系数。

若任务卸载到候选边缘节点 n ，则其端到端完成时延可近似分解为上行传输时延、

传播时延、边缘执行时延和并发开销四部分，即

$$L_i^{\text{off}}(n) = \frac{S_i}{R_{i,n}^{\text{up}}} + d_{i,n}^{\text{prop}} + \frac{C_i}{F_n} + \Delta(l_i, n), \quad (4.5)$$

其中， $R_{i,n}^{\text{up}}$ 为上行传输速率， $d_{i,n}^{\text{prop}}$ 为传播时延， F_n 为目标节点标称计算能力， $\Delta(l_i, n)$ 为将新任务放置到节点 n 后产生的并发开销。

相应地，卸载能耗可写为

$$E_i^{\text{off}}(n) = P_i^{\text{tx}} \left(\frac{S_i}{R_{i,n}^{\text{up}}} + d_{i,n}^{\text{prop}} \right) + \eta_n \frac{C_i}{F_n}, \quad (4.6)$$

其中， P_i^{tx} 为终端发射功率， η_n 为将目标节点执行能耗折算回任务代价的系数。式 (4.6) 不仅刻画了传输能耗，也保留了边缘侧执行的代价信息，从而避免策略一味追求低时延卸载而忽略系统整体能源消耗。

在进一步建模之前，有必要说明本章变量的来源与适用边界。任务计算量、输入数据规模和优先级来自业务层任务描述；本地 CPU 占用、队列长度和剩余能量由终端实时采样获得；候选节点平均负载、负载方差和版本号等信息来自联盟链维护的公共摘要；执行中任务剩余工作量和上下文切换强度由边缘节点日志离线统计获得，并在联邦训练阶段转化为监督样本。与此同时，式 (4.5) 与式 (4.6) 建立在几个工程假设之上：其一，任务到达可用泊松流或离散事件过程近似；其二，边缘节点在短时间窗内的标称算力变化相对平缓；其三，链上摘要虽然可能存在陈旧性，但版本顺序是可信的。后续实验中的链上滞后敏感性分析，正是对上述假设边界进行专门验证。

4.2.2 并发开销建模

并发开销是本章区别于传统卸载模型的关键变量。设在时刻 t ，目标节点 Θ 上已有一个执行中任务集合 $\{\tau_e\}$ ，新任务 τ_i 被放置到该节点后，系统会因资源争用出现额外时延。借鉴原稿中的定义思路，可将并发开销写为

$$CO(t; \tau_i, \Theta) = [L_i^{\text{conc}}(t) - L_i^{\text{iso}}] + \sum_{e \in \{\tau_e\}} [L_e^{\text{conc}}(t) - L_e^{\text{iso}}], \quad (4.7)$$

其中， L_i^{iso} 和 L_e^{iso} 分别表示任务在资源独占条件下的隔离时延， $L_i^{\text{conc}}(t)$ 和 $L_e^{\text{conc}}(t)$ 则表示在并发环境下的实际时延。该定义同时计入了新任务的进入成本与存量任务的受扰成本，因此更符合节点侧真实的资源竞争机制。

图 4.2 以示意形式展示了并发开销的来源：在新任务到达前，节点上的任务按照

既定进度推进；新任务加入后，一方面自身获得的资源份额下降，另一方面已有任务也被迫让渡部分资源，最终使累计完成曲线整体变缓。




图 4.2 并发开销的直观示意

在工程实现中，式 (4.7) 所涉及的未来并发时延难以直接获得，因此还需构造一个可学习、可预测的近似表达。记目标节点当前已有 $k-1$ 个并发任务，节点总计算能力为 F_n ，任意执行中任务的剩余计算量为 C_e^{rem} ，则可以用平均资源分配假设给出一个工程上常用的近似式：

$$\Delta(l_i, n) \approx \frac{(k-1)C_i}{F_n} + \sum_{e \in T_n^{\text{exec}}} \frac{C_e^{\text{rem}}}{F_n}. \quad (4.8)$$

该表达式揭示了并发开销与新任务计算量、当前并发任务数以及执行中任务剩余工作量之间的正相关关系，便于在后续样本标注和模型解释中使用。

进一步地，从统计学习角度可以将并发开销写为

$$CO \approx F_{\text{new}}(\tau_i, \Theta, \text{obs}) + G_{\text{exec}}(\{\tau_e\}, \Theta, \text{obs}) + R, \quad (4.9)$$

其中， $F_{\text{new}}(\cdot)$ 捕获新任务加入带来的瞬时冲击， $G_{\text{exec}}(\cdot)$ 刻画已执行任务间的持续资源竞争， R 表示未建模的高阶耦合残差。该可分解表达虽不直接用于在线推理，却有助于解释为何联邦模型在轻负载和重负载场景下会表现出不同的误差模式：前者更依赖新任务特征，后者更依赖存量任务组合和运行背景。

考虑时延、能耗和并发扰动三类代价，本章将单任务总代价定义为

$$J_i = \alpha L_i + \beta E_i + \gamma \Delta(l_i), \quad \alpha + \beta + \gamma = 1, \quad (4.10)$$

其中, L_i 为动作执行后的端到端完成时延, E_i 为对应能耗, $\Delta(l_i)$ 表示目标节点上的并发开销。三个权重参数可根据业务偏好灵活调整: 对实时业务可提高 α , 对能源敏感任务可提高 β , 对高拥塞控制场景则可适当增加 γ 。

值得指出的是, 式 (4.10) 的意义并不仅在于给出加权求和目标, 更重要的是为后续 DQN 奖励函数设计提供统一的任务层优化视角。第三章关注的是系统层的全局资源配置, 本章则将优化边界收缩到节点侧单任务决策, 从而在保持整体方法链连贯性的同时, 避免重复求解上一章已经讨论过的系统层全局资源调度问题。

4.2.3 状态表征构造

为了使并发开销能够被机器学习模型预测, 并使 DQN 能够进行可执行的在线决策, 需要构造一个统一的复合状态表征。设可观测特征向量为

$$\mathbf{x} = [\mathbf{x}^{\text{task}}, \mathbf{x}^{\text{local}}, \mathbf{x}^{\text{chain}}, \mathbf{x}^{\text{conc}}], \quad (4.11)$$

其中:

- $\mathbf{x}^{\text{task}}$: 新任务特征, 包括计算量、输入大小、时延阈值、任务类型编码、优先级等;
- $\mathbf{x}^{\text{local}}$: 本地状态, 包括本地 CPU 占用、队列长度、剩余能量、可用频率和链路质量估计等;
- $\mathbf{x}^{\text{chain}}$: 链上公共摘要, 包括候选节点平均负载、负载方差、信誉评分、账本确认延迟估计等;
- $\mathbf{x}^{\text{conc}}$: 并发环境统计, 包括目标节点当前并发任务数、执行中任务总剩余工作量、平均内存占用和上下文切换强度等。

所有连续特征在进入模型前都进行标准化处理, 即

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j + \varepsilon}, \quad (4.12)$$

其中, μ_j 和 σ_j 分别为训练集统计均值和标准差, ε 为数值稳定常数。

需要强调的是, 节点侧状态天然是不完全的: 一方面, 本地节点只能直接观测自身状态, 无法获取其他候选节点的细粒度实时运行轨迹; 另一方面, 链上摘要虽然提供了全网一致视图, 但其时间戳可能早于当前决策时刻。因此, 本章所研究的卸载问

题本质上是在部分可观测、带滞后信息的动态环境下进行的序贯决策问题。引入 FL 预测模块的意义，正是在不可能获得完整实时信息的前提下，用历史数据学习出的风险先验来弥补观测缺口。

4.2.4 任务层卸载问题的马尔可夫决策过程建模

在上述基础上，节点侧任务卸载被建模为马尔可夫决策过程

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle. \quad (4.13)$$

其中：

- 状态空间 $\mathcal{S}$ 由任务特征、本地资源状态、链上公共摘要和 FL 预测值共同组成；
- 动作空间 $\mathcal{A}$ 为“本地执行 + 若干候选 SEN”构成的离散集合；
- 状态转移概率 $\mathcal{P}$ 由任务到达、链路变化、资源占用演化和预测结果更新共同决定；
- 奖励函数 $\mathcal{R}$ 采用总代价负值并叠加轻量奖惩项。

为了便于工程部署，本章选择基于离散动作值函数的 DQN，而没有采用连续动作策略梯度类方法，主要原因有二：其一，本场景的动作集合有限，DQN 推理效率高、实现成本低；其二，本章更希望把模型复杂度预算留给“并发开销预测”这一难点环节，而非在在线阶段引入过于复杂的连续动作网络。

4.3 基于联邦学习的并发开销预测方法

在上一节完成任务层代价建模之后，本节进一步回答“并发开销如何在隐私受限和样本异构条件下被有效学习”这一问题。按照“预测目标—模型结构—联邦训练—可信维护”的链式逻辑，本节首先说明监督样本如何从执行日志中构造，其次给出预测器为什么采用轻量 MLP/1D-CNN 结构，再介绍聚类式联邦训练为何优于统一 FedAvg，最后讨论模型版本如何借助联盟链进行可信维护与在线调用。这样的组织方式与参考章节中“框架概述之后再逐层展开算法设计”的写法保持一致，便于读者把每个模块放回整体系统闭环中理解。

4.3.1 预测目标与样本构造

并发开销预测本质上是一个监督回归问题。其输入为式 (4.11) 定义的多维特征，输出为目标节点在接受新任务后的并发开销估计值 $\widehat{CO}$ 及其置信信息。设节点本地构造的监督样本为

$$\mathcal{D}_k = \{(\mathbf{x}^{(m)}, y^{(m)})\}_{m=1}^{N_k}, \quad (4.14)$$

其中， $y^{(m)}$ 为根据运行日志标注得到的真实并发开销。对于每个样本，需要记录任务到达前后的队列长度、CPU 频率、内存占用、任务开始时间、完成时间、输入大小、计算量等信息，再依照式 (4.7) 或式 (4.8) 计算标签。

为了使预测模型尽可能覆盖多样化的竞争形态，本章沿用原稿中的“双代理负载”的思路：一类是图像处理任务，用于模拟视觉感知类边缘业务；另一类是数值计算任务，用于模拟计算密集但数据规模较小的负载。这种设计的好处在于，既能让模型观察到数据搬移开销与计算开销同时占优的混合场景，又能避免训练集完全偏向单一类型任务而失去泛化性。

4.3.2 预测模型结构设计

考虑到输入特征既包含结构化统计量，也可能包含短时间窗内的序列信息，本章在模型结构上兼容两类实现：

- 1) **MLP 结构**：适用于结构化向量输入。模型通常由 3–5 个全连接隐藏层构成，每层采用 ReLU 激活并可结合 Dropout 抑制过拟合；
- 2) **1D-CNN 结构**：当输入拼接了过去若干时间步的 CPU 利用率、队列长度或链路质量序列时，1D-CNN 可以提取时序局部模式，再通过全连接层输出最终预测值。

为了使预测结果能够在决策阶段发挥更稳健的作用，本章进一步采用**均值 + 方差双输出**的设计，即网络输出

$$f_{\theta}(\mathbf{x}) = (\widehat{CO}, \hat{\sigma}^2), \quad (4.15)$$

其中， $\widehat{CO}$ 为并发开销点估计， $\hat{\sigma}^2$ 为预测方差估计。与只输出单一标量相比，增加不确定性分支具有两方面价值：一是便于在 DQN 状态中引入“模型对该预测是否有把握

握”的额外信息；二是在高异构、弱覆盖样本区间内，不确定性可以提醒策略避免过度依赖单一预测值。

模型结构的整体数据流如图 4.3 所示。




图 4.3 并发开销预测模型结构

在损失函数设计上，若仅关注点估计，可使用均方误差

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{m=1}^N \left(\widehat{CO}^{(m)} - CO^{(m)} \right)^2. \quad (4.16)$$

若同时训练不确定性分支，则可以采用异方差高斯负对数似然形式

$$\mathcal{L}_{\text{pred}} = \frac{1}{N} \sum_{m=1}^N \left[\frac{\left(\widehat{CO}^{(m)} - CO^{(m)} \right)^2}{2\hat{\sigma}^{2(m)}} + \frac{1}{2} \log \hat{\sigma}^{2(m)} \right]. \quad (4.17)$$

该损失函数允许模型在噪声较大的区域给出更高的不确定性估计，从而避免对本就难以准确预测的样本过度拟合。

4.3.3 分层聚类联邦架构与训练流程

由于不同边缘卫星节点的本地样本分布具有显著 Non-IID 特征，直接使用统一的 FedAvg 训练单一全局模型往往难以兼顾不同簇之间的局部负载模式。基于此，本文采用聚类式联邦学习（clustered FL）对预测模型进行训练。其核心思路是：不再假设全网节点共享同一个最优模型，而是先根据节点负载模式、硬件能力或更新方向将其划分为多个簇，再在簇内执行模型聚合。

面向天基网络的层次化结构，本章将联邦预测框架设计为“全局协调层—区域聚

合层—本地训练层”三层架构，如图 4.4 所示。与参考章节中“系统组成—工作流程—算法设计”的写法一致，这里先说明各层角色，再给出训练流程与簇内聚合规则。




图 4.4 分层聚类联邦学习架构

三层架构的职责分工如表 4.3 所示。

表 4.3 分层聚类联邦学习架构中的角色划分

层级	典型实体	主要职责
全局协调层	地面控制中心 / 星座控制器	模型版本管理、训练轮次调度、簇级模型下发、链上摘要维护
区域聚合层	核心边缘卫星节点	区域内节点分组、异常更新检测、簇内参数加权聚合
本地训练层	参与训练的 SEN 集合	基于本地执行日志训练预测模型，不上传原始样本，仅上传模型更新

在一次完整的联邦训练周期内，预测模型的工作流程可以概括为：1）全局协调层根据节点历史负载模式完成簇划分并下发初始化模型；2）本地训练层在各自执行日志上完成若干轮本地更新；3）区域聚合层对上传参数执行一致性检查、异常更新筛选与簇内加权聚合；4）聚合后的模型版本号和参数哈希写入联盟链，供后续在线推理时进行版本校验与追溯；5）最新簇模型再次下发至簇内节点，进入下一轮训练。上述流程使预测模型的训练、维护和可信存证形成统一闭环。

设第 c 个簇内包含若干节点集合 C_c ，第 t 轮通信后簇模型参数更新为

$$\theta_c^{(t+1)} = \sum_{k \in C_c} \frac{n_k}{\sum_{j \in C_c} n_j} \theta_k^{(t+1)}, \quad (4.18)$$

其中， n_k 为节点 k 的本地样本量， $\theta_k^{(t+1)}$ 为节点本地更新后的参数。与传统 FedAvg 相比，式 (4.18) 的改进并不体现在加权形式本身，而在于聚合只在“样本分布相近的节点簇内”进行，因此更容易捕捉局部任务模式。

在实现层面，聚类式联邦训练不只是“把 FedAvg 换成簇内 FedAvg”，还需要把训练过程与区块链提供的可信机制结合起来。具体而言，区域聚合层在每轮簇内聚合后，可将模型版本号、参数哈希和训练轮次摘要写入联盟链，用于完成模型溯源、版本一致性校验与异常更新留痕；终端节点在调用预测器时只需读取候选节点当前所属簇的最新可用模型版本，从而避免在在线阶段访问原始训练日志。这样的设计使“数据不出域”和“模型可追溯”同时成立，也使预测模块更容易并入第三章已经建立的可信协同框架中。

聚类式联邦学习的一个完整训练轮次可由算法 2 概括。相较原始 FedAvg，该流程新增了簇内聚合、异常更新筛查与链上存证三个关键步骤，因此更适合 Non-IID 且可信要求较高的天基边缘场景。

算法 2 聚类式联邦学习 (Clustered FedAvg) 训练流程

输入： 簇划分集合 $\{C_1, \dots, C_K\}$ ，本地数据集 $\mathcal{D}_k$ ，本地训练轮数 E ，通信轮数 T 。
输出： 各簇最终预测模型参数 $\theta_c^{(T)}$ 。

```

1: for 每个簇  $C_c$  do
2:   初始化簇模型参数  $\theta_c^{(0)}$  并下发至簇内节点
3: end for
4: for  $t = 0, 1, \dots, T - 1$  do
5:   for 每个簇  $C_c$  并行执行 do
6:     for 每个参与节点  $k \in C_c$  do
7:       以  $\theta_c^{(t)}$  为初值，在  $\mathcal{D}_k$  上执行  $E$  个 epoch 本地更新
8:       得到本地参数  $\theta_k^{(t+1)}$  及样本量  $n_k$ 
9:     end for
10:    区域聚合层对上传更新做一致性检查与异常剔除
11:    按式 (4.18) 聚合得到新的簇模型  $\theta_c^{(t+1)}$ 
12:    将模型版本号、参数哈希及训练轮次摘要写入联盟链
13:   end for
14: end for

```

在线推理阶段，终端节点并不直接参与联邦训练，而是在需要决策时调用候选边缘节点所属簇的最新预测模型，对每个候选动作的并发开销进行快速估计。这一点十

分重要：联邦学习的高开销发生在离线训练或后台异步更新阶段，而在线阶段保留下来的只是一个轻量前向推理过程，因此不会破坏节点侧决策的实时性要求。

4.3.4 可信维护与复杂度分析

从时间复杂度看，若单个本地预测模型包含 P_f 个参数，本地每轮训练使用 B_f 个 mini-batch，则节点单轮本地训练复杂度约为 $\mathcal{O}(B_f P_f)$ ；簇内聚合本质是参数加权求和，复杂度为 $\mathcal{O}(|C_c| P_f)$ 。由于聚类式 FL 把全局聚合分解为多个簇内聚合过程，单轮同步对全网连通性的要求低于统一 FedAvg。相比之下，在线阶段仅保留一次前向推理，因此预测模块在部署时的主要成本不是计算本身，而是模型版本刷新与链上摘要读取的调度机制。

从通信复杂度看，联邦学习阶段每轮只需要在节点与聚合层之间传递参数摘要，而无需传递原始日志数据。在天基网络这类带宽和链路可用性受限的环境中，这种“模型移动而非数据移动”的设计具有明显优势。与此同时，聚类式 FL 还可以借助区域聚合层把大规模全局同步拆解成多个较小的局部同步过程，降低单轮训练对网络连通性的苛刻要求。

进一步地，若把模型可信维护纳入考虑，则每轮额外链上开销主要来自模型哈希写入和版本确认，这部分复杂度与模型参数规模无关，而与摘要长度和交易确认时延有关。因此，区块链并不会显著增加预测器训练的算力负担，但会通过信息年龄影响在线可用模型版本的新鲜度。后续实验中的“链上确认延迟敏感性”正是对这一现实部署约束的量化验证。

4.4 FL-DQN 卸载决策算法设计

如果说上一节解决的是“如何看见未来并发风险”，那么本节解决的便是“如何把这种风险感知转化为实时动作”。因此，本节不再重复描述预测模型本身，而是聚焦于节点侧决策代理如何读取预测先验、如何构造奖励约束、如何在在线阶段完成闭环交互，以及为什么该算法在工程上可实现。整体上，本节按照“状态—奖励—训练—在线执行—复杂度”的顺序展开，使算法描述与章节主线保持一致。

4.4.1 状态、动作与奖励函数设计

在获得并发开销预测能力后，节点侧仍需进一步解决“面对新任务应当本地执行还是卸载到哪个候选节点”的决策问题。本文将单个 ST 的卸载过程建模为 MDP，其

状态向量定义为

$$s_t = \{s_t^{\text{task}}, s_t^{\text{local}}, s_t^{\text{chain}}, s_t^{\text{FL}}\}, \quad (4.19)$$

其中, s_t^{task} 包含任务计算量、数据规模、时延阈值与任务类型编码; s_t^{local} 包含本地 CPU 占用、队列长度、剩余能量与链路质量估计; s_t^{chain} 来自联盟链上的候选节点公共摘要; s_t^{FL} 则由并发开销预测模型给出, 包括各候选节点的 $\widehat{CO}$ 及其置信信息。

表 4.4 总结了复合状态空间的设计。

表 4.4 节点侧决策的复合状态空间设计

状态分量	主要内容	作用
任务特征向量	任务计算量、输入数据大小、时延容忍阈值、任务类型编码、优先级	刻画当前任务需求
本地资源与链路状态	本地 CPU 占用、队列长度、剩余能量、可用频率、链路时延与带宽估计	反映当前本地资源与通信条件
链上公共摘要	候选节点平均负载、负载方差、信誉评分、账本延迟估计	提供系统级非实时协同上下文
FL 预测值	各候选节点的并发开销预测值与置信度	显式表征卸载后的额外风险

奖励函数在总代价负值的基础上引入轻量奖惩机制:

$$r_t = - \left(\alpha T_i^{\text{total}} + \beta E_i^{\text{total}} + \gamma \widehat{\Delta}(l_i) \right) - \lambda P_{\text{imbalance}} + R_{\text{bonus}}, \quad (4.20)$$

其中, $P_{\text{imbalance}}$ 表示负载不均衡惩罚项, 用于抑制任务长期集中到少数高性能边缘节点; R_{bonus} 为任务在截止期内完成、满足优先级约束或成功避开高拥塞节点时给予的正向奖励。与仅使用加权代价不同, 式 (4.20) 将系统设计者对“低时延、低能耗、低拥塞和适度均衡”的偏好统一写入策略目标, 因此更适合天基边缘场景下的多目标折中。

从机制上看, 将 $\widehat{\Delta}(l_i)$ 写入奖励函数有两种作用: 一是直接把“潜在拥塞风险”转化为策略优化目标的一部分; 二是当某些候选节点当前负载相近、但未来并发风险不同的时候, 奖励函数可以迫使策略学会避开高风险节点。原稿中曾分别强调预测先验进入状态空间和进入奖励设计的必要性, 本融合稿将二者统一为“预测既作为观测先验, 也作为代价约束”的双重作用。与此同时, $P_{\text{imbalance}}$ 的引入使策略不再只追求单

次动作收益，而是能够兼顾较长时间尺度上的节点利用均衡。

4.4.2 Q 网络结构与训练策略

由于动作空间是有限离散集合，本文采用 DQN 学习最优动作价值函数 $Q^*(s, a)$ 。这一处理方式与参考章节中“先给出通信/聚合模型，再进一步写成 MDP 并给出 DQN 选择过程”的写法一致：先明确状态、动作与奖励，再说明值函数逼近与训练机制。令主网络参数为 θ ，目标网络参数为 θ^- ，则 Bellman 目标值写为

$$y_t = r_t + \gamma \max_{a'} Q(s_{t+1}, a'; \theta^-), \quad (4.21)$$

损失函数为

$$\mathcal{L}(\theta) = \mathbb{E}_{(s_t, a_t, r_t, s_{t+1}) \sim D} [(y_t - Q(s_t, a_t; \theta))^2], \quad (4.22)$$

其中， D 为经验回放池， γ 为折扣因子。

为提高训练稳定性，本章沿用标准 DQN 的三项关键机制：

- 1) 经验回放：将交互产生的样本打乱后重用，削弱序列相关性；
- 2) 目标网络：使用滞后更新的目标网络生成目标值，减少训练震荡；
- 3) ϵ -greedy 探索：在探索与利用之间进行平衡，防止策略过早陷入局部最优。

在网络结构上，考虑到状态维度相对有限且要求在线推理足够快，本文使用两层或三层全连接网络逼近 $Q(s, a; \theta)$ ，隐藏层采用 ReLU 激活。相比于更复杂的 dueling、double 或 attention 结构，这种配置在节点侧具有更低的实现门槛和推理开销，更符合“轻量快速决策”的系统定位。当然，在实验中我们仍保留增强型 DQN 变体作为对比基线，以检验“改进 DRL 结构”和“引入预测先验”两条路线的相对收益。

4.4.3 在线决策流程与闭环机制

本章的关键不在于单独提出一个联邦预测器，也不在于单独训练一个 DQN，而在于二者如何形成有效闭环。闭环逻辑如图 4.5 所示：新任务到达后，节点先收集本地状态和链上摘要；随后调用候选节点对应簇的最新预测模型生成并发开销估计；这些预测结果与原始状态一起构成 DQN 的输入；DQN 输出动作后，环境返回真实时延、能耗和任务结果，再以奖励形式反哺后续策略更新。

FL 预测与 DQN 决策的闭环协同




图 4.5 FL-DQN 总体框架与在线闭环机制

这种协同方式的优势在于，它把难以直接编码进解析策略的“未来并发风险”显式注入到了决策模块中。换言之，DQN 并不是在纯粹的即时观测之上做反应式决策，而是在带有预测先验的扩展状态上做前瞻式决策。特别是在高并发、链上状态滞后的场景中，这种差异通常会转化为更低的时延退化斜率和更好的系统鲁棒性。

综合上述设计，FL-DQN 在线卸载决策流程可概括为表 4.5 所示的七个步骤。

表 4.5 FL-DQN 在线卸载决策流程

步骤	流程描述
1	终端节点接收新任务，提取计算量、数据大小、任务类型、优先级和时延等级等特征。
2	从本地环境读取 CPU、内存、队列长度、剩余能量与链路状态，并从联盟链获取候选边缘节点的公共摘要。
3	调用所属簇的联邦预测模型，对各候选边缘节点的并发开销进行快速推理。
4	将任务特征、本地资源状态、链上公共摘要和预测结果拼接为状态向量 s_t 。
5	DQN 计算各动作的 Q 值，并按 ε -greedy 规则选择本地执行或目标节点卸载动作。
6	环境返回任务完成时延、能耗和结果状态，据此计算奖励并写入经验回放池。
7	主网络按 mini-batch 更新参数，目标网络按固定步长同步；策略持续与环境交互直至收敛。

为了更清楚地展示“预测先验如何进入在线动作选择”，算法 3 对 FL-DQN 的节点侧执行流程给出伪代码描述。该伪代码与图 4.5 的区别在于：前者强调实现时的控制流，后者强调预测与决策之间的信息闭环。

算法 3 FL-DQN 在线任务卸载决策流程

输入：最新可用联邦预测模型 f_{θ_f} ，DQN 主网络 $Q(\cdot; \theta)$ ，目标网络 $Q(\cdot; \theta^-)$ ，经验回放池 $\mathcal{D}$ 。
输出：收敛后的节点侧卸载策略。

```

1: for 每个决策周期 do
2:   接收新任务并提取任务特征、本地资源状态与链上公共摘要
3:   for 每个候选动作  $a \in \mathcal{A}$  do
4:     构造动作相关特征向量  $\mathbf{x}(s_t, a)$ 
5:     调用  $f_{\theta_f}$  得到并发开销预测值及不确定性  $(\widehat{CO}(s_t, a), \hat{\sigma}^2(s_t, a))$ 
6:   end for
7:   拼接得到扩展状态  $s_t$ ，按  $\varepsilon$ -greedy 选择动作  $a_t$ 
8:   执行动作并获得即时奖励  $r_t$  与下一状态  $s_{t+1}$ 
9:   将  $(s_t, a_t, r_t, s_{t+1})$  写入经验回放池  $\mathcal{D}$ 
10:  if 经验池样本数量足够 then
11:    从  $\mathcal{D}$  随机采样 mini-batch，并按式 (4.21) 更新主网络
12:    每隔固定步长同步目标网络参数  $\theta^- \leftarrow \theta$ 
13:  end if
14: end for

```

4.4.4 算法复杂度与可实现性分析

对于单次在线决策，若候选边缘节点数量为 N_c ，预测模型前向推理复杂度为 $\mathcal{O}(P_f)$ ，Q 网络前向推理复杂度为 $\mathcal{O}(P_q)$ ，则单次决策复杂度近似为

$$\mathcal{O}(N_c P_f + P_q). \quad (4.23)$$

由于 N_c 通常远小于全网节点数，且 P_f 和 P_q 均来自轻量级 MLP/1D-CNN 结构，因此该复杂度满足节点侧实时部署需求。

若考虑训练阶段，则每次 DQN 参数更新需要对一个大小为 B_q 的 mini-batch 执行前向与反向传播，复杂度约为 $\mathcal{O}(B_q P_q)$ ；经验回放池若容量为 $|\mathcal{D}|$ ，则其空间复杂度为 $\mathcal{O}(|\mathcal{D}| d_s)$ ，其中 d_s 为状态维度。与引入预测先验所带来的性能收益相比，这部分额外存储开销是可控的。进一步地，预测模型本身可以异步更新，节点侧仅维护最近一次下发的模型副本，因此不会把联邦训练的成本直接叠加到每个在线动作上。

相比之下，若使用中心控制器收集全网细粒度状态再做统一决策，则不仅通信开销更高，而且难以满足天基网络中严格的时延约束。尤其是在链上状态存在确认延迟、候选节点可达性随轨道运动变化的条件下，把所有决策都放在中心完成会进一步放大信息年龄问题，而 FL-DQN 通过“链上摘要 + 本地观测 + 预测先验”的组合，能够在分布式条件下保留较高的动作质量。

4.5 实验设计与结果分析

本节在保证论证完整性的前提下，对实验内容进行适度收束，重点围绕三个问题展开：其一，聚类式联邦学习是否能够在 Non-IID 负载环境下稳定提升并发开销预测精度；其二，引入预测先验后，FL-DQN 是否能在平均时延、尾时延、吞吐量和完成率等核心指标上优于分布式基线；其三，完整方法的优势主要来自哪些模块，以及这种优势是否需要付出过高的在线开销。基于这一思路，本节不再展开过多辅助性图表，而是保留最能支撑结论的预测精度图、端到端性能图、鲁棒性与公平性图以及消融图。

4.5.1 实验场景、对比基线与评价指标

并发开销预测数据由两类代理任务构造：一类为视觉感知型任务，使用 BDD100K 数据集样本模拟图像预处理、特征提取与轻量推理等边缘负载；另一类为数值计算型

任务，使用 Fibonacci 递推与矩阵运算组合模拟输入较小但计算强度较高的工作负载。两类任务交替注入至真实计算节点，以形成不同并发混合比、不同内存占用峰值和不同 CPU 争用模式下的执行日志。每条样本记录包含任务类型、输入大小、FLOPs、CPU 频率、并发任务数、执行中任务剩余工作量、上下文切换强度、实际完成时延及按式 (4.7) 或式 (4.8) 标注的并发开销。

节点侧卸载仿真默认包含 20 个 ST 和 6 个 SEN。任务到达率 λ 从轻负载逐步提高至高负载，以覆盖“偶发到达—中等拥塞—持续拥塞”三个工作区间；链路带宽与传播时延在第三章参数范围基础上叠加随机扰动，以模拟可用窗口变化；链上摘要则设置可控确认延迟，用于专门考察信息陈旧性对策略的影响。实验环境与训练协议见表 4.6。

表 4.6 预测层与决策层实验环境配置

配置项	设定说明
代理任务类型	BDD100K 图像处理任务、Fibonacci/矩阵运算数值任务、两类任务混合注入
样本标注方式	依据任务隔离时延、并发时延及执行中任务剩余量构造并发开销监督标签
特征构成	任务特征 + 本地资源状态 + 链上公共摘要 + 并发环境统计，共 28 维连续/离散混合特征
联邦客户端数量	6 个候选边缘节点作为参与方，按负载模式动态划分为 2–3 个簇
联邦轮次与本地 epoch	默认 80 轮通信，每轮本地训练 3 个 epoch，簇内按样本量加权聚合
预测模型结构	3 层 MLP (128-64-32) 为默认结构，ReLU 激活；附加比较 1D-CNN 变体
强化学习环境	20 个终端节点、6 个候选边缘节点；任务到达过程服从泊松流近似
DQN 关键超参数	经验回放池 10^4 ，批量大小 128，折扣因子 $\gamma_{\text{dqn}} = 0.95$ ，目标网络同步间隔 200 step
重复试验协议	每组配置独立重复 5 次，报告均值；曲线图额外给出代表性波动区间

对比方法保留最具有代表性的六类：**FL-DQN**、**DQN-only**、**FL-only**、**Centralized-DQN**、**Heuristic** 和 **Random**；其中 **Local/FedAvg/Clustered-FL** 用于预测层比较。指标方面，本文聚焦于能够直接支撑章节结论的核心量：预测层使用 MAE、RMSE 和 R^2 ；决策层使用平均任务时延、P99 时延、系统吞吐量、SLA 完成率和单任务能耗；同时用 Jain 公平性指数补充说明高负载下的跨节点均衡性。统计上，所有端到端结果均在相同随机种子集合下独立重复 5 次，并报告均值及波动区间。

4.5.2 预测模块结果分析

表 4.7 给出了不同训练方式在测试集上的预测精度。可以看到，相比完全独立训练的 Local 模型和标准 FedAvg，Clustered-FL 在 MAE、RMSE 和 R^2 三项指标上都更优，并且达到稳定误差带所需的通信轮次更少。这说明当不同卫星节点的任务分布、硬件能力和背景负载存在明显差异时，先进行负载模式聚类、再执行簇内聚合，能够有效缓解统一全局模型在多峰数据分布下的偏置问题。

表 4.7 不同训练方式下并发开销预测精度对比

训练方式	MAE (ms)	RMSE (ms)	R^2	稳定收敛轮次	结果解读
Local Training	18.6	25.4	0.836	—	仅适应本地样本，泛化较弱
FedAvg	13.9	18.7	0.892	63	全局平均效果尚可，但受异构性影响明显
Clustered-FL	10.8	14.6	0.914	47	在异构场景下表现最稳健

图 4.6 从收敛过程、预测—真实对应关系、置信校准和异构强度四个角度展示了预测模块表现。与原稿中过多分散的辅助图相比，这里将关键信息压缩到一张多子图中：既回答“模型是否足够准确”，也回答“模型在什么条件下会变差”。

图4-6 并发开销预测模块的多维性能结果




图 4.6 并发开销预测模块的精度、收敛性与异构鲁棒性

从图 4.6 可见，大部分样本点分布在对角线附近，说明模型能够较好追踪不同工作点下的并发开销变化；同时，Clustering-FL 在训练前半段便形成了更快的误差下降趋势，而 Local 模型始终存在更高的平台误差。随着异构性增强，FedAvg 的误差分布明显向高值区间扩散，而 Clustering-FL 仍保持相对紧凑的中位数和四分位范围。由此可见，聚类式联邦训练不是简单的实现细节，而是后续节点侧决策能够稳定工作的必要前提。

4.5.3 端到端性能与鲁棒性分析

图 4.7 展示了不同任务到达强度下各策略的平均时延、系统吞吐量、SLA 完成率和 P99 尾时延变化。相比早期版本中以单点柱状图为主的展示方式，这里采用随负载变化的趋势图，更能体现方法在拥塞逐步形成时的退化规律。总体来看，FL-DQN 在轻中载时已具备稳定优势，而在高负载区间优势进一步扩大，说明预测先验主要在系统逼近拥塞边界时发挥作用。

图4-7 不同并发强度下的卸载决策性能与稳定性




图 4.7 不同负载强度下各策略的服务质量与尾部性能对比

从图 4.7 可见，随着任务到达率增加，所有方法的平均时延和 P99 时延都呈上升趋势，但 FL-DQN 的增长斜率明显低于 DQN-only 与 Heuristic；同时，其吞吐量和 SLA 完成率在中高负载阶段保持更高水平。这表明并发开销预测的引入并非仅仅改善均值，而是有效抑制了系统在重载区间的整体退化。

表 4.8 给出中等并发工作点下的综合对比结果。可以看到，FL-DQN 在分布式可实现的前提下取得了最优或次优的综合表现：与 DQN-only 相比，平均任务时延下降约 19.6%，P99 时延下降约 22.7%，吞吐量提升约 17.0%，SLA 完成率提高超过 6 个百分点，同时单位任务能耗也进一步下降。虽然 Centralized-DQN 作为理想上界仍略优，但其建立在全局实时信息可得这一强假设之上，因此更适合作为理论参照，而不是实际部署方案。

表 4.8 中等并发工作点下各方法综合性能对比

方法	平均时延 (ms)	P99 时延 (ms)	吞吐量 (tasks/s)	单任务能耗 (Wh)	SLA 完成率 (%)
FL-DQN	172	365	55	1.82	94.8
Centralized-DQN	160	342	58	1.75	95.8
DQN-only	214	472	47	2.05	88.6
FL-only	196	412	49	1.93	90.3
Heuristic	228	492	42	2.18	82.4
Random	262	584	35	2.32	74.1

仅有均值结果仍不足以说明方法在真实系统中的价值。为此，图 4.8 进一步从三个角度补充说明：其一，链上摘要逐步陈旧时，FL-DQN 的性能下降更平缓，说明预测模块对观测缺口具有补偿作用；其二，动作热力图显示当候选节点拥塞程度升高时，智能体会自适应提升本地执行或转向低风险节点的概率；其三，效率—公平折中图表明，FL-DQN 在能耗、时延和节点均衡性之间取得了更优的 Pareto 位置。

图4-8 鲁棒性、动作偏好与多目标折中结果




图 4.8 卸载策略的鲁棒性、动作偏好与效率—公平折中关系

上述结果的工程含义在于：若策略只盯住瞬时最低时延节点，短期看似有利，但长

期会把任务持续压向少数高性能节点，最终导致尾时延和失败率共同恶化。FL-DQN 之所以在公平性和高负载稳定性上优于 DQN-only，本质上是因为并发开销预测把“未来拥塞风险”前置进了状态表示中，使智能体能够在局部最优和长期均衡之间做更成熟的权衡。

4.5.4 消融实验与结果讨论

为了量化各关键模块的边际贡献，本文采用逐一移除的方式设计消融实验，包括：去掉 FL 预测先验（-FL 预测）、去掉并发惩罚项（-并发惩罚）、去掉经验回放（-经验回放）以及去掉奖励塑形（-奖励塑形）。考虑到前文已经给出充分的性能与鲁棒性结果，这里不再单独展开更多辅助性敏感性图，而把最重要的消融表现压缩到图 4.9 和表 4.9 中。




图 4.9 消融实验：预测先验、奖励约束与训练稳定性的边际贡献

从图 4.9(a) 和 (b) 可以看出，去掉 FL 预测先验后性能下降最明显，说明完整方法的首要收益来自显式建模并发风险；去掉并发惩罚项虽然仍保留预测值作为状态输入，但由于风险没有进入奖励约束，策略会重新偏向短视动作，因此在高并发时也出现明显恶化。经验回放和奖励塑形对最终最优性能的影响相对较小，但对训练稳定性

和跨次波动具有直接作用，这一点可从图 4.9(d) 中观察到。

表 4.9 消融实验的详细结果

设置	平均时延 (ms)	P99 时延 (ms)	SLA 完成率 (%)	单次决策耗时 (ms)
FL-DQN	172	365	94.8	3.8
-FL 预测	214	472	88.6	3.1
-并发惩罚	189	421	91.2	3.6
-经验回放	197	436	90.5	2.4
-奖励塑形	185	409	91.6	3.4

综合以上实验，可以得到三个直接结论。第一，并发开销预测不是可有可无的辅助模块，而是决定策略能否从反应式决策升级为前瞻式决策的关键桥梁；一旦去掉该模块，DQN 的表现会迅速退化为对局部观测的被动响应。第二，Clustered-FL 对 Non-IID 负载的适配能力是整套方法成立的前提；如果预测层无法跟上异构环境变化，再精巧的 DQN 奖励设计也难以弥补状态表征缺失。第三，完整方法相较基础 DQN 结构只增加了很小的在线推理耗时，单次决策额外开销仍维持在毫秒级，因此其性能收益并非建立在不可接受的部署代价之上。

4.6 本章小结

本章围绕天基网络任务层实时卸载问题，提出了一个面向并发开销的“联邦预测 + DQN 决策”闭环方法。不同于第三章从系统层讨论全局可信协同资源分配，本章进一步下沉到节点侧，以单任务到达瞬间的快速动作选择为核心，系统性解决了链上状态滞后、隐私受限、负载动态变化和并发资源竞争等多重挑战，因此在全文中承担着把“可信共享能力”转化为“实时执行能力”的桥梁作用。

具体而言，本文首先从任务层视角建立了时延、能耗与并发开销的统一代价模型，并给出了并发开销的形式化定义、工程近似表达及其可分解解释；随后，针对节点本地日志难以集中上传且样本分布高度异构的问题，构建了分层聚类联邦学习框架，实现并发开销预测模型的隐私友好训练；进一步地，本文将预测值及其置信信息显式纳入 DQN 状态空间与奖励函数设计，使卸载策略具备对潜在并发风险的前瞻感知能力。实验结果表明，在中等并发工作点下，所提 FL-DQN 相比 DQN-only 的平均任务时延下降约 19.6%、P99 时延下降约 22.7%、吞吐量提升约 17.0%、SLA 完成率提高超过 6

个百分点，并且在高并发和链上状态滞后条件下仍保持更平缓的性能退化趋势。

归纳而言，本章形成了以下三个结论：第一，并发开销是影响天基网络任务级卸载质量的关键隐藏变量，不能被简单平均负载替代；第二，聚类式联邦学习能够在不上传原始数据的前提下有效建模并发风险，为节点侧决策提供可靠先验；第三，将预测先验与强化学习决策进行深度耦合，能够显著增强策略在信息不完全与高并发场景下的鲁棒性。由此，第三章所建立的系统层可信协同框架与本章提出的任务层实时决策机制共同构成了一个跨层闭环：前者保障状态共享的可信与可得，后者保障任务执行的高效与稳健。上述研究也为后续进一步讨论跨层协同优化、多智能体联合决策或更复杂的星地协同边缘智能机制奠定了方法基础。

结论

本文围绕天基网络环境下计算卸载过程中存在的可信共享不足、系统层协同困难以及任务层并发开销难以准确感知等问题，构建了“系统层可信协同—任务层并发感知卸载”的分层研究框架。前文分别从系统层协同资源分配方法、任务层并发开销预测与卸载决策方法两个层面展开了建模、算法设计与实验验证，形成了较为完整的研究链条。

从研究内容上看，本文的主要工作包括以下几个方面：其一，围绕天基网络动态拓扑、异构资源与去中心化协同需求，分析了计算卸载问题的关键约束与研究挑战，并建立了统一的系统模型与问题描述框架；其二，针对多节点协同过程中状态共享不可信、资源竞争失衡等问题，研究了基于区块链与多智能体强化学习的系统层协同资源分配方法，以提升资源利用率、负载均衡性与长期协同稳定性；其三，针对多任务并发条件下传统静态代价模型难以准确反映真实执行开销的问题，研究了基于联邦学习与深度强化学习的任务层计算卸载方法，通过引入并发开销预测机制提升节点侧决策的前瞻性与适应性。

总体而言，本文的研究表明：在天基网络计算卸载场景中，仅依赖单一层面的优化方法难以同时兼顾系统全局协同效率与任务局部执行性能；通过将区块链可信共享、多智能体强化学习、联邦学习以及深度强化学习进行分层耦合，可以在一定程度上缓解高动态环境中的状态不一致、资源竞争与代价失真等问题，为后续构建智能化、可信化的天基协同计算体系提供了方法参考。

需要说明的是，本文目前重点完成了方法框架、关键模型与阶段性实验部分的研究与整理。关于更大规模场景下的系统级综合实验、不同轨道层条件下的参数敏感性分析以及工程化部署细节，仍可在后续工作中进一步补充和完善。未来研究可继续围绕以下方向展开：一是进一步完善面向多星异构环境的统一实验平台与对比验证体系；二是增强模型对链路剧烈波动、节点失效和异常行为的鲁棒性；三是探索更适用于天基网络复杂业务场景的轻量化智能决策方法与可信协同机制。

参考文献

- [1] Kodheli O, Lagunas E, Maturo N, et al. Satellite Communications in the New Space Era: A Survey and Future Challenges[J]. IEEE Communications Surveys & Tutorials, 2021, 23(1): 70-109.
- [2] Liu J, Mao Y, Zhang J, et al. Delay-Optimal Computation Task Scheduling for Mobile-Edge Computing Systems[J]. IEEE Transactions on Wireless Communications, 2018, 17(5): 3400-3412.
- [3] Nakamoto S. Bitcoin: A Peer-to-Peer Electronic Cash System[J]. Bitcoin Whitepaper, 2008.
- [4] Tan L T, Hu R Q, Hanzo L. A Survey on Physical Layer Security for 5G Wireless Networks[J]. IEEE Communications Surveys & Tutorials, 2015, 17(3): 1242-1258.
- [5] Ousterhout K, Rasti R, Ratnasamy S, et al. Making Sense of Performance in Data Analytics Frameworks[J]. Proceedings of the 12th USENIX Symposium on Networked Systems Design and Implementation, 2015: 293-307.
- [6] Mnih V, Kavukcuoglu K, Silver D. Playing Atari with Deep Reinforcement Learning[J]. arXiv preprint arXiv:1312.5602, 2013.
- [7] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous Control with Deep Reinforcement Learning[J]. arXiv preprint arXiv:1509.02971, 2015.
- [8] Huang L, Bi S, Zhang Y A. Deep Reinforcement Learning for Online Computation Offloading in Mobile Edge Computing[J]. IEEE Transactions on Mobile Computing, 2020, 19(11): 2581-2593.
- [9] Wang J, Liu Y, Song B, et al. Intelligent Resource Allocation for Co-Locating Latency-Sensitive Services[J]. IEEE/ACM Transactions on Networking, 2018, 26(5): 2225-2238.
- [10] Foerster J, Farquhar G, Afouras T, et al. Counterfactual Multi-Agent Policy Gradients[J]. arXiv preprint arXiv:1705.08056, 2017.
- [11] Kshetri N. Blockchain's Roles in Meeting Key Supply Chain Management Objectives[J]. International Journal of Information Management, 2018, 39: 80-89.
- [12] Y G, Z J, K Z, et al. Game-Based Computation Offloading and Power Allocation for LEO Constellation Networks in Distributed and Dynamic Environment[J]. IEEE Internet of Things Journal, 2024, 11(4): 7040-7058.
- [13] Y T, N C, L Z, et al. Task Offloading and Resource Allocation for Satellite-Terrestrial Integrated Networks[J]. IEEE Transactions on Communications, 2024, 72(12): 7840-7855.
- [14] Kang J, Yu R, Huang X, et al. Blockchain for Internet of Things: Architecture, Applications and Challenges[J]. IEEE Internet of Things Journal, 2019, 6(5): 8106-8123.
- [15] Bonawitz K, Eichner H, Grieskamp W, et al. Towards Federated Learning at Scale: System Design [J]. Proceedings of Machine Learning and Systems, 2019, 1: 374-388.

- [16] X W, H L, Y Z, et al. Computation Offloading and Resource Allocation in Satellite Edge Computing Networks: A Multi-Agent Reinforcement Learning Approach[J]. Computer Networks, 2025, 272: 111680.
- [17] M J, J W, L Z, et al. Federated Deep Reinforcement Learning Based Computation Offloading in a Low Earth Orbit Satellite Edge Computing System[J]. Frontiers of Information Technology & Electronic Engineering, 2025, 26(6): 805-815.
- [18] M S, J H, K Q, et al. LLM-Based Task Offloading and Resource Allocation in Satellite Edge Computing Networks[J]. IEEE Transactions on Vehicular Technology, 2026, 75(3): 5262-5267.
- [19] J W, M J, Q G, et al. Multi-Agent Deep Reinforcement Learning-Based Offloading Computation in LEO Satellite Networks[C]. Proceedings of IEEE VTC 2025-Spring. 2025: 1-6.
- [20] A H, V C J, H S. Multi Agent Reinforcement Learning for Sequential Satellite Assignment Problems [C]. Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-25): vol. 39. 2025.
- [21] Z C, L W, J L, et al. Spatiotemporal-Aware Multi-Agent Reinforcement Learning for Revisit-Oriented Multi-Satellite Observation Task Scheduling[J]. Applied Sciences, 2026, 16(6): 2685.
- [22] J H D, S H, J L D, et al. Cooperative Federated Learning over Ground-to-Satellite Integrated Networks: Joint Local Computation and Data Offloading[J]. IEEE Journal on Selected Areas in Communications, 2024, 42(5): 1080-1096.
- [23] Z L, X C, Y W, et al. Blockchain-Aided Digital Twin Offloading Mechanism in Space-Air-Ground Networks[J]. IEEE Transactions on Mobile Computing, 2025, 24(1): 1-16.
- [24] L X, H Z, Y L, et al. StarCross: Redactable Blockchain-Based Secure and Lightweight Data Sharing Framework for Satellite-Based IoT[J]. Computer Networks, 2024, 253: 110718.
- [25] Dorri A, Kanhere S S, Jurdak R. Blockchain in Internet of Things: Challenges and Solutions[J]. Future Generation Computer Systems, 2018, 88: 173-190.
- [26] W W, Z S, Q Z, et al. A Sharded Blockchain-Based Secure Federated Learning Framework for LEO Satellite Networks[Z]. arXiv preprint arXiv:2411.06137. 2024.
- [27] H Z, Y L, S C, et al. Federated learning-based ISAC network in cohesive clustered satellite networks [J]. Science China Information Sciences, 2025, 68(3): 132301.
- [28] Z C, S Y, Y D, et al. FedLEO: An Offloading-Assisted Decentralized Federated Learning Framework for Low Earth Orbit Satellite Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(5): 5260-5279.
- [29] Dinh T T A, Liu R, Zhang M, et al. Untangling Blockchain: A Data Processing View of Blockchain Systems[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(7): 1366-1385.
- [30] Saad M M, Tariq M A, Khan M T R, et al. Non-Terrestrial Networks: An Overview of 3GPP Release 17 & 18[J]. IEEE Internet of Things Magazine, 2024, 7(1): 20-26.

- [31] Wang F, Zhang S, Yang H, et al. Non-Terrestrial Networking for 6G: Evolution, Opportunities, and Future Directions[J]. Engineering, 2025, 54: 56-68.
- [32] Mahboob S, Liu L. Revolutionizing Future Connectivity: A Contemporary Survey on AI-Empowered Satellite-Based Non-Terrestrial Networks in 6G[J]. IEEE Communications Surveys & Tutorials, 2024, 26(2): 1279-1321.
- [33] Yin Z, Wu C, Guo C, et al. A Comprehensive Survey of Orbital Edge Computing: Systems, Applications, and Algorithms[J]. Chinese Journal of Aeronautics, 2025, 38(7): 103316.
- [34] Huang T, Fang Z, Tang Q, et al. Integrated Computing and Networking for LEO Satellite Mega-Constellations: Architecture, Challenges and Open Issues[J]. IEEE Wireless Communications, 2024, 31(5): 92-100.
- [35] Zhai Z, Zeng L, Ouyang T, et al. SECO: Multi-Satellite Edge Computing Enabled Wide-Area and Real-Time Earth Observation Missions[C]. Proceedings of IEEE INFOCOM 2024. 2024: 2548-2557.
- [36] Qu Y, Dai H, Wang X, et al. End-to-End Task Offloading and Resource Allocation in Satellite-Terrestrial Edge Computing Networks[J]. IEEE Transactions on Wireless Communications, 2024, 23(8): 9224-9238.
- [37] Zhao D, Ding R, Song B. Satellite-assisted 6G Wide-Area Edge Intelligence: Dynamics-Aware Task Offloading and Resource Allocation for Remote IoT Services[J]. Science China Information Sciences, 2025, 68: 122303.
- [38] Sun M, Hou J, Qiu K, et al. LLM-Based Task Offloading and Resource Allocation in Satellite Edge Computing Networks[J]. IEEE Transactions on Vehicular Technology, 2026, 75(3): 5262-5267.
- [39] Tang Q, Xie R, Fang Z, et al. Joint Service Deployment and Task Scheduling for Satellite Edge Computing: A Two-Timescale Hierarchical Approach[J]. IEEE Journal on Selected Areas in Communications, 2024, 42(5): 1063-1079.
- [40] Zhang X, Liu J, Zhang R, et al. Energy-Efficient Computation Peer Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(4): 3077-3091.
- [41] Zhou J, Yang Q, Zhao L, et al. Mobility-Aware Computation Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024, 23(10): 9135-9149.
- [42] Feng C, Yang M, Jing Z, et al. Latency-Aware Service Deployment and Peer Offloading: A Long-Term Optimization Framework for Satellite Edge Computing[J]. IEEE Internet of Things Journal, 2026, 13(1): 405-417.
- [43] Fan W, Meng Q, Wang G, et al. Satellite Edge Intelligence: DRL-Based Resource Management for Task Inference in LEO-Based Satellite-Ground Collaborative Networks[J]. IEEE Transactions on Mobile Computing, 2025, 24(10): 10710-10728.
- [44] Zhong L, Li Y, Ge M F, et al. Joint Task Offloading and Resource Allocation for LEO Satellite-

- Based Mobile Edge Computing Systems With Heterogeneous Task Demands[J]. IEEE Transactions on Vehicular Technology, 2025, 74(7): 11337-11352.
- [45] Liu S, Zhang Z, Zeadally S. Device-satellite-satellite Collaborative Task Offloading Computing and Resource Allocation in 6G Satellite-Ground Edge Computing Network[J]. Computer Networks, 2026, 274: 111871.
- [46] Li H, Yu J, Cao L, et al. Multi-agent Reinforcement Learning Based Computation Offloading and Resource Allocation for LEO Satellite Edge Computing Networks[J]. Computer Communications, 2024, 222: 268-276.
- [47] Xiu Q, Liu J, Liu X, et al. Computation Offloading and Resource Allocation in Satellite Edge Computing Networks: A Multi-Agent Reinforcement Learning Approach[J]. Computer Networks, 2025, 272: 111680.
- [48] Rao Z, Zhu Z, Yao Y, et al. Computation-Offloading Optimization for Satellite Edge Computing via Diffusion and Lyapunov-Based Deep Reinforcement Learning[J]. IEEE Internet of Things Journal, 2025, 12(18): 37747-37762.
- [49] Zhang H, Zhao H, Liu R, et al. Collaborative Task Offloading Optimization for Satellite Mobile Edge Computing Using Multi-Agent Deep Reinforcement Learning[J]. IEEE Transactions on Vehicular Technology, 2024, 73(10): 15483-15498.
- [50] Matthiesen B, Razmi N, Leyva-Mayorga I, et al. Federated Learning in Satellite Constellations[J]. IEEE Network, 2024, 38(2): 232-239.
- [51] Tan M, Marwah M. Multiagent Reinforcement Learning in Sequential Social Dilemmas[J]. Proceedings of the 16th International Conference on Autonomous Agents and Multiagent Systems, 2016: 464-473.

附录 A 仿真参数与环境配置

本附录用于补充正文实验部分未展开列出的参数设置与环境说明，便于对本文方法的实验条件进行统一说明与后续复现实验。实验环境主要围绕天基网络计算卸载场景进行构建，涉及卫星终端、卫星边缘节点、链路参数、任务到达过程以及算法超参数等多个方面。对于不同实验场景，可在统一参数基线的基础上对节点规模、任务强度、链路时延与负载水平进行适当调整。

在系统参数设置方面，可重点说明卫星节点数量、节点计算能力范围、任务输入规模、任务计算量分布、链路带宽区间、传播时延范围以及任务时延约束设置等内容；在算法参数设置方面，可进一步补充多智能体强化学习、联邦学习与深度强化学习相关的学习率、折扣因子、训练轮数、批大小与聚合周期等参数。对于实验中使用的评价指标，如平均时延、任务完成率、系统吞吐量、负载均衡度和能耗等，也可在附录中统一列出其统计口径与计算方式。

附录 B 关键模型推导与补充说明

本附录用于补充正文中为保持行文紧凑而未详细展开的模型推导过程与符号说明。针对系统层协同资源分配问题，可进一步给出状态变量、动作变量、奖励函数各分量以及约束条件之间的对应关系；针对任务层并发感知卸载问题，可补充并发开销定义、工程近似表达及其与综合代价函数之间的推导联系。

此外，对于文中涉及的关键符号、参数物理意义与公式适用条件，也可在本附录中进行集中说明，以增强模型表达的一致性与可读性。当后续章节补充完整实验内容后，本附录还可进一步加入复杂度分析、敏感性分析推导或部分中间证明过程，以形成与正文相互支撑的完整结构。

附录 C 附录内容说明

附录部分主要用于补充不宜在正文中大篇幅展开、但对理解论文研究过程和复现实验结果具有参考价值的材料。其内容通常包括但不限于以下几类：

1. 正文中为保证结构紧凑而省略的详细模型推导、符号说明与中间证明过程；
2. 实验平台配置、参数设置、数据生成规则与评价指标统计口径等支撑性材料；
3. 关键算法流程、训练细节、补充结果或扩展对比分析；
4. 对同行读者具有参考意义、但不适合直接纳入正文主体的技术性补充内容。

C.1 附录内容组织说明

为便于后续完善，附录可按照“实验参数补充—模型推导补充—结果说明补充”的结构逐步补全，并与正文中对应章节保持编号和引用关系的一致性。

C.1.1 后续补充建议

随着第五章、第六章内容的进一步完善，可将更具体的仿真参数表、额外实验图表及推导细节逐步整理至本附录中，以增强全文结构的完整性与学术表达的规范性。

攻读学位期间发表论文与研究成果清单

- [1] Zhang W, **Mao X**, Chen X, Zhu C. Manage On-Road Services With Chains: A Distributed Vehicular Task Offloading Approach Based on Blockchain Technology[J]. IEEE Transactions on Vehicular Technology, 2026, 75(4): 6689-6704.
- [2] 朱超, **毛心璐**, 陈霄, 王添润. 基于联邦学习的车辆任务卸载系统与方法: ZL 2025 1 0074060.6[P]. 发明专利. 北京理工大学, 北京理工大学长三角研究院. (已授权)
- [3] 朱超, **毛心璐**, 陈霄, 王添润. 一种基于 DQN 的车辆任务卸载系统及方法: 202510074061.0[P]. 发明专利. 北京理工大学, 北京理工大学长三角研究院. (已申请)

致谢

在本论文的研究与撰写过程中，我得到了导师、课题组老师与同学们的悉心指导和帮助。导师在研究选题、技术路线设计、论文结构组织以及学术表达规范等方面给予了耐心细致的指导，使我能够逐步完成从问题分析到方法设计、再到论文整理的全过程。在此谨向导师致以诚挚的感谢。

同时，感谢课题组各位老师和同学在研究讨论、资料整理、实验推进与论文修改过程中提供的帮助与建议。与大家交流使我对天基网络计算卸载、区块链协同、联邦学习与强化学习等相关问题有了更加深入的理解，也为本论文的完善提供了重要支持。

此外，感谢学校和学院提供的学习与科研条件，感谢家人在研究和生活过程中给予的理解、鼓励与支持。正是因为来自师长、同学与家人的帮助，我才能较为顺利地完成本阶段的学习与研究工作。

作者简介

本人为北京理工大学网络与信息安全专业硕士研究生，研究方向为区块链、卫星网络、计算卸载与智能优化。硕士阶段围绕天基网络环境下的可信数据管理、协同资源分配与任务级计算卸载问题开展学习与研究，重点关注区块链、联邦学习和强化学习等方法在分布式智能协同场景中的应用。

硕士学位论文不必提供作者简介。博士学位论文应该提供作者简介，主要包括：姓名、性别、出生年月、民族、出生地；简要学历、工作经历（职务）；攻读学位期间取得的其他研究成果或奖励。